线性代数：向量、矩阵与特征分解

读前须知

- **前置**：高中数学的向量与矩阵乘法。如果已经遗忘，只需记住一条——矩阵乘向量，就是对向量做一次线性组合。
- **这一篇的位置**：模型里的数据、权重、变换几乎都用向量和矩阵描述；后面的 PCA、神经网络前向传播，都是这一篇的直接应用。
- **读完能做什么**：把一份数据写成矩阵并说清每个维度的含义；判断矩阵是否可逆；用特征值和特征向量解释“变换中保持方向不变的那几根轴”。

一、为什么人工智能从线性代数开始

今天的各种人工智能技术，最终都可以还原为一组数学模型；而这些数学模型几乎无一例外地生长在线性代数的框架里。

线性代数的重要性有两层：

- **工具层面**：从量子力学到图像处理，向量和矩阵是通用语言。图像是一个矩阵，一个 batch 的彩色图像是一个四维张量，网络的每一层本质上是矩阵乘法加非线性函数。
- **认知层面**：它提供了一种抽象的看世界的方式——**任何事物都可以拆成若干特征的组合，然后在既定规则下被静态地或动态地观察。**“静态”指对象本身的取值，“动态”指对象如何变化。这个视角是理解后面所有算法的前提。

二、从集合到张量：数据对象的层级

2.1 集合：一切抽象的原点

集合（set）是数学中最基本的概念：把某些特定对象汇总成一个集体，就得到集合。集合里的元素通常有共性，才便于用统一的方式处理：

- {苹果, 橘子, 梨} 的共性是“水果”；
- {牛, 马, 羊} 的共性是“动物”；
- {苹果, 牛} 也能凑成一个集合，但两者没有可利用的共性，这样的集合在实际问题里没什么用。

问题在于，“苹果”“牛”这类具体概念超出了数学的处理范围。所以下一步必须做**抽象**：用数字或符号来表示元素。抽象之后，元素既可以是单个数字，也可以按某种方式排列成组合。

2.2 标量、向量、矩阵、张量

由**单独一个数**构成的元素叫**标量（scalar）**，它可以是整数、实数或复数。

把若干个标量 a_i 按顺序排成一列，就得到**向量（vector）**：

$$\mathbf{a} = (a_1, a_2, \ldots, a_n)^{\mathrm{T}}$$

向量可以看成标量的扩展：一个数变成一组数，维度随之增加，必须靠下标才能唯一确定某个元素。

如果把向量中的每个标量都替换成同规格的向量，得到的就是**矩阵（matrix）**：

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}$$

矩阵中的元素需要**两个下标**（行、列）才能定位，维度比向量又高了一层。

同理，把矩阵中的每个元素再替换成向量，就得到**张量（tensor）**。直观理解：**张量就是更高阶的矩阵**。

> 一个经典类比：把三阶魔方的每个小方块看成一个数，整个魔方就是一个 3×3×3 的张量；而 3×3 的矩阵恰好是魔方的一个面，也就是张量的一个切片。

补充说明：在主流深度学习框架里，张量的"阶"对应 `shape` 的长度。例如一批彩色图像通常写成 (N, C, H, W)——分别表示批大小、通道数、高、宽，这就是一个四阶张量。理解这一点，就能明白为什么框架里几乎所有数据都是 tensor。

> **新手提示：`shape` 怎么看**
>
> `shape` 就是每个维度上的长度，用方括号括起来的一串数字，比如 `[64, 3, 224, 224]`。数一数有几个数字，就是几阶；每个数字对应一个方向上的长度。可以把它想成"盒子的长宽高"：外面一层套一层，最外层是批大小，最里层是单个数值。

另外，下面三种说法很容易混，先记住区别：

说法	含义	例子
阶（order / rank of tensor）	张量有几个维度	矩阵是二阶张量
维数（dimension）	向量或空间有几个方向	三维空间、768 维词向量
秩（rank of matrix）	矩阵中真正线性无关的行（或列）有几条	秩为 1 的矩阵所有行都成比例

"阶""维""秩"在中文里经常被混用，看英文原文最不容易歧义。

2.3 为什么计算机必须用这种结构

人感知的是一个连续变化的世界，而计算机只处理离散取值的二进制信息。因此来自模拟世界的信号，必须在**定义域**和**值域**上同时数字化，才能被存储和计算。

从这个角度看，**线性代数是用虚拟的数字世界表示真实物理世界的工具。**维度与存储形式的对应关系很清晰：

数学对象	计算机存储	典型例子
标量	零维数组	单个像素值、损失值
向量	一维数组	一段语音信号、一个词向量
矩阵	二维数组	灰度图像、权重矩阵
张量	三维及以上数组	RGB 图像、视频、批量数据

三、度量向量自身：范数

要用数学语言描述一个向量，最需要的是两件事：**它有多大、它和别的向量关系如何。**前者由范数刻画，后者由内积刻画。

范数（norm） 是对单个向量大小的度量，作用是把向量映射为一个非负实数。通用的 Lp 范数定义为：

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^{n} |x_i|^p \right)^{\frac{1}{p}}, \qquad p \geq 1$$

几个最常用的特例：

- **L1 范数**：$\|x\|_1 = \Sigma_i |x_i|$，所有元素绝对值之和，也叫曼哈顿距离；
- **L2 范数**：$\|x\|_2 = \sqrt{(\Sigma x_i^2)}$，通常意义上的向量长度，即欧氏距离；
- **L 无穷范数**（L_∞）：$\|x\|_\infty = \max_i |x_i|$，取绝对值最大的那个元素。

补充说明：范数的选择会实质影响模型行为。L_2 正则化会把权重压得整体偏小且分散，L_1 正则化则倾向于把部分权重压成 0，因此常被用来做特征选择——这就是 Lasso 回归与 Ridge 回归的核心区别。L_0 范数（非零元素个数）也常被提及，但它不满足范数的齐次性要求，严格来说只是一个“伪范数”，且求解困难。

四、度量向量之间：内积与正交

内积（inner product） 描述两个同维向量之间的关系：

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^{n} x_i \cdot y_i$$

即对应元素相乘再求和。由内积可以导出两个向量夹角的余弦——设两个向量的夹角为 θ（希腊字母，读作 theta）：

$$\cos\theta = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\|_2 \, \|\mathbf{y}\|_2}$$

它把“方向是否一致”量化成了 [−1, 1] 之间的一个数。这也是文本相似度、推荐系统中余弦相似度的来源。

一个特殊而重要的情形是内积为 0：

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0$$

在二维平面上，这意味着两个向量夹角为 90°，彼此垂直；在高维空间中，这种关系称为**正交（orthogonality）**。对两个**非零**向量来说，正交意味着它们线性无关、互不影响、彼此不携带对方的信息。

补充说明：对非零向量来说，正交一定线性无关（零向量与任何向量都正交，但它是线性相关的），而线性无关不一定正交。正交是“无关”的加强版——它不仅要求不能互相表示，还要求投影为零。这一点在特征降维时非常关键：正交基下的坐标互不干扰，可以独立分析。

五、线性空间、基与坐标系

如果一个集合的元素都是同维数的向量（有限或无限个），并且定义了加法与数乘等结构化运算，这个集合就称为**线性空间（linear space）**，也叫向量空间。若在线性空间上再定义内积运算，就得到**内积空间（inner product space）**。

线性空间里有一个漂亮的对应关系：**任意一个向量代表空间中的一个点，空间中任意一点也可以唯一地用一个向量表示。**两者完全等效。

关键在于：**参考系怎么选。**现实生活里，给定经度、纬度、海拔，就能唯一确定空间中的一个点，于是 (x, y, h) 这个三维向量就对应了物理空间中的一个位置。可在高维空间里，坐标系远没有这么直观——神经网络要处理的特征动辄上万维，对应的就是一个上万维的空间。

这时就需要**正交基**：

> **新手提示：什么是“基”**
>
> 基就是一组“基准方向”。选定基以后，空间中任何一个向量都可以唯一地写成这些基准方向的加权和，权重就叫**坐标**。就像描述一个位置必须说清楚“往东多少、往北多少”，这里的“东”“北”就是基。基的个数就是空间的**维数**。

- 一组**非零**、两两正交、且能张成整个空间的向量，构成这个空间的**正交基（orthogonal basis）**；
- 若正交基中每个基向量的 L_2 范数都是 1，这组基就是**标准正交基（orthonormal basis）**。

正交基的作用，就是给内积空间定义“经纬度”。基一旦确定，向量与点之间的对应关系也随之确定。

正交基并不唯一。二维平面上，平面直角坐标系和极坐标系就对应了两种不同的描述方式，各有各的便利之处（严格地说，极坐标的基向量随点的位置变化，属于局部基，这里作为直观类比理解即可）。

六、线性变换与矩阵的双重解读

线性空间的一个重要特征是**能承载变化。**当标准正交基确定后，空间中的点可以用向量表示；点从一个位置移动到另一个位置，描述它的向量也随之改变。

点的变化对应**向量的线性变换（linear transformation）**，而描述这种变换的数学语言正是矩阵。

怎么算：矩阵乘向量

规则很简单：**结果的第 i 个数，等于矩阵第 i 行与向量逐项相乘再相加。**举个具体例子：

$$\begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 2\times 1 + 1\times 2 \\ 0\times 1 + 3\times 2 \end{pmatrix} = \begin{pmatrix} 4 \\ 6 \end{pmatrix}$$

所以矩阵乘向量，本质是“对向量的各个分量做一组加权求和”——矩阵有几行，结果就有几个数。

变化有两种实现方式，对应两种完全不同的理解：

方式一：点动，参考系不动。 让某个点发生变化，用代表变化的矩阵乘以代表对象的向量：

$$A\mathbf{x} = \mathbf{y}$$

x 经过矩阵 A 描述的变换，变成了 y。

方式二：点不动，参考系动。 换一个观察角度，结果同样会不同，正所谓“横看成岭侧成峰”。这时矩阵不再改变对象，而是**变换参考系（正交基）**。同一个表达式 Ax = y，可以理解为一个对象在参考系 A 下的坐标为 x，在标准坐标系 I 下的坐标为 y，其中 I 是**单位矩阵**（主对角线为 1、其余为 0）。

于是 Ax 可以读成一句话：**“把参考系 A 下的坐标 x 换算回标准坐标系 I”。**想换一套参考系，就换一个声明它的矩阵。对坐标系施加变换的方法，就是让表示原坐标系的矩阵与表示变换的矩阵相乘。

补充说明：矩阵乘法天然对应变换的复合。先做 B 再做 A，合起来就是 AB（注意顺序：先作用的在右边）。另外，**行列式（determinant）**描述的是变换对体积的缩放倍数，|det A| = 1 表示保体积，det A = 0 表示这个变换把空间压扁了、不可逆——这也是判断矩阵是否可逆的直接依据。

七、特征值与特征向量：变换中的不变量

对给定矩阵 A，若存在数 λ 和非零向量 x 满足

$$A\mathbf{x} = \lambda\mathbf{x}$$

则 λ（希腊字母，读作 lambda）称为 A 的**特征值（eigenvalue）**，x 称为对应的**特征向量（eigenvector）**。

矩阵对向量的作用，通常会同时改变**方向**和**尺度**；但对某些特殊向量，矩阵只改变尺度、不改变方向。这类“只被拉伸、不被旋转”的向量就是特征向量，拉伸的倍数就是特征值。

一个形象的比喻：把矩阵代表的变化看作一个奔跑的人，**特征值是他的速度，特征向量是他的方向**。而矩阵更像是有分身术的哪吒——不同分身以不同速度朝不同方向跑，所有分身的运动叠加起来，才是矩阵的完整效果。

动态意义：特征值与特征向量刻画了变化的速度与方向。这解释了为什么在迭代系统中，最大的特征值（主特征值）往往主导长期行为。

7.1 特征值分解与它的限制

求解全部特征值和特征向量的过程叫**特征值分解（eigendecomposition）**。它有一个硬性前提：**矩阵必须是 n×n 的方阵**，并且要有 n 个线性无关的特征向量。此时

$$A = Q\Lambda Q^{-1}$$

其中 Q 的每一列是一个特征向量，Λ 是以对应特征值为对角元素的对角矩阵。

补充说明：实对称矩阵的性质特别好——特征值全为实数，且不同特征值对应的特征向量彼此正交，于是可以写成 A = QΛQᵀ，称为**谱分解**。主成分分析（PCA）本质就是协方差矩阵的谱分解：最大特征值对应的特征向量就是方差最大的方向，也就是第一主成分。

7.2 奇异值分解：推广到任意矩阵

把特征值分解推广到**任意形状**的矩阵，就得到**奇异值分解（singular value decomposition, SVD）**：

$$A = U\Sigma V^{\mathrm{T}}$$

- U、V 是正交矩阵，列向量分别称为左、右奇异向量；
- Σ 是对角矩阵，对角元素为奇异值，恒非负且按从大到小排列。

为什么它有用：只保留最大的若干个奇异值，就得到原矩阵的最佳低秩近似。图像压缩、推荐系统中的隐语义模型、潜在语义分析（LSA）、以及今天大模型里的低秩适配（LoRA），背后都是这套思想。

四个常见误区

- **“所有矩阵都能做特征分解”**——只有可对角化的矩阵才行；实对称矩阵才能保证正交对角化。一般矩阵可能只有复特征值（如旋转矩阵），也可能缺少足够多的线性无关特征向量。
- **“矩阵乘法与数的乘法差不多”**——矩阵乘法不可交换，先做 A 再做 B 与先做 B 再做 A 通常不是一回事；它只满足结合律，不满足交换律。
- **“秩就是非零行的个数”**——秩的定义是列空间（或行空间）的维数，行化简只是计算手段。数值计算中浮点误差还会让“秩”变得模糊，所以有数值秩的概念。
- **“特征值就是矩阵的固有属性，与坐标无关”**——特征值确实不随基变换改变，但特征向量会变。把特征向量理解为“在这组坐标下方向不变的方向”，才不会把它当成绝对的对象。

八、要点回顾

1. 线性代数的本质，是把具体事物抽象为数学对象，并描述其静态结构与动态变化。
2. 标量、向量、矩阵、张量是同一抽象层层嵌套的结果，对应零维到高维的数组。
3. 范数度量单个向量的大小，内积度量两个向量的关系；两个非零向量内积为零即正交，正交则线性无关。
4. 线性空间中的点与向量一一对应，正交基（标准正交基）的作用是给空间定义坐标。

5. 线性变换可以用矩阵表示；Ax 既可读作“对 x 做变换”，也可读作“把 A 系下的坐标换算回标准坐标系”。
6. 特征值与特征向量描述变换的速度与方向，特征值分解要求方阵，奇异值分解则适用于任意矩阵。
7. 线性代数之于人工智能，如同加法之于高等数学——它是最底层、最高频被调用的工具。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
线性代数	Linear Algebra	LA	研究向量、向量空间、线性变换及其矩阵表示的分支
集合	Set	—	由若干确定对象汇总而成的整体
标量	Scalar	—	单独一个数，是张量体系中的零阶对象
向量	Vector	—	一组有序排列的标量，可视作一维数组或空间中的点
矩阵	Matrix	—	按行列排布的二维数表，用于表示线性变换或数据集合
张量	Tensor	—	多维数组的统称，矩阵是其二维特例
范数	Norm	—	把向量映射为非负实数的“长度”度量
内积	Inner Product	IP	对应元素乘积求和，刻画两向量的夹角与相关性
正交	Orthogonality	—	两非零向量内积为零，几何上互相垂直且线性无关
线性空间	Linear Space	—	对加法与数乘封闭的向量集合，又称向量空间
内积空间	Inner Product Space	—	定义了内积运算的线性空间
正交基	Orthogonal Basis	—	由一组非零、两两正交的向量构成的基
标准正交基	Orthonormal Basis	—	每个基向量范数均为 1 的正交基
线性变换	Linear Transformation	—	保持加法与数乘结构的映射，可用矩阵表示
单位矩阵	Identity Matrix	I	主对角线元素为 1、其余为 0 的方阵，代表恒等变换
行列式	Determinant	det	方阵对应的标量，表示变换对体积的缩放倍数
特征值	Eigenvalue	—	矩阵作用于特征向量时的伸缩倍数
特征向量	Eigenvector	—	被矩阵作用后方向不变、仅长度缩放的向量

名称	英文全称	英文缩写	简短介绍
特征值分解	Eigenvalue Decomposition	EVD	将方阵分解为特征向量矩阵与对角特征值矩阵之积
谱分解	Spectral Decomposition	—	实对称矩阵的正交特征值分解形式
奇异值分解	Singular Value Decomposition	SVD	任意矩阵分解为左右奇异向量矩阵与奇异值对角阵的形式
主成分分析	Principal Component Analysis	PCA	基于协方差矩阵特征分解的线性降维方法
潜在语义分析	Latent Semantic Analysis	LSA	用奇异值分解挖掘词与文档潜在语义关系的技术
低秩适配	Low-Rank Adaptation	LoRA	用两个低秩矩阵近似权重更新，实现大模型高效微调