概率论：不确定性、贝叶斯与常见分布

读前须知

- **前置**：集合、求和符号，以及“随机变量是一个函数”这句话。
- **这一篇的位置**：概率论是不确定性建模的语言。朴素贝叶斯、贝叶斯网络、变分自编码器，都从这里的长链公式出发。
- **读完能做什么**：在联合、条件、边缘三种分布之间自由换算；用贝叶斯公式更新信念；看到一份数据时，判断该用哪种分布去描述它。

一、概率论为什么成了主流工具

研究智能问题躲不开不确定性：传感器有噪声，数据有缺失，用户行为随机，模型参数也无法精确知晓。随着连接主义路线兴起，**概率统计逐渐取代数理逻辑，成为人工智能研究的主力工具。**在数据规模暴涨、算力指数增长的今天，概率论已经从“辅助工具”升格为“核心语言”。

和线性代数一样，概率论也是一种看世界的方式，只不过它关注的焦点是**无处不在的可能性。**它的任务，是给“某件事可能发生”这种模糊直觉，建立一套能做加减乘除的数学描述——这个过程就是概率的公理化。

二、频率学派：概率是频率的极限

把一枚硬币抛 10 次，正面朝上可能是 0 次，也可能是 10 次，对应的频率分别是 0% 和 100%。单次实验的结果显然会随机波动。但**随着重复试验次数增加，特定事件出现的频率会趋于稳定，逐渐逼近某个常数。**

从频率角度理解概率，就是所谓**频率学派（frequentist probability）**：概率是可独立重复的随机试验中，单个结果出现频率的极限。稳定的频率是统计规律性的体现，所以用大量重复试验的频率来表征可能性，是一种合理的定义方式。

2.1 古典概型

频率学派做定量计算时，最基础的模型是**古典概率模型。**它有两个前提：

1. 试验结果只包含**有限个**基本事件；
2. 每个基本事件发生的**可能性相同。**

设基本事件总数为 n，事件 A 包含 k 个基本事件，则

$$P(A) = \frac{k}{n}$$

这个公式看似简单，却是大量复杂概率计算的起点。**补充说明**：它的适用范围很窄——掷骰子、抽签、洗牌这类“对称”场景才满足等可能性；现实中绝大多数问题（比如明天下雨的概率）并不满足，必须换用其他定义方式。

三、条件概率：引入信息之后的概率

上面的定义只针对单个事件。要刻画两个事件之间的关系，就得引入**条件概率（conditional probability）**。

举个直观的例子：一支球队“1:0 取胜”和“0:2 落后时 3:2 翻盘”，两者概率显然不同——因为后者自带了一个额外条件。条件概率正是“根据已有信息调整样本空间”之后的概率分布。对事件 A 与 B：

$$P(A \mid B) = \frac{P(AB)}{P(B)}, \qquad P(B) > 0$$

其中 P(AB) 称为**联合概率（joint probability）**，表示 A 与 B 同时发生。由定义直接得到**乘法公式**：

$$P(AB) = P(A \mid B)\, P(B) = P(B \mid A)\, P(A)$$

3.1 独立

如果联合概率等于各自概率的乘积：

$$P(AB) = P(A) \cdot P(B)$$

就说 A 与 B **相互独立**。对独立事件，条件概率退化为自身概率：

$$P(A \mid B) = P(A)$$

注意区分：独立描述的是"发生与否互不影响"，互斥描述的是"不能同时发生"。两个概率都为正的互斥事件反而**一定不独立**——其中一个发生就排除了另一个。

3.2 全概率公式

复杂事件的概率往往难以直接计算，**全概率公式（law of total probability）** 提供了一条"分而治之"的路径：把样本空间按一组互不重叠的假设 B_i 切成若干部分，再分别求解、求和。

$$P(A) = \sum_{i=1}^{N} P(A \mid B_i) \cdot P(B_i), \qquad \sum_{i=1}^{N} P(B_i) = 1$$

它的思路代表了频率学派解决问题的典型套路：**先做假设，再在假设下计算条件概率。**补充一点：切割必须满足"互斥且穷尽"（即 $\{B_i\}$ 构成样本空间的一个划分），否则求和会重复或遗漏。

3.3 贝叶斯公式

对全概率公式稍作整理，就得到求解**逆概率**问题的工具。所谓逆概率，是"结果已知，反推原因"：观测到结果 A 之后，判断各个假设 B_i 的可能性有多大。

$$P(B_i \mid A) = \frac{P(A \mid B_i) \cdot P(B_i)}{\sum_{j=1}^{N} P(A \mid B_j) \cdot P(B_j)}$$

分母正是全概率公式，作用是把分子归一化，使结果满足概率之和为 1。

写成更抽象的形式，就是**贝叶斯定理（Bayes' theorem）**：

$$P(H \mid D) = \frac{P(D \mid H) \cdot P(H)}{P(D)}$$

三个名字必须记牢：

项	名称	含义
P(H)	先验概率（prior）	观测之前，假设成立的把握
P(D|H)	似然（likelihood）	假设成立时，观测到该数据的概率
P(H|D)	后验概率（posterior）	观测到数据之后，假设成立的把握

> **新手提示：用"看病"理解三个名词**

> 先验就是"进医院前你对病情的初步判断"，似然是"如果真的患这种病，症状会这样表现的概率"，后验是"做完检查、看到结果后，你对病情的新判断"。贝叶斯公式说的就是：**新判断 = 旧判断 × 症状吻合度，再归一化。**

一个具体例子：记 S 为"患病"，$\bar{S}$ 为"健康"，T 为"检测阳性"。已知患病率 P(S) = 0.01；患者阳性率 P(T|S) = 0.99；健康人误报率 P(T|$\bar{S}$) = 0.05。问：检测阳性时真正患病的概率是多少？

$$P(S \mid T) = \frac{P(T \mid S)P(S)}{P(T \mid S)P(S) + P(T \mid \bar{S})P(\bar{S})} = \frac{0.99 \times 0.01}{0.99 \times 0.01 + 0.05 \times 0.99} = \frac{0.0099}{0.0594} \approx 16.7\%$$

结果远低于直觉。这解释了为什么罕见病筛查往往需要复检——**先验概率极低时，再高的检测准确率也会被误报稀释。**

四、两个学派的根本分歧

4.1 对"概率"的理解不同

- **频率学派**：概率是长期频率的极限，是客观属性。
- **贝叶斯学派（Bayesian probability）**：概率是对事件发生的**可信程度。**天气预报说明天下雨概率 85%，并不是在说"重复一万个明天有 8500 个下雨"，而是在说"这件事的把握有 85%"。

4.2 对"参数"的理解不同

维度	频率学派	贝叶斯学派
参数性质	客观存在但未知的固定常数	随机变量，本身服从某个分布
先验分布	存在但无从知晓	可以显式设定，并随数据修正
数据的作用	用于估计固定参数	用于更新对参数的信念
核心方法	最大似然估计	最大后验估计、后验推断

贝叶斯学派的观点有一个很实用的推论：**假设取决于观察结果，是不确定且可修正的。**数据的价值就在于不断修正主观认识，使其逼近客观实际。

4.3 两种参数估计方法

机器学习中，参数估计是核心任务之一，两种方法正好对应两个学派。

最大似然估计（maximum likelihood estimation, MLE）：让训练数据出现的概率最大化，以此确定未知参数 θ（希腊字母，读作 theta）。

$$\hat{\theta}_{\text{MLE}} = \arg\max_{\theta} \prod_{i=1}^{n} p(x_i;\theta) = \arg\max_{\theta} \sum_{i=1}^{n} \log p(x_i;\theta)$$

> **新手提示：为什么最大似然要取对数**
>
> 因为连乘很容易"下溢"——几十个小于 1 的数相乘，结果很快就小到浮点数表示不了。而 log 是单调递增的，**取对数不会改变最大值出现在哪个位置**，却能把连乘变成连加，既避开下溢又好求导。公式里第二个等号就是这么来的。

最大后验估计（maximum a posteriori, MAP）：在数据之外再引入先验，让参数的后验概率最大化。

$$\hat{\theta}_{\text{MAP}} = \arg\max_{\theta} \left[\sum_{i=1}^{n} \log p(x_i;\theta) + \log p(\theta) \right]$$

关键差异：MLE 只看数据，MAP 还要加一项先验。**补充说明**：从公式形式看，MAP 相当于在 MLE 的目标上加了一个正则项——先验取高斯分布时对应 L_2 正则化，先验取拉普拉斯分布时对应 L_1 正则化。这条联系把"贝叶斯"和"正则化"两件事直接打通了，是理解深度学习权重衰减的一把钥匙。

> **新手提示：`arg max` 怎么读**
>
> arg max*θ* 表示"让后面这个式子取最大值的那一个 θ"。注意它返回的是***参数本身***，而不是最大值是多少——对比一下：*max*θ f(θ) 返回最大函数值，arg max_θ f(θ) 返回取到最大值时的 θ。

五、随机变量与概率分布

5.1 离散型与连续型

随机变量（random variable） 是把随机试验的结果映射为数值的函数。按取值空间分为两类：

- **离散型随机变量（discrete random variable）**：取值有限或可列无限。
- **连续型随机变量（continuous random variable）**：取值充满某个区间，不可列。

描述离散型随机变量，用**概率质量函数（probability mass function, PMF）**：每个取值与它的概率一一对应，所有概率非负、总和为 1，不在取值集合里的点概率为 0。

描述连续型随机变量，用**概率密度函数（probability density function, PDF）**。这里有个极易混淆的点：

> **密度不是概率**。连续型变量取值不可列无限，归一化的概率被分配到无穷多个点上，每个点的概率都是无穷小量，取极限就是 0。密度刻画的是这些无穷小量之间的**相对大小**。

例如，当 $x \to \infty$ 时，1/x 与 2/x 都趋于 0，但后者始终是前者的两倍。这种相对差异由密度刻画。要得到真实概率，必须对密度**积分**：

$$P(a < X \le b) = \int_a^b f(x)\,\mathrm{d}x, \qquad \int_{-\infty}^{+\infty} f(x)\,\mathrm{d}x = 1$$

补充说明：描述随机变量还有第三种方式——**累积分布函数（cumulative distribution function, CDF）**，F(x) = P(X ≤ x)。它对离散型和连续型统一适用，且单调不减、右连续、取值范围 [0, 1]，在工程实现中比 PDF 更好处理。

5.2 重要的离散分布

两点分布（Bernoulli distribution）：试验只有两种结果，发生概率为 p，不发生为 1−p。

$$P(X=1) = p, \qquad P(X=0) = 1-p$$

抛一次硬币就是等概率（p = 0.5）的两点分布。

二项分布（binomial distribution）：把参数为 p 的两点试验独立重复 n 次，事件发生的总次数服从参数为 (n, p) 的二项分布。

$$P(X=k) = \binom{n}{k} p^k (1-p)^{n-k}, \qquad 0 \le k \le n$$

其中 C(n, k) 称为**组合数**，表示从 n 次试验中挑出 k 次成功的方式数，按阶乘计算：

$$\binom{n}{k} = \frac{n!}{k!\,(n-k)!}$$

泊松分布（Poisson distribution）：描述单位时间（或空间）内稀有事件发生次数的分布，典型例子是放射性物质在规定时间内释放的粒子数。

$$P(X=k)=\frac{\lambda^k e^{-\lambda}}{k!},\qquad k=0,1,2,\dots$$

其中 λ（希腊字母，读作 lambda）是**单位时间（或单位空间）内事件发生的平均次数**，也是泊松分布唯一的参数：λ 越大，事件越频繁。

当二项分布的 n 很大、p 很小时，令 λ=np，二项分布的概率值可以用泊松分布近似。**补充说明**：泊松分布的期望与方差都等于 λ，这个"期望等于方差"的性质常被用来初步判断数据是否近似泊松。

5.3 重要的连续分布

均匀分布（uniform distribution）：在区间 (a, b) 上密度恒定。

$$f(x)=\frac{1}{b-a},\qquad a<x<b$$

它落在区间内任意等长子区间的可能性相同。

指数分布（exponential distribution）：只取正值，参数为 θ（希腊字母，读作 theta），含义是**平均等待时间**：比如粒子平均每隔 θ 分钟到达一个。

$$f(x)=\frac{1}{\theta}e^{-x/\theta},\qquad x>0$$

它最重要的特征是**无记忆性**：

$$P(X>s+t\mid X>s)=P(X>t)$$

也就是说，"已经等了 s 小时"这件事，不会改变还要再等多久的分布。**补充说明**：指数分布与泊松分布是一枚硬币的两面——若事件到达次数服从参数为 λ 的泊松分布，则相邻两次到达的时间间隔服从参数为 θ=1/λ 的指数分布（λ 是单位时间平均来几次，θ 就是平均多久来一次，两者互为倒数）。离散场景下具有同样性质的是几何分布。

正态分布（normal distribution）：参数为均值 μ、标准差 σ（两个希腊字母，分别读作 mu、sigma）。

$$f(x)=\frac{1}{\sqrt{2\pi}\,\sigma}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

当 μ=0、σ=1 时称为**标准正态分布**，记为 N(0, 1)。正态分布是最重要的一种分布，自然界中大量现象都近似服从它，原因就是**中心极限定理（central limit theorem）**：大量独立同分布随机变量之和，其分布近似正态，与个体本身的分布形式无关。这也是为什么测量误差、身高体重、股价收益率都常被假设为正态。

六、数字特征：期望、方差与协方差

分布函数完整描述了随机变量，但有时我们只需要几个概括性的常数，这就是**数字特征**。

数学期望（expected value） 即均值，是可能取值的概率加权平均。离散型用求和，连续型用积分：

$$E(X)=\sum_i x_i\,p(x_i)$$

$$E(X)=\int_{-\infty}^{+\infty} x f(x)\,\mathrm{d}x$$

不要把它理解成"最可能出现的值"——它表示的是把随机变量作为整体来看的规律。期望具有**线性性**：E(aX+bY) = aE(X) + bE(Y)，且**不要求 X、Y 独立**，这是它的强大之处。

方差（variance） 刻画取值与期望的偏离程度：

$$\mathrm{Var}(X) = E\left[(X - E(X))^2\right] = E(X^2) - [E(X)]^2$$

方差小说明取值集中在期望附近，方差大说明取值分散。标准差是方差的平方根，量纲与原变量一致，解释起来更直观。

6.1 协方差与相关系数

期望与方差描述单个变量，要描述两个变量之间的关系，需要**协方差（covariance）**：

$$\mathrm{Cov}(X, Y) = E\left[(X - E(X))(Y - E(Y))\right]$$

协方差度量的是两个随机变量之间的**线性关联**：两者是同向变化还是反向变化、步调有多一致。但它受量纲影响，数值大小不便直接比较，于是标准化得到**相关系数（correlation coefficient）**，记作 ρ（希腊字母，读作 rho）：

$$\rho_{XY} = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \, \sigma_Y} \in [-1, 1]$$

- ρ=1：完全正相关；
- ρ=-1：完全负相关；
- ρ=0：不（线性）相关。

换句话说，只有 Y 能精确写成 Y = aX + b（a≠0）时，才有 |ρ|=1；其余情况下 |ρ| 只表示线性关系的强弱。

必须记住的边界：相关系数只刻画**线性**关系。如果 Y = X²，两者高度相关但 ρ 可能为 0——这种非线性相关超出了协方差和相关系数的表达能力。**补充说明**：ρ=0 只意味着"没有线性关系"，不意味着"独立"；反过来，独立一定推出不相关。只有当 (X, Y) 服从联合正态分布时，不相关与独立才等价。

四个常见误区

- **"独立就是互斥"**——恰好相反。两个都有正概率的事件若互斥，则一个发生就排除了另一个，它们强相关，不独立。独立指的是"知道一个不影响对另一个的判断"。
- **"条件概率就是因果"**——条件概率只描述统计关联。P(病|阳性) 与 P(阳性|病) 完全是两个数，混淆二者是医学检测与司法推理中最常见的错误。
- **"概率密度必须小于 1"**——密度是单位区间上的概率，可以大于 1，只有积分（即区间概率）才必须落在 0 到 1 之间。
- **"大数定律意味着小样本会自己拉平"**——大数定律讲的是样本量趋于无穷时的极限行为。抛十次都是正面，下一次正面的概率仍是二分之一，这不是"该反了"。

七、要点回顾

1. 概率论关注的是客观世界中的不确定性，是人工智能的另一块理论基石。
2. 频率学派用长期频率的极限定义概率，靠最大似然估计求参数；贝叶斯学派把概率看作可信度，靠后验概率最大化求参数。
3. 条件概率引出乘法公式、全概率公式与贝叶斯公式，三者构成概率推断的基本链条。
4. MLE 只用数据，MAP 需要先验；MAP 在形式上等价于 MLE 加正则化。
5. 密度不是概率，连续型变量的区间概率要靠积分求得；CDF 是更通用的描述方式。

6. 常见分布：离散用两点、二项、泊松，连续用均匀、指数、正态。

7. 期望、方差描述单个变量，协方差与相关系数描述两个变量，但只覆盖线性关系。

八、名词汇总

名称	英文全称	英文缩写	简短介绍
概率论	Probability Theory	—	研究随机现象统计规律、对不确定性做定量描述的数学分支
频率学派	Frequentist Probability	—	把概率解释为长期重复试验中频率的极限
贝叶斯学派	Bayesian Probability	—	把概率解释为对事件的可信程度，并随证据更新
古典概率模型	Classical Probability Model	—	基本事件有限且等可能时的概率计算模型
条件概率	Conditional Probability	—	已知某事件发生的前提下另一事件发生的概率
联合概率	Joint Probability	—	两个或多个事件同时发生的概率
全概率公式	Law of Total Probability	—	按完备事件组分解，把复杂事件概率转化为条件概率加权和
贝叶斯公式	Bayes' Formula	—	由先验与似然求后验概率的公式
贝叶斯定理	Bayes' Theorem	—	贝叶斯公式的一般化表述，是贝叶斯推断的核心
先验概率	Prior Probability	—	观测数据之前对假设成立程度的把握
似然函数	Likelihood Function	—	给定参数时观测到现有数据的概率，视参数为其函数
后验概率	Posterior Probability	—	观测数据之后对假设成立程度的修正结果
最大似然估计	Maximum Likelihood Estimation	MLE	选择使训练数据出现概率最大的参数取值
最大后验估计	Maximum A Posteriori Estimation	MAP	结合先验，选择使后验概率最大的参数取值
随机变量	Random Variable	RV	把随机试验结果映射为数值的函数
离散型随机变量	Discrete Random Variable	—	取值有限或可列无限的随机变量
连续型随机变量	Continuous Random Variable	—	取值不可列、充满某个区间的随机变量

名称	英文全称	英文缩写	简短介绍
概率质量函数	Probability Mass Function	PMF	描述离散变量每个取值对应概率的函数
概率密度函数	Probability Density Function	PDF	描述连续变量取值相对可能性的密度函数
累积分布函数	Cumulative Distribution Function	CDF	描述随机变量不大于某值的概率，F(x) = P(X ≤ x)
两点分布	Bernoulli Distribution	—	只有成功与失败两种结果的离散分布
二项分布	Binomial Distribution	—	n 次独立两点试验中成功次数的分布
泊松分布	Poisson Distribution	—	描述单位时间或空间内稀有事件次数的分布
均匀分布	Uniform Distribution	—	区间内各处密度相同的连续分布
指数分布	Exponential Distribution	—	描述等待时间且具有无记忆性的连续分布
正态分布	Normal Distribution	—	钟形对称的连续分布，由均值与标准差确定
中心极限定理	Central Limit Theorem	CLT	大量独立同分布变量之和近似服从正态分布
数学期望	Expected Value	E	随机变量取值的概率加权平均
方差	Variance	Var	随机变量取值偏离期望的平方的期望
协方差	Covariance	Cov	两个随机变量线性相关程度的度量
相关系数	Correlation Coefficient	—	标准化后的协方差，取值范围为 [−1, 1]
独立	Independence	—	联合概率等于边缘概率之积的性质