数理统计：参数估计与假设检验

读前须知

- **前置**：概率论中的期望、方差与常见分布。
- **这一篇的位置**：概率论从已知分布推数据，数理统计反过来从数据推分布，是模型评估与实验设计的依据。
- **读完能做什么**：区分总体与样本；写出极大似然估计的步骤；解释 p 值、置信区间与两类错误各自意味着什么。

一、统计与概率：一对反向的学问

在人工智能研究中，基础知识里有一半要靠统计撑起来：只有把模型的输出作出合理解释，数据的价值才能真正落地。

数理统计（mathematical statistics） 的任务是：根据观测或实验得到的数据，研究随机现象，并对研究对象的客观规律做出合理估计与判断。

它与概率论的关系，可以概括成一句话：

> **数理统计是"逆向的概率论"。**

维度	概率论	数理统计
前提	随机变量的分布已知	分布未知
方法	由分布推演事件的性质与规律	由观测数据反推分布的性质
方向	正向演绎	逆向归纳

打个比方：概率论解决的是"已知摇奖规则，判断某个号码中奖的可能性"；数理统计解决的是"看着历史开奖记录，猜测摇奖规则"。前者是可以精确计算的，后者往往只能给出带有误差范围的猜测。

二、总体、样本与统计量

- **总体（population）**：研究对象所有可能取值的集合。
- **样本（sample）**：实际可用的、有限的数据集合。

统计推断的核心逻辑是"**用样本推断总体**"。为了使推断成立，样本通常来自对总体**多次独立的重复观测**，这保证了两件事：

1. 不同样本值之间相互独立；
2. 每个样本值都与总体同分布。

工程上，这两条被称为 **i.i.d. 假设（独立同分布）**，是绝大多数统计方法的前提。数据存在时间相关性、分布漂移或采样偏差时，这个前提会失效，结论也就不可靠。

2.1 统计量

实际推断中，使用的往往不是样本原始值，而是**统计量（statistic）**——样本的函数。

关键在于：**统计量本身是一个随机变量。**换一批样本，它就取不同的值；它的分布（抽样分布）决定了推断的可靠程度。两个最重要的统计量是：

样本均值：

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

样本方差：

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \bar{X}\right)^2$$

补充说明：样本方差为什么除以 n-1 而不是 n

因为 X̄ 本身由样本算出，数据已经"用掉"了一个自由度。若除以 n，得到的估计量会系统性地小于真实方差，是有偏的；除以 n−1 恰好抵消这一偏差，使 $E(S^2) = \sigma^2$——这里的 σ^2（读作 sigma 的平方）指**总体的真实方差**。这正是**无偏估计**思想最经典的体现。

三、参数估计

参数估计（estimation theory） 是用随机抽取的样本估计总体分布的方法，可进一步分为**点估计（point estimation）** 和**区间估计（interval estimation）**。

3.1 点估计

在已知总体分布的函数形式、但不知道其中一个或多个参数时，用一个样本估计未知参数，就是点估计。

设未知参数记为 θ（希腊字母，读作 theta）；给它戴上"帽子"的 $\hat{\theta}$ 表示由样本算出的**估计值**——这是统计学里"估计"的通用写法。点估计的核心，就是构造合适的统计量 $\hat{\theta}$，用它的观测值去近似 θ。常用方法有两种。

矩估计法

矩（moment） 描述分布的数值特征，k 阶原点矩定义为

$$E\left(X^k\right)$$

矩估计法（method of moments） 的思路是：**用样本的 k 阶矩去估计总体的 k 阶矩。**

$$\hat{E}(X^k) = \frac{1}{n}\sum_{i=1}^{n} X_i^k$$

理论依据是大数定律：样本矩几乎处处收敛于总体矩。样本量足够大时，几乎每次都能得到相当接近的近似值。优点是计算简单、几乎不用求导；缺点是**结果可能落在参数空间之外**（比如估出负的方差），且往往不是最有效的估计。

最大似然估计法

最大似然估计（MLE） 直接来源于频率学派对概率的理解。它的直觉非常朴素：

> 既然抽样已经抽到了这一组样本，就说明"取到这组样本"的概率应该不小；所以在估计参数时，应当让已有样本出现的可能性最大。

似然函数定义为样本观测值出现的概率。由于样本相互独立，似然函数可以写成各样本概率密度（或质量）的连乘：

$$L(\theta) = \prod_{i=1}^{n} p\left(x_i;\theta\right)$$

准则就是让 L(θ) 取最大值。连乘容易数值下溢，通常取对数变成求和，于是等价于求解

$$\hat{\theta} = \arg\max_{\theta} \sum_{i=1}^{n} \log p\left(x_i; \theta\right)$$

再令导数为 0 求解。**补充说明**：对伯努利分布，MLE 得到的参数就是样本中正例的比例，也就是样本均值，即 p̂ = x̄——这是 MLE 最直观的一个例子。深度学习中的交叉熵损失，也正是从"最大化对数似然"推导出来的。

3.2 如何评价一个估计量

同一参数可以用不同方法估计，结果往往不同，于是需要评价标准。实际应用中通常考虑三条。

无偏性（unbiasedness）

$$E\left(\hat{\theta}\right) = \theta$$

意思是：给定样本时估计值可能偏大也可能偏小，但如果反复重抽样、每次都用新样本算一遍，这些估计值的**平均偏差为零**，即不存在系统误差。

有效性（efficiency）

在无偏估计量中，方差越小越有效。方差小意味着估计值更稳定、更精确。**补充说明**：有效性衡量的是"同样的样本量下谁更准"，这也是 MLE 在大样本下被偏好的原因——它具有良好的渐近有效性，能达到克拉美-罗下界。

一致性（consistency）

$$\lim_{n\to\infty} P\left(\left|\hat{\theta} - \theta\right| < \varepsilon\right) = 1$$

其中 ε（希腊字母，读作 epsilon）是任意小的正数。

即随样本容量增大，估计量依概率收敛到真实值。不具备一致性的估计量，无论采多少数据都无法精确，因此不可取。

补充说明：三个标准综合起来可以用**均方误差（MSE）** 概括：

$$\mathrm{MSE}\left(\hat{\theta}\right) = E\left[\left(\hat{\theta} - \theta\right)^2\right] = \mathrm{Var}\left(\hat{\theta}\right) + \left[\mathrm{Bias}\left(\hat{\theta}\right)\right]^2$$

也就是说，误差由"波动"与"系统偏差"两部分构成。有时为了让总误差更小，人们反而会故意接受一点点偏差——这正是机器学习中"用正则化换泛化"的统计依据。

3.3 区间估计与置信区间

点估计只给出一个值，但真实参数几乎不可能恰好等于它。于是还需要给出一个范围，并说明这个范围有多可信。

置信区间（confidence interval） 由两个样本统计量构成，分别作为置信下限 θ_与置信上限 θ̄：

$$\left(\underline{\theta},\ \overline{\theta}\right)$$

先约定符号：α（希腊字母，读作 alpha）叫**显著性水平（significance level）**，指的是"允许自己判断出错"的概率，通常事先取定，如 0.05。正确理解置信区间的方式如下（很容易记错）：

> 对总体反复抽样多次，每次都得到容量相同的样本，每组样本都能算出一个置信区间。**若所有区间中包含真实参数 θ 的比例为 1-α，则 1-α 就是置信水平。**

所以 95% 置信区间的含义是“用这种方法构造的区间，长期来看有 95% 会罩住真值”，而**不是**“θ 有 95% 的概率落在这一个区间里”——后者是贝叶斯可信区间的说法，两者不能混用。

补充说明：当样本均值近似正态时，常用

$$\bar{X} \pm z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

其中 z 是标准正态分布的分位数（α=0.05 时 z(0.975) ≈ 1.96），这就是“±1.96 倍标准误”的由来。区间宽度与 √n 成反比，意味着要把精度提高一倍，样本量需要增加四倍。

> **新手提示：什么叫“标准误”**
>
> 标准差描述“单个数据点有多分散”，标准误（standard error）描述“用样本均值去估总体均值，这个估计算得准不准”。样本量越大，标准误越小，估计越稳——所以区间会随样本量增大而变窄。

四、假设检验

4.1 基本框架

参数估计的对象是总体的某个参数，**假设检验（hypothesis test）** 的对象则是关于总体的某个论断。检验中的一对假设是：

- **原假设 H_0（null hypothesis）**：通常表示“没有效应/没有差异”；
- **备择假设 H_1（alternative hypothesis）**：研究者希望证实的对立命题。

检验过程，就是根据样本在 H_0 与 H_1 之间做出选择。

4.2 两类错误

理想情况是“假设为真且被接受”，但检验基于样本，错误决策必然存在：

真实情况 vs 决策	接受 H_0	拒绝 H_0
H_0 为真	正确	**第 I 类错误（弃真）**
H_0 为假	**第 II 类错误（取伪）**	正确

- **第 I 类错误**：H_0 为真却被拒绝，概率记为 α，也就是**显著性水平**；
- **第 II 类错误**：H_0 为假却被接受，概率记为 β。

1-β 称为**检验功效（power）**，即在假设确实为假时成功发现它的概率。**补充说明**：在样本量固定的前提下，α 与 β 不能同时减小——降低误报率必然抬高漏报率。唯一能同时改善两者的办法是**增加样本量**。这和机器学习里“精确率与召回率此消彼长”是同一件事。

4.3 检验的思维方式

假设检验的逻辑建立在一个前提上：**全称命题只能被证伪，不能被证实。**

要证明“所有天鹅都是白的”极其困难，但要推翻它只需找到一只黑天鹅。要在 H_0 与 H_1 之间做判断，同样更适合去证伪：**找一个反例。**

但在统计场景下，“反例”不是绝对违背假设，而是以**小概率事件**的形式出现：

- 通常把发生概率小于 1%（也常用 5%）的事件视为小概率事件；
- 小概率事件在单次试验中被认为几乎不会发生；

- 若一次观测中真的出现了小概率事件，就有理由怀疑前提不成立，于是拒绝原假设。

于是流程可以固定为四步：

1. 提出 H_0 与 H_1；
2. 选择检验统计量并确定其在 H_0 下的分布；
3. 设定显著性水平 α，确定拒绝域；
4. 计算统计量取值，落入拒绝域则拒绝 H_0，否则不拒绝。

补充说明：现代实践中更常用 **p 值（p-value）** 替代固定阈值。p 值表示"在 H_0 为真的前提下，出现当前或更极端结果的概率"。p 值小于 α 即拒绝 H_0。注意 p 值**不是**"H_0 为真的概率"，这也是被误用最多的统计概念之一。另外，检验分为**单侧检验**与**双侧检验**，选择依据是 H_1 的方向性；方向事先由业务判断确定，不能看数据之后再挑。

五、统计视角下的机器学习

5.1 学习就是假设空间中的搜索

从统计角度看，监督学习算法的任务，就是在**假设空间**中搜索一个能对特定问题做出良好预测的假设。

> **新手提示：什么是"假设空间"**
>
> 假设空间就是"所有候选模型的集合"。例如用直线做分类，所有可能的直线（不同斜率和截距）就构成一个假设空间；训练就是在其中挑出最符合数据的那一条。神经网络的全部可能参数组合同样构成一个巨大的假设空间。

学习器在训练数据上拟合出来的模型，能否适用于没见过的新样本，这种能力叫**泛化能力（generalization ability）**。显然，泛化能力越强越好。

假设检验的作用就在这里：用学习器在测试集上的表现，推断它泛化能力的强弱，并给出结论的精确程度；进一步还可以比较不同学习器的优劣。由于常用指标是错误率，检验的假设自然落在"泛化错误率"上，依据则是测试集上的测试错误率。**补充说明**：这也是为什么测试集必须与训练集独立——一旦泄漏，测试错误率就不再是对泛化错误率的无偏估计，后续所有检验都失去意义。

5.2 泛化误差的三个来源

对泛化性能的解释，是机器学习算法分析的另一条主线。泛化误差可分解为三部分：

$$E\left[(y-\hat{f}(x))^2\right]=\left[\mathrm{Bias}\left(\hat{f}\right)\right]^2+\mathrm{Var}\left(\hat{f}\right)+\sigma^2$$

公式右边三项依次是：

1. $\mathrm{bias}(\hat{f})^2$：偏差的平方；
2. $\mathrm{var}(\hat{f})$：方差；
3. σ^2：数据本身的噪声。

成分	含义	对应的模型问题
偏差（bias）	预测值与真实结果的系统性偏离	欠拟合：模型太简单，学不到规律
方差（variance）	数据扰动引起的预测波动	过拟合：模型太复杂，记住了噪声

成分	含义	对应的模型问题
噪声（noise）	当前任务上能达到的最小泛化误差	任务本身的难度上限，任何模型都无法消除

偏差与方差难以同时优化，这正是欠拟合与过拟合之间难以调和的矛盾。模型复杂度上升，偏差下降、方差上升；复杂度下降则相反。**补充说明**：这条规律是正则化、早停、集成学习、交叉验证等一整套工程手段的理论源头——它们的共同目标，都是在偏差与方差之间找到一个更优的平衡点。

四个常见误区

- **"p 值是原假设为真的概率"**——它不是。p 值回答的是"假定原假设成立，出现当前或更极端结果的概率"，两者方向相反。
- **"置信区间表示参数落在里面的概率"**——在频率派框架下，参数是固定的，区间是随机的。95% 指的是"重复抽样构造的区间中约 95% 会覆盖真值"。
- **"显著就是效应大"**——样本量足够大时，微小差异也会显著。看 p 值的同时必须看效应量。
- **"极大似然估计总是无偏的"**——不一定。正态分布方差的最大似然估计要除以 n，是有偏的；除以 n−1 才是无偏版本。

六、要点回顾

1. 概率论由分布推演数据，数理统计由数据反推分布，方向相反、互相依赖。
2. 统计推断的工具是统计量；统计量是样本的函数，本身也是随机变量。
3. 点估计常用矩估计与最大似然估计；样本方差除以 n−1 是为了保证无偏。
4. 评价估计量看三条：无偏性（无系统误差）、有效性（方差小）、一致性（大样本收敛）。
5. 区间估计在点估计的基础上补充了误差范围与可信程度，置信水平是长期覆盖率而非单次概率。
6. 假设检验通过小概率事件证伪假设；第 I 类错误是弃真，第 II 类错误是取伪，两者此消彼长。
7. 泛化误差 = 偏差² + 方差 + 噪声，偏差对应欠拟合，方差对应过拟合。

七、名词汇总

名称	英文全称	英文缩写	简短介绍
数理统计	Mathematical Statistics	—	由观测数据推断随机现象客观规律的学科
总体	Population	—	研究对象所有可能取值的集合
样本	Sample	—	从总体中抽取的有限观测数据集合
独立同分布	Independent and Identically Distributed	i.i.d.	样本彼此独立且服从同一分布，是统计推断的基本前提
统计量	Statistic	—	完全由样本决定的函数，本身是随机变量
样本均值	Sample Mean	—	样本的算术平均，用于估计总体均值

名称	英文全称	英文缩写	简短介绍
样本方差	Sample Variance	—	用 n−1 归一化的样本波动度量，是总体方差的无偏估计
参数估计	Estimation Theory	—	用样本估计总体分布未知参数的方法总称
点估计	Point Estimation	—	用一个统计量的取值作为未知参数的近似
区间估计	Interval Estimation	—	给出以一定置信水平包含未知参数的区间
矩	Moment	—	随机变量幂次的期望，描述分布形态特征
矩估计法	Method of Moments	MM	用样本矩匹配总体矩来求解参数的方法
最大似然估计	Maximum Likelihood Estimation	MLE	选择使观测样本出现概率最大的参数
无偏性	Unbiasedness	—	估计量的期望等于被估计参数的真实值
有效性	Efficiency	—	在无偏估计中方差更小、估计更稳定
一致性	Consistency	—	样本量趋于无穷时估计量依概率收敛于真值
均方误差	Mean Squared Error	MSE	估计误差的平方期望，等于方差加偏差的平方
置信区间	Confidence Interval	CI	以给定置信水平覆盖真实参数的取值区间
置信水平	Confidence Level	—	大量重复抽样中置信区间覆盖真值的比例
假设检验	Hypothesis Testing	—	依据样本判断关于总体的假设是否成立
原假设	Null Hypothesis	H_0	通常表示无差异或无效应的待检验命题
备择假设	Alternative Hypothesis	H_1	与原假设对立、希望被证实的命题
第 I 类错误	Type I Error	α	原假设为真却被拒绝，即弃真错误
第 II 类错误	Type II Error	β	原假设为假却被接受，即取伪错误

名称	英文全称	英文缩写	简短介绍
显著性水平	Significance Level	α	允许犯第 I 类错误的概率上限
检验功效	Statistical Power	1-β	原假设为假时被正确拒绝的概率
p 值	p-value	—	原假设成立时出现当前或更极端结果的概率
泛化能力	Generalization Ability	—	模型适应未见过的新样本的能力
泛化误差	Generalization Error	—	模型在未知数据上的期望误差
偏差	Bias	—	模型预测的系统性偏离，反映欠拟合程度
方差	Variance	—	模型对数据扰动的敏感程度，反映过拟合程度
欠拟合	Underfitting	—	模型过于简单，训练与测试表现都不佳
过拟合	Overfitting	—	模型过度记住训练数据噪声，测试表现变差