信息论：熵、互信息与最大熵

读前须知

- **前置**：概率论中的分布与期望，以及对数运算。
- **这一篇的位置**：分类任务最常用的交叉熵损失、决策树的信息增益、最大熵模型，全部建立在这一篇之上。
- **读完能做什么**：手算熵、条件熵与互信息；解释交叉熵为什么能当损失函数；说清 KL 散度为什么不是距离。

一、从不确定性出发

越来越多的科学结论指向同一个事实：**不确定性才是世界的常态。**而描述不确定性最成熟的工具是概率，把概率用于刻画“信息”，就诞生了信息论。

1948 年，供职于贝尔实验室的克劳德·香农（Claude Shannon）发表《通信的数学理论》（*A Mathematical Theory of Communication*），第一次给“信息”这个原本只能定性描述的概念建立了定量度量，标志信息论作为独立学科正式诞生。

香农在论文开篇就划清了边界：

> 通信的根本问题，是在一端精确或近似地复现另一端所选定的消息。消息往往带有含义，指向某种物理或概念上的实体；但**消息的语义与工程问题无关**，真正重要的是——这条消息选自一个“所有可能消息”的集合。

这个“剥离语义”的操作极其关键：它让所有类型的信息都被抽象成**逻辑符号**，于是通信任务的范畴被极大拓展，信息论也获得了远超通信的适用范围。今天我们用熵衡量特征重要性、用交叉熵做损失函数、用 KL 散度约束分布，源头都在这里。

二、自信息：一个事件带来多少信息

2.1 信息量与概率成反比

生活经验告诉我们，不同消息带来的信息量差别巨大：

- “某支从未进过世界杯决赛圈的球队夺冠”——几乎不可能发生，一旦发生，信息量极大；
- “某支长期垄断冠军的球队再次夺冠”——习以为常，信息量很小。

由此可以得到一条朴素的规律：**事件发生的概率越小，它发生时提供的信息量越大。**用不确定性来度量信息，是合理的建模方式。

2.2 定义

设事件 A 发生的概率为 p(A)，其**自信息量（self-information）** 定义为

$$h(A) = -\log_2 p(A)$$

取负号，是因为概率越小、对数值越负，加负号后信息量为正；取以 2 为底，是因为单位定为**比特（bit）**——这正是计算机表示二值信息的最小单位。

性质很直观：

- p = 1（必然事件）时 h = 0，没有不确定性，也就没有信息；
- p → 0 时 h → ∞，越罕见的事件信息量越大；

- 两个独立事件同时发生的信息量等于各自信息量之和，因为 $-\log(p_1 p_2) = -\log p_1 - \log p_2$。这条**可加性**是选择对数形式的根本原因。

2.3 一个数值例子

某彩票头奖的中奖概率约为 1/17721088，若真的中奖，其自信息量为

$$h = -\log_2 \frac{1}{17721088} \approx 24.1 \text{ bit}$$

而抛一枚均匀硬币，正面朝上只有

$$h = -\log_2 \frac{1}{2} = 1 \text{ bit}$$

两者相差 20 多倍，正对应着"可能性相差悬殊"这一直观感受。**可以看到，自信息其实是在用比特数给"意外程度"标价。**

三、信息熵：一个信源的平均信息量

单个事件的信息量还不够用。通信中真正关心的是：**一个信源每发出一个符号，平均能提供多少信息。**这就是**信息熵（entropy）**。

设离散信源 X 共有 n 个符号，符号 a_i 的取值概率为 $p(a_i)$，则信源熵为

$$H(X) = -\sum_{i=1}^{n} p(a_i) \log_2 p(a_i)$$

从定义看，它就是**各符号自信息量在概率空间上的统计平均**：

$$H(X) = E[h(X)] = \sum_{i} p(a_i) [-\log_2 p(a_i)]$$

关于"熵"这个词：它借自热力学。冯·诺伊曼当年建议香农用这个词，理由是"没人真正知道熵是什么"。直到被引入信息论，熵的本质才被讲清楚——**一个系统内在的混乱程度（不确定性程度）**。

3.1 关键性质

- **非负性**：$H(X) \geq 0$；
- **最大性**：当所有符号等概率出现时熵达到最大，$H_{max} = \log_2 n$，此时信源随机程度最高、最难预测；
- **确定性为零**：若某个符号概率为 1，其余为 0，则 H = 0；
- **可加性**：两个独立信源的联合熵等于各自熵之和。

补充说明：二值信源的熵称为**二元熵函数**：

$$H(p) = -p \log_2 p - (1-p) \log_2 (1-p)$$

它在 p = 0.5 时取最大值 1 bit，在 p = 0 或 p = 1 时为 0。这条曲线是理解"为什么训练初期损失大、后期损失小"的最好图像——模型越确定，熵越低。

补充说明：熵还给出了**压缩的极限**。对服从分布 P 的信源做无损编码，平均码长的下界正是 H(P)。这就是为什么"熵编码"能做到接近理论极限的压缩比。

四、条件熵：知道 X 之后，Y 还剩多少不确定

概率论里有条件概率，信息论里对应的概念是**条件熵（conditional entropy）**。

如果两个信源相关，那么在已知其中一个信源 X 的条件下，另一个信源 Y 的不确定性会下降。条件熵 H(Y|X) 定义为：给定 X 时 Y 的条件概率所对应的熵，再对 X 求期望。

$$H(Y \mid X)=\sum_{i=1}^{n} p\left(x_i\right) H\left(Y \mid X=x_i\right)=-\sum_{i=1}^{n} \sum_{j=1}^{m} p\left(x_i, y_j\right) \log_2 p\left(y_j \mid x_i\right)$$

它的操作含义很有画面感：**先按 X 的取值把 Y 分成若干组，分别计算每组的熵，再按 X 的分布对这些熵求加权平均。**

举一个例子：一个班自由选座，可能的座位分布五花八门，熵很高；若规定“按身高分区就座”，情况被分成若干小类，虽然每类内部仍然随机，但整体不确定性已经明显下降。**分类之后各类内部残余不确定性的加权平均，正是条件熵所度量的东西；而由此带来的那部分不确定性下降量，则是互信息。**

补充说明：条件熵满足**链式法则**

$$H(X, Y)=H(X)+H(Y \mid X)=H(Y)+H(X \mid Y)$$

它对应概率里的 p(x, y) = p(x)p(y|x)，是联合熵分解的基本工具。

五、互信息：X 帮我们消掉了多少关于 Y 的不确定

有了条件熵，就能定义**互信息（mutual information）**：

$$I(X ; Y)=H(Y)-H(Y \mid X)$$

含义是：Y 的熵减去“已知 X 时 Y 的条件熵”，也就是**由 X 带来的关于 Y 的不确定性的消除量**，可以理解为 X 给 Y 的**信息增益。**

由对称性可以证明（补充说明）：

$$I(X ; Y)=I(Y ; X)=H(X)+H(Y)-H(X, Y)$$

即互信息是对称的，谁给谁的信息量都一样。

5.1 信息增益与特征选择

在通信领域习惯叫**互信息**，在机器学习领域习惯叫**信息增益（information gain）**，两者本质相同。

用于特征选择时：

- H(Y)：不给任何特征时，对训练集分类的不确定性；
- H(Y|X)：使用特征 X 之后，分类的不确定性；
- I(X;Y)：特征 X 带来的不确定性下降量，也就是 X 对 Y 的**区分度。**

显然，信息增益越大，特征的分类能力越强。决策树（ID3）就是按信息增益挑选划分特征的。

但有个陷阱：信息增益的绝对值高度依赖数据集本身的熵 H(Y)，不具备跨数据集、跨特征的绝对可比性。为此提出**信息增益比（gain ratio）**：把信息增益除以特征 X 自身取值分布带来的“分裂信息”，这个分裂信息就是按 X 分组后各组比例构成的熵：

$$g(X ; Y)=\frac{I(X ; Y)}{H(X)}, \qquad H(X)=-\sum_{v=1}^{V} p(v) \log_2 p(v)$$

其中 p(v) 是特征 X 取第 v 个值的样本占比。这样一来，**取值特别多的特征会因为 H(X) 很大而被“惩罚”**，不同特征之间才便于比较（C4.5 采用的就是这个思路）。**补充说明**：信息增益比又可能过度惩罚取值多的特征，实践中常见做法是先用信息增益挑出候选，再用增益比修正。

六、KL 散度：两个分布差多远

机器学习中另一个高频概念是 **Kullback-Leibler 散度（KL divergence）**，简称 KL 散度，用来衡量两个概率分布 P 与 Q 的差异：

$$D_{\mathrm{KL}}\left(P \parallel Q\right) = \sum_{i=1}^{n} p\left(x_i\right) \log_2 \frac{p\left(x_i\right)}{q\left(x_i\right)}$$

连续情形则写成积分形式。

6.1 编码视角的理解

设某信源的真实分布为 P(X)。如果为它设计一套最优编码，平均每个符号所需的比特数最少，这个最小值就是 H(P)。

现在符号集合没变，但我们手里有一套按 Q(X) 设计的最优编码，而实际数据仍然服从 P(X)。用它去编码，平均码长会比最优值多一些比特——**多出来的这部分，就是 KL 散度**：

$$H(P, Q) = H(P) + D_{\mathrm{KL}}\left(P \parallel Q\right)$$

逐项翻译这三个符号：

- H(P,Q)：用分布 Q 的编码去表示分布 P 的数据，平均每个符号要花的比特数（即交叉熵）；
- H(P)：用完全匹配的编码时的理论最优值（即熵）；
- D_KL(P‖Q)：多付出来的那部分比特。

所以 KL 散度也可以读作“**用错误的分布去编码，平均每个符号浪费的比特数**”，或者“两个分布之间的距离”。

6.2 两个必须记住的性质

非负性：

$$D_{\mathrm{KL}}\left(P \parallel Q\right) \geq 0$$

等号仅在 P = Q 时成立（可由 Jensen 不等式证明）。

非对称性：

$$D_{\mathrm{KL}}\left(P \parallel Q\right) \neq D_{\mathrm{KL}}\left(Q \parallel P\right)$$

因此**KL 散度不满足数学意义上对“距离”的要求**（距离必须对称且满足三角不等式），严格说它只是“散度”。

补充说明：两个方向代表两种不同的近似偏好：

- 最小化 D_KL(P‖Q)：要求 Q 在 P 不为 0 的地方也不能为 0，倾向**覆盖所有模式**（mass-covering），结果是分布较宽；
- 最小化 D_KL(Q‖P)：要求 Q 在 P 为 0 的地方也为 0，倾向**只抓住一个模式**（mode-seeking），结果是分布较窄。

这也是变分推断中“用简单分布近似复杂后验”时，必须明确优化方向的原因。另外，因为它不对称，实践中常改用对称化的 **JS 散度（Jensen-Shannon divergence）**。

6.3 交叉熵：深度学习最常用的损失

补充说明：把上式移项，就得到**交叉熵（cross entropy）**：

$$H(P,Q) = H(P) + D_{\mathrm{KL}}(P \parallel Q) = -\sum_i p(x_i)\log_2 q(x_i)$$

训练分类模型时，真实标签分布 P 固定，H(P) 是常数，于是**最小化交叉熵等价于最小化 KL 散度。**这就是为什么分类任务几乎统一使用交叉熵损失——它本质上是在让预测分布尽量贴近真实分布。

七、最大熵原理与最大熵模型

7.1 原理

最大熵原理（maximum entropy principle） 是确定随机变量统计特性时，力图最符合客观情况的一条准则。

思想很朴素：

> 对一个未知的分布，在只掌握部分约束的前提下，应当选择**熵最大**（最均匀、最不确定）的那个。

理由：熵最大意味着没有额外引入任何约束与假设，预测的风险最小。最糟的情形是把概率全押在某个取值上——一旦猜错，代价极大。投资中的"不要把鸡蛋放在同一个篮子里"，就是这条原理的日常版本。

> **新手提示：熵为什么可以当作"不偏不倚"的标准**
>
> 可以这样想：如果你对结果毫无头绪，那么"认为每种可能都差不多"是最安全的赌注；只要稍微偏向某个结果，一旦猜错就要额外付出代价。严格地说这里有一个极小极大的论证：在所有满足已知约束的分布中，熵最大的那个意味着你假设数据最"没规律"、最难压缩；按这个假设去做编码或决策，即使真实情况比预想更有规律，你也不会吃大亏；反过来，如果假设得太"乐观"（以为数据很有规律），一旦猜错损失就很大。

补充说明：从贝叶斯视角看，最大熵分布是在给定约束下"最不偏向任何特定结果"的先验，因此也被称为**最小信息先验。**这与前面讲过的"先验信息越少越好"一脉相承。

7.2 最大熵模型

把最大熵原理用于分类，就得到**最大熵模型（maximum entropy model, MaxEnt）。**

步骤是：

第一步：定义特征函数 $f_i(x, y)$，用来描述输入 x 与类别 y 之间的某种统计规律。

第二步：要求经验期望与模型期望一致，即特征在模型分布下的期望应等于它在训练数据经验分布 $\tilde{P}(x)$ 下的期望：

$$E_P[f_i] = E_{\tilde{P}}[f_i]$$

这条要求保证了特征函数是无偏的，每个特征函数都对应一个**约束条件。**

第三步：在约束下最大化条件熵：

$$\max_p \; H(p) = -\sum_{x,y} \tilde{p}(x)\, p(y \mid x)\log_2 p(y \mid x)$$

其中 p(y|x) 就是待求的条件分布。

计算上，这是一个约束优化问题；引入**拉格朗日乘子**消去约束后，转化为无约束优化问题。数学上可以证明，**该模型的解存在且唯一**，且具有指数族形式：

$$p(y \mid x) = \frac{1}{Z(x)} \exp\left(\sum_i \lambda_i f_i(x, y)\right)$$

其中 λᵢ（希腊字母，读作 lambda）是**每个特征函数对应的权重**，和逻辑回归里的系数一样由训练数据学出来；Z(x) 是**归一化因子。补充说明**：这个形式与逻辑回归、以及今天大模型里的 softmax 输出完全同构——"指数族 + 归一化"是最大熵思想留下的最深烙印。

> **新手提示：归一化因子是什么**
>
> exp(·) 算出来的数值只是"相对得分"，加起来不一定等于 1。除以所有得分之和（即 Z(x)），就把它们换算成了真正的概率。softmax 函数做的就是这件事。

四个常见误区

- **"熵就是信息量"**——熵度量的是随机变量的平均不确定性，不是某一条具体消息的信息量。具体消息的信息量是负对数概率，两者不是同一个量。
- **"KL 散度是距离"**——它不对称，也不满足三角不等式。它衡量的是"用 q 近似 p 时多付的编码代价"，方向不同结果不同。
- **"交叉熵与 KL 散度是两个目标"**——在真实分布固定的前提下，最小化交叉熵等价于最小化 KL 散度，差的只是一个不随参数变化的熵项。
- **"最大熵就是最随机"**——它是在已知约束下最不偏的选择：只把已知信息用上，不对未知部分做额外假设。均匀分布只是无约束时的特例。

八、要点回顾

1. 信息论处理的是客观世界中的不确定性，香农把信息从"语义"中剥离，使其可被定量计算。
2. 自信息 $h = -\log_2 p$ 度量单个事件的意外程度，稀有小概率事件信息量大。
3. 信息熵是自信息在概率空间上的期望，等概率时取最大值 $\log_2 n$，同时给出无损压缩的理论极限。
4. 条件熵刻画"已知 X 后 Y 的剩余不确定性"；互信息 $I(X;Y) = H(Y) - H(Y|X)$ 是消除量，即信息增益。
5. 信息增益在特征选择中表示区分度，但受 H(Y) 影响，需要信息增益比做归一化。
6. KL 散度衡量两个分布的差异，非负且非对称；交叉熵 = 熵 + KL 散度，是分类任务的默认损失。
7. 最大熵原理在约束下选择最不确定的分布，对应的最大熵模型解存在且唯一，形式为指数族。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
信息论	Information Theory	—	研究信息的度量、传输与编码极限的数学理论
自信息	Self-Information	—	单个事件发生时提供的信息量，等于负对数概率
比特	Binary Digit	bit	信息量的基本单位，对应一次二值选择的不确定性
信息熵	Information Entropy	H	信源各符号自信息的期望，度量平均不确定性与压缩极限

名称	英文全称	英文缩写	简短介绍
二元熵函数	Binary Entropy Function	—	二值信源的熵随成功概率变化的曲线，0.5 时取最大值
联合熵	Joint Entropy	—	多个随机变量共同的不确定性度量
条件熵	Conditional Entropy	—	已知一个变量后另一个变量剩余的不确定性
链式法则	Chain Rule of Entropy	—	联合熵等于边缘熵与条件熵之和
互信息	Mutual Information	MI	一个变量提供的关于另一个变量的不确定性的消除量
信息增益	Information Gain	IG	使用某特征后分类不确定性下降的幅度，用于特征选择
信息增益比	Gain Ratio	—	信息增益与特征分裂信息（特征取值分布的熵）之比，用于修正增益的偏好
KL 散度	Kullback-Leibler Divergence	KLD	衡量两个概率分布差异的非负、非对称度量
JS 散度	Jensen-Shannon Divergence	JSD	对 KL 散度做对称化与有界化处理后的分布差异度量
交叉熵	Cross Entropy	—	用近似分布编码真实分布的平均代价，等于熵加 KL 散度
最大熵原理	Maximum Entropy Principle	MaxEnt	在已知约束下选择熵最大的分布，以最小化额外假设
最大熵模型	Maximum Entropy Model	MaxEnt	以最大熵原理为准则、由特征函数约束确定的分类模型
拉格朗日乘子	Lagrange Multiplier	—	将约束条件并入目标函数、构造无约束问题的系数
指数族分布	Exponential Family	—	可写成指数形式的一类分布，最大熵模型的解属于此类
无损压缩	Lossless Compression	—	不丢失信息地压缩数据，平均码长下界为信源熵