机器学习概论：假设空间、泛化误差与模型评估

读前须知

- **前置**：线性代数与概率论的基本符号；不需要任何机器学习基础。
- **这一篇的位置**：全库的方法论总纲。“假设空间”“过拟合”“交叉验证”这几个词，后面每一篇都会反复用到。
- **读完能做什么**：区分监督、无监督与强化学习；说清训练误差与泛化误差为何不是一回事；独立设计一次训练集/验证集/测试集划分。

一、机器学习是什么

在规则系统时代，让计算机完成一件事的办法是**把流程写死**：人先想清楚每一步判断，再翻译成代码。这条路在处理人脸识别、语音理解、垃圾邮件判别这类任务时走不通——因为没人能写出“什么样的脸是某个人的脸”这种规则。机器学习换了个方向：**不写规则，而是给样本，让算法自己把规则找出来。**

因此机器学习有两条常见定义，分别从能力和方法切入：

- **形式化角度**：如果一个程序利用经验 E 在任务类 T 上的性能 P 得到改善，就说它在进行机器学习。这条定义强调“性能可度量”，因此必须先有明确的评价指标。
- **方法论角度**：机器学习是计算机基于数据构建概率统计模型，并运用模型对数据进行预测与分析的学科。这条定义强调“模型”这一中间产物。

两条定义指向同一个内核：**从数据中来，到数据中去。**数据是唯一的信息来源，模型是数据的压缩表达，最终又要回到新数据上去验证。

这里有一个容易被忽略的前提：**已有数据必须具备一定的统计特性**，不同样本可以视为满足独立同分布的随机变量。没有这个前提，“从训练数据推出适用于未知数据的模型”在逻辑上就不成立——单次观测不足以支撑任何推断。

> **新手提示：什么叫独立同分布**
>
> “独立”指样本之间互不影响，抽到这一个不影响抽到那一个；“同分布”指所有样本来自同一个概率分布。机器学习的所有理论保证几乎都建立在 i.i.d. 假设上。现实数据一旦打破它（比如时间序列、用户行为前后相关），模型效果就会打折扣，这也是时序预测比图像分类更难的根本原因之一。

按训练数据**是否带标签**，学习方式可分为三类：

类型	训练数据	目标	典型任务
监督学习	带标签	学习输入到输出的映射	分类、回归、标注
无监督学习	无标签	发现数据的内在结构	聚类、降维、密度估计
半监督学习	少量标签 + 大量无标签	借助无标签数据提升效果	半监督分类

效果较好的算法大多执行监督学习任务。即便是号称“自学成才”、不依赖棋谱的 AlphaGo Zero，训练过程也要受围棋胜负规则约束，因此依然脱不开监督学习的范畴。

> **新手提示：AlphaGo Zero 到底算不算无监督**

> 它不学人类棋谱，看起来"无人教"；但它通过与自己对弈、依据最终胜负获得奖励信号，本质上是**强化学习**——一种以环境反馈代替人工标签的监督形式。所谓"无标签"，只是没有人工标注而已。

补充说明：机器学习与统计学的关系常被误解。两者都用数据拟合模型，但统计学的重心是**推断**——估计参数、给出置信区间、回答"这个效应是否真实存在"；机器学习的重心是**预测**——在未知样本上把误差降到最低。因此机器学习模型即使内部系数不可解释，只要预测准确就有价值；而统计模型即使预测一般，只要能给出可靠推断就算成功。这种目标差异直接决定了二者的方法论分歧：统计学家偏好简洁可解释的模型，机器学习从业者偏好交叉验证下的最优模型。

二、数据、属性与特征空间

在机器学习里，"数据"不是通常意义上的数值，而是**对对象某些性质的描述**：

- 被描述的性质叫**属性（attribute）**，也叫特征；
- 属性的取值叫**属性值（attribute value）**；
- 不同的属性值有序排列得到的向量，就是**数据**，也叫**实例（instance）**或样本。

举例来说，判断一个人来自哪个东亚国家，可以取肤色、眼睛大小、鼻子长短、颧骨高度四个属性。一个具体的人是实例，四个取值 {浅、小、长、高} 是它的属性值向量。

2.1 特征空间与特征向量

每个属性代表一个维度，这些维度共同张成了**特征空间（feature space）**。每一组属性值都是空间中的一个点，因而每个实例都可以视为特征空间中的一个向量，即**特征向量（feature vector）**。

这个转换的意义在于：一旦对象被表示成向量，距离、内积、投影、线性组合这些几何工具就都能用上。后面几乎所有算法——最近邻、支持向量机、聚类、主成分分析——第一步都是把对象放进某个特征空间，然后在空间里做几何运算。

> **新手提示：这里的"特征向量"和线性代数里的不是一回事**
>
> 线性代数中的特征向量讲的是"被矩阵作用后方向不变的向量"，对应特征值；机器学习里说的特征向量，只是"把样本的各个属性值排成一个向量"。两者同名不同义，读文献时要看上下文。

补充说明：属性并不都适合直接放进特征空间。性别、国籍这类**标称属性**只能比较相等与否，硬编码成 1、2、3 会凭空造出"大小"关系；有序属性（小、中、大）可以保序映射为数值；而文本、图像这类非结构化数据，需要先转成向量才能参与计算。这个从原始属性到有效特征的转换过程叫**特征工程（feature engineering）**，它曾是传统机器学习的主要工作量，深度学习兴起后则由网络自己学习表示。

2.2 属性的规模与维度灾难

属性越多，特征空间的维数越高，空间体积增长得越快。设想每个属性有 100 种取值：两个属性张成 $100^2 = 10000$ 个格点，三个属性就是 10^6 个，十个属性则是 10^{20} 个。样本数远远跟不上格点数的增长，于是数据在空间中变得极其稀疏——任意两个样本之间的距离都趋于相近，基于距离的方法随之失效。

这就是**维度灾难（curse of dimensionality）**：增加属性并不总是增加信息，反而可能让模型更难学到规律。这也是降维方法存在的根本原因。

三、预测任务的三种类型

按输入与输出的类型，监督学习任务可分三类：

- **分类问题（classification）**：输出变量为有限个离散值。只有两个取值时叫**二分类（binary classification）**，是最简单也最常见的情形。判断国籍、判别垃圾邮件都属于此类。
- **回归问题（regression）**：输入和输出均为连续变量。预测房价、气温、股票收益率都属于此类。

- **标注问题（tagging / sequence labeling）**：输入和输出均为变量序列，比如给一句话中的每个词标注词性，或者识别一句话中的人名、地名。

补充说明：任务类型决定了损失函数与评价指标的选择，这一步定错，后面全错。分类任务常用交叉熵损失、以准确率或 F1 为指标；回归任务常用均方误差、以 RMSE 或 MAE 为指标。二者不能混用：分类问题用均方误差会因梯度消失而训练缓慢，回归问题用准确率则几乎没有意义。此外还有一类**结构化预测**，输出不是单个标量或标号而是复杂结构（如整棵句法树），可以看作标注问题的一般化。

四、误差：衡量学习器好坏

每个国家的人都不是一个模子刻出来的。一个浓眉大眼的韩国人可能被认成中国人，一个肤色偏深的日本人可能被认成泰国人。算法也一样：**既不可能与所有训练数据完全吻合，也不可能对所有测试数据预测得毫厘不差**。于是误差成为机器学习最重要的指标。

误差（error） 定义为学习器的实际预测输出与样本真实输出之间的差异。

4.1 错误率与精度

分类问题中最常用的是**错误率（error rate）**：分类错误的样本占全部样本的比例。设 m 个样本中有 a 个分错，则

$$E = \frac{a}{m}$$

与之对应，**精度（accuracy）** 为 1 − E。两者互为补集，报出一个就等于报出了另一个。

4.2 训练误差与泛化误差

误差按数据来源分为两类，这两者的区别是理解整个机器学习的关键：

名称	别称	含义	作用
训练误差	经验误差	学习器在训练集上的误差	反映输入属性与输出标记之间的相关性，判断问题“好不好学”
测试误差	泛化误差	学习器在新样本上的误差	反映对未知数据的预测能力，是真正关心的指标

实用的学习器都是测试误差较低的，也就是在新样本上表现好的。训练误差低而测试误差高，是典型的过拟合信号。

补充说明：精度在不平衡数据上会给出严重误导。一个数据集里 99% 是负例，模型只要全部判成负例，精度就有 99%，但完全失去了识别正例的能力。此时应改用**精确率（precision）**、**召回率（recall）** 与 **F1 值**，或者直接看 ROC 曲线下的面积（AUC）。这也说明一个原则：**评价指标必须与业务代价对齐**，漏诊和误诊的代价不同，指标就不能只看准确率。

五、过拟合与欠拟合

学习器要用已知数据去拟合真实情况，因此需要在训练数据中尽可能提取出适用于所有未知数据的**普适规律**。提取不足和提取过度，对应两种典型的失败方式。

5.1 过拟合

一旦过于看重训练误差，一味追求与训练数据吻合，就会把训练样本自身的**非普适特性**误当成所有数据的普遍性质，导致泛化能力下降。这就是**过拟合（overfitting）**。

如果接触的外国人样本很少，从没见过双眼皮的韩国人，脑子里就会形成"单眼皮都是韩国人"的错误定式——把训练数据的偶然特征当成了整体规律。

过拟合的常见原因是**模型包含的参数过多**：训练误差很低，测试误差却很高。

5.2 欠拟合

与过拟合对应的是**欠拟合（underfitting）**：学习能力太弱，连训练数据的基本性质都没学到。学习器能力不足时，甚至会把黑猩猩的图像认作人。

两者的处理难度并不对等：**欠拟合可以通过改进算法克服，过拟合却无法彻底避免，只能尽量降低影响。**因为训练样本数量有限，参数足够多的模型总能把所有训练样本纳入其中；但参数越多，能与之精确相符的数据就越少，用到无穷的未知数据上，过拟合便不可避免。更何况训练样本本身还可能含噪声，随机噪声又会给模型带来额外误差。

5.3 模型复杂度与测试误差

测试误差与模型复杂度之间呈抛物线关系：

- 复杂度低时，测试误差高，对应欠拟合；
- 复杂度增加，测试误差逐渐下降，达到最小值；
- 复杂度继续上升，测试误差转而增加，对应过拟合。

> **新手提示：为什么"越复杂越差"**
>
> 可以把模型想象成一张能随意弯曲的纸。弯曲程度不够，贴不住数据的起伏（欠拟合）；弯曲得太过分，连噪声的抖动都照着描了一遍（过拟合）。真正合适的复杂度，是刚好能描出趋势、又不描噪声的那一档。

补充说明：这条抛物线可以用**偏差—方差分解（bias-variance decomposition）**精确刻画。设真实函数为 f(x)，观测标签为 y = f(x) + ε（ε 为零均值、方差为 σ^2 的噪声），在训练集 D 上学到的模型为 f_D(x)，它在不同训练集上的期望为 f̄(x)，则泛化误差满足

$$\mathbb{E}_D\left[(y - f_D(\mathbf{x}))^2\right] = \left(f(\mathbf{x}) - \bar{f}(\mathbf{x})\right)^2 + \mathbb{E}_D\left[\left(f_D(\mathbf{x}) - \bar{f}(\mathbf{x})\right)^2\right] + \sigma^2$$

右边三项依次是偏差的平方、方差与不可约噪声。模型越简单，偏差越大（假设空间里根本没有真函数），方差越小；模型越复杂，偏差下降而方差上升（对训练集扰动过于敏感）。最优点正是三项之和的最小处。这一分解是正则化、早停、集成学习等一整套工程手段的共同理论源头。

六、模型选择：交叉验证与调参

模型选择和参数设定都无法仅凭训练误差决定，必须先估计出可靠的测试误差。

6.1 k 折交叉验证

模型选择时，为了更精确地估计测试误差，广泛使用**交叉验证（cross validation）**。它的思想是**重复利用有限的训练样本**：把数据切成若干子集，让不同子集轮流充当训练集与测试集。

以 10 折交叉验证为例，把训练数据分成 10 个子集 D_1 到 D_{10}：

1. 第 1 轮用 D_2~D_{10} 训练，在 D_1 上测试；
2. 第 2 轮用 D_1、D_3~D_{10} 训练，在 D_2 上测试；
3. 依此类推，直到每个子集都当过一次测试集。

模型性能取 10 次测试结果的均值：

$$\bar{E} = \frac{1}{k}\sum_{i=1}^{k} E_i$$

不同模型中**平均测试误差最小**的那个就是最优模型。

> **新手提示：交叉验证和"留出法"的区别**
>
> 留出法是一次性切出一块验证集，简单但结果对切法很敏感；交叉验证让每个样本都参与测试一次，结果更稳定，代价是要训练 k 次模型。数据量小的时候，k 折交叉验证几乎是标配。

补充说明：还有两种常见的重采样方式。一是**留一法（leave-one-out）**，即 k 等于样本数，每轮只留一个样本做测试，偏差最小但计算量最大，且对方差估计偏高。二是**自助法（bootstrap）**，每次有放回地抽取 m 个样本，约 36.8% 的样本不会被抽中，正好用作测试集——这也是 Bagging 系列方法的基础。三种方式的取舍本质上是在偏差、方差、计算成本三者之间做平衡。

6.2 调参：性能与效率的折中

除了算法本身，参数取值同样决定模型性能。同样的算法在不同参数配置下，效果可能天差地别。因此**调参**（设定算法参数）是机器学习中重要的工程问题，在神经网络与深度学习中尤其明显。

假设一个神经网络有 1000 个参数，每个参数有 10 种取值，那么仅一组训练/测试集就要考察

$$10^{1000}$$

个模型。这个数量远超宇宙中的原子总数，穷举毫无可能。所以调参的核心矛盾是**性能和效率之间的折中**：既要找到好参数，又要在可接受的时间内找到。

补充说明：工程上常用的三种搜索策略各有侧重。**网格搜索（grid search）** 逐点枚举，简单但组合爆炸；**随机搜索（random search）** 在超参数空间中随机采样，理论证明它比网格搜索更高效——因为真正重要的往往只有少数几个超参数，随机采样能让每个维度获得更多不同取值；**贝叶斯优化（Bayesian optimization）** 则用一个代理模型拟合"超参数到性能"的映射，主动选择最有希望的下一组参数，适合单次训练代价很高的场景。

七、假设空间与两类建模方法

7.1 假设空间

监督学习假定训练数据满足独立同分布，并根据训练数据学习一个由输入到输出的映射模型。反映这一映射关系的模型可能有无数种，**所有候选模型共同构成假设空间（hypothesis space）**。监督学习的任务，就是在假设空间中按特定误差准则找到最优模型。

> **新手提示：假设空间可以有多大**
>
> 用直线做二分类，所有可能的直线（不同斜率和截距）就构成一个假设空间；神经网络全部可能的参数组合同样构成一个假设空间。算法设计的一个隐含前提，是先把假设空间圈定下来——圈得太小容易欠拟合，圈得太大则难以搜索且容易过拟合。

补充说明：假设空间的圈定，本质上是在引入**归纳偏置（inductive bias）**——即算法对“什么形状的解更可能”的预设偏好。卷积神经网络偏好局部平移不变的模式，决策树偏好轴平行的分段常值区域，线性模型偏好全局线性关系。没有归纳偏置的算法无法从有限样本泛化，这正是**没有免费午餐定理（no free lunch, NFL）**的结论：在所有可能问题上平均来看，任何算法的期望性能都相同；算法的优越性只能相对于特定问题分布成立。所以“最好的算法”并不存在，只有“最匹配当前数据分布的算法”。

7.2 生成方法与判别方法

监督学习按建模对象可分为两类：

- **生成方法（generative approach）**：先根据数据估计输入与输出的**联合概率分布** P(X, Y)，再由它求出条件概率分布 P(Y|X)。它刻画的是“数据是怎么生成的”。
- **判别方法（discriminative approach）**：直接学习条件概率 P(Y|X) 或决策函数 f(X)。它刻画的是“给定输入该输出什么”。

维度	生成方法	判别方法
学习对象	联合分布 P(X, Y)	条件分布 P(Y|X) 或决策函数
收敛速度	较快	较慢
适用范围	较广	相对聚焦
准确率	通常略低	通常更高
使用方式	相对复杂	简单直接

两相对比：生成方法收敛更快、适用面更广；判别方法准确率更高、使用更简单。后续的朴素贝叶斯是生成方法的代表，逻辑回归则是判别方法的代表。

补充说明：生成方法的“适用范围更广”体现在它能处理缺失输入，也能生成新样本——因为联合分布 P(X, Y) 本身就描述了数据如何产生。但它的代价是必须对 P(X) 建模，而 P(X) 往往比 P(Y|X) 复杂得多，需要更多样本才能估准。理论上有结论表明：在样本量趋于无穷时，判别方法的误差上界更低；而在小样本下，生成方法因其更强的假设反而可能占优。这个“小样本靠生成、大样本靠判别”的规律，与本节 7.2 中两种方法的对比正好呼应。

四个常见误区

- **“测试集可以用来调参”**——一旦根据测试集结果反复选择模型，测试集就事实上变成了验证集，最后报出的指标会偏乐观。测试集只能用一次。
- **“准确率高就是模型好”**——在极度不平衡的数据上，全猜多数类也能获得很高的准确率。此时应看精确率、召回率、F1 或 AUC。
- **“过拟合就是因为参数太多”**——参数多只是提供了容量，真正导致过拟合的是“容量相对数据量与噪声过大”。同样的参数规模，加正则与数据增强后可能完全不过拟合。
- **“交叉验证能解决一切评估问题”**——如果预处理（如标准化、特征选择）在划分之前就用了全量数据，信息会泄漏到验证集，交叉验证的结果同样不可信。

八、要点回顾

1. 机器学习不写死规则，而是从数据中提取规律；核心是“从数据中来，到数据中去”，前提是样本满足独立同分布。
2. 按标签情况分为监督学习、无监督学习、半监督学习；按输出形式分为分类、回归、标注三类任务。

3. 一条数据是一个实例，由属性值构成；所有属性张成特征空间，实例即空间中的向量。属性过多会引发维度灾难。
4. 误差分为训练误差与泛化误差；后者才是真正关心的指标，精度在不平衡数据上会造成误导。
5. 过拟合是把训练数据的偶然特征当成普遍规律，无法彻底避免，只能通过控制模型复杂度、正则化、集成等手段降低影响；欠拟合则可以通过增强学习能力克服。
6. 测试误差随模型复杂度呈抛物线变化，其根源是偏差与方差的此消彼长。
7. 交叉验证通过轮换训练集与测试集，更可靠地估计测试误差；调参的本质是性能与效率的折中。
8. 监督学习在假设空间中按误差准则搜索最优模型。假设空间的圈定即归纳偏置的引入，没有免费午餐定理说明不存在普适最优算法。
9. 按建模对象分为生成方法与判别方法：前者学联合分布、收敛快、适用广；后者学条件分布、准确率高、使用简单。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
机器学习	Machine Learning	ML	基于数据构建概率统计模型并对数据进行预测与分析的学科
属性	Attribute	—	对对象某一性质的描述，也称特征
属性值	Attribute Value	—	属性在具体对象上的取值
实例	Instance	—	一组属性值组成的向量，也称样本
特征空间	Feature Space	—	由全部属性张成的空间，每个实例是其中一点
特征向量	Feature Vector	—	实例在特征空间中的向量表示
标称属性	Nominal Attribute	—	取值仅能比较相等与否、无大小关系的属性
特征工程	Feature Engineering	FE	把原始属性转换为有效特征向量的过程
维度灾难	Curse of Dimensionality	—	维数升高导致样本稀疏、距离失效的现象
分类	Classification	—	输出为有限个离散取值的预测任务
回归	Regression	—	输入输出均为连续变量的预测任务
标注	Tagging	—	输入输出均为变量序列的预测任务
误差	Error	—	学习器预测输出与样本真实输出之间的差异
错误率	Error Rate	—	分类错误的样本占全部样本的比例
精度	Accuracy	—	分类正确的样本占全部样本的比例

名称	英文全称	英文缩写	简短介绍
训练误差	Training Error	—	学习器在训练集上的误差，也称经验误差
测试误差	Test Error	—	学习器在新样本上的误差，也称泛化误差
过拟合	Overfitting	—	模型记住了训练数据的非普适特性，导致泛化能力下降
欠拟合	Underfitting	—	模型学习能力不足，连训练数据的基本性质都没学到
偏差—方差分解	Bias-Variance Decomposition	—	把泛化误差拆为偏差、方差与不可约噪声的分析框架
交叉验证	Cross Validation	CV	轮换训练集与测试集以更可靠估计测试误差的方法
留一法	Leave-One-Out	LOO	k 等于样本数的交叉验证，每轮只留一个样本测试
自助法	Bootstrap	—	有放回抽样构造训练集与测试集的重采样方法
调参	Hyperparameter Tuning	—	设定算法参数以取得更优性能的工程过程
网格搜索	Grid Search	—	在超参数网格上逐点枚举的搜索策略
贝叶斯优化	Bayesian Optimization	BO	用代理模型指导超参数搜索的全局优化方法
监督学习	Supervised Learning	SL	基于带标签的训练数据学习映射模型
无监督学习	Unsupervised Learning	UL	基于无标签的训练数据发现数据内在结构
半监督学习	Semi-Supervised Learning	SSL	同时利用带标签与无标签数据的学习方式
强化学习	Reinforcement Learning	RL	通过与环境交互并获得奖励信号来学习策略
独立同分布	Independent and Identically Distributed	i.i.d.	样本之间相互独立且来自同一分布
假设空间	Hypothesis Space	—	所有候选模型的集合，学习即在此空间中搜索
归纳偏置	Inductive Bias	—	算法对解的形式所作的预设偏好

名称	英文全称	英文缩写	简短介绍
没有免费午餐定理	No Free Lunch Theorem	NFL	在所有问题上平均而言不存在最优算法的结论
生成方法	Generative Approach	—	先学联合分布 P(X, Y) 再求条件分布的建模思路
判别方法	Discriminative Approach	—	直接学习条件分布 P(Y|X) 或决策函数的建模思路