线性回归：最小二乘、正则化与广义线性模型

读前须知

- **前置**：矩阵乘法与转置；最小二乘的求导过程会用到矩阵微积分。
- **这一篇的位置**：第一个能写出闭式解的模型，也是理解“损失函数 + 优化”这一套流程的最佳入口。
- **读完能做什么**：推导正规方程；解释为什么加正则项能抑制过拟合；把逻辑回归、泊松回归都归到广义线性模型的框架里。

一、线性模型为什么值得先学

线性模型是机器学习里形式最简单的一类模型，却也是内涵最丰富的一类：它既能承载最核心的基本思想，又能扩展出功能强大的非线性模型。机器学习中的**线性回归（linear regression）**就是这样一类基础任务，它串起了一连串影响深远的数学工具——最小二乘、最大似然、正则化，几乎都能在这里找到最初的影子。

二、回归与线性回归

2.1 什么是回归分析

在数理统计中，**回归分析（regression analysis）** 是确定多种变量之间相互依赖的定量关系的方法。

线性回归假设输出变量是若干输入变量的**线性组合**，并据此求解组合中的最优系数。在众多回归方法里，线性回归最容易拟合，估计结果的统计特性也最容易确定，因而应用最广。

在机器学习语境下，回归问题隐含了一个前提：**输入变量和输出变量都可以连续取值。**因此用线性回归模型，可以对任意输入给出对输出的估计。

2.2 “回归”一词的由来

1875 年，从事遗传问题研究的英国统计学家弗朗西斯·高尔顿想弄清父代与子代身高之间的关系。分析 1078 对父子的身高数据后，他发现散点图大致呈直线，即父亲身高与儿子身高正相关。

但正相关背后还藏着另一个现象：**矮个子父亲的儿子更可能比父亲高，高个子父亲的儿子更可能比父亲矮。**受表亲达尔文的影响，高尔顿把这个现象称为“**回归效应**”——大自然把人类身高的分布约束在相对稳定的水平，不至于两极分化。他给出了历史上第一个线性回归表达式：

$$y = 0.516x + 33.73$$

式中 y 和 x 分别代表以英寸为单位的子代与父代身高。这个式子今天看来平平无奇，但它第一次把“从数据中拟合规律”变成了可计算的数学问题。

> **新手提示：为什么父子身高一定是“回归”而不是“发散”**
>
> 如果高个子父亲的儿子总是更高、矮个子父亲的儿子总是更矮，不用几代人身高就会两极分化到离谱的程度。现实中身高分布长期稳定，说明存在向均值拉回的力量。这种“极端值向中间靠拢”的现象，正是回归一词的本义，也是今天“回归分析”这个名字的来源。

补充说明：回归与分类的划分标准不是“输出是不是数字”，而是**输出空间的类型。**身高、房价这类连续量对应回归；国籍、是否垃圾邮件这类有限离散集对应分类。同样是预测年龄，若输出“具体多少岁”就是回归，若输出“属于哪个年龄段”就是分类。一个任务可以被写成多种形式，选择哪一种取决于业务真正需要的信息粒度，以及标签数据的获取难度。

三、线性回归的数学形式

假定一个实例可以用列向量表示：

$$\mathbf{x} = (x_1; x_2; \ldots; x_n)$$

每个 x_i 代表实例在第 i 个属性上的取值。线性回归要习得一组参数 w_i（i = 0, 1, ..., n），使预测输出可以表示为以这组参数为权重的属性线性组合。引入常量 $x_0 = 1$，模型即

$$f(\mathbf{x}) = \mathbf{w}^{\mathrm{T}}\mathbf{x} = \sum_{i=0}^{n} w_i \cdot x_i$$

- 只有一个属性时，输入输出关系是二维平面上的一条直线；
- 属性较多时，得到 n+1 维空间上的一个**超平面（hyperplane）**，对应一个维度为 n 的线性子空间。

> **新手提示：$x_0 = 1$ 这个技巧**
>
> 把偏置项 b 写成 $w_0 \cdot x_0$（其中 x_0 恒为 1），就能把"w 的线性组合 + 偏置"统一成一个纯粹的向量内积。好处是公式更短、推导更整齐，编程实现时也只需在特征矩阵最前面补一列 1。

补充说明：这里的"线性"指的是**对参数 w 线性**，而不是对输入 x 线性。把 x 先做一组非线性变换 φ(x)（比如平方项、交叉项、正弦基），模型 $f(x) = w^{\mathrm{T}}\varphi(x)$ 依然是线性模型——因为它对 w 仍是线性的，仍可用最小二乘直接求解，却可以拟合弯曲的关系。这就是**基函数扩展（basis expansion）**，也是核方法的思想雏形：与其在原始空间里拟合非线性函数，不如把数据映射到另一个空间，在那里做线性拟合。

四、均方误差与最小二乘法

在训练集上确定系数 w_i 时，核心指标是预测输出 f(x) 与真实输出 y 之间的误差。线性回归用**均方误差（mean squared error, MSE）**来定义这个误差。

当模型是二维平面上的直线时，均方误差就是预测点与真实点之间距离平方的平均——单点的偏差对应两点间向量的 L_2 范数的平方。以使均方误差最小为目标的求解方法，就是**最小二乘法（least squares method）**：

$$\mathbf{w}^* = \arg\min_{\mathbf{w}} \sum_{k=1}^{m} \left(\mathbf{w}^{\mathrm{T}}\mathbf{x}_k - y_k\right)^2 = \arg\min_{\mathbf{w}} \sum_{k=1}^{m} \left\| y_k - \mathbf{w}^{\mathrm{T}}\mathbf{x}_k \right\|_2^2$$

式中每个 x_k 代表训练集中的一个样本，m 为样本总数。

在单变量线性回归中，最小二乘法的作用就是**找到一条直线，使所有样本的残差平方和最小**（残差是样本在输出方向上到直线的偏差）。

五、为什么最小二乘是合理的

讲到这儿问题就来了：凭什么"均方误差最小"的参数就是与训练样本最匹配的模型？

答案要从概率论里找。线性回归得到的是统计意义上的拟合结果，单变量情形下，可能每个样本点都没有恰好落在直线上。一种解释是：

- 回归结果能完美匹配**理想样本点**的分布；
- 但训练用的真实样本点是"理想样本点 + 噪声"的叠加，因而与回归模型产生偏差；
- 每个样本点上的噪声取值恰好等于 $y_k - f(x_k)$。

5.1 噪声假设

假定影响样本点的噪声服从均值为 0、方差为 σ^2 的正态分布（σ 读作 sigma，是标准差）。这意味着：

- 噪声等于 0 的概率密度最大；
- 幅度（无论正负）越大，出现的概率越小。

5.2 最大似然估计

在这种假设下，对参数 w 的推导可以用**最大似然估计（maximum likelihood estimation, MLE）**：在已知样本数据及其分布的条件下，找到使样本数据以最大概率出现的假设。

单个样本 x_k 出现的概率，实际上就是噪声等于 $y_k - f(x_k)$ 的概率：

$$p\left(y_k \mid \mathbf{x}_k; \mathbf{w}\right) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2\sigma^2}\left(y_k - \mathbf{w}^{\mathrm{T}}\mathbf{x}_k\right)^2\right]$$

样本相互独立，因此所有样本同时出现的概率是各自概率的乘积：

$$p\left(y_1, y_2, \ldots, y_m \mid \mathbf{X}; \mathbf{w}\right) = \prod_{k=1}^{m} \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2\sigma^2}\left(y_k - \mathbf{w}^{\mathrm{T}}\mathbf{x}_k\right)^2\right]$$

最大化这个乘积，等价于最大化它的对数——取对数不影响单调性，却能把连乘变成连加：

$$\log L(\mathbf{w}) = \sum_{k=1}^{m}\left[-\frac{1}{2}\log\left(2\pi\sigma^2\right) - \frac{1}{2\sigma^2}\left(y_k - \mathbf{w}^{\mathrm{T}}\mathbf{x}_k\right)^2\right]$$

其中前一项与 w 无关，可以丢掉；后一项带负号，最大化它等价于最小化

$$\sum_{k=1}^{m}\left(y_k - \mathbf{w}^{\mathrm{T}}\mathbf{x}_k\right)^2$$

这不就是最小二乘法的目标函数吗？

> **新手提示：这个结论说明了什么**
>
> 它说明：**在噪声服从零均值正态分布的前提下，从几何意义出发的最小二乘法，与从概率意义出发的最大似然估计完全等价。**这不是巧合——最小二乘之所以好用，根源就在于"噪声近似正态"这个在现实数据中相当普遍的假设。反过来看，如果噪声明显不是正态（比如含大量离群点），最小二乘就不再是最优选择，这也是稳健回归存在的理由。

补充说明：这个等价关系背后有一条更强的结论——**高斯—马尔可夫定理（Gauss-Markov theorem）**。它指出：只要噪声零均值、同方差、彼此不相关（**不要求正态**），最小二乘估计就是所有线性无偏估计中方差最小的那个，即 **BLUE（best linear unbiased estimator）**。正态假设的作用是让最小二乘同时成为最大似然解，并使得参数的检验统计量服从 t 分布与 F 分布；去掉正态假设，最小二乘依然是最优的线性无偏估计，只是不能直接做显著性检验了。

六、如何求解

6.1 单变量：求偏导

单变量线性回归的方程可以写成 $y = w_1x + w_0$。把表达式代入均方误差，分别对 w_1 和 w_0 求偏导，令两个偏导数都等于 0，解出的就是最优参数：

$$w_1 = \frac{\sum_{k=1}^{m} y_k\left(x_k - \frac{1}{m}\sum_{k=1}^{m} x_k\right)}{\sum_{k=1}^{m} x_k^2 - \frac{1}{m}\left(\sum_{k=1}^{m} x_k\right)^2}$$

$$w_0 = \frac{1}{m}\sum_{k=1}^{m}(y_k - w_1 x_k)$$

6.2 多元：矩阵形式

子代身高并非只由遗传决定，营养条件、生活环境都会产生影响。当样本涉及多个属性时，问题就变成**多元线性回归（multiple linear regression）**。

参数同样用最小二乘法估计，最优解同样由偏导数确定，但参与运算的元素从向量变成了矩阵。理想情况下最优参数为

$$\mathbf{w}^* = \left(\mathbf{X}^{\mathrm{T}}\mathbf{X}\right)^{-1}\mathbf{X}^{\mathrm{T}}\mathbf{y}$$

式中 X 由所有样本的转置共同构成，y 是全部真实输出组成的向量。

> **新手提示：这个公式长得很像"除法"**
>
> 在一维无截距的情形，最优解是 w = Σx_ky_k / Σx_k²，本质仍是"用 x 的平方和去除"。矩阵形式里没有除法，只能用**逆矩阵**代替，于是 $(X^TX)^{-1}$ 就承担了"除以"的角色。这也解释了它为什么要求 X^TX 可逆。

6.3 逆不存在时会怎样

上式只在矩阵 X^TX 的逆存在时成立。而在大量复杂任务中，**每个样本的属性数目甚至会超过训练样本总数**，此时解出的 w* 不唯一，具体选哪一个取决于学习算法的**归纳偏好**。

但不论用什么标准挑选，多个最优解并存这件事本身无法改变，这正是过拟合的温床。更麻烦的是：过拟合时，训练数据上毫厘之差的扰动，可能导致训练出的模型谬以千里，模型稳定性无从保证。

> **新手提示：为什么"属性多、样本少"特别危险**
>
> 想象用两个点去拟合一条直线——无数条直线都能穿过它们，你无法判断哪条更对。属性数超过样本数时，方程是欠定的，解空间是一整个超平面，模型可以把训练数据拟合得分毫不差，却对新样本毫无把握。这就是"维数灾难"的一种直观表现。

补充说明：正规方程需要计算矩阵逆，时间复杂度约为 $O(n^3)$，特征维度上万时不可接受；而且当 X^TX 接近奇异时，数值求逆会严重失真。此时改用**梯度下降**迭代逼近更实际：它的单步代价只与样本数成线性关系，还能处理数据分批到达的流式场景。工程上的选择很明确——特征维度低、数据能一次性装入内存时用正规方程，维度高或数据量大时用梯度下降。

七、正则化：岭回归与 LASSO

解决过拟合的常见做法是**正则化（regularization）**：在目标函数里添加额外的惩罚项。按惩罚项的不同，线性回归的正则化分为两类——**岭回归**与 **LASSO 回归**。

7.1 岭回归

岭回归又称"参数衰减"，20 世纪 40 年代由前苏联学者安德烈·季霍诺夫提出。当时机器学习尚未诞生，他提出这一方法主要是为了解决**矩阵求逆的稳定性**问题；这一思想后来被引入正则化，形成了今天的岭回归。

岭回归的实现方式，是在原始均方误差项之上添加一个待求解参数的**二范数项**：

$$J(\mathbf{w}) = \sum_{k=1}^{m}\left\|y_k - \mathbf{w}^{\mathrm{T}}\mathbf{x}_k\right\|_2^2 + \|\Gamma\mathbf{w}\|_2^2$$

其中的 Γ（读作 Gamma）被称为**季霍诺夫矩阵**，通常可以简化为一个常数乘以单位矩阵。

从最优化角度看，二范数惩罚项的作用是**优先选择范数较小的 w**：相当于在最小均方误差之外，额外加了一重关于最优解特性的约束，把解限制在高维空间内的一个球里。

效果上，岭回归相当于在最小二乘结果上做了缩放：每个参数的贡献被削弱，但**参数的数目并没有变少**（不会有系数被压成 0）。

补充说明：岭回归最大的工程价值在于**它总有唯一解。**把目标函数对 w 求导并令其为零，得到

$$\mathbf{w}^* = \left(\mathbf{X}^{\mathrm{T}}\mathbf{X} + \lambda\mathbf{I}\right)^{-1}\mathbf{X}^{\mathrm{T}}\mathbf{y}$$

由于 X^TX 半正定、加上 λI（λ > 0）后必定正定，这个矩阵**一定可逆。**于是在"属性数超过样本数"的欠定情形下，岭回归直接把一个不可解的问题变成了可解的问题——这正是季霍诺夫当年要解决的求逆稳定性问题。

7.2 LASSO 回归

LASSO 的全称是"最小绝对缩减和选择算子"（Least Absolute Shrinkage and Selection Operator），由加拿大统计学家罗伯特·提布什拉尼于 1996 年提出。

与岭回归不同，LASSO 选择的惩罚项是**一范数**：

$$J(\mathbf{w}) = \sum_{k=1}^{m} \left\| y_k - \mathbf{w}^{\mathrm{T}}\mathbf{x}_k \right\|_2^2 + \lambda \| \mathbf{w} \|_1$$

其中的 λ（希腊字母，读作 lambda）是一个常数，用来控制惩罚强度：λ 越大，惩罚越重。

LASSO 最鲜明的特点是**稀疏性**：它会把一部分参数的贡献直接压成 0，使 w 中非零元素的数目远小于原始特征数目。

这可以看作**奥卡姆剃刀原理**的一种实现：主要矛盾和次要矛盾同时存在时，优先解决主要矛盾。饮食、环境、运动都会影响身高，但决定性因素显然在染色体上。

> **新手提示：为什么 L1 能压出 0，L2 不能**
>
> 几何上，L2 惩罚的等高线是圆的，最优解一般落在圆周的平滑处，坐标很少恰好为 0；L1 惩罚的等高线是**菱形**，顶点恰好落在坐标轴上，而最优点倾向于卡在顶点，于是某些坐标被压成 0。这个"菱形有尖角"的直观解释，是理解稀疏性最省力的方式。

稀疏性还有一个实际好处——**可解释。**当几百个特征里只有十几个系数非零时，可以直接读出"哪几个因素真正影响结果"，这在医疗、金融等需要给出理由的场景中往往比精度更重要。反过来，岭回归给出的是一组普遍偏小的系数，虽然预测可能更稳，却无法回答"到底哪几个因素关键"。两类正则化因此对应两类需求：重预测选岭回归，重解释选 LASSO。稀疏性在数据压缩、信号处理等领域同样应用广泛。

7.3 两者的概率视角

前面已经从概率角度说明了最小二乘与最大似然的关系，岭回归和 LASSO 也能这样解释：

方法	惩罚项	对应的先验假设	估计方式
岭回归	二范数	w_i 服从正态先验分布	最大后验估计
LASSO	一范数	w_i 服从拉普拉斯先验分布	最大后验估计

无论哪种，作用都是通过惩罚项抑制过拟合，**以训练误差的上升换取测试误差的下降。**

补充说明：把两种惩罚项同时加入，就得到**弹性网络（elastic net）**：

$$J(\mathbf{w}) = \sum_{k=1}^{m} \left\| y_k - \mathbf{w}^{\mathrm{T}} \mathbf{x}_k \right\|_2^2 + \lambda_1 \| \mathbf{w} \|_1 + \lambda_2 \| \mathbf{w} \|_2^2$$

它在特征高度相关时比 LASSO 更稳定——LASSO 面对一组强相关特征时往往只随机保留其中一个，弹性网络则会成组地保留。代价是多了一个需要调节的超参数。

八、从线性回归到广义线性模型

8.1 连接函数与指数族

线性回归的预测值 f(x) = w^Tx 可以取任意实数，但很多问题的输出被限制在特定范围内：概率必在 0 与 1 之间，计数必须是非负整数。直接套用线性回归，会预测出 −0.3 的概率或 2.7 次点击这类无意义的结果。

广义线性模型（generalized linear model, GLM） 的处理办法是：保留线性预测器 η = w^Tx 不动，再通过一个**连接函数（link function）** g 把它映射到输出的合法范围上：

$$g\left(\mathbb{E}\left[y \mid \mathbf{x}\right]\right) = \mathbf{w}^{\mathrm{T}} \mathbf{x}$$

反过来写就是

$$\mathbb{E}\left[y \mid \mathbf{x}\right] = g^{-1}\left(\mathbf{w}^{\mathrm{T}} \mathbf{x}\right)$$

这样就把"线性"从**输出层**移到了**预测器层**：模型对参数仍然是线性的，因此最大似然、迭代加权最小二乘等求解方法依然适用；而输出可以服从任意指数族分布。

8.2 逻辑回归与泊松回归

三种最常见的情形，区别只在分布假设与连接函数：

模型	输出类型	分布假设	连接函数
线性回归	连续实数	正态分布	恒等函数 g(μ) = μ
逻辑回归	二值 0/1	伯努利分布	对数几率 g(μ) = ln(μ/(1−μ))
泊松回归	非负计数	泊松分布	对数函数 g(μ) = ln μ

从这里可以看出，逻辑回归并不是一个独立的新算法，而是线性回归在伯努利分布下的推广——这也解释了它为什么叫"回归"却用来做分类。

补充说明：GLM 的统一框架带来一个实用推论：同一套最大似然估计与显著性检验流程，可以原封不动地用在三种模型上。在统计软件里，三者共用同一个调用入口，只是换一个分布族参数。理解这一层统一性，比记住三个独立公式更有价值。

四个常见误区

- **"最小二乘不需要假设"**——它要求误差零均值、同方差、互不相关；否则估计仍可能无偏，但不再是最优的，标准误也会算错。
- **"R^2 高就说明模型对"**——R^2 只说明拟合了样本内的方差，加变量一定会让它上升。模型是否正确要看残差结构、外推表现与业务合理性。
- **"多重共线性会让预测失效"**——共线性主要破坏的是系数的可解释性（系数不稳定、符号反常），对预测精度的影响往往有限。
- **"正则化只是防止过拟合"**——它还改善了病态问题的数值稳定性，并在特征远多于样本时让解变得唯一。

九、要点回顾

1. 线性回归假设输出变量是若干输入变量的线性组合，并求解组合中的最优系数。
2. 引入 $x_0 = 1$ 后，模型可以写成纯粹的向量内积形式 w^Tx；属性多时对应高维空间中的超平面。
3. 最小二乘法以均方误差最小为目标求解参数；当噪声服从零均值正态分布时，它与最大似然估计等价。
4. 单变量可用偏导数为 0 直接解出解析式；多元的最优解为 $(X^TX)^{-1}X^Ty$，仅在逆存在时成立。
5. 属性数超过样本数时最优解不唯一，极易过拟合且模型不稳定。
6. 岭回归添加二范数惩罚项，缩小参数但不产生零；LASSO 添加一范数惩罚项，可把部分参数压成 0，实现特征选择。
7. 岭回归与 LASSO 分别对应正态先验与拉普拉斯先验下的最大后验估计；两者结合得到弹性网络。
8. 广义线性模型保留线性预测器、用连接函数把输出映射到合法范围，逻辑回归与泊松回归都是它的特例。

十、名词汇总

名称	英文全称	英文缩写	简短介绍
线性回归	Linear Regression	LR	假设输出为输入的线性组合并求解最优系数的回归方法
回归分析	Regression Analysis	—	确定多种变量之间相互依赖的定量关系的统计方法
回归效应	Regression Effect	—	极端取值在下一代向均值靠拢的现象，是“回归”一词的来源
超平面	Hyperplane	—	高维空间中维度比原空间少一维的线性子空间
均方误差	Mean Squared Error	MSE	预测值与真实值之差的平方的平均，衡量回归拟合优劣
最小二乘法	Least Squares Method	LS	以均方误差最小为目标求解参数的估计方法
最大似然估计	Maximum Likelihood Estimation	MLE	选择使已观测数据出现概率最大的参数取值
多元线性回归	Multiple Linear Regression	MLR	输入包含多个属性的线性回归
归纳偏好	Inductive Bias	—	学习算法在等价解之间做选择的固有倾向
正则化	Regularization	—	在目标函数中加入惩罚项以抑制过拟合的技术
岭回归	Ridge Regression	—	以参数二范数为惩罚项的线性回归，又称参数衰减

名称	英文全称	英文缩写	简短介绍
季霍诺夫矩阵	Tikhonov Matrix	Γ	岭回归中作用于参数向量的惩罚矩阵，常简化为常数
LASSO 回归	Least Absolute Shrinkage and Selection Operator	LASSO	以参数一范数为惩罚项、可产生稀疏解的线性回归
稀疏性	Sparsity	—	解向量中大量分量为零的性质
拉普拉斯分布	Laplace Distribution	—	尖峰重尾的连续分布，对应 LASSO 的先验假设
奥卡姆剃刀	Occam's Razor	—	在效果相近的假设中优先选择更简单的那个的原则
基函数扩展	Basis Expansion	—	对输入做非线性变换后再做线性拟合的方法
高斯—马尔可夫定理	Gauss-Markov Theorem	—	噪声零均值同方差且不相关时，最小二乘为最佳线性无偏估计
最佳线性无偏估计	Best Linear Unbiased Estimator	BLUE	在所有线性无偏估计中方差最小的估计量
弹性网络	Elastic Net	EN	同时加入一范数与二范数惩罚项的正则化回归
广义线性模型	Generalized Linear Model	GLM	通过连接函数将线性预测器映射到输出合法范围的模型族
连接函数	Link Function	—	把输出期望变换为线性预测器的可逆函数
泊松回归	Poisson Regression	—	以对数函数为连接函数、用于非负计数数据的广义线性模型