朴素贝叶斯：贝叶斯决策、条件独立与平滑

读前须知

- **前置**：条件概率、全概率公式与贝叶斯公式。
- **这一篇的位置**：第一个纯概率的分类器。它把"分类"翻译成"在已知特征下哪个类别的后验最大"。
- **读完能做什么**：写出朴素贝叶斯的分类决策式；说清"条件独立"到底省掉了多少计算量；用拉普拉斯平滑处理训练集里没出现过的特征。

一、贝叶斯框架下的分类

1.1 从回归到分类

线性回归解决的是"输入连续、输出也连续"的回归问题。接下来要讲的算法，解决的是**分类问题**——把连续取值的输入映射为离散取值的输出。

分类的依据是数据的属性。**朴素贝叶斯方法（naive Bayes）** 假定样本的不同属性满足**条件独立性假设**，并在此基础上应用贝叶斯定理完成分类。它的基本思想很直接：分别计算待分类样本属于每个类别的后验概率，取后验概率最大的类别作为输出。

假设训练数据的属性由 n 维随机向量 X 表示，分类结果用随机变量 Y 表示。那么 X 与 Y 的统计规律可以用**联合概率分布** P(X, Y) 描述，每一个具体样本 (x_i, y_i) 都可以由 P(X, Y) 独立同分布地产生。

朴素贝叶斯的出发点就是这个联合分布。根据条件概率的性质：

$$P(X,Y) = P(Y)\cdot P(X \mid Y) = P(X)\cdot P(Y \mid X)$$

由此得到两个关键量：

- **类先验概率（prior）** P(Y)：每个类别出现的概率；
- **类条件概率**（也称**似然**，likelihood）P(X|Y)：给定类别下，不同属性取值出现的概率。

1.2 先验容易，似然很难

先验概率很好算：统计各类别样本的数目即可。

但似然概率受属性取值数目的影响，估计起来非常困难。假设每个样本只有 2 个属性、每个属性有 100 种取值，那么对每一个类别，要估计的条件概率数目就是

$$100^2 = 10000$$

若样本有 100 个属性，则需要估计 100^{100} 个条件概率——这是一个远超宇宙原子总数的天文数字。

参数这么多，要精确估计似然概率就需要海量数据，而现实中根本拿不出这么多数据。**这就是朴素贝叶斯要解决的核心矛盾。**

补充说明：这里的困难本质上是**维数灾难**在概率估计上的具体表现。参数数目随属性个数呈指数增长，而样本量只能线性增长，两者永远追不上。工程上的出路只有两条：要么降低参数数目（引入假设，即朴素贝叶斯），要么降低估计难度（假设分布形式、只估分布参数）。这两种思路恰好对应了后续的两条路线：贝叶斯方法走假设简化，线性模型走参数化——前者由本章的朴素贝叶斯代表，后者由 010 的逻辑回归代表。

二、条件独立性假设："朴素"在哪

2.1 假设的内容

条件独立性假设保证：**所有属性相互独立、互不影响，每个属性独立地对分类结果发生作用。**

于是类条件概率可以拆成属性条件概率的乘积：

$$P(\mathbf{X}=\mathbf{x} \mid Y=c)=P\left(X^{(1)}=x^{(1)}, X^{(2)}=x^{(2)}, \ldots, X^{(n)}=x^{(n)} \mid Y=c\right)=\prod_{j=1}^{n} P\left(X^{(j)}=x^{(j)} \mid Y=c\right)$$

这正是"朴素"（naive）二字的由来：**用必要的假设把难解的问题简化成可算的问题。**

2.2 假设带来的两个好处

一是参数数量从指数级降到线性级。 原本要估计 100^{100} 个条件概率，现在只需为每个属性估计 100 个，总计 100n 个。

二是样本利用率提高了 n 倍。 没有这个假设时，分类结果 y 只能刻画其所有属性 $x_1, x_2, \ldots, x_n$ 形成的整体，只有属性取值完全相同的样本才能放在一起评价。属性多、数据少时，要让 n 个属性同时取到相同特征，实在需要些运气。

有了这个假设，分类结果 y 相当于被"复用"了 n 次：同一个样本既可以用来刻画 x_1，也可以用来刻画 x_n。分析每个属性的每个取值对分类结果的影响时，就有了 n 倍的样本支撑。

> **新手提示：为什么说这是"样本复用"**
>
> 原本要研究"肤色浅 + 眼小 + 鼻长 + 颧骨高 → 韩国人"，必须找到四项全都一致的样本，稀有到几乎找不到；拆开之后只需分别研究"眼小 → 韩国人""鼻长 → 韩国人"，每个样本都能在各自的问题上发挥作用。这就是参数共享带来的统计效率提升。

2.3 这个假设其实很强

必须说明：**属性条件独立性假设是个相当强的假设。**

以银行发放房贷为例。是否放贷本质上是个二分类问题，需要考虑申请人的年龄、工作岗位、婚姻状况、收入水平、负债情况等因素。这些因素显然不独立——中年人的收入通常高于青年人，已婚者的负债水平通常也高于未婚者。

因此在实际应用中，这个假设会导致数据被过度简化，分类性能会受些影响。但它带来的数学便利极大降低了计算复杂度，**性能上的部分折中也就并非不可接受。**

补充说明：文本分类是条件独立假设"看起来不合理却异常有效"的最佳例证。一篇文章里"机器"与"学习"两个词几乎总是一起出现，明显不独立；但朴素贝叶斯在垃圾邮件过滤、情感分析上依然表现出色。原因有两层：一是词频特征是**弱相关**的，相关性与分类信号相比很小；二是高维稀疏场景下，假设带来的参数缩减收益远大于偏差带来的损失。这也解释了为什么深度学习时代朴素贝叶斯仍未退出工程实践——它训练成本极低、增量更新方便，适合作为基线模型和快速原型。

三、分类决策规则

有了训练数据，先验概率 P(Y) 和似然概率 P(X|Y) 就成为已知条件，可用来求后验概率 P(Y|X)。

对给定的输入 x，朴素贝叶斯用贝叶斯定理求后验概率，并把后验概率最大的类作为输出：

$$y=\arg\max_{c_k} P\left(Y=c_k\right) \prod_{j} P\left(X^{(j)}=x^{(j)} \mid Y=c_k\right)$$

> **新手提示：分母 P(X) 去哪了**
>
> 由贝叶斯定理，后验正比于"先验 × 似然"再除以 P(X)。而 P(X) 对所有类别都是同一个数，比较大小的时候不影响结果，所以直接省掉。这也是朴素贝叶斯计算量小的原因之一——只需要算分子。

3.1 连续属性怎么办

如果属性是连续值，“取某个具体值的概率”没有意义。通常的做法是**假定属性数据服从正态分布**，再根据每个类别下的训练数据，算出正态分布的均值与方差，用概率密度代替概率。

3.2 概率连乘会下溢

属性维度高时，几十个小于 1 的数连乘，结果会迅速逼近 0，浮点数直接表示不了。工程上的解决办法是**取对数**，把连乘变成连加：

$$\log P\left(Y=c_k\right)+\sum_j \log P\left(X^{(j)}=x^{(j)} \mid Y=c_k\right)$$

log 是单调递增的，**取对数不改变最大值出现在哪个类**，却避开了下溢。

补充说明：对数化还有一个实际好处——加法比乘法更适合并行与增量计算。在流式场景下，每来一个新样本只需把它的对数似然加到累加器上，无需重新遍历历史数据。另外，标准实现会对每个特征类的对数概率做归一化，防止某一类因样本多而系统性占优，这一细节在多分类不平衡数据上影响明显。

四、为什么后验最大化就是期望风险最小

从模型最优化角度看，朴素贝叶斯是平均意义上预测能力最优的模型，即**使期望风险最小化。**

期望风险（expected risk） 是风险函数的数学期望，度量的是平均意义下模型预测的误差特性，可视为单次预测误差在联合分布 P(X, Y) 上的期望。

当以“分类错误的实例数”作为误差时，期望风险恰好等于

$$R(f)=1-P\left(Y=f(X) \mid X\right)$$

要让 R(f) 最小，就要让 P(Y=f(X)|X) 最大。于是**后验概率最大化等价于期望风险最小化。**

> **新手提示：这一步在说什么**
>
> 说白了就是：每次预测时选概率最大的那个类别，长期来看出错次数最少。这是贝叶斯决策论最基本的一条结论，朴素贝叶斯不过是它在“属性独立”假设下的具体实现。

补充说明：把风险函数从“错误个数”换成其他代价，结论依然成立，只是阈值会变——这就是**代价敏感学习（cost-sensitive learning）**。例如漏诊的代价是误诊的 10 倍时，最优决策不再是“概率超过 0.5 就判正例”，而是按代价比例下调阈值。这条推广在医疗、风控领域几乎是必备设置。

五、零概率问题与拉普拉斯平滑

受训练数据规模限制，某些属性的取值可能从未与某个类别同时出现，这会导致属性条件概率为 0。而概率连乘中只要有一项为 0，整个后验就是 0，分类必然出错。

还以房贷为例：如果训练集里没有“年龄大于 60 且获批贷款”的样本，那么一位退休人员来申请时，哪怕他坐拥百亿身家，朴素贝叶斯也会因为后验概率为零而将他拒绝。

为避免训练集未曾覆盖的取值污染结果，计算时需要加一步**拉普拉斯平滑（Laplace smoothing）**：在分子上加一个较小的修正量，在分母上加“修正量 × 对应的取值数目”——先验概率用类别数 K，属性条件概率用该属性的取值数 S_j。

先验概率的平滑：

$$P\left(Y=c_k\right)=\frac{\sum_{i=1}^N I\left(y_i=c_k\right)+\lambda}{N+K\lambda}$$

条件概率的平滑：

$$P\left(X^{(j)}=a_{jl}\mid Y=c_k\right)=\frac{\sum_{i=1}^{N} I\left(x_i^{(j)}=a_{jl},\, y_i=c_k\right)+\lambda}{\sum_{i=1}^{N} I\left(y_i=c_k\right)+S_j\lambda}$$

式中 N 是样本总数，K 是类别总数，S_j 是第 j 个属性的取值数目，I(·) 是示性函数（条件成立取 1，否则取 0），λ（希腊字母，读作 lambda）是平滑系数——取 1 时就是标准的拉普拉斯平滑。

这样既保证了概率的基本性质（各概率非负、总和为 1），又避免了零概率的影响。训练数据量大时，修正量的影响可以忽略不计。

补充说明：拉普拉斯平滑并不是一个临时应付的工程技巧，它对应一个明确的贝叶斯解释：在多项式分布上引入均匀的**狄利克雷先验（Dirichlet prior）**，再做最大后验估计。取 λ = 1 相当于先验认为每种取值已经各出现过一次。这也意味着 λ 的取值本质上是在调节先验强度：λ 越大，先验越强势，估计越保守；样本越多，先验的影响越弱。

六、假设不成立，为什么依然好用

这里有个耐人寻味的疑问：属性条件独立看起来像空中楼阁，为什么朴素贝叶斯在绝大多数分类任务中依然表现优良？

6.1 只要排序对，值不精确也没关系

当指标是"分类是否正确"时，只要朴素贝叶斯能找到最大的后验概率，就能给出正确分类。**最大后验概率的估计值是否精确，反而没那么重要。**

举例：某实例在两个类别上的真实后验概率是 0.9 和 0.1，朴素贝叶斯估出来可能是 0.6 和 0.4。数值差得远，但大小关系没变，依据这个粗糙估计分类，结果依然正确。

6.2 相关性可能相互抵消

一种可能的解释是：给定训练集上，两个属性之间可能具有相关性，但这种相关性**在每个类别上都以同样的程度体现**。这种情况违背了条件独立性假设，却不会破坏分类的最优性。

即使相关性在不同类别上分布不均匀也没关系。只看两个单独属性，它们之间可能存在强依赖并影响分类结果；但当**所有属性之间的依赖关系一起发挥作用时，它们可能相互抵消**，不再影响分类。

简而言之：影响朴素贝叶斯分类的，是**所有属性之间的依赖关系在不同类别上的分布**，而不仅仅是依赖关系本身。

补充说明：这个现象在理论上有一个更精确的名字——**后验概率的相对大小对估计误差不敏感**。分类只需要正确排序，而排序所需的精度远低于概率值的精度，这与回归任务截然不同。因此评估分类器时看混淆矩阵、看 F1，而不去看概率输出的绝对偏差；只有当概率值本身要被用作决策依据（如风控定价）时，才需要额外的**概率校准（probability calibration）**。

七、半朴素贝叶斯与典型应用

7.1 独依赖估计

属性条件独立性假设确实会影响性能。为了放宽它，研究者提出了**半朴素贝叶斯分类器（semi-naive Bayes classifier）**：考虑**部分属性之间的依赖关系**，既保留了较强的相关性，又不必计算完整的联合概率分布。

常用做法是建立**独依赖关系（one-dependent estimator, ODE）**：假设每个属性除类别之外，最多只依赖一个其他属性。根据依赖关系的确定方式不同，衍生出三类典型方法：

方法	依赖关系的确定方式	特点
SPODE	人为指定每个属性的超父属性	简单但依赖先验知识
TAN	用最大权重生成树从数据中学习依赖结构	精度高、需额外训练步骤

方法	依赖关系的确定方式	特点
AODE	对多个超父候选做集成平均	稳定、计算开销最大

7.2 典型应用场景

朴素贝叶斯在文本领域应用最广：

- 根据关键词判断一封邮件是否为垃圾邮件（二分类）；
- 判断社交网络账号是活跃用户还是僵尸粉；
- 信息检索中的文本分类与相关度判断。

以朴素贝叶斯为代表的贝叶斯分类方法，策略可以概括为一句话：**根据训练数据计算后验概率，基于后验概率选择最佳决策。**

补充说明：半朴素贝叶斯与逻辑回归正好代表了两种不同的放宽思路。半朴素贝叶斯保持生成式建模，只在属性依赖图上做局部修正；逻辑回归则彻底放弃生成假设，直接对 P(Y|X) 参数化。前者在小样本下更稳健，后者在大样本下更准——这正是 007 中生成方法与判别方法对比的一个具体回响。

四个常见误区

- **"条件独立不成立，模型就没用"**——假设几乎从不严格成立，但分类只要求"最大的那个后验别被排错"。实际文本分类、垃圾邮件过滤中，它依然是很强的基线。
- **"朴素贝叶斯输出的概率可以直接信"**——由于独立性假设过强，它的概率估计往往过度自信，校准很差。用它的排序（选最大的类）比用它的具体数值更可靠。
- **"平滑系数越大越稳"**——α 过大会把特征的作用抹平，退化成只看先验；α 需要通过验证集选择。
- **"朴素贝叶斯只能处理离散特征"**——高斯朴素贝叶斯、伯努利朴素贝叶斯、多项式朴素贝叶斯分别对应连续、二值、计数三类特征。

八、要点回顾

1. 朴素贝叶斯利用后验概率选择最佳分类，后验概率由贝叶斯定理求解。
2. 它假定所有属性相互独立，从而把类条件概率转化为属性条件概率的乘积，把参数数量从指数级降到线性级。
3. 在所有类别上后验概率的分母 P(X) 相同，比较时可以直接忽略。
4. 后验概率最大化等价于以错误率为指标的期望风险最小化。
5. 零概率会让整个后验归零，需要用拉普拉斯平滑处理。
6. 影响分类效果的是属性间依赖关系在不同类别上的分布，而不只是依赖关系本身，这解释了强假设下依然好用的现象。
7. 半朴素贝叶斯通过引入部分属性依赖，在假设强度与计算复杂度之间取折中。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
朴素贝叶斯	Naive Bayes	NB	基于贝叶斯定理与属性条件独立性假设的分类方法
先验概率	Prior Probability	—	观测到数据之前，各类别出现的概率
后验概率	Posterior Probability	—	观测到数据之后，样本属于各类别的概率

名称	英文全称	英文缩写	简短介绍
似然	Likelihood	—	给定类别时观测到该属性组合的概率
条件独立性假设	Conditional Independence Assumption	—	假定各属性在给定类别下相互独立
类条件概率	Class-Conditional Probability	—	给定类别时属性取值的概率分布
期望风险	Expected Risk	—	单次预测误差在联合分布上的数学期望
拉普拉斯平滑	Laplace Smoothing	—	在概率估计的分子分母上加修正量以消除零概率
示性函数	Indicator Function	$I(\cdot)$	条件成立取 1、不成立取 0 的函数
半朴素贝叶斯	Semi-Naive Bayes	—	允许部分属性之间存在依赖的贝叶斯分类方法
独依赖估计	One-Dependent Estimator	ODE	假设每个属性最多依赖一个其他属性的半朴素贝叶斯方法
超父属性	Super-Parent	—	独依赖结构中被其他属性共同依赖的那个属性
SPODE	Super-Parent One-Dependent Estimator	SPODE	人为指定超父属性的独依赖分类器
TAN	Tree-Augmented Naive Bayes	TAN	用最大权重生成树学习依赖结构的独依赖分类器
AODE	Averaged One-Dependent Estimator	AODE	对多个超父候选做集成平均的独依赖分类器
贝叶斯定理	Bayes' Theorem	—	由先验与似然计算后验的条件概率公式
代价敏感学习	Cost-Sensitive Learning	—	按不同错误的实际代价调整决策阈值的方法
狄利克雷先验	Dirichlet Prior	—	定义在单纯形上的分布，是多项分布参数的共轭先验
概率校准	Probability Calibration	—	使模型输出的概率值与真实频率一致的修正过程
生成模型	Generative Model	—	学习联合概率分布、再据此推断后验的建模方式