逻辑回归：对数几率、最大似然与 Softmax

读前须知

- **前置**：Sigmoid 函数与最大似然估计；会求对数即可。
- **这一篇的位置**：分类任务的基准模型，也是神经网络最后一层的标准组件。
- **读完能做什么**：从对数几率推出 Sigmoid；写出交叉熵损失并说清它为什么不是平方误差；把二分类自然推广到 Softmax 多分类。

一、顶着“回归”名号的分类器

朴素贝叶斯是生成模型的代表：先构造联合概率分布 P(X, Y)，再据此分类。如果换一种思路，转而用判别模型解决分类问题，得到的算法就是**逻辑回归（logistic regression）**。

它虽然顶着“回归”的名号，解决的却是实打实的**分类问题**。之所以叫这个名字，是因为它来源于对线性回归的改进——把连续预测值“压缩”成离散标记。

二、从线性回归到逻辑回归

2.1 引入单调可微函数

通过引入一个单调可微函数 g(·)，线性回归模型可以推广为

$$y = g^{-1}\left(\mathbf{w}^{\mathrm{T}}\mathbf{x}\right)$$

这样就把线性回归的连续预测值，与分类任务的离散标记联系了起来。当 g(·) 取成**对数几率函数**的形式时，线性回归就变成了逻辑回归。

在最简单的二分类问题中，标记可以抽象为 0 和 1，因此线性回归的实值输出需要映射为二进制结果。

2.2 Sigmoid 函数

逻辑回归中用来完成这一映射的，是**对数几率函数**，也叫 **Sigmoid 函数**：

$$y = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-\mathbf{w}^{\mathrm{T}}\mathbf{x}}}$$

它的形状是一条平滑的 S 形曲线，把整个实数轴映射到 (0, 1) 区间。

2.3 为什么选它

选择对数几率函数，是因为它具备几项很好的性质。

第一，输出范围天然合适。 它把线性回归从负无穷到正无穷的输出，压缩到 (0, 1) 之间，正好符合“概率”的取值范围，也符合对二分类任务的直观感觉。

第二，自带一个清晰的分界点。 当线性回归结果 z = 0 时，逻辑回归输出 y = 0.5：

- z > 0 时 y > 0.5，判为正例；
- z < 0 时 y < 0.5，判为反例。

第三，可解释性好。 它在线性回归的“得分”和逻辑回归的“概率”之间，建立了一个平滑而单调的桥梁。

> **新手提示：Sigmoid 为什么长这样**

> 注意它的一个漂亮性质：导数恰好等于 y(1 − y)。这让梯度计算异常简洁，也是它在神经网络时代依然活跃的原因之一。另外，Sigmoid 的输出可以理解为"指数族分布下的自然参数变换"，并不是随手挑的函数。

2.4 几率与对数几率

这种可解释性还可以从数学上进一步诠释。

如果把对数几率函数的结果 y 视为样本 x 作为**正例**的可能性，那么 1 − y 就是它作为**反例**的可能性。两者的比值

$$\frac{y}{1-y}, \qquad 0 < \frac{y}{1-y} < +\infty$$

称为**几率（odds）**，体现的是样本作为正例的相对可能性。

对几率取对数，并把 Sigmoid 的表达式代入，可得

$$\ln \frac{y}{1-y} = \mathbf{w}^{\mathrm{T}}\mathbf{x} + b$$

由此可见：**逻辑回归用线性回归去拟合的是"对数几率"。**也就是把"正例与反例可能性之比的对数"设成了输入的线性函数。这正是它名字里"逻辑"（logistic，对数几率）的由来。

> **新手提示：几率和对数几率到底在描述什么**
>
> 几率 3:1 意味着"正例可能性是反例的 3 倍"。几率取对数后取值范围从 (0, +∞) 变成 (−∞, +∞)，正好与线性函数的输出范围对齐，于是才可以用线性模型去拟合。这一步变换，是把"有界概率"转化为"无界实数"的关键。

补充说明：对数几率是广义线性模型中的**规范连接函数（canonical link）**。所谓规范，是指它在数学上恰好是伯努利分布的自然参数，这使得逻辑回归的损失函数是凸的、梯度形式极简。相比之下，若改用其他函数（如直接对概率线性建模的线性概率模型），预测值会超出 [0, 1]，且最小二乘解不再等价于最大似然解。选择哪一个连接函数，本质上是在"可解释的凸优化"与"其他性质"之间做权衡。

三、模型的条件概率形式

归根结底，逻辑回归模型由条件概率分布表示：

$$p(y=1 \mid \mathbf{x}) = \frac{e^{\mathbf{w}^{\mathrm{T}}\mathbf{x}+b}}{1+e^{\mathbf{w}^{\mathrm{T}}\mathbf{x}+b}}$$

$$p(y=0 \mid \mathbf{x}) = \frac{1}{1+e^{\mathbf{w}^{\mathrm{T}}\mathbf{x}+b}}$$

对给定实例，逻辑回归比较两个条件概率值的大小，把实例划分到概率较大的那一类。

补充说明：逻辑回归输出的数值虽然形式上在 (0, 1) 之间，但它**不一定是真实概率。**当特征与标签的关系近似线性时，输出接近真实频率；当模型设定有偏或数据不平衡时，输出会系统性偏移。因此以逻辑回归的概率作风险定价前，常需先做 Platt 缩放或等渗回归做校准。相反，若只用它做正负例判别，直接比大小即可，无需校准。

四、参数学习：最大似然

学习时，逻辑回归在给定训练集上应用**最大似然估计**确定参数：让每个样本属于其真实标记的概率最大化，以此确定 w 的最优值。

4.1 似然函数

每个样本的输出 y_i 服从两点分布，且样本之间相互独立，于是似然函数为

$$L(\mathbf{w} \mid \mathbf{X}) = \prod_{i=1}^{N} [p(y=1 \mid \mathbf{x}_i; \mathbf{w})]^{y_i} \cdot [1 - p(y=1 \mid \mathbf{x}_i; \mathbf{w})]^{1-y_i}$$

这个式子的构造很巧妙：当 $y_i = 1$ 时只保留第一项，当 $y_i = 0$ 时只保留第二项——一个式子同时覆盖了两种情况。

4.2 取对数并化简

对似然取对数，把乘积变成求和：

$$\log L(\mathbf{w} \mid \mathbf{X}) = \sum_{i=1}^{N} y_i \log [p(y=1 \mid \mathbf{x}_i; \mathbf{w})] + (1-y_i) \log [1 - p(y=1 \mid \mathbf{x}_i; \mathbf{w})]$$

由于 y_i 只能取 0 或 1，上式两项中每次只有一项非零。把条件概率的对数几率形式代入并化简，得到

$$\log L(\mathbf{w} \mid \mathbf{X}) = \sum_{i=1}^{N} \left[y_i \cdot (\mathbf{w}^{\mathrm{T}} \mathbf{x}_i) - \log \left(1 + e^{\mathbf{w}^{\mathrm{T}} \mathbf{x}_i} \right) \right]$$

4.3 怎么求这个最优化问题

寻找上式的最大值，就是以对数似然函数为目标函数的最优化问题。通常用**梯度下降法**或**拟牛顿法**求解。

> **新手提示：这个式子其实就是交叉熵**
>
> 把上式取负号再除以 N，得到的正是二分类的**交叉熵损失**。所以“逻辑回归用交叉熵损失训练”和“逻辑回归做最大似然估计”是同一件事的两种说法。这条联系在深度学习里非常重要——分类模型几乎统一使用交叉熵，根源就在这里。

补充说明：由于对数似然是凹函数，逻辑回归的优化问题是**凸优化**，不存在局部最优陷阱，梯度下降一定能收敛到全局最优。这与神经网络的多峰损失曲面形成鲜明对比。此外，牛顿法与它的变体（如 BFGS）因为利用了二阶信息，迭代次数远少于梯度下降，计算量主要花在 Hessian 矩阵上；特征维度不高时优先选拟牛顿法，维度很高时则用 L-BFGS 或小批量梯度下降。

4.4 信息论视角

当训练数据是从全体数据中均匀抽取、且数量较大时，上面的结果还能用一种信息论方式解释：

对数似然函数的最大化，等价于待求模型与训练数据的经验分布之间 KL 散度的最小化，也就是交叉熵最小化。

这意味着，最优估计对参数做出的额外假设是最少的。这与**最大熵原理**不谋而合：在所有符合事实的模型中，选那个最“不偏不倚”的。

补充说明：这一视角把逻辑回归与另一类模型直接联系了起来。若把“符合事实”具体化为“满足训练集上的特征期望”，用最大熵原理推导出的模型就是**最大熵模型**，而它在二分类情形下的解正是逻辑回归。换言之，逻辑回归可以从两条完全不同的路径得到：一条是判别式建模加最大似然，另一条是最大熵原理加约束优化。两条路汇到同一个解，是这个模型最耐人寻味的地方。

五、判定边界

从数学角度看，线性回归与逻辑回归的渊源来自非线性的对数似然函数；从特征空间的角度看，两者的区别则在于**判定边界（decision boundary）** 的变化。

判定边界可以类比为棋盘上的楚河汉界，边界两侧分别对应不同类型的数据。

以最简单的二维平面直角坐标系为例：

- 受模型形式限制，**线性回归**只能得到**直线**形式的判定边界；
- **逻辑回归**在特征层面依然线性，Sigmoid 只改变输出的概率解释、不改变边界的形状：p=0.5 的等值面仍是一个超平面（二维即直线）；若引入特征的高阶组合，边界才能推广为**曲线**，完成更精细的分类。

> **新手提示：逻辑回归的边界为什么是直线**
>
> 逻辑回归的判定规则是比较 p(y=1|x) 与 0.5，等价于判断 $w^Tx + b$ 与 0 的大小——这条等式在特征空间里正是一个超平面。所以**逻辑回归本身是线性分类器**；要得到曲线边界，必须靠人工构造多项式特征或使用核方法，而不是模型自带的能力。

补充说明：这条"边界一定是超平面"的结论，也适用于感知机、线性支持向量机等一切线性分类器。它们的区别不在边界形状，而在**怎么选边界**：感知机只要分对就行，解不唯一；逻辑回归最大化似然，解唯一且可输出概率；支持向量机最大化间隔，解只由支持向量决定。理解了这一点，就能明白为何在特征工程充分的场景下，三者效果常常相差无几。

六、与朴素贝叶斯的关系

逻辑回归与线性回归称得上系出同门，与朴素贝叶斯则是**殊途同归**。

6.1 两条不同的路径

两者都能利用条件概率 P(Y|X) 完成分类，实现路径却截然不同：

维度	朴素贝叶斯	逻辑回归
模型类型	生成模型	判别模型
学习对象	联合分布 P(X, Y)	条件分布 P(Y|X)
P(Y|X) 的角色	由联合分布推出的后验概率	直接建模的似然概率
思路	先学数据怎么生成，再反推类别	直接学给定输入该输出什么

6.2 特定条件下两者等价

即便原理不同，在特定条件下两者依然可以等效。

用朴素贝叶斯处理二分类任务时，假设对每个 x_i，属性条件概率 $p(x_i|Y = y_k)$ 都满足正态分布，且正态分布的标准差与标记 Y 无关。那么根据贝叶斯定理，后验概率可以写成

$$p(Y=0 \mid \mathbf{X}) = \frac{1}{1+\exp\left(\ln \frac{p(Y=1)\cdot p(\mathbf{X}|Y=1)}{p(Y=0)\cdot p(\mathbf{X}|Y=0)}\right)}$$

根据朴素贝叶斯的假设，类条件概率可表示为属性条件概率的乘积。令 p(Y=0) = p_0，并把满足正态分布的属性条件概率代入（μ 读作 mu，是均值；σ 读作 sigma，是标准差），经过计算得到

$$p(Y=0 \mid \mathbf{X}) = \frac{1}{1+\exp\left(\ln\frac{1-p_0}{p_0} + \sum_i \left(\frac{\mu_{i1}-\mu_{i0}}{\sigma_i^2}X_i + \frac{\mu_{i0}^2-\mu_{i1}^2}{2\sigma_i^2}\right)\right)}$$

不难看出，这个式子和逻辑回归中 p(y=0|x) 的形式**完全一致**——说明朴素贝叶斯和逻辑回归学习到的是同一个模型。

更一般地，只要 p(x|Y) 的分布属于**指数族**，类似的结论都成立。

6.3 区别在哪

联系说完了，再看区别。当朴素贝叶斯的模型假设不成立时，逻辑回归和朴素贝叶斯通常会学到不同的结果：

- **样本量趋于无穷时**，逻辑回归的渐近分类准确率优于朴素贝叶斯；
- 逻辑回归**不依赖属性相互独立**的假设，即使数据违反假设，条件似然最大化算法也会调整参数以拟合数据；
- 相比之下，逻辑回归**偏差更小，方差更大**；
- **收敛速度**上，逻辑回归的参数估计慢于朴素贝叶斯。

因此实践中的经验是：**训练数据充足时逻辑回归更优，数据稀缺时朴素贝叶斯反而更好。**

> **新手提示：偏差大、方差小意味着什么**
>
> 朴素贝叶斯带着"属性独立"这个强假设，相当于提前把解空间压得很小——假设错了就系统性偏离（偏差大），但结果稳定（方差小）。逻辑回归假设更弱、更贴近数据，代价是对数据扰动更敏感（方差大）。这正是"强假设换稳定性、弱假设换准确性"的经典权衡。

补充说明：这一对比有实验支撑。经典研究在 15 个数据集上系统比较了两类模型，结论是：**样本量较大时判别式方法（逻辑回归）几乎总是更准；而样本量很小时生成式方法（朴素贝叶斯）反而占优**，并且这个拐点大致出现在 30 个样本量级。这为工程选型提供了一个可操作的判据，而不只是理论口号。

七、多分类

二分类只是特例，更通用的情形是多分类，比如手写数字识别。要让逻辑回归处理多分类，有两种改进方式。

7.1 多个二分类器

通过多次二分类实现多个类别的标记：为每个类别各建一个二分类器。若类别数为 m，就得到 m 个二分类逻辑回归模型，对一个实例的分类结果，取这 m 个分类函数中输出值最大的那个。

这种方式实现简单，但每次分类都要调用 m 次模型，效率较低。

7.2 Softmax 回归

另一种方式直接修改输出形式，使之适应多分类，得到的模型就是 **Softmax 回归**：

$$p(Y=k \mid \mathbf{x}) = \frac{e^{\mathbf{w}_k^{\mathrm{T}}\mathbf{x}}}{\sum_{j=1}^{K} e^{\mathbf{w}_j^{\mathrm{T}}\mathbf{x}}}$$

式中 w_k 代表与类别 k 相关的权重参数。Softmax 给出的是实例在每一种分类结果下出现的概率，所有类别的概率之和为 1。

Softmax 回归的训练与逻辑回归类似，同样可以转化为梯度下降或拟牛顿法求解的最优化问题。

补充说明：Softmax 有一个必须注意的数值细节。当某个 $w_k^T x$ 很大时，e 的指数会溢出；标准实现会先减去所有得分中的最大值再取指数：

$$\text{softmax}(z_k) = \frac{e^{z_k - \max_j z_j}}{\sum_j e^{z_j - \max_j z_j}}$$

减去的常数在分子分母中同时出现，不改变结果，却保证了指数不会溢出。这也解释了为何手写 Softmax 时容易得到 NaN——根因几乎总是溢出而非公式错误。

7.3 怎么选

两种方式都能实现多分类，适用范围略有区别：

- 所有类别之间**明显互斥**（输出只能属于一个类别）时，Softmax 更高效；
- 类别之间**不存在互斥关系**、可能有交叉时，用多个二分类逻辑回归，可以为同一个实例打上多个标记。

补充说明：这两种情形在术语上要区分清楚。**多分类（multi-class）** 指类别互斥、每个样本只能属于一类，用 Softmax；**多标签（multi-label）** 指一个样本可同时属于多个类别，用多个独立的二分类器，每个都有自己的阈值。图像分类通常是前者，而给一张图打上“人、车、建筑”多个标签则是后者。指标也不同：多分类看整体准确率或宏平均 F1，多标签看每个标签的精确率与召回率。

四个常见误区

- **“逻辑回归输出的就是真实概率”**——它给出的是模型假设下的概率，若数据分布与假设不符，数值会偏高或偏低，需要做概率校准。
- **“逻辑回归只能画直线”**——决策边界对输入是线性的，但对特征是线性的；加入多项式特征、样条或核，边界就可以弯曲。
- **“数据完全可分时结果更可靠”**——完全可分会让最大似然解发散，权重趋于无穷。实际训练必须加正则项或提前停止。
- **“Softmax 就是多个 Sigmoid 拼起来”**——每个 Sigmoid 独立建模“属于某类”的概率，各类之和不必为 1；Softmax 强制各类互斥且归一，两者假设不同。

八、要点回顾

1. 逻辑回归是对线性回归的改进，用于解决分类问题，本质是用线性函数拟合对数几率。
2. Sigmoid 函数把实数轴压缩到 (0, 1)，0.5 是天然的判定分界点。
3. 逻辑回归输出实例属于每个类别的概率，取概率最大的类别作为结果。
4. 参数通过最大似然估计确定，等价于最小化交叉熵损失；也可从 KL 散度最小化与最大熵原理的角度理解。
5. 逻辑回归本身是线性分类器，判定边界是超平面。
6. 在属性条件概率服从正态分布（更一般地，属于指数族）的假设下，朴素贝叶斯与逻辑回归等价；但数据充足时逻辑回归更准，数据稀缺时朴素贝叶斯更稳。
7. 多分类可以用多个二分类器，也可以用 Softmax 回归；类别互斥时选后者，允许交叉时选前者。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
逻辑回归	Logistic Regression	LR	用 Sigmoid 压缩线性输出、直接建模条件概率的分类方法
Sigmoid 函数	Sigmoid Function	—	把实数映射到 (0, 1) 的 S 形函数，导数等于 $y(1-y)$
对数几率	Log-Odds	—	正例与反例可能性之比取对数，逻辑回归的拟合对象
几率	Odds	—	事件发生与不发生概率的比值
判定边界	Decision Boundary	—	特征空间中划分不同类别的分界面
交叉熵	Cross Entropy	CE	衡量两个概率分布差异的指标，逻辑回归的损失函数
最大熵原理	Maximum Entropy Principle	—	在符合事实的模型中优先选择最不偏不倚的那个
KL 散度	Kullback-Leibler Divergence	KL	衡量两个概率分布差异的非对称指标
指数族	Exponential Family	—	可写成统一指数形式的一大类概率分布
Softmax 回归	Softmax Regression	—	用 Softmax 函数输出多类别概率的分类方法
规范连接函数	Canonical Link Function	—	等于分布自然参数、使目标函数为凸的连接函数
Platt 缩放	Platt Scaling	—	用逻辑回归将分类器得分映射为校准概率的后处理
多标签分类	Multi-Label Classification	—	一个样本可同时属于多个类别的分类任务
拟牛顿法	Quasi-Newton Method	—	用梯度差分近似 Hessian 矩阵的一类二阶优化方法
生成模型	Generative Model	—	学习联合分布再据此推断后验的建模方式
判别模型	Discriminative Model	—	直接学习条件分布或决策函数的建模方式