决策树：信息增益、基尼系数与剪枝

读前须知

- **前置**：熵与条件熵。如果还没读信息论那一篇，先记住“熵越大，越不确定”这一句就够用了。
- **这一篇的位置**：最接近人类判断方式的模型，也是随机森林、梯度提升树的基学习器。
- **读完能做什么**：手算一次信息增益与基尼指数；解释 ID3、C4.5、CART 的差别；说清预剪枝与后剪枝各自防的是什么。

一、像人一样做判断

决策树是解决分类问题的另一种思路。与基于概率推断的朴素贝叶斯、逻辑回归不同，决策树采用**树形结构**，层层推理得出最终分类。

与贝叶斯方法相比，决策树的优势在于**构造过程不需要任何先验条件**，因此特别适合探索式的知识发现。它的判断方式也更接近人的思维，这可以用买房来说明。

面对眼花缭乱的房源，普通人首先看每平方米的价格：不贵就买，贵了就不买。价格合适，再看面积：不小就买，小了就不买。面积也合适，接着看位置——单身业主考虑离单位远近，为人父母的则斟酌是不是学区房。位置也满意，还可以继续看交通、物业、优惠条件，逐步筛选出最终目标。

在这套策略里：

- 每套房源都要给出“买”或“不买”的**决策结果**；
- 价格、面积、学区房等因素构成**判断条件**；
- 每个条件下的选择表示不同情况下的**决策路径**；
- 每个“买/不买”背后都对应一条完整的决策过程。

决策树，就是把上面的过程形式化、并引入量化指标后形成的分类算法。

二、决策树的结构

决策树是包含**根节点**、**内部节点**和**叶节点**的树结构：

节点类型	含义
根节点	包含样本全集
内部节点	对应一个特征属性上的测试
叶节点	代表决策结果（类别）

从根节点到每个叶节点的每条路径，都对应一个“从数据到决策”的判定流程。

使用决策树进行预测的过程是：从根节点开始，测试待分类项的特征属性，按取值选择输出的分支；当走到某个叶节点时，就把该节点存放的类别作为结果。

> **新手提示：决策树和“if-else 嵌套”是一回事**
>
> 一棵决策树完全可以翻译成一串嵌套的 if-else 语句。这也解释了它为什么可解释性强——模型结构本身就是人能读懂的规则。代价是：规则一旦确定就写死了，对数据分布的细微变化不如概率模型灵活。

补充说明：需要区分两种“特征选择”。本节讲的**特征选择**是决策树内部的划分准则，目标是在每个节点上挑出最能降低不确定性的属性；而数据预处理阶段的**特征选择**（过滤式、包裹式、嵌入式）是从全部属性中剔除冗余与无关属性，目标是为任何模型降维。两者名字相同，尺度不同：前者只在树的一个节点上做局部决策，后者在整个数据集上做全局筛选。

三、学习过程的三个步骤

决策树是基于特征对实例分类的，因此其学习本质是**从训练集中归纳出一组“如果……那么……”规则**。这组规则既要在训练数据上有较高的符合度，也要具备良好的泛化能力。

完整的学习过程包括三步：

1. **特征选择**：决定用哪些特征来划分特征空间；
2. **决策树生成**：按选定准则递归地划分节点，长出整棵树；
3. **决策树剪枝**：主动去掉部分分支，对抗过拟合。

四、特征选择

训练数据中，每个样本的属性可能有很多个，它们在分类中起到的作用有大有小。**特征选择**的作用，就是筛选出与分类结果相关性较高、即分类能力较强的特征。

理想的特征选择是：**每次划分之后，分支节点包含的样本都尽可能属于同一类别**（纯度尽可能高）。

4.1 信息增益

特征选择中最常用的准则是**信息增益（information gain）**。机器学习中的信息增益，就是通信理论中的**互信息（mutual information）**，是信息论的核心概念之一。

信息增益描述的是：**已知特征之后，对数据分类不确定性的减少程度**。因此：

- 特征的信息增益越大，分类结果的不确定度越低，该特征的分类能力越强；
- 信息增益越小，说明这个特征对划分几乎没帮助。

用公式表述。设当前样本集合 D 中第 k 类样本所占比例为 p_k，则 D 的**信息熵**为

$$\mathrm{Ent}(D) = -\sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k$$

其中 $|\mathcal{Y}|$ 是类别总数。用属性 a 对 D 进行划分，产生若干个分支节点，则属性 a 的信息增益为

$$\mathrm{Gain}(D, a) = \mathrm{Ent}(D) - \sum_{v} \frac{|D^v|}{|D|} \mathrm{Ent}\left(D^v\right)$$

式中 D^v 是属性 a 取值为 v 的样本子集。后一项是划分后的**条件熵**：按样本比例加权，衡量“知道 a 的取值之后还剩多少不确定性”。

根据信息增益准则选择特征的过程，就是**自顶向下划分，每次计算所有特征的信息增益并取最大值。**

> **新手提示：为什么增益大就说明特征好**
>
> 熵衡量的是“混乱程度”。划分前的熵是总混乱度，划分后各子集的熵按比例加权平均，得到“分完之后还剩多少混乱”。两者之差，就是“因为知道了这个特征而消除掉的混乱”。消除得越多，这个特征越有区分度——这就是信息增益的全部含义。

补充说明：公式里的对数取以 2 为底，单位是比特；取自然对数则为纳特。底数选择只改变数值的绝对值，不改变不同特征之间信息增益的相对大小，因此不影响特征选择的结果。另外，信息增益天然地等价于互信息 I(D; a)，所以第 005 篇中的"互信息"与这里的"信息增益"是同一个量的两种叫法。

4.2 一个直观的例子

银行发放贷款时，会根据申请人的特征决定是否放款。假设训练数据中每个样本都包含年龄、是否有工作、是否有房产、信贷情况等特征，标签是"同意贷款"或"不同意"。

极端情形一：某个特征与结果完全吻合。 如果"是否有房产"的取值与是否放贷完全对应——有房的都同意、没房的都不同意——那么这个特征的信息增益最大，它**完全消除了分类的不确定性**。预测新实例时，只看这一个特征就能定结果，甚至无需考虑其他特征。

极端情形二：某个特征与结果完全无关。 如果"年龄"的每个取值（青年/中年/老年）里，同意与不同意的样本数目都大致相等，说明分类结果在年龄上是随机分布的，两者没有任何规律。这个特征的信息增益很小，不具备分类能力。

一般说来，抛弃这类特征对决策树的精度影响不大。

4.3 ID3 算法

最早提出的决策树算法 **ID3**，就是按信息增益准则选择特征的。构建方法：

1. 从根节点出发，计算所有特征的信息增益；
2. 选择信息增益最大的特征作为该节点的划分特征；
3. 按该特征的不同取值建立子节点；
4. 对每个子节点递归调用上述过程，直到信息增益都很小，或没有特征可选为止。

4.4 信息增益比与 C4.5

ID3 用的是信息增益的**绝对取值**，而信息增益有个毛病：**属性可取值数目越多，其信息增益的绝对值往往越大。**

比如用"身份证号"做特征，每个样本自成一类，纯度直接拉满，信息增益极高——但对新样本毫无预测能力。若在决策树初期就做这种过细的划分，泛化能力必然受损。

为避免对多值属性的偏好，ID3 的提出者给出了改进版 **C4.5**：不再直接用信息增益，而引入**信息增益比（gain ratio）**：

$$\mathrm{Gain_ratio}(D, a) = \frac{\mathrm{Gain}(D, a)}{\mathrm{IV}(a)}$$

其中 IV(a) 称为属性的**固有值**（intrinsic value），等于按该属性取值计算出的信息熵：

$$\mathrm{IV}(a) = -\sum_{v} \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

属性取值越多，IV(a) 通常越大，正好抵消了信息增益对多值属性的偏好。

在特征选择时，C4.5 先**从候选特征中找出信息增益高于平均水平**的，再从中选**增益率最高**的作为节点特征——这样既避免了偏好多值属性，又不会反过来偏好取值极少的属性。生成方式与 ID3 类似。

补充说明：C4.5 相对 ID3 的改进不只增益比一项，还有两个同样关键。一是**连续属性处理**：对连续特征按取值排序，在相邻取值的中点处枚举候选切分点，选信息增益最大的那个——这也是所有决策树处理连续变量的通用做法。二是**缺失值处理**：给缺失样本按各分支的样本比例分配权重，同时把权重计入增益计算，避免直接丢弃造成偏差。

4.5 基尼系数与 CART

无论 ID3 还是 C4.5，都基于熵模型做特征选择，绕不开大量对数运算。另一种主流算法 **CART** 则用**基尼系数（Gini index）** 取代了熵。

CART 全称分类与回归树（Classification and Regression Tree），既可用于分类也可用于回归。假设共有 K 个类别，第 k 类的概率为 p_k，则基尼系数为

$$\mathrm{Gini}(p) = \sum_{k=1}^{K} p_k\,(1 - p_k) = 1 - \sum_{k=1}^{K} p_k^2$$

它的直观含义是：**从数据集中随机抽两个样本，其类别不一致的概率。**基尼系数越小，数据纯度越高。

基尼系数与熵模型高度近似，却避免了对数运算，因此 CART 分类树的执行效率更高。

为了进一步简化模型，**CART 每次只对某个特征的值做二分而非多分**，最终生成的是二叉树。因此计算基尼系数时，要对每个特征找到使其最小的最优切分点；生成时按最优特征与最优切分点分出两个子节点，把训练数据分配进去。

举例：若某个特征 A 上有 A_1、A_2、A_3 三种取值，CART 会考察

- {A_1} / {A_2, A_3}
- {A_2} / {A_1, A_3}
- {A_3} / {A_1, A_2}

三种二分方式，取基尼系数最小的那一种。

> **新手提示：为什么“随机抽两个不一致的概率”能衡量纯度**
>
> 如果集合里全是同一类，抽两个必然一致，不一致概率为 0，纯度最高；如果两类各占一半，不一致概率为 0.5，最混乱。所以基尼系数越小越纯——这和熵是一模一样的逻辑，只是把 log 换成了乘法。

补充说明：CART 名为分类与回归树，回归时的准则与分类完全不同。分类用基尼系数衡量纯度，回归则用**平方误差**衡量拟合程度：每个叶节点输出落在该节点内训练样本的均值，划分时选使左右子节点平方误差之和最小的切分点。因此 CART 回归树可以看作“分段常值函数”，它的分段数与切分位置都由数据决定。

五、剪枝

与其他机器学习算法一样，决策树也难以克服过拟合。**剪枝（pruning）** 是决策树对抗过拟合的主要手段。

园丁剪枝是为了树形完好；决策树剪枝则是主动去掉分支，以降低过拟合风险、提升泛化性能。

如何判定泛化性能是否提升？一种方法是定义决策树的整体损失函数并使其极小化，这等价于使用正则化的最大似然估计做模型选择；另一种更简单的做法是**从训练集中分出一部分作为验证集**，根据验证集精度的变化决定是否剪枝。

5.1 预剪枝

预剪枝（pre-pruning） 在生成过程中进行：划分之前先对每个节点做估计，如果当前划分不能带来泛化性能的提升，就直接把该节点标为叶节点。

- **好处**：禁止欠佳节点展开，在降低过拟合风险的同时显著减少训练时间；

- **风险**：可能“误伤”。某些分支当前看似没用，在其基础上的后续划分却可能大幅提升性能；把这些“深藏不露”的节点提前砍掉，会导致**欠拟合**。

5.2 后剪枝

后剪枝（post-pruning） 先从训练集生成一棵完整决策树，计算其在验证集上的精度，再自底向上考察内部节点，比较剪枝前后的精度决定分支是否保留。

- **好处**：通常能保留更多分支，**欠拟合风险较小**，泛化性能往往优于预剪枝；
- **代价**：需要逐一考察所有内部节点，训练开销较大。

5.3 对比

维度	预剪枝	后剪枝
时机	生成过程中	生成完整树之后
训练开销	小	大
过拟合风险	较低	较低
欠拟合风险	**较高**	较低
泛化性能	一般	通常更好

补充说明：更系统的做法是**代价复杂度剪枝（cost-complexity pruning）**，CART 采用的就是它。做法是定义一个带正则项的整体损失

$$C_\alpha(T) = C(T) + \alpha\,|T|$$

其中 C(T) 是树 T 在训练集上的误差、|T| 是叶节点数、α 是调节强度的超参数。从小到大逐步增大 α，每步剪掉使损失上升最少的子树，得到一串嵌套的候选树，最后用交叉验证在验证集上选定最优的那一棵。这本质上与 008 中岭回归的思路一致：**以训练误差的上升换取结构复杂度的下降。**

六、多变量决策树

以上算法结构简单、逻辑易解释，但有个重要缺点：**“一言堂”**——每个内部节点只依据一个最优特征做决策。

实际问题中，分类结果往往受多个因素共同影响，需要综合考量。依赖多个特征共同决策的，就是**多变量决策树（multivariate decision tree）**。

在特征空间上，这个差别很直观：

- **单变量决策树**的分类边界由**与坐标轴平行**的分段组成；
- **多变量决策树**的分类边界可以是**斜线**（更一般地，是斜的超平面），因此能用更少的节点拟合更复杂的边界。

> **新手提示：斜边界为什么更省节点**
>
> 想用横平竖直的阶梯去逼近一条斜线，必须切很多刀；而斜边界一刀就能切开。这就是多变量决策树在同样精度下往往更浅、更紧凑的原因。代价是每个节点要学习一个线性组合，可解释性随之下降。

补充说明：多变量决策树实际上把决策树与线性模型缝合在了一起：每个节点的判断是一个线性分类器（类似感知机或逻辑回归），整体仍保留树的分支结构。这样一来，它既有树的分段能力，又有线性模型的斜边界表达力。但代价不只是可解释性下降——节点内需要求解一个小型优化问题，训练成本明显高于单变量划分。这也是工程上仍然以 CART、ID3 为主流的原因：它们在准确率与成本之间的性价比更高。

四个常见误区

- **"信息增益越大，这个特征就越好"**——信息增益天然偏好取值多的特征（比如用户 ID），容易选出过拟合的分裂。C4.5 用增益率来修正这一点。
- **"树越深拟合越好"**——深到每个叶子只有一个样本时，训练误差为零，泛化能力却最差。这也是必须剪枝的原因。
- **"决策树对数据尺度不敏感，所以很稳"**——尺度确实不影响分裂点，但树对训练集的微小扰动非常敏感，换一批样本可能长出完全不同的结构。
- **"剪枝就是删掉不重要的特征"**——剪枝删的是分支（样本划分），特征仍然保留在树的其他位置，两者不是一回事。

七、要点回顾

1. 决策树是包含根节点、内部节点、叶节点的树结构，通过逐层判定特征属性完成分类。
2. 学习过程包括特征选择、决策树生成、决策树剪枝三个步骤。
3. 特征选择的指标有信息增益（ID3）、信息增益比（C4.5）与基尼系数（CART）。
4. 信息增益偏好可取值多的属性，信息增益比通过固有值归一化来纠正这一偏差。
5. 基尼系数与熵高度近似但无需对数运算，CART 因此效率更高，且只做二分。
6. 剪枝分为预剪枝与后剪枝：前者开销小但易欠拟合，后者开销大但泛化通常更好。
7. 单变量决策树的边界与坐标轴平行；多变量决策树可用斜边界，结构更紧凑。

八、名词汇总

名称	英文全称	英文缩写	简短介绍
决策树	Decision Tree	DT	用树形结构逐层判定特征完成分类的模型
根节点	Root Node	—	包含全部训练样本的起始节点
内部节点	Internal Node	—	对应一个特征属性测试的分支节点
叶节点	Leaf Node	—	存放最终决策结果（类别）的终端节点
特征选择	Feature Selection	—	从候选属性中挑出划分能力最强者的过程
信息增益	Information Gain	IG	已知特征后分类不确定性减少的量，等价于互信息
信息熵	Information Entropy	—	度量集合纯度（混乱程度）的指标
条件熵	Conditional Entropy	—	已知某特征取值后剩余的不确定性

名称	英文全称	英文缩写	简短介绍
信息增益比	Gain Ratio	—	用属性固有值归一化后的信息增益
固有值	Intrinsic Value	IV	属性自身取值分布带来的分裂信息量
基尼系数	Gini Index	—	随机抽两样本类别不一致的概率，衡量不纯度
ID3	Iterative Dichotomiser 3	ID3	以信息增益为准则的决策树生成算法
C4.5	—	C4.5	以信息增益比为准则的决策树生成算法
CART	Classification and Regression Tree	CART	以基尼系数为准则、只做二分的分类回归树
剪枝	Pruning	—	主动去掉部分分支以抑制过拟合的手段
预剪枝	Pre-pruning	—	生成过程中提前停止节点划分的剪枝策略
后剪枝	Post-pruning	—	生成完整树后自底向上裁剪分支的剪枝策略
多变量决策树	Multivariate Decision Tree	—	每个节点综合多个特征做线性组合判定的决策树
互信息	Mutual Information	MI	两个随机变量共享的信息量，等价于信息增益
代价复杂度剪枝	Cost-Complexity Pruning	CCP	用带叶节点数惩罚的整体损失选择子树的正则化剪枝法