支持向量机：间隔最大化、核技巧与 SMO

读前须知

- **前置**：内积、范数与二次规划的基本概念；拉格朗日乘子法会在推导中用到。
- **这一篇的位置**：小样本、高维场景下的经典强基线，“间隔”与“核”两个思想影响了后来的很多模型。
- **读完能做什么**：写出最大间隔的原始问题与对偶问题；解释核技巧为什么能避开显式高维映射；说清支持向量究竟“支持”了什么。

一、从大量可行解中挑一个

1.1 线性可分的训练集

假定有若干个点全部位于 x 轴上方，另外若干个点全部位于 x 轴下方，这两个点集就共同构成了一个**线性可分的训练数据集**，而 x 轴就是将它们区分开来的一维超平面，也就是一条直线。

再进一步假设：x 轴上方的点全部位于直线 y = 1 上及其上方，x 轴下方的点全部位于直线 y = −2 上及其下方。此时任何一条平行于 x 轴、且在 −2 到 1 之间的直线，都能把这个训练集分开。

于是一个问题浮现出来：在这么多可用的划分超平面中，哪一个才是最好的？

1.2 间隔最大的那一条

直观看来，最好的分界线是直线 y = −0.5。因为这条线正好位于两个边界的中间，与两个类别的间隔可以同时达到最大。当训练集中的数据因噪声干扰而移动时，这条线所受的影响最小，因而具有最强的**泛化能力**。

> **新手提示：为什么“中间的线”更好**
>
> 假设你只能凭感觉画一条线，画得离某一类特别近。那么该类只要有一个点稍微往外飘一点，就会被分错。而取正中间时，两类点各自都还有半个“缓冲带”可以容错。支持向量机的全部思想，就是把这条“最宽的缓冲带”用数学严格地求出来。

1.3 支持向量机与它的来历

这种只关心分界线附近的点、把间隔撑到最大的思路，就是**支持向量机（Support Vector Machine，SVM）**。

1963 年，在前苏联莫斯科控制科学学院攻读统计学博士学位的**弗拉基米尔·瓦普尼克**（Vladimir Vapnik）和他的同事**阿列克谢·切尔沃宁基斯**（Alexey Chervonenkis）共同提出了支持向量机算法，随后几年两人又在此基础上进一步完善了**统计学习理论**。受当时国际环境的影响，这些以俄文发表的成果并没有立即进入西方学术界的视野。直到 1990 年，瓦普尼克随移民潮到达美国，统计学习理论才被重新发现，并在二十世纪末大放异彩。

具体说来，支持向量机是一种**二分类算法**，通过在高维空间中构造超平面实现对样本的分类。按数据分布由易到难，它可以分成三种形态：

模型	前提	策略	处理的问题
线性可分支持向量机	数据严格线性可分	硬间隔最大化	线性分类

模型	前提	策略	处理的问题
线性支持向量机	数据近似线性可分	软间隔最大化	线性分类（含少量噪声）
非线性支持向量机	数据线性不可分	核技巧 + 软间隔最大化	非线性分类

三者是一条逐步放宽条件的路线：先要求严格可分，再容忍少量越界，最后把战场搬到高维空间。非线性支持向量机是最普适的情形，前两种都可以视为它的特例，因此通常说的支持向量机并不区分是否线性可分。

补充说明：间隔最大化不只是一条几何直觉，它在统计学习理论中有明确地位。瓦普尼克提出的**结构风险最小化**（structural risk minimization）原则指出，模型的真实风险由经验风险加上一个与模型容量（VC 维）有关的置信项构成。支持向量机通过最大化间隔来压低容量，从而在经验风险不增加的前提下收紧置信项——这正是它在小样本上泛化能力强的理论解释。相比之下，只最小化经验风险的做法（例如无正则的最小二乘）缺少这层保障。

二、划分超平面与间隔

2.1 超平面方程与法向量

在高维的特征空间上，划分超平面可以用简单的线性方程描述：

$$\mathbf{w}^{\mathrm{T}} \cdot \mathbf{x} + b = 0$$

式中的 n 维向量 w 为**法向量**，决定了超平面的方向；b 为**截距**，决定了超平面和高维空间中原点的距离。

划分超平面将特征空间分为两个部分：

- 位于法向量所指向一侧的数据被划分为**正类**，分类标记 y = +1；
- 位于另一侧的数据被划分为**负类**，分类标记 y = −1。

线性可分支持向量机，就是在给定训练数据集的条件下，根据**间隔最大化**学习最优划分超平面的过程。

2.2 几何间隔与函数间隔

给定超平面后，特征空间中的样本点 x_i 到超平面的距离可以表示为：

$$r = \frac{\left|\mathbf{w}^{\mathrm{T}} \cdot \mathbf{x} + b\right|}{\| \mathbf{w} \|}$$

分母上的 ‖w‖ 做的正是**归一化**，所以这个距离被称为**几何间隔**（geometric margin）——它是真正的、可以拿尺子量的距离。

结合前面的描述，通过合理设置参数 w 和 b，可以让每个样本点到最优划分超平面的距离都不小于 1，即满足：

$$\begin{cases} \mathbf{w}^{\mathrm{T}}\mathbf{x}_i + b \geq 1, & y_i = +1 \\ \mathbf{w}^{\mathrm{T}}\mathbf{x}_i + b \leq -1, & y_i = -1 \end{cases}$$

也就是说，要求

$$y_i \left(\mathbf{w}^{\mathrm{T}}\mathbf{x}_i + b\right) \geq 1$$

需要注意的是，这里用的是**非归一化**的距离，被称为**函数间隔**（functional margin）。函数间隔和几何间隔的区别，就在于未归一化和归一化的区别。

2.3 支持向量与间隔

在特征空间中，距离划分超平面最近的样本点能让上式取得等号，这些样本被称为**支持向量**（support vector）。两个异类支持向量到超平面的距离之和为：

$$\frac{2}{||\mathbf{w}||}$$

这个量就是所谓的**间隔**（margin）。

> **新手提示：名字的由来**
>
> 只有支持向量"顶"在间隔的边界上，其余样本点无论怎么在各自那一侧移动，只要不越过边界，算出来的最优超平面都不会变。可以说整个模型是被这几个"撑住"边界的样本点决定出来的——它们"支持"了这台机器，所以叫支持向量机。

补充说明：函数间隔存在一个尺度上的自由度。把 w 和 b 同时乘以一个正数 k，超平面的位置没有变，但函数间隔变成原来的 k 倍；几何间隔因为分子分母同比例缩放而保持不变。这说明函数间隔的绝对值没有几何意义，只有相对大小有意义。也正因如此，才能强制约定"最近点的函数间隔等于 1"——这个约定不是额外限制，而是把尺度自由度用掉来换取一个统一的归一化基准。约束 ‖w‖ = 1 是另一种等价做法，但会引入非光滑约束，不如固定函数间隔好用。

三、硬间隔最大化

3.1 原始优化问题

对于线性可分支持向量机来说，其任务就是在满足上面不等式的前提下，寻找 2/‖w‖ 的最大值。

而最大化 2/‖w‖ 等效于最小化 ‖w‖，也就等效于最小化 ½‖w‖²。于是上述问题可以改写为：

$$\begin{aligned} \min_{\mathbf{w},b} \quad & \frac{1}{2}||\mathbf{w}||^2 \\ \text{s.t.} \quad & y_i\left(\mathbf{w}^{\mathrm{T}}\mathbf{x}_i+b\right) \geq 1, \quad i=1,2,\ldots,N \end{aligned}$$

线性可分支持向量机，就是使**硬间隔**（hard margin）最大化的算法。

3.2 为什么写成 ½‖w‖²

把"最大化 2/‖w‖"改写成"最小化 ½‖w‖²"不是随手变形，而是为了把问题落进标准形式。二次函数求导后是线性函数，目标函数因此严格凸；约束也都是线性的，可行域因此是凸集。凸目标配线性约束，得到的就是**凸二次规划**（convex quadratic programming）问题，它有唯一全局最优解，也能借助成熟的对偶方法求解。若直接对 ‖w‖ 求最小，目标函数在原点不可微，反而破坏了这些好性质。

补充说明：硬间隔支持向量机的价值不只在分类本身，更在于它给出了一条通往对偶形式的路径。原始问题带 N 个不等式约束，对偶问题则有 N 个拉格朗日乘子——样本有多少，对偶变量就有多少。更关键的是，对偶形式中样本只以内积的形式出现，这为引入核函数埋下了伏笔：把内积换成核函数值，整个算法不必改动结构。这就是所谓"核化"能够一行不改地成立的原因。

四、软间隔与线性支持向量机

在实际问题中，训练数据集里通常会出现噪声或异常点，导致其线性不可分。要解决这个问题，就需要把学习算法一般化，得到的就是**线性支持向量机**（去掉了"可分"这个条件）。

线性支持向量机的通用性体现在：将原始的硬间隔最大化策略转变为**软间隔**（soft margin）最大化。

4.1 松弛变量

这个转变的动机很朴素：在线性不可分的训练集中，导致不可分的往往只是少量异常点。只要把这些异常点去掉，余下的大部分样本点依然满足线性可分的条件。

从数学上看，线性不可分意味着某些样本点距离划分超平面的函数间隔不满足"不小于 1"的约束，因而需要对每个样本点引入非负的**松弛变量**（slack variable）ξᵢ ≥ 0，使得函数间隔和松弛变量的和不小于 1。这样一来，软间隔最大化下的约束条件就变成：

$$y_i\left(\mathbf{w}^{\mathrm{T}}\mathbf{x}_i+b\right)\geq 1-\xi_i,\quad \xi_i\geq 0$$

相应地，最优化问题中的目标函数演变为：

$$\min_{\mathbf{w},b,\xi}\ \frac{1}{2}\|\mathbf{w}\|^2+C\sum_{i=1}^{N}\xi_i$$

4.2 惩罚参数 C

其中 C > 0 被称为**惩罚参数**（penalty parameter），表示对误分类的惩罚力度。

这个最小化目标函数是一对矛盾的折中：既希望间隔（2/‖w‖）尽量大，即 ½‖w‖² 尽量小，也兼顾了误分类点的个数（即 Σξᵢ 尽量小）。

与要求所有样本都划分正确的硬间隔相比，软间隔允许某些样本不满足硬间隔的约束，但会限制这类特例的数目。C 越大，对误分类的容忍度越低，越接近硬间隔；C 越小，容忍度越高，模型越宽松。

> **新手提示：C 的调法**
>
> C 是支持向量机里最重要的超参数。C 调大容易过拟合（为了迁就每个点而把间隔压窄），C 调小容易欠拟合（间隔很宽但错误率上升）。实践中通常用交叉验证在对数尺度（如 0.01、0.1、1、10、100）上搜索。

补充说明：软间隔目标还可以改写成另一副面孔。把松弛变量的最优取值代回，每个样本的惩罚项恰好等于 max(0, 1 − yᵢ(wᵀxᵢ + b))，这就是**合页损失**（hinge loss）。于是软间隔支持向量机等价于"合页损失 + L2 正则"的经验风险最小化。这个视角把它拉回到与其他模型同一张桌子上：逻辑回归用对数损失，支持向量机用合页损失，两者都是"损失函数 + 正则项"的组合，区别只在损失曲线的形状——合页损失在间隔之外直接取 0，正是支持向量稀疏性的根源。

五、核技巧：从线性到非线性

5.1 原始空间不够用

前面涉及的分类问题，都假定两类数据点可以用原始特征空间上的超平面区分开来，这类问题就是**线性问题**；如果原始空间中不存在能够正确划分的超平面，问题就演变成了**非线性问题**。

在二维平面直角坐标系中，如果按照与原点之间的距离对数据点进行分类，分类的模型就不再是一条直线，而是一个圆，也就是**超曲面**。这个问题就是个非线性问题，与距离的平方形式相呼应。

不论是线性可分支持向量机还是线性支持向量机，都只能处理线性问题，对非线性问题无能为力。可如果能将样本从原始空间映射到更高维度的特征空间之上，在新的特征空间上样本就可能是线性可分的。**如果样本的属性数有限，那么一定存在一个高维特征空间使样本可分。**

将原始低维空间上的非线性问题转化为新的高维空间上的线性问题，这就是**核技巧**（kernel trick）的基本思想。

核技巧可以用中国象棋来解释。开战之前，红黑两军各自陈兵，不越雷池一步，只需楚河汉界便可让不同的棋子泾渭分明。可随着车辚辚马萧萧激战渐酣，红黑棋子捉对厮杀，难分敌我，想再造一条楚河汉界将混在一起的两军分开已无可能。

好在我们还有高维空间。不妨把两军之争想象成一场围城大战，红帅率兵于高墙坚守，黑将携卒在低谷强攻。如此一来，不管棋盘上的棋子如何犬牙交错，只要能够在脑海中构造出一个立体城池，便可以根据位置的高低将红黑区分开来。这就是棋盘上的核技巧。

5.2 核函数的定义

当核技巧应用到支持向量机中时，原始空间与新空间之间的转化是通过**非线性变换**实现的。假设原始空间是低维欧几里得空间 X，新空间为高维希尔伯特空间 H，则从 X 到 H 的映射可以用函数表示：

$$\phi(\mathbf{x}):\ X \to H$$

核函数可以表示成映射函数内积的形式：

$$K(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x}) \cdot \phi(\mathbf{z})$$

核函数有两个特点：

1. **计算发生在低维空间。**它的计算过程是在低维空间上完成的，因而避免了高维空间（可能是无穷维空间）中复杂的计算——我们永远不需要真的算出 φ(x)，只需要算 K。
2. **对应关系不唯一。**对于给定的核函数，高维空间 H 和映射函数 φ 的取法并不唯一：高维空间的取法可以不同；即使在同一个空间上，映射函数也可以有所区别。

5.3 正定核与再生核希尔伯特空间

核函数的使用涉及一些复杂的数学问题，其结论是：一般的核函数都是**正定核函数**（positive definite kernel）。正定核函数的充要条件是，由函数中任意数据的集合形成的**核矩阵**（kernel matrix）都是半正定的。这意味着任何一个核函数都隐式定义了一个称为**再生核希尔伯特空间**（Reproducing Kernel Hilbert Space，RKHS）的特征空间。

补充说明：判断一个二元函数能否充当核函数，依据的是 **Mercer 条件**：对任意有限个样本，由其两两函数值构成的核矩阵必须半正定。这个条件不只是理论上的一纸判据，它还带来一个实用性质——核函数对加法和数乘封闭。两个核函数的和、积、正系数线性组合仍然是核函数，因此可以把描述不同相似性的核叠加起来（例如线性核加高斯核），让模型同时捕捉全局趋势与局部结构。这正是多核学习的出发点。

六、五种常用的核函数

在支持向量机的应用中，核函数的选择是一个核心问题。不好的核函数会将样本映射到不合适的特征空间，从而导致分类性能不佳。常用的核函数包括以下几种。

6.1 各核函数的表达式

线性核（Linear Kernel）：

$$K(\mathbf{X}, \mathbf{Y}) = \mathbf{X}^{\mathrm{T}}\mathbf{Y}$$

多项式核（Polynomial Kernel）：

$$K(\mathbf{X}, \mathbf{Y}) = \left(\mathbf{X}^{\mathrm{T}}\mathbf{Y} + c\right)^{d}$$

其中 c 为常数，d ≥ 1 为多项式次数。

高斯核（Gaussian Kernel，又称 RBF 核）：

$$K(\mathbf{X},\mathbf{Y})=\exp\left(-\frac{\|\mathbf{X}-\mathbf{Y}\|^2}{2\sigma^2}\right)$$

其中 σ > 0 为高斯核的带宽。

拉普拉斯核（Laplacian Kernel）：

$$K(\mathbf{X},\mathbf{Y})=\exp\left(-\frac{\|\mathbf{X}-\mathbf{Y}\|}{\sigma}\right)$$

其中 σ > 0。

Sigmoid 核：

$$K(\mathbf{X},\mathbf{Y})=\tanh\left(\beta\mathbf{X}^{\mathrm{T}}\mathbf{Y}+\theta\right)$$

其中 β > 0，θ < 0。

6.2 如何选择核函数

核函数	表达式特征	适用场景
线性核	直接内积，无超参数	特征维度高、样本线性可分，如文本分类
多项式核	内积的 d 次幂，参数 c、d	特征间存在明确的低阶交互
高斯核	距离的指数衰减，参数 σ	通用性最强，无先验知识时的默认选择
拉普拉斯核	距离绝对值的指数衰减	数据分布比高斯核更“尖”、更稀疏
Sigmoid 核	双曲正切形式	与神经网络里的激活函数同源，某些情形等价于两层感知机

> **新手提示：σ 的作用**
>
> 高斯核中的 σ 控制“影响半径”。σ 很小，每个支持向量的影响范围就很小，模型会围绕每个点画出小圈，容易过拟合；σ 很大，影响范围过宽，模型退化成近似线性的样子，容易欠拟合。所以 σ 和惩罚参数 C 通常要一起调。

补充说明：工程实现里高斯核常被写成 $\exp(-\gamma\|X-Y\|^2)$，其中 $\gamma = 1/(2\sigma^2)$。这时 γ 越大对应 σ 越小，两者的作用方向相反，看论文或调用库函数时容易混淆，务必先确认参数的定义方式。经验做法是：样本量与特征维度都很大、且特征已经做过良好归一化时，线性核往往不输高斯核，而且训练快得多；只有在样本量中等、特征维度不高、又缺乏领域先验时，高斯核作为默认选择才真正占优。核函数一旦选定，还必须对特征做标准化，否则距离计算会被大量纲特征主导。

七、对偶问题与 SMO 算法

在实际应用中，对最优化目标函数的求解需要应用到最优化的理论。

7.1 拉格朗日对偶

如果将支持向量机的最优化作为**原始问题**（primal problem），应用最优化理论中的**拉格朗日对偶性**（Lagrange duality），可以通过求解其**对偶问题**（dual problem）得到原始问题的最优解。三种模型的参数学习都可以转化为对偶问题的求解。

对偶形式的价值有两层。一是把"关于 w、b 的带约束问题"变成"关于 N 个乘子的问题"，约束结构更整齐；二是这种结构恰好适合下文要说的 SMO。此外，在满足强对偶条件时，原始问题与对偶问题的最优值相等，可以从对偶解反推原始解。

7.2 SMO 为什么每次优化两个变量

在算法实现的过程中，支持向量机会遇到在大量训练样本下全局最优解难以求得的尴尬。目前高效实现支持向量机的主要算法是 **SMO 算法**（Sequential Minimal Optimization，序列最小最优化）。

支持向量机的学习问题可以形式化为**凸二次规划**问题的求解。SMO 算法的特点正是：不断将原始的二次规划问题分解为只有两个变量的二次规划子问题，并求解子问题的解析解，直到所有变量满足条件为止。

> **新手提示：为什么是"两个变量"**
>
> 对偶问题带有一个等式约束，所有乘子的带符号加权之和为零，即 $\Sigma \alpha_i y_i = 0$。若只挑一个变量来优化，它会被这个等式约束唯一确定，动不了。所以每次至少得放开两个变量，让它们此消彼长，才能在满足约束的同时下降目标函数。这就是 SMO 必须"成对"优化的原因。

7.3 模型只与支持向量有关

支持向量机的一个重要性质是：当训练完成后，最终模型**只与支持向量有关**，这也是"支持向量机"这个名称的来源。算法的复杂度也主要取决于支持向量的数目，而非训练样本的总数。

这个性质带来两个实际好处：

- **存储省**：预测时只需要保存支持向量，不需要保存全部训练数据；
- **速度快**：支持向量通常只占训练集的一小部分，预测时的计算量与支持向量数目成正比。

补充说明：稀疏性来自对偶问题的 **KKT 条件**。互补松弛条件要求每个样本的"拉格朗日乘子 × 约束违反量"为零：落在间隔边界之外的样本严格满足约束，乘子只能取 0，对模型毫无贡献；只有恰好落在边界上或越界的样本，乘子才非零。SMO 的收敛判据正是所有乘子都满足 KKT 条件，其外层循环也据此优先挑选违反条件最严重的样本。至于多分类，支持向量机本身只处理二分类，工程上通过一对一或一对多的组合推广，其中一对一每次只训练两类、单次规模小，在主流实现中更为常见。

补充说明：支持向量机在 2000 年前后几乎是分类任务的默认选择，但它在样本量很大时训练代价高，且不直接输出概率。深度学习的兴起让它在图像、语音等领域让出了主导地位。不过核方法并未消失：高斯核与无穷宽神经网络之间存在理论联系，核支持向量机在中小规模、高维稀疏（如文本）数据上仍是强基线，而合页损失的思想也被广泛借用到各类学习系统中。

四个常见误区

- **"核函数就是把数据映射到无穷维"**——核技巧的价值在于用内积直接算出高维空间的结果，而不必显式构造那个空间。映射的维度取决于核函数，高斯核对应的是无穷维。
- **"支持向量就是所有分错的点"**——支持向量是恰好落在间隔边界上（或违反间隔）的样本，它们决定了超平面；正确分类且远离边界的点对模型没有影响。
- **"C 越大分类越准"**——C 控制对误分类的惩罚。C 过大会让间隔变窄、对噪声敏感；C 过小则欠拟合。它是偏差与方差的调节旋钮。

- **“SVM 不需要预处理”**——它基于距离与内积，对特征尺度非常敏感。不做标准化时，量纲大的特征会主导结果。

八、要点回顾

1. 支持向量机是一种二分类算法，用高维空间中的划分超平面把样本分开，核心策略是**间隔最大化。**
2. 几何间隔是归一化后的真实距离，函数间隔是未归一化的量；约定最近样本的函数间隔为 1，是为了消掉尺度自由度。
3. 线性可分支持向量机通过**硬间隔最大化**求解，形式上是凸二次规划问题，有唯一的全局最优解。
4. 线性支持向量机通过**软间隔最大化**求解：松弛变量允许少量样本越界，惩罚参数 C 控制容忍度，C 越大越接近硬间隔。
5. 软间隔支持向量机等价于“合页损失 + L2 正则”，合页损失在间隔之外直接取 0，这正是支持向量稀疏性的来源。
6. 非线性支持向量机借助**核函数**，在低维空间计算内积、在高维空间完成划分；常用核有线性核、多项式核、高斯核、拉普拉斯核和 Sigmoid 核。
7. 正定核的充要条件是核矩阵半正定，它隐式定义了一个再生核希尔伯特空间。
8. 学习问题通过对偶形式求解，**SMO 算法**每次只优化两个乘子，反复迭代直到所有乘子满足 KKT 条件。
9. 最终模型只由**支持向量**决定——这是名字的由来，也是它存储省、预测快的原因。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
支持向量机	Support Vector Machine	SVM	通过最大化间隔在特征空间中构造划分超平面的二分类算法
超平面	Hyperplane	—	高维空间中比所在空间低一维的线性子空间，二维时是一条直线
法向量	Normal Vector	—	垂直于超平面的向量，决定超平面的方向
截距	Intercept	—	超平面方程中的常数项，决定超平面到原点的距离
几何间隔	Geometric Margin	—	样本点到超平面的归一化距离，是真实可度量的距离
函数间隔	Functional Margin	—	未归一化的距离，支持向量机中约定其下界为 1
支持向量	Support Vector	SV	恰好落在间隔边界上的样本点，唯一决定最终模型
硬间隔	Hard Margin	—	要求所有样本都被正确划分且间隔最大化的策略
软间隔	Soft Margin	—	允许少量样本违反间隔约束、以换取更强泛化能力的策略

名称	英文全称	英文缩写	简短介绍
松弛变量	Slack Variable	—	衡量单个样本违反间隔约束程度的非负变量
惩罚参数	Penalty Parameter	C	控制对误分类惩罚力度的超参数
合页损失	Hinge Loss	—	在间隔之外取零的损失函数，软间隔支持向量机的等价形式
结构风险最小化	Structural Risk Minimization	SRM	在经验风险之外加上模型容量惩罚的学习原则
VC 维	Vapnik-Chervonenkis Dimension	VC	衡量模型假设空间容量大小的指标
核技巧	Kernel Trick	—	用核函数在内积层面隐式完成高维映射的技术
核函数	Kernel Function	—	等于两样本在高维特征空间中内积的函数
正定核	Positive Definite Kernel	PD	对应核矩阵半正定的核函数，可隐式定义再生核希尔伯特空间
核矩阵	Kernel Matrix	—	由样本两两核函数值构成的对称矩阵
Mercer 条件	Mercer's Condition	—	核矩阵对任意样本集合半正定的核函数判定条件
再生核希尔伯特空间	Reproducing Kernel Hilbert Space	RKHS	由核函数隐式定义的高维特征空间
线性核	Linear Kernel	—	直接取内积的核函数，等价于不做映射
多项式核	Polynomial Kernel	—	内积加常数后取 d 次幂的核函数
高斯核	Gaussian Kernel	RBF	基于距离平方指数衰减的核函数，也称径向基核
拉普拉斯核	Laplacian Kernel	—	基于距离绝对值指数衰减的核函数
Sigmoid 核	Sigmoid Kernel	—	双曲正切形式的核函数，与两层感知机同源
多核学习	Multiple Kernel Learning	MKL	把多个核函数组合起来使用的学习方法
原始问题	Primal Problem	—	带约束的、关于模型参数的最优化问题本身
对偶问题	Dual Problem	—	由拉格朗日函数导出的、关于乘子的等价优化问题

名称	英文全称	英文缩写	简短介绍
拉格朗日对偶性	Lagrange Duality	—	把带约束的原始问题转化为对偶问题求解的理论工具
KKT 条件	Karush-Kuhn-Tucker Conditions	KKT	凸优化最优解必须满足的一组条件，含互补松弛性
凸二次规划	Convex Quadratic Programming	QP	目标函数为二次、约束为线性的凸优化问题
序列最小最优化	Sequential Minimal Optimization	SMO	每次只优化两个变量、迭代求解支持向量机的算法