集成学习：Boosting、Bagging 与随机森林

读前须知

- **前置**：决策树；偏差与方差这两个概念（机器学习概论一篇）。
- **这一篇的位置**：工业界最常用的建模手段。同样的基学习器，换一种组合方式，效果可以差一个量级。
- **读完能做什么**：说清 Bagging 与 Boosting 在“改什么”上的根本区别；解释随机森林为何不容易过拟合；用偏差—方差拆解一个集成模型的收益来源。

一、集成学习要解决什么问题

1.1 分集增益给出的启示

在无线通信中，有一种广受欢迎的传输技术叫多输入多输出（Multiple Input Multiple Output，MIMO）。它的早期配置是在发送端和接收端同时布置多个发射机和多个接收机：每个发射机发送相同的信号副本，而每个接收机则接收到来自多个发射机的不同信号，这些信号经历的衰减是相互独立的。

这样一来，在接收端多个信号同时被严重衰减的概率就会以指数形式减小，通过获得**分集增益**带来误码率的下降与信道容量的提升。

无线通信中的分集思想，在机器学习中的对应就是**集成学习**（ensemble learning）。它使用多个个体学习器来获得比每个单独学习器更好的预测性能。

1.2 为什么要整合多个假设

监督学习的任务，是通过假设空间搜索来找到能够对特定问题给出良好预测的假设。但问题是：即使这样的假设存在，能否找到也在两可之间。

因而集成学习的作用，就是将多个可以得到的假设整合为单个更好的假设。其一般结构是：

1. 先产生一组**个体学习器**（base learner）；
2. 再使用某种策略将它们加以整合。

1.3 同质集成与异质集成

每个组中的个体学习器，如果属于同一类型（比如都是线性回归，或者都是决策树），形成的就是**同质集成**（homogeneous ensemble）；相应地，由不同类型学习器得到的集成则称为**异质集成**（heterogeneous ensemble）。

类型	个体学习器	常见算法	特点
同质集成	全部同一种模型	随机森林、AdaBoost、GBDT	研究与应用的主流，便于统一训练与理论分析
异质集成	不同类型模型混合	投票法、堆叠法（Stacking）	可利用不同模型的归纳偏置互补

补充说明：集成学习能在理论上成立，靠的是计算学习理论中的一条经典结论：**弱可学习等价于强可学习**。如果某个问题存在仅略优于随机猜测的弱学习算法，那么它一定存在多项式时间内的强学习算法。Schapire 在 1990 年用构造性方法证明了这一点，而这个构造正是 Boosting 的雏形。这条结论解释了为什么“用一堆粗糙规则拼出精细规则”不是碰运气，而是有理论保证的做法。

二、多样性与准确性之间的折中

2.1 两个前提

直观来看，性能优劣不一的个体学习器放在一块儿，可能产生的是更加中庸的效果，即比最差的要好，也比最好的要差。那么集成学习如何实现“1 + 1 > 2”呢？这其实是对个体学习器提出了两点要求。

第一，个体学习器的性能要有一定的保证。 如果每个个体学习器的分类精度都不高，在集成时错误的分类结果就可能占据多数，导致集成学习的效果甚至会劣于原始的个体学习器，正如俗语所言“和臭棋手下棋，越下越臭”。

第二，个体学习器的性能要有一定的差异。 和而不同才能取得进步。**多样性**（diversity）是不同的个体学习器性能互补的前提。

> **新手提示：多样性和分集是同一个词**
>
> MIMO 里的“分集”和机器学习里的“多样性”，英文都是 diversity。在 MIMO 中，一个重要的前提条件是不同信号副本传输时经历的衰减要相互独立；同样的原则在机器学习中体现为个体学习器的**误差相互独立**。

2.2 折中从哪里来

由于个体学习器是为了解决相同问题训练出来的，要让它们的性能完全独立，着实是勉为其难。尤其是当个体学习器的准确性较高时，要获得多样性就不得不以牺牲准确性作为代价。

由此，集成学习的核心问题在于：**在多样性和准确性之间做出折中**，进而产生并结合各具优势的个体学习器。同一批数据、同一个假设空间，想让个体学习器既准又各不相同，只能靠对训练过程注入扰动——扰动样本、扰动属性、扰动权重，这正是后面各种算法分野的根源。

补充说明：多样性可以用**误差—分歧分解**（error-ambiguity decomposition）量化。对平方损失而言，集成后的误差等于个体学习器的加权平均误差减去加权平均分歧。分歧越大，集成效果越好。这条式子把“多样性有用”从直觉变成了可计算的量，但它也揭示了一重限制：平均误差本身不能太大，否则分歧再多也补不回来——这正是准确性前提的数学表达。

三、两种数据使用机制：Boosting 与 Bagging

3.1 序列化与并行化

个体学习器的生成方式，很大程度上取决于数据的使用策略。根据训练数据使用方法的不同，集成学习方法可以分为两类：

- **序列化方法**：个体学习器之间存在强依赖关系，因而必须串行生成；
- **并行化方法**：个体学习器之间不存在强依赖关系，因而可以同时生成。

3.2 Boosting：重复使用全量数据

序列化方法中的数据使用机制被称为**提升**（Boosting），其基本思路是对所有训练数据进行多次重复应用，每次应用前需要对样本的概率分布做出调整，以达到不同的训练效果。

3.3 Bagging：拆分子集独立训练

与 Boosting 相比，并行化方法中的数据使用机制是将原始的训练数据集拆分成若干（可重叠的）自助采样子集，再根据每个子集独立地训练出不同的个体学习器。这种方法被称为**自助聚合**（Bootstrap AGgregation），简称**打包**（Bagging）。

在 Bagging 机制中，不同个体学习器之间的多样性容易得到保证；但由于每个个体学习器只能使用一小部分数据进行学习，其效果就容易出现断崖式下跌。

3.4 自助采样与包外估计

在基于训练数据集生成样本的子集时，Bagging 采用的是**放回抽样**（有放回采样）的策略，即某些样本可能出现在不同的子集之中，而另外某些样本可能没有出现在任何子集之内。

计算未被抽取概率的极限，可以得到：

$$\lim_{m\to\infty}\left(1-\frac{1}{m}\right)^m=\frac{1}{e}\approx 0.368$$

也就是说，放回抽样会导致 **36.8%** 的训练数据没有出现在采样数据集中。

这些未使用的数据没有参与个体学习器的训练，但可以作为验证数据集，用于对学习器的泛化性能做出**包外估计**（out-of-bag estimate，OOB）。包外估计得到的泛化误差已被证明是真实值的**无偏估计**。

> **新手提示：为什么 36.8% 是个好数字**
>
> 一个样本在一次抽样中不被抽到的概率是 1 − 1/m，抽 m 次都不被抽到的概率就是 (1 − 1/m)^m，其极限正是 1/e。这个“没用上”的 36.8% 看似浪费，实则白送了一份从未参与训练的验证集——不用额外切分数据，就能评估泛化性能。

补充说明：Bagging 之所以能降方差，可以用一个简化模型看清。若 m 个个体学习器的方差各为 σ^2、两两相关系数为 ρ，则集成后的方差约为 $\rho\sigma^2 + (1-\rho)\sigma^2/m$。增加基学习器数量只能让第二项趋于零，第一项却由相关性 ρ 牢牢压住。这说明**单纯堆数量并不能消除相关性带来的误差下限**，随机森林引入属性随机，正是为了把 ρ 压下去。

四、AdaBoost 的两个核心问题

典型的序列化学习算法是**自适应提升方法**（Adaptive Boosting），通常简称 **AdaBoost**。

在解决分类问题时，提升方法遵循的是循序渐进的原则：先通过改变训练数据的权重分布，训练出一系列具有粗糙规则的**弱个体分类器**，再基于这些弱分类器进行反复学习和组合，构造出具有精细规则的**强分类器**。

从以上的思想中不难看出，AdaBoost 要解决两个主要问题：

1. **训练数据权重调整的策略**；
2. **弱分类器结果的组合策略**。

4.1 权重调整：专项整治

在训练数据的权重调整上，AdaBoost 采用“专项整治”的方式：在每一轮训练结束后，**提高分类错误的样本权重，降低分类正确的样本权重**。

因此在下一轮次的训练中，弱分类器就会更加重视错误样本的处理，从而得到性能的提升。这就像一个学生在每次考试后专门再把错题重做一遍，有针对性地弥补不足。

虽然训练数据集本身没有变化，但不同的权重使数据在每一轮训练中发挥着不同的作用。

4.2 结果组合：加权线性叠加

在 AdaBoost 的弱分类器组合中，每一轮得到的学习器结果都会按照一定比例叠加到前一轮的判决结果上，并参与到下一轮次权重调整之后的学习器训练中。

当学习的轮数达到预先设定的数目 T 时，最终分类器的输出就是 T 个个体学习器输出的**线性组合**：

$$H(\mathbf{x}) = \operatorname{sign}\left(\sum_{t=1}^{T} \alpha_t h_t(\mathbf{x})\right)$$

每个个体学习器在最终输出中的权重，与其分类错误率相关：个体学习器的分类错误率越低，其在最终分类器中起到的作用就越大。

$$\alpha_t = \frac{1}{2}\ln\frac{1-e_t}{e_t}$$

其中 e_t 是第 t 个弱分类器的加权错误率。e_t 越小，$(1-e_t)/e_t$ 越大，α_t 也就越大。

但需要注意的是，所有个体学习器的权重之和并不要求等于 1。

> **新手提示：错误率超过 50% 会怎样**
>
> 若 $e_t > 0.5$，则 $\alpha_t < 0$，该弱分类器在最终投票中相当于被“反着用”。这并不荒唐：一个总是分错的分类器，把它的结论取反就是一个不错的分类器。但如果 $e_t = 0.5$，$\alpha_t = 0$，它对结果毫无影响，因为它的判断等同于随机猜。

4.3 “自适应”体现在哪里

随着训练过程的深入，弱学习器的训练重心会自行调整到被当前分类器错误分类的样本上，因而每一轮次的模型都会根据之前轮次模型的表现结果进行调整——这就是 AdaBoost 名字中“**自适应**”（adaptive）的来源。

补充说明：AdaBoost 有一个漂亮的理论保证——训练集上的指数损失随轮数持续下降，其分类误差的上界为 $\exp(-2\Sigma\gamma_t^2)$，其中 γ_t 是第 t 轮弱分类器的边缘（即 0.5 减去错误率）。只要每一轮的弱分类器都比随机猜测略好一点，γ_t 就恒为正，上界便随轮数指数衰减。这就是“弱学习器能拼出强学习器”的具体速率。不过这个保证只针对训练误差，轮数过多仍会过拟合，实践中同样需要早停或限制轮数。

五、换个视角：加法模型 + 指数损失 + 前向分步

5.1 加法模型

前面介绍的是 AdaBoost 的执行策略。换个视角来看，AdaBoost 可以视为：**使用加法模型，以指数函数作为损失函数，使用前向分步算法的二分类学习方法。**

$$H(\mathbf{x}) = \sum_{t=1}^{T} \alpha_t h_t(\mathbf{x})$$

加法模型反映出 AdaBoost 以个体学习器的线性组合作为最终分类器的特性。

5.2 指数损失

指数损失函数衡量的是预测与真实标记之间的偏差：

$$\ell_{\exp}(H \mid \mathcal{D}) = \mathbb{E}_{\mathbf{x}\sim\mathcal{D}}\left[e^{-yH(\mathbf{x})}\right]$$

5.3 前向分步算法

在这个模型下求解指数型损失函数的最小值是个复杂的问题，但可以通过每次只学习线性组合其中的一项来简化处理，这种方法就是**前向分步算法**（forward stagewise algorithm）。

前向分步算法学习基函数的过程，和 AdaBoost 学习个体学习器的过程是一致的——每一步都在已有模型的基础上，找一个最优的基学习器与系数补上去，而不去动已经确定的那些项。

> **新手提示：这个视角有什么用**
>
> 一旦把 AdaBoost 看成"加法模型 + 指数损失 + 前向分步"，就可以很自然地推广：把指数损失换成平方损失，就得到梯度提升回归；换成任意可微损失并对负梯度做拟合，就得到梯度提升决策树（GBDT）。现代工业界常用的 XGBoost、LightGBM，都是沿着这条路线长出来的。

补充说明：把指数损失换成任意可微损失，前向分步的每一步就变成"用基学习器去拟合损失的负梯度"，这就是**梯度提升**（gradient boosting）。若进一步对损失做二阶泰勒展开，就得到 XGBoost 一类实现；若用直方图分桶加速分裂点搜索，则是 LightGBM 的做法。需要注意的是，梯度提升对学习率和树深度都很敏感：学习率调小通常能换来更好的泛化，但需要更多轮数，两者的乘积大致决定了模型的有效容量。

六、随机森林：双重随机的集成

典型的并行化学习方法是**随机森林**（random forest）。正所谓"独木不成林"，随机森林就是对多个决策树模型的集成。"随机"的含义体现在两方面。

6.1 样本随机

每个数据子集中的样本是在原始的训练数据集中随机抽取的（自助采样）。

6.2 属性随机

在决策树生成的过程中引入了随机的属性选择。每棵决策树在选择划分属性时，首先从结点的属性集合中随机抽取出包含 k 个属性的一个子集，再在这个子集中选择最优的划分属性生成决策树。

为什么要执行随机的属性选择呢？ 其目的在于保证不同基决策树之间的多样性。如果某一个或几个属性对输出的分类结果有非常强的影响，那么很可能所有不同的个体决策树都选择了这些属性，这将导致不同子集上训练出的个体决策树呈现出众口一辞的同质性，对原始训练样本的有放回随机抽取也就失去了意义。

在这个意义上，随机特征选取是对集成学习算法中多样性的一重保护措施。

6.3 合成策略

在合成策略上，随机森林通常采用**少数服从多数**的策略，选择在个体决策树中出现最多的类别标记作为最终的输出结果。当数据较多时，也可以采用更加强大的学习法，即通过另一个单独的学习器实现复杂合成策略的学习。

> **新手提示：k 怎么取**
>
> 属性子集大小 k 是随机森林的主要超参数。k 越小，单棵树越弱但树间差异越大；k 越大，单棵树越强但树间越相似。分类任务的经验起点是 $k \approx \sqrt{n}$（n 为属性总数），回归任务常用 $k \approx n/3$。随机森林是罕有的具有强通用性的机器学习方法，能够以较小的计算开销在多种现实任务中展现出强大的性能。

补充说明：随机森林的袋外样本还有第二个用途——估计**特征重要性**。把某个特征在所有树上的取值打乱，观察袋外误差上升多少，上升越多说明该特征越关键。这种置换重要性不依赖模型内部的划分准则，比基于不纯度的快速估计更可靠。另外，若把随机性再推进一步——每个节点在随机选出的特征子集上再随机挑一个切分阈值——得到的就是**极限随机树**（Extra-Trees），它训练更快、方差更低，代价是偏差略有上升。

七、Boosting 降偏差，Bagging 降方差

数据使用机制的不同，在泛化误差的构成上也有体现。

对比项	Boosting（序列化）	Bagging（并行化）
数据使用	每轮使用全量数据，仅改变权重分布	每轮使用自助采样的子集
个体关系	强依赖，必须串行	弱依赖，可以并行
主要作用	降低**偏差**（bias）	降低**方差**（variance）
对异常点	较敏感，异常点会被反复加权	较稳健，异常点可能不入样
典型算法	AdaBoost、GBDT、XGBoost	随机森林、Bagging + 决策树

以 Boosting 方法为代表的序列化方法使用了全体训练数据，并根据每次训练的效果不断迭代以使损失函数最小化，因而可以降低平均意义上的偏差，能够基于泛化能力较弱的学习器构建出较强的集成。

以 Bagging 方法为代表的并行化方法则利用原始训练数据生成若干子集，因而受异常点的影响较小；对在每个子集上训练出的不完全相关的模型取平均，也有助于平衡不同模型之间的性能，因而可以一定程度上降低方差。

补充说明：还有第三类集成策略——**堆叠法**（stacking）。它不局限于对个体学习器的输出做投票或平均，而是把它们的输出当作新的特征，再训练一个元学习器来决定如何组合，异质集成常走这条路。代价是必须严格用交叉验证生成元特征，否则元学习器会看到个体学习器在训练集上的"作弊"输出，导致严重过拟合。此外，随机森林的每棵树都可以长到很深而不过多剪枝，正是因为它把"单棵树的高方差"交给了集成平均去抵消。

四个常见误区

- **"随机森林的树越多越准"**——准确率随树数增加而上升，但很快饱和；继续加树只增加计算与内存。通常几百棵就足够。
- **"Bagging 与 Boosting 可以随便换"**——Bagging 主要降方差，适合强但不稳的基学习器；Boosting 主要降偏差，适合弱学习器。用反了效果会很差。
- **"Boosting 一定比 Bagging 强"**——Boosting 对噪声与离群点敏感，数据脏时反而不如随机森林稳健。
- **"集成模型完全不可解释"**——树模型可以用特征重要性、部分依赖图做整体解释；难解释的是具体某一条预测的完整推导。

八、要点回顾

1. 集成学习使用多个个体学习器来获得比每个单独学习器更好的预测性能，包括序列化方法和并行化方法两类。
2. **多样性**要求集成学习中的不同个体学习器之间具有足够的差异性；它与准确性是一对需要折中的矛盾。

3. 序列化方法采用 **Boosting** 机制，通过重复使用概率分布不同的训练数据实现集成，可以降低泛化误差中的**偏差**。
4. 并行化方法采用 **Bagging** 机制，通过在训练数据中多次自助抽取不同的采样子集实现集成，可以降低泛化误差中的**方差**。
5. 自助采样使约 36.8% 的样本从未入样，这部分数据可直接用于**包外估计**，得到泛化误差的无偏估计。
6. AdaBoost 的两个核心是样本权重调整与弱分类器加权组合；弱分类器的权重由对数几率式的 α_t 决定，错误率越低权重越大。
7. AdaBoost 等价于加法模型下的指数损失最小化，可用**前向分步算法**求解；换成任意可微损失并把指数损失替换掉，就有了梯度提升。
8. 随机森林在 Bagging 的基础上再加一重属性随机，以双重随机保护多样性，同时还附带袋外误差与特征重要性两项诊断能力。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
集成学习	Ensemble Learning	—	组合多个个体学习器以获得更优预测性能的方法
个体学习器	Base Learner	—	集成中所使用的基本模型，也称基学习器
同质集成	Homogeneous Ensemble	—	所有个体学习器属于同一类型的集成
异质集成	Heterogeneous Ensemble	—	由不同类型个体学习器构成的集成
多样性	Diversity	—	个体学习器之间误差相互独立的程度，是性能互补的前提
误差—分歧分解	Error-Ambiguity Decomposition	—	把集成误差拆成平均误差与平均分歧之差的恒等式
提升	Boosting	—	串行生成个体学习器、每轮调整样本分布的数据使用机制
自助聚合	Bootstrap Aggregation	Bagging	并行生成个体学习器、每个使用自助采样子集的数据使用机制
自助采样	Bootstrap Sampling	—	有放回地从训练集中抽取等量样本的采样方式
包外估计	Out-of-Bag Estimate	OOB	用未被采样的约 36.8% 数据评估泛化性能的无偏估计
自适应提升	Adaptive Boosting	AdaBoost	每轮提高错分样本权重、按错误率加权组合的 Boosting 算法
弱分类器	Weak Classifier	—	性能仅略优于随机猜测的个体分类器

名称	英文全称	英文缩写	简短介绍
强分类器	Strong Classifier	—	由多个弱分类器组合而成、性能显著提升的分类器
加法模型	Additive Model	—	将多个基函数线性叠加而成的模型形式
指数损失	Exponential Loss	—	形如 exp(−yH(x)) 的损失函数，AdaBoost 的等价目标
前向分步算法	Forward Stagewise Algorithm	—	每步只优化加法模型中一项的贪心求解策略
梯度提升	Gradient Boosting	GB	每步用基学习器拟合损失负梯度的加法模型训练框架
梯度提升决策树	Gradient Boosting Decision Tree	GBDT	以负梯度拟合残差、逐棵叠加决策树的 Boosting 框架
随机森林	Random Forest	RF	对样本与属性双重随机采样后集成多棵决策树的算法
极限随机树	Extremely Randomized Trees	Extra-Trees	每个节点只用随机选出的单个特征切分的随机森林变体
堆叠法	Stacking	—	用元学习器组合多个个体学习器输出的异质集成策略
偏差	Bias	—	模型期望输出与真实结果的偏离程度，反映拟合能力
方差	Variance	—	模型对训练集扰动的敏感程度，反映稳定性