聚类分析：距离度量、k 均值与 DBSCAN

读前须知

- **前置**：向量、范数与距离的定义。
- **这一篇的位置**：无监督学习的第一站。没有标签时，我们只能靠“彼此有多像”来组织数据。
- **读完能做什么**：写出 k 均值的目标函数与迭代步骤；解释它为什么对初始点和尺度敏感；判断什么形状的数据该用 DBSCAN 而不是 k 均值。

一、先划分数据，再确定类别

1.1 聚类与分类的分野

聚类分析是一种**无监督学习方法**，其目标是学习**没有分类标记**的训练样本，以揭示数据的内在性质和规律。

具体来说，聚类分析要将数据集划分为若干个互不相交的子集，每个子集中的元素在某种度量之下，都与本子集内的元素具有更高的相似度。用这种方法划分出的子集就是**聚类**（也称为“簇”，cluster），每个聚类都代表了一个潜在的类别。

分类和聚类的区别也正在于此：

对比项	分类	聚类
学习方式	监督学习	无监督学习
是否有标记	训练样本带类别标记	训练样本无类别标记
划分顺序	先确定类别，再划分数据	先划分数据，再确定类别
典型算法	逻辑回归、SVM、决策树	k 均值、DBSCAN、层次聚类

1.2 聚类要回答的两个问题

聚类分析本身并不是具体的算法，而是要解决的一般任务。从名称就可以看出这项任务的两个核心问题：

1. 如何判定哪些样本属于同一“类”？
2. 怎么让同一类的样本“聚”在一起？

前一个问题归结为相似性的度量，后一个问题归结为算法的设计。下文的结构也按这两条线索展开。

1.3 四大类型总览

目前公开发表的聚类算法已经超过了 100 种，但无监督学习的特性决定了不可能存在通用的聚类算法。根据应用场景的差别，不同算法在组成聚类的概念以及有效找到聚类的方法上也会有所区别。针对某种模型设计的算法，在其他模型的数据集上表现得一塌糊涂，也不是什么新鲜事。

类型	别称	对“聚类”的定义	典型算法
层次聚类	基于连接的聚类	不同距离水平上连通的一组样本	会聚式层次聚类

类型	别称	对“聚类”的定义	典型算法
原型聚类	基于质心的聚类	围绕某个中心向量的一组样本	k 均值
分布聚类	基于概率模型的聚类	最可能属于同一分布的一组样本	期望极大算法（EM）
密度聚类	基于密度的聚类	由密度可达关系导出的最大密度相连集合	DBSCAN

1.4 从性格研究到通用方法

20 世纪 40 年代，美国心理学家**罗伯特·泰昂**（Robert Tryon）和**雷蒙德·卡泰尔**（Raymond Cattell）借鉴人类学中的研究方法，提出“聚类分析”的概念，通过从相关矩阵中提取互相关的成分进行性格因素的研究。

随着时间的推移，聚类分析的应用范围越来越广泛，逐渐演化成一种主要的机器学习方法。

补充说明：聚类没有标签，所以“对不对”无法直接判定，只能退而问“好不好”。评价指标分两类：**外部指标**把聚类结果与某个参考划分做比较（如兰德指数、Jaccard 系数），只在有真值时可用；**内部指标**只看聚类本身的紧致与分离程度（如轮廓系数、DB 指数）。这也意味着同一个数据集上，不同指标常常给出不同的最优 k——所谓“最佳聚类数”从来不是数据的客观属性，而是评价标准与业务目标共同定义的。

二、相似性怎么度量：距离

解决“哪些样本属于同一类”的问题，需要对**相似性**进行度量。无论采用何种划定标准，聚类分析的原则都是：**让类内样本之间的差别尽可能小，而类间样本之间的差别尽可能大。**

度量相似性最简单的方法，就是引入**距离测度。**聚类分析正是通过计算样本之间的距离来判定它们是否属于同一个“类”。

根据线性代数的知识，如果每个样本都具有 N 个特征，那就可以将它们视为 N 维空间中的点，进而计算不同点之间的距离。

2.1 距离的四条性质

作为数学概念的距离，需要满足以下性质：

- **非负性**：距离不小于 0；
- **同一性**：任意点与其自身之间的距离为 0；
- **对称性**：交换点的顺序不改变距离；
- **直递性**：满足三角不等式，即经由第三点的路径不会比直达更短。

> **新手提示：三角不等式为何重要**
>
> 三角不等式保证了“绕路不可能更近”。它是很多聚类与近邻算法的效率基石：它给出下界 $d(A,C) \geq |d(A,B) - d(B,C)|$，一旦这个下界已经超过当前的搜索半径，就能直接排除 A 与 C 相近的可能，从而省掉大量距离计算。

2.2 闵可夫斯基距离族

在聚类分析中常用的距离是**闵可夫斯基距离**（Minkowski distance），其定义为：

$$\mathrm{dist}_{\mathrm{mk}}\left(\mathbf{x}_i, \mathbf{x}_j\right) = \left(\sum_{n=1}^{N} \left|x_{in} - x_{jn}\right|^p\right)^{\frac{1}{p}}$$

式中的 p 是个常数。当 p = 2 时，闵可夫斯基距离就变成了**欧式距离**，也就是通常意义上的长度：

$$\mathrm{dist}_2\left(\mathbf{x}_i, \mathbf{x}_j\right) = \sqrt{\sum_{n=1}^{N} \left(x_{in} - x_{jn}\right)^2}$$

当 p = 1 时是**曼哈顿距离**，当 p → ∞ 时则退化为各维差值的最大绝对值，即**切比雪夫距离**。三者构成一个由 p 控制的连续谱：p 越大，距离越被单维最大差异所主导。

补充说明：距离的选择会实质改变聚类结果，因为“相似”的定义本身就写在这个距离里。几个常用替代方案如下。**马氏距离**用协方差矩阵做归一化，能消除特征相关性与量纲差异；**余弦相似度**只看向量夹角、忽略长度，适合文本这类以方向而非幅值表达语义的数据；**Jaccard 系数**面向集合型特征，计算交集与并集之比。若特征量纲悬殊又直接使用欧式距离，数值大的特征会单方面主导结果，所以聚类前一般都要先做标准化。

三、层次聚类：在不同的距离水平上切一刀

层次聚类又被称为**基于连接的聚类**，其核心思想源于：样本应当与附近而非远离的样本具有更强的相关性。

由于聚类生成的依据是样本之间的距离，因而聚类的特性可以用聚类内部样本之间的距离尺度来刻画。聚类的划分是在不同的距离水平上完成的，划分过程就可以用**树状图**（dendrogram）来描述，这也解释了“层次聚类”这个名称的来源。

3.1 会聚与拆分

层次聚类对数据集的划分，既可以采用自顶向下的**拆分策略**，也可以采用自底向上的**会聚策略**，后者是更加常用的方法。

在采用会聚策略的层次聚类算法中：

1. 数据集中的每个样本都被视为一个初始聚类；
2. 算法每执行一步，就将距离最近的两个初始聚类合并；
3. 这个过程一直重复到合并后的数目达到预设数为止。

3.2 三种链接准则

根据距离计算方式的不同，会聚算法可以分为**单链接算法**、**全链接算法**和**均链接算法**等：

算法	使用的距离	由什么决定
单链接	最小距离	两个不同聚类中相距**最近**的样本
全链接	最大距离	两个不同聚类中相距**最远**的样本
均链接	平均距离	两个不同聚类中的**所有**样本共同决定

> **新手提示：单链接的“链式效应”**

> 单链接只看最近的一对点，因此只要两个簇之间有一条稀疏的“桥”连着，它就会把两者合并，容易产生细长的、串成一串的聚类。全链接则要求最远的一对点也足够近，倾向产生紧凑的球形簇。均链接介于两者之间，是更稳健的默认选择。

补充说明：会聚式层次聚类的时间复杂度通常是 $O(n^3)$，样本上万就难以承受；空间上还要保存 n^2 的距离矩阵。改进思路有两类：一是先用 k 均值之类的方法把数据压缩成少量代表点，再对代表点做层次聚类，这正是 BIRCH 的思路；二是借助空间索引或最近邻图，把每轮“找最近两簇”的代价降下来。另外，单链接对噪声和桥接极其敏感，实践中若没有形状上的先验，均链接或 Ward 方法更稳妥。

四、原型聚类与 k 均值

原型聚类又被称为**基于质心的聚类**，其核心思想是：每个聚类都可以用一个**质心**（centroid）表示。

原型聚类将给定的数据集初始分裂为若干聚类，每个聚类都用一个中心向量来刻画，然后通过反复迭代来调整聚类中心和聚类成员，直到每个聚类不再变化为止。

4.1 把聚类变成最优化问题

k 均值（k-means）算法是典型的原型聚类算法，它将聚类问题转化为最优化问题。

具体做法是：先找到 k 个聚类中心，并将所有样本分配给最近的聚类中心，分配的原则是让所有样本到其聚类中心的**距离平方和**最小：

$$E = \sum_{i=1}^{k} \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|_2^2$$

其中 C_i 表示第 i 个聚类，μ_i 表示它的中心向量。

显然，距离平方和越小，意味着每个聚类内样本的相似度越高。但是这个优化问题没有办法精确求解，因而只能搜索近似解。k 均值算法就是利用**贪心策略**，通过迭代优化来近似求解最小平方和的算法。

4.2 计算过程

k 均值算法的计算过程非常直观。

1. **初始化**：从数据集中随机选取 k 个样本，作为 k 个聚类各自的中心；
2. **分配**：对其余样本分别计算它们到这 k 个中心的距离，并将样本划分到离它最近的中心所对应的聚类中；
3. **更新**：当所有样本的聚类归属都确定后，再计算每个聚类中所有样本的算术平均数，作为聚类新的中心：

$$\boldsymbol{\mu}_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$$

4. **迭代**：将所有样本按照 k 个新的中心重新聚类，重复“取平均 → 重新计算中心 → 重新聚类”的过程，直到聚类结果不再变化为止。

> **新手提示：k 均值为什么一定会停下来**
>
> 每一步操作（重新分配样本、重新计算中心）都不会让距离平方和 E 增大，而 E 的取值组合是有限的，所以算法不可能无限下降，必然在有限步内稳定到一个局部最优。但它只是一定会停，并不保证停在全局最优——初始化不同，结果可能不同，这也是实践中要跑多次取最优的原因。

4.3 两个主要缺点

第一，需要预先指定聚类数目 k。 大多数 k 均值类型的算法需要预先指定 k，这是算法为人诟病的一个主要因素。

第二，倾向于划分出相似大小的聚类。 由于算法优化的对象是每个聚类的中心，因而 k 均值算法倾向于划分出相似大小的聚类，这会降低聚类边界的精确性。

补充说明：这两个短板都有成熟的补救。初始化敏感可以用 **k-means++**：第一个中心随机选，后续每个中心按"到已有中心距离平方"成正比的概率抽取，使初始中心尽量分散，理论上能把近似比从无界降到 O(log k)。k 的选择常用**肘部法**（画出 k 与距离平方和 E 的曲线，找拐点）或**轮廓系数**（衡量样本与本簇的紧致度相对于与最近邻簇的分离度），但两者都只是启发式。数据量大时还可以用小批量版本，每次只用一小批样本更新中心，用少量精度换数量级的提速。

五、分布聚类与 EM 算法

分布聚类又被称为**基于概率模型的聚类**，其核心思想是：假定隐藏的类别是数据空间上的一个**分布**。

在分布聚类中，每个聚类都是最可能属于同一分布的对象的集合。这种聚类方式类似于数理统计中获得样本的方式，也就是每个聚类都由在总体中随机抽取的独立同分布样本组成。

其缺点则在于：无法确定隐含的概率模型是否真的存在，因而常常导致过拟合的发生。

5.1 逆向思考

聚类分析的任务原本是将数据划分到不同的聚类中。可如果我们将样本看作**观察值**，将潜在类别看作**隐藏变量**，那么就可以逆向认为：数据集是由不同的聚类产生的。

在这个前提下，基于概率模型的聚类分析的任务是：推导出最可能产生已有数据集的 k 个聚类，并度量这 k 个聚类产生已有数据集的**似然概率**。

基于概率模型的聚类实质上就是进行**参数估计**：估计出聚类的参数集合，以使似然函数最大化。

5.2 期望步与最大化步

期望极大算法（Expectation Maximization algorithm，EM）是典型的基于概率模型的聚类方法。EM 算法是一种迭代算法，用于含有不可观察的隐变量的概率模型中，在这种模型下对参数做出极大似然估计，因而可以应用在聚类分析之中。

EM 算法执行的过程包括"期望"和"最大化"两个步骤：

1. 将待估计分布的参数值**随机初始化**；
2. **期望步**（E 步）：利用初始参数来估计样本所属的类别（即计算隐变量的后验概率）；
3. **最大化步**（M 步）：利用估计结果求取当似然函数取得极大值时，对应参数值的取值；
4. 两个步骤不断迭代，直到收敛为止。

> **新手提示：E 步和 M 步在轮流猜**
>
> 可以把它想成"先猜归属，再改参数"：既然不知道每个点属于哪个簇，就先按当前参数算一个"软归属"（E 步）；既然有了归属，就按归属重新估计参数（M 步）。如此反复，似然只会升不会降，最终收敛到一个局部极大值。

补充说明：高斯混合模型与 k 均值的关系可以看得很清楚。若各分量的协方差矩阵都取 $\sigma^2 I$ 并让 σ 趋于 0，E 步的后验概率会退化成 0/1 的硬分配，M 步的均值更新就变成簇内求平均——EM 就此退化为 k 均值。反过来说，k 均值是高斯混合模型的一个极端特例：它假设每个簇是各向同性的球，且归属非此即彼。放宽这两条假设，就得到软分配与可伸长的椭圆簇，代价是要估计更多参数，也更容易陷入局部极

大。

六、密度聚类与 DBSCAN

密度聚类又被称为**基于密度的聚类**，其核心思想是：样本分布的**密度**能够决定聚类结构。

每个样本集中分布的区域都可以看作一个聚类，聚类之间由分散的噪声点区分。密度聚类算法根据样本密度考察样本间的**可连接性**，再基于可连接样本不断扩展聚类以获得最终结果。

最流行的基于密度的聚类方法，是利用噪声的基于密度的空间聚类（Density-Based Spatial Clustering of Applications with Noise），简称 **DBSCAN**。

6.1 几个核心概念

DBSCAN 通过将距离在某一个阈值之内的点连接起来而形成聚类，但连接的对象只限于满足密度标准的点。

ε-邻域（ε-neighborhood）给出了对邻域的限制：

$$N_\epsilon(\mathbf{x}) = \{\mathbf{y} \in D \mid \mathrm{dist}(\mathbf{x}, \mathbf{y}) \leq \epsilon\}$$

密度的可连接性，则通过以下一系列标准定义：

- **核心点**：ε-邻域内至少包含 MinPts 个样本的点；
- **密度直达**：若点 q 落在核心点 p 的 ε-邻域内，则 q 由 p 密度直达；
- **密度可达**：存在一串点，相邻两点满足密度直达，则首尾两点密度可达；
- **密度相连**：若存在点 o，使 p 与 q 都由 o 密度可达，则 p 与 q 密度相连。

根据这些概念形成的聚类，就是由密度可达关系导出的**最大的密度相连样本集合**。

6.2 参数怎么定

> **新手提示：DBSCAN 好在哪**
>
> 它不需要预先指定聚类数目，能自动识别噪声点（不属于任何簇的点），而且能发现任意形状的簇——不像 k 均值那样只擅长球状簇。代价是要给定 ε 和 MinPts，而 ε 的取值对结果相当敏感。

补充说明：DBSCAN 的 ε 不能凭感觉定，常用 **k-距离曲线**辅助：对每个点算出它到第 k 近邻的距离（k 一般取 MinPts），把这些距离升序排列画成曲线，拐点处对应的值就是合适的 ε。DBSCAN 在无索引时的时间复杂度是 $O(n^2)$，建了空间索引后接近 $O(n \log n)$，但维度一高索引就会失效。它还有一个短板：当不同簇的密度差异很大时，单一 ε 无法同时适配，**OPTICS** 通过给每个点记录"可达距离"并排序，把密度参数变成一条可变的曲线，缓解了这个问题。

七、其他方法与典型应用

根据思想的不同，聚类方法主要包括以上的四种类型，每种类型上也有其典型算法。

7.1 谱聚类与模糊聚类

传统方法之外，现代聚类方法还包括**谱聚类**和**模糊聚类**等。

谱聚类把样本看作图的顶点、把相似度看作边的权重，先求图的拉普拉斯矩阵的低维特征向量，再在特征空间中做一次简单的聚类。它的优势是能识别非凸形状的簇，且与降维有天然联系；代价是要构造 n×n 的相似度矩阵，样本量大时开销可观。

模糊聚类则放弃“非此即彼”的归属，允许一个样本以不同的隶属度同时属于多个簇。它给出的是一张隶属度矩阵而非硬划分，在边界模糊的场景（如图像分割）中更符合实际。

7.2 用户画像

聚类分析在工业界最典型的落地场景就是**用户画像**。

在商业应用中判别新用户的类型时，往往要先对用户进行**聚类分析**，再根据聚类分析的结果训练**分类模型**，用于用户类型的判别。聚类使用的特征通常包括人口学变量、使用场景、行为数据等。

> **新手提示：无监督就没有标准答案**
>
> 由于无监督学习的特性，在评估聚类方法时不存在绝对客观的标准。尤其是在数据多样化、高维化、非均衡化的趋势下，评价聚类方法的难度甚至超出了设计聚类方法的难度。实践中通常用轮廓系数等内部指标，或借助下游任务的效果来间接判断。

补充说明：用户画像的典型流程是“先聚类、后分类”——拿一批已有用户的行为与属性做聚类，人工给每个簇起一个有业务含义的名字，这些名字就成了伪标签；再用分类模型学习“什么样的用户会落进这个簇”，从而给新用户实时打标。这个范式之所以流行，是因为它把无监督发现与有监督预测接了起来，既省掉了昂贵的人工标注，又保留了线上预测的速度。需要注意的是，簇的语义必须由人来解释，聚类算法本身不会告诉你“这是一群价格敏感型用户”。

四个常见误区

- **“k 均值什么数据都能聚”**——它隐含假设簇是凸的、大小相近、方差相似。遇到月牙形或同心环数据，它会把簇切错，此时应换 DBSCAN 或谱聚类。
- **“肘部法总能给出明确的 k”**——肘部有时非常平缓，看不出拐点。实践中还要结合业务含义与轮廓系数。
- **“聚类有唯一正确答案”**——聚类是无监督任务，类别由距离定义与算法假设共同决定，换一种度量就可能得到另一套合理的划分。
- **“DBSCAN 不需要调参”**——eps 与 minPts 直接决定哪些点算噪声，特征尺度不同时还必须先标准化。

八、要点回顾

1. 聚类分析是一种**无监督学习方法**，通过学习没有分类标记的训练样本，发现数据的内在性质和规律。
2. 数据之间的相似性通常用**距离**度量；类内差异应尽可能小，类间差异应尽可能大。
3. 距离需要满足非负性、同一性、对称性与直递性；闵可夫斯基距离通过参数 p 统一了欧式、曼哈顿与切比雪夫距离。
4. 根据形成聚类方式的不同，聚类算法可以分为**层次聚类、原型聚类、分布聚类、密度聚类**等几类。
5. 层次聚类在不同距离水平上合并或拆分，可用树状图描述，链接准则决定簇的形状倾向。
6. k 均值以质心为代表、以距离平方和为目标做贪心迭代，收敛到局部最优；k 的取值与初始化质量是它的两个主要痛点。
7. EM 在隐变量模型下轮流做期望步与最大化步，高斯混合模型在参数退化时正好回到 k 均值。
8. DBSCAN 依据密度可达关系扩展出任意形状的簇，并能识别噪声，但对 ε 与密度的均匀性有要求。
9. 聚类分析的一个重要应用是先对用户分组，再训练分类模型判别新用户类型。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
聚类分析	Cluster Analysis	—	无监督地把无标记样本划分为若干相似子集的方法
聚类	Cluster	—	划分结果中的一个子集，也称簇，代表一个潜在类别
无监督学习	Unsupervised Learning	—	训练样本不含类别标记的学习方式
距离测度	Distance Measure	—	衡量两样本相似程度、满足四条距离性质的函数
闵可夫斯基距离	Minkowski Distance	—	各维差值 p 次幂求和后开 p 次方的通用距离形式
欧式距离	Euclidean Distance	—	闵可夫斯基距离在 p = 2 时的特例，即直线距离
曼哈顿距离	Manhattan Distance	—	闵可夫斯基距离在 p = 1 时的特例，即各维差绝对值之和
切比雪夫距离	Chebyshev Distance	—	闵可夫斯基距离在 p 趋于无穷时的特例，即最大维差
马氏距离	Mahalanobis Distance	—	用协方差矩阵归一化、可消除特征相关性的距离
余弦相似度	Cosine Similarity	—	用向量夹角余弦衡量方向相似性的度量
层次聚类	Hierarchical Clustering	—	在不同距离水平上合并或拆分样本的聚类方法
树状图	Dendrogram	—	描述层次聚类合并过程的树形结构图
会聚策略	Agglomerative Strategy	—	自底向上、逐步合并最近聚类的划分策略
单链接	Single Linkage	—	以两簇间最小距离作为簇间距离的合并准则
全链接	Complete Linkage	—	以两簇间最大距离作为簇间距离的合并准则
均链接	Average Linkage	—	以两簇间所有样本对的平均距离作为簇间距离的准则
原型聚类	Prototype-based Clustering	—	用一个中心向量代表一个聚类的聚类方法

名称	英文全称	英文缩写	简短介绍
质心	Centroid	—	聚类内所有样本的算术平均数，代表该聚类
k 均值	k-Means	—	以距离平方和最小为目标、贪心迭代的原型聚类算法
k-means++	k-Means++	—	按距离平方成比例地分散选取初始中心的初始化方法
肘部法	Elbow Method	—	借助距离平方和随 k 变化的拐点选择聚类数的方法
轮廓系数	Silhouette Coefficient	—	综合紧致度与分离度的聚类内部评价指标
分布聚类	Distribution-based Clustering	—	假定每个聚类来自同一概率分布的聚类方法
期望极大算法	Expectation Maximization	EM	在含隐变量模型中交替做期望步与最大化步的参数估计方法
高斯混合模型	Gaussian Mixture Model	GMM	用多个高斯分布加权组合刻画数据的概率聚类模型
密度聚类	Density-based Clustering	—	依据样本分布密度与可连接性形成聚类的方法
ε-邻域	Epsilon Neighborhood	—	与给定点距离不超过 ε 的样本集合
核心点	Core Point	—	ε-邻域内样本数达到 MinPts 的点
密度直达	Directly Density-Reachable	—	一个点落在核心点 ε-邻域内的关系
密度可达	Density-Reachable	—	通过一串密度直达关系传递得到的连接关系
密度相连	Density-Connected	—	两点均可由同一点密度可达的关系
基于密度的空间聚类	Density-Based Spatial Clustering of Applications with Noise	DBSCAN	依据密度可达关系扩展聚类并识别噪声的算法
谱聚类	Spectral Clustering	—	在相似度图的拉普拉斯特征空间中做划分的聚类方法
模糊聚类	Fuzzy Clustering	—	允许样本以不同隶属度同时属于多个簇的聚类方法

名称	英文全称	英文缩写	简短介绍
用户画像	User Profiling	—	用聚类对用户分组、再用分类判别新用户类型的应用