降维学习：主成分分析、核化 PCA 与特征选择

读前须知

- **前置**：协方差矩阵、特征值分解；这两样在 001 篇里都有。
- **这一篇的位置**：高维数据的压缩与可视化。它回答一个问题：能不能用更少的维度，保住尽量多的信息？
- **读完能做什么**：推导 PCA 的目标函数；解释为什么主成分就是协方差矩阵的特征向量；区分特征提取与特征选择两条路线。

一、高维数据带来的三重困境

1.1 为什么维度必须压缩

高维数据有一个基本事实：真正决定结果的维度往往只占很小一部分。一张图片有几百万个像素，一段文本有上万维的词表，一份基因数据动辄两万个基因，其中大量维度彼此冗余、甚至与任务完全无关。

降维（dimensionality reduction）要做的，就是把其中有信息量的那部分找出来，用尽可能少的维度承载尽可能多的结构。

1.2 计算、样本与噪声

高维数据在进入模型之前，通常要面对三重困境：

- **计算开销**：距离计算、矩阵求逆、模型训练的复杂度往往随维度急剧上升；
- **样本稀疏**：维度越高，要覆盖同样的特征空间就需要指数级增长的样本量，而样本总是有限的；
- **噪声与冗余**：大量彼此相关或无关的属性会干扰模型，让学到的规律偏离真实规律。

因此在特征较多而样本较少的问题里，降维往往不是可选项，而是必需的前置步骤。

补充说明：维数灾难有一个反直觉的表现——**距离集中**。在高维空间中，任意两个随机点之间的距离会趋于相近，最近邻与最远邻的距离之比接近 1，基于距离的算法（k 均值、k 近邻）因此逐渐失效，这也是高维数据通常要先降维再聚类的原因。另一种表现是样本稀疏：要让样本密度保持不变，样本量必须随维度指数增长，而现实中样本量只能线性增加。两条合起来说明，维度不是“多一点信息”那么简单，它会改变整个问题的几何性质。

二、主成分分析：把数据拟合进一个椭球

2.1 几何直观

主成分分析（Principal Component Analysis，PCA）是最经典的线性降维方法。

从几何意义来看，主成分分析是要将原始数据拟合成新的 n 维**椭球体**，这个椭球体的每个轴代表着一个主成分。如果椭球体的某个轴线较短，那么该轴线所代表的主成分的**方差**也很小。在数据集的表示中省略掉该轴线以及其相应的主成分，只会丢失相当小的信息量。

换句话说：数据在哪个方向上“散得最开”，那个方向就最重要；散得最不开的方向，可以丢掉。

> **新手提示：PCA 不是在删列**

> 主成分分析中降维的实现，并不是简单地在原始特征中选择一些保留，而是**利用原始特征之间的相关性重新构造出新的特征**。原始特征可能是“身高”和“体重”，PCA 造出来的新特征可能是“体型大小”和“胖瘦程度”——后者在原始数据里根本不存在。

2.2 五个步骤

具体说来，主成分分析遵循如下的步骤：

1. **数据规范化**：对 m 个样本的相同属性值求出算术平均数，再用原始数据减去平均数，得到规范化后的数据：

$$x_{ij} \leftarrow x_{ij} - \frac{1}{m}\sum_{i=1}^{m} x_{ij}$$

2. **协方差矩阵计算**：对规范化后的新样本计算不同属性之间的协方差矩阵。如果每个样本有 n 个属性，得到的协方差矩阵就是 n 维方阵：

$$\mathbf{C} = \frac{1}{m}\sum_{i=1}^{m}(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^{\mathrm{T}}$$

3. **特征值分解**：求解协方差矩阵的特征值和特征向量，并将特征向量归一化为单位向量：

$$\mathbf{C}\mathbf{w} = \lambda\mathbf{w}$$

4. **降维处理**：将特征值按照降序排序，保留其中最大的 k 个，再将其对应的 k 个特征向量分别作为列向量，组成特征向量矩阵 W_k（n × k 维）；

5. **数据投影**：将减去均值后的 m × n 维数据矩阵和由 k 个特征向量组成的 n × k 维特征向量矩阵相乘，得到的 m × k 维矩阵就是原始数据的投影：

$$\mathbf{Z} = \mathbf{X}\mathbf{W}_k$$

经过这几步简单的数学运算后，原始的 n 维特征就被映射到新的 k 维特征之上。这些相互**正交**的新特征就是**主成分**。

步骤	输入	输出
规范化	原始数据 m × n	零均值数据
协方差矩阵	零均值数据	n × n 对称矩阵
特征值分解	协方差矩阵	n 个特征值与特征向量
降维处理	特征值与特征向量	最大的 k 个特征向量组成的 W_k
数据投影	X 与 W_k	降维后的 m × k 数据

补充说明：五个步骤里的第一步只完成了中心化。如果各属性量纲不同，还必须除以标准差，也就是做标准化。原因很直接：PCA 追求投影方差最大，而方差对量纲极度敏感，用毫米和米记录同一个长度，算出的主成分方向会截然不同。标准化之后，协方差矩阵恰好等价于相关系数矩阵。至于要不要标准化，取决于属性量纲是否有可比意义——图像像素都在同一尺度上，通常只做中心化；而身高、收入、年龄混在一起时，标准化是必需的。

三、为什么降维有效：两种等价解释

从线性空间的角度理解，主成分分析可以看成将正交空间中的样本点以**最小误差**映射到一个**超平面**上。如果这样的超平面存在，那它应该具备以下的性质：

- 一方面，不同样本点在这个超平面上的投影要尽可能地**分散**；
- 另一方面，所有样本点到这个超平面的距离都应该尽可能**小**。

这两条性质，分别对应 PCA 的两种等价解释。

3.1 最大方差原理

样本点在超平面上的投影尽可能分散，体现出的就是**最大方差原理**。

在信号处理理论中，当信号的均值为零时，方差反映的就是信号的能量，能量越大的信号对抗噪声和干扰的能力也就越强。而让投影后样本点的方差最大化，就是要让超平面上的投影点尽可能地分散。如果原始信号的投影都集中在超平面的同一个区域，不同的信号之间就会难以区分。

在数学上，投影后所有样本点的方差可以记作：

$$\sum_i \mathbf{W}^{\mathrm{T}}\mathbf{x}_i\mathbf{x}_i^{\mathrm{T}}\mathbf{W}$$

式中每个 n 维向量 x_i 都代表具有 n 个属性的样本点，W 则是经过投影变换后得到的新坐标系。最大方差要求的正是求解最优的 W，以使上式中对应矩阵所有**对角线元素的和**（即矩阵的迹）最大化。

经过数学处理后可以得到：使方差最大化的 W，就是由所有最大特征值的特征向量组合在一起形成的——也就是主成分分析的解。

3.2 最小均方误差原理

最小均方误差原理，则对应着考察“点到超平面的距离”的那一面。

所有样本点到这个超平面的距离都应该尽可能小，意味着这些点到平面距离之和同样最小。原始样本点在低维超平面上的投影的表达式是：

$$\mathbf{z}_i = (z_{i1}; z_{i2}; \cdots; z_{ik})$$

其中每个 $z_{ij} = w_j^{\mathrm{T}}x_i$，是原始样本点 x_i 在低维超平面上第 j 维上的坐标。因而，原始样本点和在投影超平面上重构出的样本点之间的距离可以表示为：

$$\left\| \sum_{j=1}^{k} z_{ij}\mathbf{w}_j - \mathbf{x}_i \right\|_2^2$$

在整个训练集上对距离求和并最小化，求出的解就是最小均方误差意义下的最优超平面。经过数学处理后同样可以得到：使均方误差最小化的 W，就是由所有最大特征值的特征向量组合在一起形成的。

> **新手提示：两条路，同一个终点**
>
> “投影散得最开”和“重构误差最小”，听起来是两件事，却在数学上指向同一组特征向量。原因是：数据的总方差是固定的，投影保留的方差越多，被丢掉、也就是重构不回来的那部分就越少。所以“保留尽可能多的方差”与“损失尽可能少的信息”是同一句话的两种说法。

补充说明：实践中很少真的去算协方差矩阵再分解，而是直接对中心化后的数据矩阵做**奇异值分解**（singular value decomposition，SVD）。若数据矩阵分解为 $X = U\Sigma V^{\mathrm{T}}$，那么 V 的列就是主成分方向，Σ 中奇异值的平方除以样本数就是对应的特征值。SVD 的数值稳定性更好，而且不必显式构造 n×n 的协方差矩阵——当特征维度远大于样本数时，这一点尤其关键。大规模数据上还会改用随机化 SVD 或

增量式算法。

四、保留多少个主成分

在主成分分析中，保留的主成分数目 k 是由用户来确定的。常见有几种经验做法：

- **特征值法**：保留所有大于 1 的特征值，以其对应的特征向量来做坐标变换；
- **方差贡献率法**：根据不同特征值在整体中的贡献（$\lambda_i / \Sigma\lambda$）以一定比例进行保留，例如累计贡献率达到 85% 或 95%；
- **重构误差法**：计算新数据和原始数据之间的误差，令误差和原始数据能量的比值小于某个预先设定的阈值。

主成分分析能够对数据进行降维处理，保留正交主成分中最重要的部分，在压缩数据的同时最大程度地保持了原有信息。

补充说明：除了这三种做法，**碎石图**（scree plot）也很常用：把特征值按降序画成曲线，找曲线由陡变缓的拐点。需要提醒的是，“保留特征值大于 1 的主成分”这条经验准则只在标准化之后才成立——此时每个原始变量的方差恰为 1，特征值小于 1 意味着该主成分解释的方差还不如单个原始变量。若没有标准化，特征值的绝对大小没有可比基准，这条准则就失去了意义。三方法给出的 k 常常并不一致，最终还是要回到下游任务上验证。

五、PCA 的优点与局限

5.1 不受参数限制

优点：主成分分析完全**不受参数的限制**，即不需要先验的参数或模型对计算过程的人为干预，分析的结果只与数据有关。

5.2 两重局限

局限也有两面：

- **先验知识无法注入。**有得必有失，这个特点的另一面是：即使用户具有对训练数据集的先验知识，也没有办法通过参数化等方法加以利用；
- **只处理线性相关。**由于主成分分析中利用的是协方差矩阵，因而只能去除**线性相关**关系，对更加复杂的非线性相关性就无能为力了。

补充说明：PCA 是无监督的，它只关心数据本身的方差结构，完全不管标签，这带来一个常被忽视的风险：方差最大的方向未必是最能区分类别的方向。极端情况下，把 PCA 用在分类任务之前，可能恰好丢掉类间差异所在的那一维。若目标是有监督分类，**线性判别分析**（linear discriminant analysis，LDA）更合适——它最大化类间散度与类内散度之比。工程上常见的组合是先用 PCA 做粗降维去噪，再用 LDA 做判别投影。

六、核化 PCA

解决上面第二条局限的办法，是将支持向量机中介绍过的**核技巧**引入主成分分析：先用核函数把样本隐式映射到高维特征空间，再在那个空间里做 PCA。

这样一来，原本在原始空间中非线性相关的结构，在高维空间里可能变成线性相关的结构，从而被 PCA 捕获。**核化 PCA**（Kernel PCA）将先验知识以非线性变换的形式体现，因而扩展了主成分分析的应用范围。

补充说明：核化 PCA 在实现上有一个容易漏掉的细节：高维空间里的数据同样需要中心化，但映射后的均值无法显式计算，只能通过核矩阵做中心化修正，即把核矩阵 K 替换为 K 减去按行、按列的均值矩阵再加上总体均值矩阵。这一步若省掉，得到的就不是真正的核空间主成分。计算上，核化 PCA 需要对 m×m 的核矩阵做特征分解，复杂度是 $O(m^3)$，因此它适合样本量中等、原始维度较高的场景；样本量上万时，通常要先做采样或使用低秩近似。

七、特征选择：另一种降维思路

主成分分析实现降维的前提，是通过正交变换对不同属性进行**去相关**。另一种更加直观的降维方式，则是直接对样本的属性做出筛选，这种降维方法就是**特征选择**（feature selection）。

特征选择的出发点在于：去除不相关的特征，往往能够降低学习任务的难度。它和主成分分析共同构成了处理高维数据的两大主流技术。

7.1 特征选择与特征提取的区别

特征选择与特征提取不同：

- **特征提取**（feature extraction）是根据原始特征的功能来**创建新特征**，PCA 属于这一类；
- **特征选择**则是**选取原始特征中的一个子集**用于学习任务，不创造新特征。

特征选择通常用于**特征较多而样本较少**的问题中。使用特征选择技术的核心前提是：数据包含许多冗余和不相关特征，它们可以在不引起信息损失的情况下被移除。

7.2 三类特征选择方法

特征选择算法是“搜索新的特征子集”和“对搜索结果进行评估”两个步骤的组合。

最简单的选择方法是测试每个可能的特征子集，从中找出错误率最小的特征子集。这是一个详尽的空间搜索，但子集的数目会随着特征数目的增加以**指数方式**增加，特征稍多时就无法进行。

相比之下，一种可行的做法是：产生一个特征子集并评价其效果，根据评价结果再产生新的特征子集并继续评价，直到无法找到更好的候选子集为止。

根据评价方式的不同，特征选择算法主要可以分为三类：

类别	评价方式	计算量	优点	缺点
包裹法	用预测模型在验证集上的错误率打分	大	能找到适配特定模型的最佳子集	每个子集都要重训模型，代价高
过滤法	用与模型无关的统计指标打分	小	通用性强，有助于揭示特征间关系	未与模型建立对应，性能通常弱于包裹法
嵌入法	在模型训练过程中自动完成选择	中	兼顾效果与效率	与具体模型绑定

包裹法（wrapper）使用预测模型来评价特征子集。每个新的特征子集都用来训练一个模型，并在验证数据集上进行测试，模型在验证数据集上的错误率也就是该子集的分数。由于包裹法为每个子集都要训练一个新的模型，因而其计算量较大，但它的优点是能够找到适用特定模型的最佳特征子集。

过滤法（filter）先对数据集进行特征选择，也就是对初始特征进行过滤，再用过滤后的特征来训练模型。过滤法的计算负荷要小于包裹法，但由于特征子集和预测模型之间并没有建立对应关系，因而其性能也会劣于包裹法。但另一方面，过滤法得到的特征子集具有更强的**通用性**，也有助于揭示不同特征之间的关系。许多过滤器提供的不是一个明确的最佳特征子集，而是不同特征的**排名**，因而过滤法可以作为包裹法的预处理步骤来使用。

嵌入法（embedding）结合了包裹法和过滤法的思路，将特征选择和模型训练两个过程融为一体，使学习器在训练过程中自动完成特征选择。其典型的方法是引入 L1 范数作为正则项的 **LASSO** 方法——L1 正则会天然把不重要的权重压到恰好为零，权重为零的特征就等于被剔除。一般来说，嵌入法的计算复杂度在包裹法和过滤法之间。

7.3 典型应用场景

特征选择的主要应用场景包括**书面文本分析**和 **DNA 微阵列数据的分析**。这些场景下，样本的数目通常数以百计，每个样本却可能包含成千上万的特征。

在这类"宽数据"（特征数远大于样本数）问题中，直接训练模型极易过拟合，降维既是为了提速，更是为了让模型有可能学到真正起作用的规律。

补充说明：包裹法的搜索策略值得补充。穷举不可行，常用的是**序列前向选择**（每次加入一个当前最优特征）、**序列后向消除**（每次删掉一个最差特征），以及允许回退的浮动搜索。特征数很多时前向选择更快，特征数较少时后向消除更稳。另一个实用思路是**稳定性选择**：对数据做多次子采样，每次跑一遍选择算法，最后保留被选中频率高的特征。它不依赖某一次划分的偶然结果，在超高维数据上比单次选择可靠得多。

四个常见误区

- **"PCA 选出的主成分一定利于分类"**——PCA 是无监督的，它保留的是方差最大的方向，而方差最大的方向未必是区分类别最好的方向。有标签时应考虑 LDA 这类监督降维。
- **"降维总能提升效果"**——如果丢弃的成分里恰好包含判别信息，降维会直接损害性能。降维首先是可视化与压缩工具，不是免费的提效手段。
- **"方差大就代表信息多"**——方差大也可能只是噪声大。做 PCA 前通常需要去噪或确认主成分与目标确实相关。
- **"核 PCA 能给出显式映射"**——它只在核诱导的空间里做特征分解，无法直接写出原空间到高维空间的映射函数。

八、要点回顾

1. 高维数据同时带来计算开销、样本稀疏与噪声冗余三重困境，降维因此常常是必需的前置步骤。
2. 主成分分析利用**正交变换**，将可能存在相关性的原始属性转换成一组线性无关的新属性，并通过选择重要的新属性实现降维。
3. PCA 的求解过程是中心化、算协方差矩阵、特征值分解、排序取前 k 个特征向量、投影这五步；量纲不一致时还需标准化。
4. 主成分分析的解同时满足**最大方差**和**最小均方误差**两类约束，因而具有最大可分性和最近重构性；实践多用 SVD 求解。
5. 保留主成分的数目可用特征值法、方差贡献率法、重构误差法或碎石图确定，但都只是启发式。
6. PCA 不受参数限制、结果只与数据有关，但也因此无法注入先验知识，且只能去除**线性**相关；引入核技巧可得到核化 PCA。
7. PCA 是无监督的，方差最大的方向未必最利于分类，此时应改用 LDA 或把两者组合使用。
8. 特征选择是选取原始特征中的一个**子集**用于学习任务，与"创建新特征"的特征提取不同。

9. 特征选择的关键问题是对特征子集的评价，主要算法包括**包裹法、过滤法和嵌入法**；LASSO 是嵌入法的代表。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
降维	Dimensionality Reduction	—	把高维数据映射到低维表示、保留主要信息的技术
维数灾难	Curse of Dimensionality	—	维度升高导致样本稀疏、计算与泛化难度剧增的现象
距离集中	Distance Concentration	—	高维空间中点对距离趋于相近、近邻失去区分度的现象
主成分分析	Principal Component Analysis	PCA	基于协方差矩阵特征分解的线性降维方法
主成分	Principal Component	PC	由原始属性正交变换得到的新属性，彼此线性无关
协方差矩阵	Covariance Matrix	—	描述各属性两两线性相关程度的对称方阵
特征值分解	Eigenvalue Decomposition	EVD	把方阵分解为特征向量与特征值的过程
奇异值分解	Singular Value Decomposition	SVD	把任意矩阵分解为左右奇异向量与奇异值的过程
方差贡献率	Variance Contribution Rate	—	某个特征值占总特征值之和的比例，衡量该主成分的重要性
碎石图	Scree Plot	—	按降序画出特征值曲线、以拐点确定主成分数目的方法
最大方差原理	Maximum Variance Principle	—	选择投影后方差最大方向作为主成分的准则
最近重构性	Nearest Reconstruction	—	以重构误差最小为准则选择主成分的等价解释
核化主成分分析	Kernel Principal Component Analysis	Kernel PCA	先用核函数映射到高维空间再做 PCA 的非线性降维方法
线性判别分析	Linear Discriminant Analysis	LDA	最大化类间散度与类内散度之比的有监督降维方法
特征选择	Feature Selection	—	从原始属性中挑选一个子集用于学习任务的降维方法
特征提取	Feature Extraction	—	由原始属性重新构造出新特征的降维方法

名称	英文全称	英文缩写	简短介绍
包裹法	Wrapper Method	—	以模型在验证集上的表现评价特征子集的方法
过滤法	Filter Method	—	以与模型无关的统计指标评价特征的方法
嵌入法	Embedded Method	—	在模型训练过程中自动完成特征选择的方法
序列前向选择	Sequential Forward Selection	SFS	每轮加入一个当前最优特征、逐步扩充子集的搜索策略
稳定性选择	Stability Selection	—	通过多次子采样统计特征入选频率的选择框架
最小绝对收缩与选择算子	Least Absolute Shrinkage and Selection Operator	LASSO	引入 L1 正则、可把不重要特征权重压为零的嵌入法代表