神经元与感知器：MP 模型、赫布学习与异或困境

读前须知

- **前置**：向量内积与阶跃函数；知道“权重”是一个可调数字。
- **这一篇的位置**：第一个能学习的神经元模型，也是“为什么需要多层网络”这个问题的出处。
- **读完能做什么**：写出 MP 模型与感知器的输出式；手算一次感知器权重更新；用几何图解释异或为什么线性不可分。

一、MP 神经元：第一个形式化的计算单元

1.1 二值化的机械大脑

1943 年，美国芝加哥大学的神经科学家沃伦·麦卡洛克和他的助手沃尔特·皮茨发表论文《神经活动中思想内在性的逻辑演算》，系统阐释了他们的想法：一个极度简化的机械大脑。

他们的做法分两步：首先把神经元的状态二值化，一个神经元要么激活要么静息，不存在中间状态；再通过复杂的方式衔接不同的神经元，从而实现对抽象信息的逻辑运算。正是这篇论文宣告了人工神经网络的诞生。论文的核心洞见是：如果神经元的状态只有两种，那么神经元之间的连接就可以完全用逻辑运算来描述，思维于是可以被写成符号演算。

1.2 MP 神经元的数学形式

与生理学上的神经网络类似，麦卡洛克和皮茨的人工神经网络也由类似神经元的基本单元构成，这一基本单元以两位发明者的名字命名为 **MP 神经元**。

大脑中的神经元接受神经树突的兴奋性突触后电位和抑制性突触后电位，产生出沿其轴突传递的动作电位；MP 神经元则接受一个或多个输入，并对输入的线性加权进行非线性处理以产生输出。假定 MP 神经元的输入信号是个 N+1 维向量 ($x_0, x_1, \cdots, x_N$)，第 i 个分量的权重为 w_i，则其输出可以写成

$$y = \phi\left(\sum_{i=0}^{N} w_i x_i\right)$$

上式中的 x_0 通常被赋值为 +1，也就使 w_0 变成固定的偏置输入 b。偏置的作用是把决策边界整体平移，它让神经元在全部输入为零时也能有非零的输出倾向。

> **新手提示：偏置项就是阈值换了个位置**
>
> 把偏置从求和号里拆出来，加权和写成 $\Sigma w_i x_i + b$，判据“大于阈值 θ”就变成“加权和大于 −b”。所以偏置与阈值是同一个东西的两种写法：阈值写在比较运算里，偏置写在加权和里。神经网络代码里通常只保留偏置，因为这样可以把“求和”与“比较”统一成一个线性变换加一个激活函数。

1.3 传递函数与阈值逻辑

MP 神经元中的函数 φ(·) 被称为**传递函数**，用于将加权后的输入转换为输出。传递函数通常被设计成连续且有界的非线性增函数，但在 MP 神经元中，麦卡洛克和皮茨将输入和输出都限定为二进制信号，使用的传递函数则是不连续的**符号函数**。

符号函数以预先设定的阈值作为参数：当输入不小于阈值（≥）时，符号函数输出 1，反之则输出 0。这样一来，MP 神经元的工作形式就类似于数字电路中的逻辑门，能够实现类似“逻辑与”或者“逻辑或”的功能，因而又被称为**阈值逻辑单元**。

补充说明：只要阈值选得合适，单个 MP 神经元就能表达基本逻辑运算。取两个二值输入，权重都为 1：阈值设为 2 时实现“与”（两个都为 1 才输出 1），阈值设为 1 时实现“或”（有一个为 1 就输出 1）；若把一个输入的权重取为 −1、阈值设为 0，则实现“非”。这说明阈值逻辑单元在表达能力上等价于逻辑门电路。但等价不等于够用：任何有限的逻辑门电路都只能表达预先设计好的函数，而智能系统需要的是从数据中自行确定这些阈值，这正是 MP 神经元缺少的那一环。

二、赫布理论：学习发生在突触上

2.1 一起激活，一起增强

MP 神经元虽然简单实用，但它缺乏一个在人工智能中举足轻重的特性，也就是学习机制。

1949 年，加拿大心理学家唐纳德·赫布提出了以其名字命名的**赫布理论**，其核心观点是学习的过程主要是通过神经元之间突触的形成和变化来实现的。通俗地说，两个神经细胞之间的交流越多，它们之间的联系就会越来越强化，学习的效果也在联系不断强化的过程中逐渐产生。后人把这条规律概括成一句话：一起激活的神经元，连接会增强。

2.2 赫布准则为什么不适用于 MP 神经元

从人工神经网络的角度来看，赫布理论的意义在于给出了改变模型神经元之间权重的准则。如果两个神经元同时被激活，它们的权重就应该增加；只有一个被激活时权重保持不变；而当两者倾向于输出相反的结果时，权重才应降低。如果两个结点倾向于同时输出相同的结果，两者就应具有较强的正值权重；反过来，倾向于输出相反结果的结点之间则应具有较强的负值权重。

$$\Delta w_{ij} = \eta \, x_i \, x_j$$

式中 x_i 与 x_j 分别是两个神经元的输出，η 是学习率。当两者同号时权重增大，异号时权重减小，与上面的描述一致。

遗憾的是，赫布的学习机制并不适用于 MP 神经元，因为 MP 神经元中的权重 w_i 都是固定不变的，不能做出动态的调整。MP 神经元是一台算好的机器，赫布理论则是一条改造机器的规则，两者还差一个把规则落到权重上的算法。

补充说明：纯粹的赫布规则有一个明显的缺陷——权重只增不减，反复输入同样的样本会让权重无界增长，最终整个网络饱和。后来的改进是给它加上衰减项，其中最著名的是 **Oja 规则**：在增量上减去一个与输出平方成正比的项，使权重向量收敛到输入协方差矩阵的主特征向量。这个结果很有意思：一条纯局部的生理学规则，居然自动实现了主成分分析。它提示赫布式学习并非只能做分类，也可以做无监督的特征提取。

三、感知器：第一个会学习的网络

3.1 从赫布理论到学习算法

会学习的神经元模型并没有让人等待太久。1957 年，任职于美国康奈尔大学航天实验室的心理学家弗兰克·罗森布拉特受到赫布理论的启发，提出了著名的**感知器**模型。

感知器并不是真实的器件，而是一种二分类的监督学习算法，能够决定由向量表示的输入是否属于某个特定类别。作为第一个用算法精确定义的神经网络，感知器由输入层和输出层组成：输入层负责接收外界信号，输出层是 MP 神经元，也就是阈值逻辑单元。每个输入信号（也就是特征）都以一定的权重被送入 MP 神经元中，MP 神经元则利用符号将特征的线性组合映射为分类输出。

与 MP 神经元的关键差别在于，感知器的权重不再是设计者指定的，而是由训练数据拟合出来的。

3.2 学习规则

给定一个包含若干输入输出对应关系实例的训练集时，感知器引入了学习机制，能够通过权重的调整提升分类的效果，其具体的学习步骤为：

1. 初始化权重 w(0) 和阈值，其中权重可以初始化为 0 或较小的随机数；
2. 对训练集中的第 j 个样本，将其输入向量 x_j 送入已初始化的感知器，得到输出 $y_j(t)$；
3. 根据 $y_j(t)$ 和样本 j 的给定输出结果 d_j，按下式更新权重向量；
4. 重复以上两个步骤，直到训练次数达到预设值。

第 3 步的更新规则是

$$w_i(t+1) = w_i(t) + \eta\,[d_j - y_j(t)]x_{j,i} \qquad 0 \le i \le n$$

式中的正常数 $0 < \eta \le 1$ 被称为**学习率**，是修正误差的一个比例系数。

3.3 权重更新的直观含义

显然，第三步要对感知器的权重进行更新，是学习算法的核心步骤。这一步的作用在于评估不同输入对分类精确度的影响。

如果分类结果和真实结果相同，则 $d_j - y_j = 0$，权重不变；如果不同，就需要具体情况具体分析：如果输出值应该为 0 但实际为 1，就要减少 x_j 中输入值为 1 的分量的权重；如果输出值应该为 1 但实际为 0，则要增加 x_j 中输入值为 1 的分量的权重。

换句话说，每次更新只动那些“对错误有贡献”的权重，贡献大小由对应的输入分量决定。输入为 0 的分量不会被修改，因为它在这次判断中没起作用。

> **新手提示：学习率到底控制什么**
>
> 学习率 η 决定每次修正的步长。取大了，权重会在最优点两侧来回跳动，甚至越过最优点越来越远；取小了，收敛虽然稳定，但要迭代很多轮。感知器收敛定理只保证“存在一个足够小的学习率使其收敛”，并没有告诉你具体取多少。实践中常见的做法是先取 0.1 量级试跑，观察误差曲线是否平稳下降，再作调整。

四、收敛性：感知器为什么一定能成功

4.1 收敛定理

感知器能够学习的前提是它具有收敛性。罗森布拉特证明了：当输入数据线性可分时，感知器学习算法能够在有限次的迭代后收敛，并且得到的决策面是位于两类之间的超平面。

这个结论的分量在于“有限次”三个字。它不是说误差会越来越小然后趋于某个极限，而是说算法会在某个确定的迭代步数之内彻底停止犯错。后来的 Novikoff 定理进一步给出了迭代次数的上界，它与样本的间隔成反比：两类数据分得越开，收敛越快。

4.2 损失函数视角

本质上讲，在执行二分类问题时，感知器以所有误分类点到超平面的总距离作为损失函数，用随机梯度下降法不断使损失函数下降，直到得到正确的分类结果。

把标签取为 +1 与 −1，误分类集合记为 M，损失函数可以写成

$$L(w) = -\sum_{x_j \in M} y_j\, w^{\top} x_j$$

被误分类的样本满足 $y_j w^T x_j < 0$，因此求和号内每一项都是负的，取相反数后 L 为正。对 w 求梯度得到 $-\Sigma\, y_j x_j$，沿负梯度方向走一步恰好就是上面那条更新规则。所以感知器学习规则不是凭空设计的技巧，而是对一个几何上很自然的损失函数做随机梯度下降的结果。

4.3 非参数化与自适应性

除了优良的收敛性能外，感知器还有很多优点。

首先是非参数化特性，即没有做出任何关于固有分布形式的假设，只是通过不同分布重叠区域产生的误差来运行，这意味着即使输入数据是非高斯分布时，算法依然能够正常工作。其次是自适应性，只要给定训练数据集，算法就可以基于误差修正自适应地调整参数而无需人工介入，这无疑在 MP 神经元的基础上前进了一大步。

补充说明：非参数化这个优点要打个折扣来看。感知器确实不假设数据的概率分布形式，但它隐含假设了另一件事——数据是线性可分的。这个假设比高斯假设更强，也更难验证：你无法从有限样本出发判定两类是否真的线性可分。当假设不成立时，算法不会给出“近似解”，而是持续振荡，这一点在下一节会看到。

五、线性可分与线性不可分

5.1 超平面划分

作为神经网络的基础，感知器通过传递函数确定输出，神经元之间通过权重传递信息，权重的变化则根据误差来进行调节。由此，神经网络实现了最基础的学习过程。

虽然感知器的形式简洁优雅，但它的应用范围也相当有限：只能解决线性分类问题。所谓线性分类，意指所有的正例和负例可以通过高维空间中的一个超平面完全分开而不产生错误。

几何上的判断很直接：在二维平面上是一条直线，在三维空间中是一个平面，在更高维空间中是一个超平面。只要存在这样一个面，感知器就一定能找到它；只要不存在，感知器就永远找不到。

5.2 两类问题的对比

如果一个圆形被分成一黑一白两个半圆，这就是个线性可分的问题；可如果是个太极图的话，单单一条直线就没法把黑色和白色完全区分开来了，这对应着线性不可分问题。

感知器对于线性不可分问题无能为力。如果训练数据集不是线性可分的，也就是正例不能通过超平面与负例分离，那么感知器就永远不可能将所有输入向量正确分类。在这种情况下，标准学习算法下不会产生“近似”的解决方案，而是出现振荡，导致算法完全失败。

补充说明：把感知器与逻辑回归放在一起看，会发现两者只差一层。它们都是线性分类器，都用 $w^T x$ 的符号决定类别，区别在于感知器用阶跃的符号函数、逻辑回归用平滑的 Sigmoid。正是这层平滑带来了三个差异：逻辑回归的损失函数处处可微，可以用梯度下降而非分段更新；它的输出可以解释为概率，而不只是一个类别；面对线性不可分的数据，它不会振荡，而是收敛到一个使交叉熵最小的折中解。可见同为线性模型，“能不能处理不可分数据”并非结构的功劳，而是损失函数与激活函数的选择造成的。

六、异或困境

6.1 异或的几何

批判感知器最有名的例子就是所谓的“异或”问题。异或操作是一种两输入的逻辑操作：当两个输入不同时，输出为真；而当两个输入相同时，输出为假。

异或操作可以放在包含四个象限的平面直角坐标系下观察：在第一象限和第三象限中，横坐标和纵坐标的符号相同；而在第二象限和第四象限中，横坐标和纵坐标的符号相反。这样一来，一三象限上的两个点 (1, 1) 和 (−1, −1) 就可以归为一类，二四象限上的两个点 (−1, 1) 和 (1, −1) 则可以归为另一类。

划分这四个点就是一个二分类问题。这个问题不是线性分类问题，因为找不到任何一条直线能将正方形中两组对角线上的顶点分为一类——任何一条直线要么把某一类的两个点分开，要么把两类的点混在一起。

补充说明：异或不可分也可以纯代数地看出来。设直线方程为 $w_1x_1 + w_2x_2 + b = 0$，要正确分类四个点必须同时满足四个不等式：$w_1 + w_2 + b > 0$、$-w_1 - w_2 + b > 0$、$-w_1 + w_2 + b < 0$、$w_1 - w_2 + b < 0$。把前两式相加得到 $2b > 0$，即 $b > 0$；把后两式相加得到 $2b < 0$，即 $b < 0$。同一个 b 不可能同时为正为负，矛盾。这个推导说明异或不可分是结构性的，换任何算法都绕不过去，唯一的出路是改变模型本身的表达能力。

6.2 明斯基的批判

1969 年，新科图灵奖得主马文·明斯基和他的麻省理工学院同侪塞默尔·帕波特合著了《感知器：计算几何简介》一书，系统论证了感知器模型的两个关键问题。

第一，单层感知器无法解决以异或为代表的线性不可分问题；第二，受硬件水平的限制，当时的计算机无法完成训练感知器所需要的超大的计算量。

明斯基的著作对感知器无疑是致命的打击。异或问题是最简单的逻辑问题之一，如果连异或的分类都无法解决，这样的模型存在的意义就颇为有限了。

> **新手提示：单层与多层不是同一回事**
>
> 明斯基批判的是**单层**感知器。他在书中其实也讨论过多层结构，但指出当时没有可行的多层训练算法——能算出多层网络的权重该取什么值，这件事直到反向传播普及才解决。所以严格说来，被否定的不是“神经网络”这个方向，而是“当时能训练出来的神经网络”。把这个区别记住，才能理解 1980 年代复兴为何来得如此突然。

七、第一次寒冬

7.1 学术之外的恩怨

明斯基的著作发表后，政界对神经网络的热情被这一盆冷水浇了个透心凉，这直接导致了科研经费的断崖式下跌；而学界则视人工神经网络研究为洪水猛兽，避之不及。连接主义学派的第一波凛冬就此到来。

只是在学术争鸣背后，明斯基的所作所为还藏着些文人相轻的意味。罗森布拉特其人性格张扬，于区区 29 岁的年纪提出感知器模型后更加受人追捧，俨然一副学术网红的模样。更重要的是，大量来自政府的经费都涌向罗森布拉特的项目，这也许才是让明斯基不爽的真正原因。此外，明斯基和罗森布拉特求学路上的交集也暗示着两人之间的纠葛冰冻三尺，绝非一日之寒。

在 1969 年版《感知器》中，明斯基不仅论证了感知器在科学上的局限，更夹带了不少对罗森布拉特进行人身攻击的私货。罗森布拉特对感知器在符号处理方面的局限心知肚明，但他没想到这些缺陷会被明斯基以如此敌意而致命的方式呈现出来。1971 年，罗森布拉特在 43 岁生日当天划船时意外淹死，至于这究竟是意外事故还是以死明志，恐怕只有他自己知道了。

7.2 寒冬之后

补充说明：把这场争论放回技术史里看，明斯基的判断有一半是对的，另一半被时间推翻了。对的那一半是：单层感知器确实表达力有限，异或这样的简单函数就能让它失效，而且当时的算力也确实不足以训练大网络。被推翻的那一半是：他把“当前无法训练多层网络”当成了“多层网络没有前途”，而反向传播在十几年后给出了训练方法。这段历史留下的教训不是“权威会犯错”，而是**否定一个方向时，要分清是原理上不可能，还是工程上暂时做不到**。这两者的区别，往往要等一代人才看得清。

四个常见误区

- **“感知器就是线性分类器，所以已经过时”**——线性可分时它保证在有限步内收敛，而且它第一次把“从数据中调权重”变成了可执行流程。今天的反向传播，沿用的仍是这个思路。
- **“异或困境说明单层网络一无是处”**——它否定的只是“一条直线切分空间”这类决策边界，并不否定整个方向。加一层隐藏层，问题立刻解开。
- **“感知器学习规则就是梯度下降”**——两者形式相似，但感知器规则是错误驱动的启发式修正，目标函数不可导，不能当作梯度下降的特例。
- **“赫布学习能直接解释现代网络”**——“同时激活则连接增强”只解释了无监督的局部规则，而今天的有监督训练靠的是误差反传，两者机制不同。

八、要点回顾

1. MP 神经元把神经元状态二值化，用加权求和加符号函数实现逻辑运算，是人工神经网络的起点。
2. 偏置项与激活阈值是同一个东西的两种写法，偏置让决策边界可以整体平移。
3. 赫布理论指出学习发生在突触上，共同激活的神经元之间连接增强，但它没有给出适用于 MP 神经元的算法。
4. 感知器在 MP 神经元之外加了学习机制，用误差驱动的权重更新完成二分类。
5. 感知器学习规则等价于对误分类点到超平面距离之和做随机梯度下降。
6. 当数据线性可分时，感知器在有限次迭代内必然收敛，且解是一个分离超平面。
7. 异或问题不是线性可分的，任何单层感知器都无法解决，这是结构性的表达力限制。
8. 明斯基对单层感知器的批判成立，但由此否定整个连接主义方向，让研究停滞了十余年。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
MP 神经元	McCulloch-Pitts Neuron	MP Neuron	第一个形式化的人工神经元，二值输入输出加阈值激活
传递函数	Transfer Function	—	把加权输入映射为输出的非线性函数
符号函数	Sign Function	sgn	输入超过阈值输出 1、否则输出 0 的不连续函数
阈值逻辑单元	Threshold Logic Unit	TLU	用阈值实现逻辑运算的神经元，等价于逻辑门
偏置	Bias	—	加在加权和上的常数项，等价于平移激活阈值

名称	英文全称	英文缩写	简短介绍
兴奋性突触后电位	Excitatory Postsynaptic Potential	EPSP	使下游神经元更易激活的突触输入
抑制性突触后电位	Inhibitory Postsynaptic Potential	IPSP	使下游神经元更难激活的突触输入
动作电位	Action Potential	—	神经元激活后沿轴突传导的电脉冲
赫布理论	Hebbian Theory	—	共同激活的神经元之间连接增强的学习假设
赫布规则	Hebbian Rule	—	$\Delta w = \eta x_i x_j$，按两神经元输出的乘积调整权重
Oja 规则	Oja's Rule	—	带衰减项的赫布规则，收敛到输入的主特征向量
感知器	Perceptron	—	第一个带学习算法的二分类神经网络
学习率	Learning Rate	η	控制每次权重修正步长大小的正系数
收敛定理	Perceptron Convergence Theorem	—	数据线性可分时感知器在有限步内收敛的结论
误分类损失	Misclassification Loss	—	以误分类点到超平面距离之和定义的损失函数
随机梯度下降	Stochastic Gradient Descent	SGD	每次用单个或小批样本估计梯度并更新参数
线性可分	Linear Separability	—	存在一个超平面能把两类样本完全分开的性质
超平面	Hyperplane	—	高维空间中比所处空间低一维的线性子空间
线性不可分	Linear Inseparability	—	不存在任何超平面能完全分开两类样本的情形
异或问题	XOR Problem	—	两输入相异输出为真的逻辑运算，线性不可分的典型例子
振荡	Oscillation	—	数据线性不可分时感知器权重反复跳动无法收敛的现象
连接主义寒冬	Connectionism Winter	—	1969 年后神经网络研究经费与关注度骤降的时期
反向传播	Backpropagation	BP	用链式法则从输出层向输入层逐层求梯度的算法