径向基函数网络：局部逼近、感受野与 K 均值训练

读前须知

- **前置**：高斯函数、欧氏距离与 k 均值聚类的思路。
- **这一篇的位置**：神经网络里的另一条逼近路线——不靠全局的 Sigmoid 叠加，而是用一串“局部小山包”拼出曲面。
- **读完能做什么**：写出 RBF 神经元的输出式；解释“局部逼近”与“全局逼近”各自的代价；说清为什么 RBF 网络可以两阶段分开训练。

一、全局逼近与局部逼近

1.1 牵一发而动全身的全局作用

多层感知器是一类**全局逼近**的神经网络，网络的每个权重对任何一个输出都会产生同等程度的影响。因而对于每次训练，网络都要调整全部权值，这就造成全局逼近网络的收敛速度较慢。

“全局”这个说法有具体的几何含义：网络中每个隐藏神经元的响应范围覆盖整个输入空间，无论输入落在这里还是那里，它都会给出一个非零的响应。改动一个权重，整个输入空间上的输出曲面都会跟着变形。

1.2 局部作用与感受野

与全局作用对应的是局部作用。在局部作用中，每个局部神经元只对特定区域的输入产生响应。如果输入在空间上是相近的，对这些输入的反应应该是相似的，那么被这些输入激活的神经元也应该是同一批神经元。进一步推广又可以得到：如果一个输入 A 在另外两个输入 B_1 和 B_2 的空间位置之间，那么响应输入 B_1 和 B_2 的神经元也应该在一定程度上被 A 激活。

神经元的局部作用原理有它的生理学依据。当你仰望夜空中的点点繁星时，茫茫暗夜中的星光激活的是视觉神经的特定部分。随着地球的自转，星光也会移动，虽然亮度没有变化，但不同位置的星光激活的就是视觉神经中的不同部分，因而产生响应的神经元也会发生变化。有些原本被激活的神经元会因为目标对象的移出而被抑制，有些原本被抑制的神经元则因为目标对象的移入而被激活。

在神经科学中，这个概念被称为**感受野**（receptive field）。一个感觉神经元的感受野指的是位于这一区域内的适当刺激能够引起该神经元反应的区域。

人类神经的感受野的变化方式可以在人工神经网络中以权重系数的形式体现出来，而按照感受野的变化规律设置权重系数，得到的就形成了**径向基函数神经网络**。

> **新手提示：感受野不等于视野**
>
> 视野是眼睛能看到的全部范围，感受野是某一个神经元“负责”的那一小块。一个神经元只对落在自己感受野内的刺激作出反应，落在外面则几乎无动于衷。这个机制的意义在于分工：如果每个神经元都对整个视野负责，那么任何一个方向的刺激都会激活全部神经元，信息就无法区分。局部化让不同的神经元负责不同的区域，特征才有被分辨的可能。

补充说明：感受野不是固定大小的，而是逐层放大的。视觉皮层的早期神经元只对视野中很小一块的朝向边缘作出反应，更深的神经元把若干个小感受野汇总，响应范围变大，能识别的模式也更复杂。卷积网络把这一结构直接写进了架构：卷积核就是一个小感受野，堆叠多层后，深层的单个单元对应原图上一大片区域。径向基网络只用了“局部响应”这半条思路，没有采用逐层放大，因而它的每个隐藏单元都直接面对整个输入，这也是它难以处理高维图像的原因之一。

二、径向基函数网络的结构

2.1 三层结构与权重约定

径向基网络通常包含三层：一个输入层、一个隐藏层和一个输出层。其中隐藏层是径向基网络的核心结构。

每个隐藏神经元都选择径向基函数作为传递函数，对输入分量的组合加以处理。需要注意的是，输入节点和隐藏节点之间是直接相连的，权重系数为 1。这一点与多层感知器截然不同：多层感知器的输入到隐藏层要经过一个可训练的权重矩阵，而径向基网络的这一层不做加权，只把输入原样送给每个隐藏神经元，由后者自己计算与中心的距离。

2.2 径向基函数的形式

径向基函数是只取决于与中心矢量的距离的函数，也就是不管不同的点是在东西还是南北，只要它们和中心点之间的距离相同，其函数值就是相同的。径向基函数的图形会根据确定的中心点呈现圆周对称的性质。

如果将欧氏距离作为距离的度量，函数的形式就可以定义为平缓变化的高斯函数：

$$\rho\left(x, w_i, \sigma\right)=\exp\left(-\frac{\left\|x-w_i\right\|^2}{2\sigma^2}\right)$$

式中的每个中心向量 w_i 都是径向基网络中的权重系数。一般情况下，所有高斯函数会共享同一个带宽 σ，因而将不同隐藏单元区分开来的就是中心向量 w_i。

> **新手提示：带宽决定了“局部”有多局部**
>
> σ 越大，高斯函数的钟形越平缓，每个神经元的响应范围越宽，越接近全局逼近；σ 越小，钟形越尖，响应范围越窄，每个神经元只管自己附近的一小片。σ 趋于零时，网络退化为最近邻查表；σ 趋于无穷时，所有神经元响应几乎相同，网络失去分辨能力。带宽因此是控制“局部性程度”的关键超参数。

2.3 输出层

每个径向基函数的输出按照参数进行线性组合后，再被送到输出神经元加以处理，输出神经元通常是普通的 MP 神经元。写成式子是

$$y_k=\sum_{i=1}^{K} w_{ki}\,\rho\left(x, w_i, \sigma\right)$$

这里的 w_{ki} 是隐藏层与输出层之间的权重，也是第二阶段训练要确定的参数。注意整个网络对输出是线性的：一旦中心与带宽定下来，拟合输出层就退化成一个线性回归问题。

三、隐藏层的作用：把数据映射到高维

3.1 非线性变换

前面介绍的是径向基网络的生理学依据，下面看这套方法在数学上的意义。

隐藏层的作用是实现从输入空间到非显式特征空间的非线性变换，由此，低维空间上的非线性可分数据就被映射到高维空间之中。在一定的条件下，转换后的数据变为线性可分的可能性很高，这一点已经在数学上得到证明。

“非显式”三个字值得强调。多层感知器的隐藏层输出是可以用显式公式写出的复合函数，而径向基网络的隐藏层输出是一组局部响应，它的每个分量只在中心附近取较大值，整体构成了一个以中心为节点的分布式编码。这种编码更像是一组“相似度打分”，而不是一组抽象的坐标。

3.2 与核技巧的联系

支持向量机中的核技巧能够把低维空间中的非线性问题映射成高维空间中的线性问题，将低维空间中曲面形式的决策边界转化为高维空间中的超平面，从而降低分类问题的难度。

在支持向量机中常用的核函数就包括高斯核函数，它的形式与径向基网络中的高斯函数几乎一模一样。两者的差别在于用法：支持向量机把核函数当作样本之间的相似度，用它构造核矩阵，再在对偶问题里求解；径向基网络把同一族函数当作隐藏神经元的激活函数，用中心向量的位置来组织特征空间。

补充说明：高维映射之所以常常能让问题变简单，背后有一个概率论的结论，通常称为 **Cover 定理**：把本来线性不可分的一组点非线性地映射到足够高的维度后，它们变成线性可分的概率会显著提高。但这条结论有个常被忽略的前提——映射不能是任意的，必须保持一定的结构。任意升维可以把任何数据变成线性可分（甚至把每个点映射到自己的独立维度上），但这样做毫无泛化能力。核方法与径向基网络的取舍正在于此：它们只引入受控的非线性，换来的可分性是能推广到新样本的。

四、异或问题的另一种解法

还是以异或问题为例。在异或问题中，四个数据点 (0, 0)、(0, 1)、(1, 0)、(1, 1) 是正方形的四个顶点，处于对角线方向上的两个点属于同一个模式。

如果引入两个高斯函数

$$\Phi_i(x) = \exp\left(-\|x - u_i\|^2\right), \qquad i = 1, 2$$

其中 u_1 = [0, 0]、u_2 = [1, 1]，则原始的四个数据点就被变换为：

原始点	Φ_1	Φ_2	异或结果
(0, 0)	1.0000	0.1353	0
(0, 1)	0.3679	0.3679	1
(1, 0)	0.3679	0.3679	1
(1, 1)	0.1353	1.0000	0

经过高斯函数的变换后，(0, 1) 和 (1, 0) 两个具有相同异或结果的点重合在一起，而 (0, 0) 与 (1, 1) 分别落在特征平面的两个角上。三类点在平面上呈现为两个角点加一个重合的中心点，用一条直线就能把异或为 0 的两点与异或为 1 的两点分开。

关键在于：在整个处理中空间的维数并未增加，问题的转化只用到了非线性的高斯函数。这正说明了上面那句话——未必需要“牛刀”，一个合适的非线性映射就足以在低维空间里把问题解决。

补充说明：用同样的高斯函数，径向基网络与支持向量机会得到不同形状的决策边界。支持向量机只保留支持向量对应的那部分基函数，系数由最大间隔准则确定，边界尽量远离两类样本；径向基网络则把全部中心都保留下来，系数由最小二乘拟合确定，边界只需穿过两类之间即可。前者更“保守”，泛化往往更稳；后者更“贴数据”，样本多时拟合更精确。两者共享同一个函数形式，差别在于选哪些中心、以及用什么准则定系数。

五、插值视角：把离散点连成曲面

5.1 超曲面拟合

另一个理解径向基网络的角度是**多变量插值**。

整体上看，径向基网络的作用是学习一个高维空间上的超曲面，根据训练数据进行训练的过程就是对超曲面进行拟合的过程。但由于数据中存在噪声，因而训练得到的结果还需要泛化处理，泛化的任务就是在数据点之间进行插值，使插值后的曲面仍然要经过所有数据点。

在插值过程中，使用的插值函数就是不同类型的径向基函数。训练数据中的每个样本都是新的高维空间中的一个点，插值要做的是把所有离散的点连成一片，形成一个曲面。

5.2 高斯函数的叠加

那么插值操作具体是如何进行的呢？

高斯形式的径向基函数将每个训练样本映射为一个连续的函数，函数的中心就是样本点的取值。在整个空间内对所有的高斯函数求和，得到的就是拟合出的曲面。当新样本出现时，其在曲面上的映射值就等于所有高斯径向基函数在这个数据点上的函数值之和。

感受野理论告诉我们，每个训练数据对曲面的影响都只限于其数据周边的一个小范围内，因而在新样本的插值结果中，贡献较大的是离它比较近的训练数据。如果某些训练数据距离新样本较远，就不会对新样本产生影响。

这就解释了为什么径向基网络天然具有“局部泛化”的性质：新样本的预测主要由邻近的样本决定，远处样本的权重按距离指数衰减，几乎可以忽略。

补充说明：纯插值式的径向基网络有一个隐患——样本点越多，需要的高斯函数越多，而每个高斯函数的中心都钉在一个训练样本上。当样本含有噪声时，网络会把噪声也精确地插值进去，形成过拟合。解决办法是**正则化径向基网络**：不再要求曲面严格经过每个数据点，而是在拟合误差之外加一项平滑惩罚。这与回归里的岭回归是同一思路，只是作用在了函数空间上。

六、两阶段训练

6.1 K 均值确定中心

在实际应用中，对径向基网络的训练包括两个步骤。第一步的任务是初始化中心向量 w_i 的位置，中心向量的位置既可以随机分配，也可以通过 K 均值聚类这一无监督学习的方法完成。这个步骤对应的是隐藏层的训练。

使用 K 均值算法训练隐藏层时，聚类的数目 K 决定了隐藏神经元的数目，通过这个参数设计者可以控制径向基网络的性能和计算复杂度。算法的参数确定后，就能够对训练数据进行无监督的分类，计算出的每个聚类的中心就是高斯函数的中心。

出于简化设计的考虑，每个高斯函数的带宽都是相同的，并被统一设置为 $\sigma = d_{max} / (2K)$，其中 d_{max} 是不同中心之间的最大距离。这种带宽的配置符合 K 均值算法中的中心散布，保证了各个高斯函数既不会太宽也不会太窄。

补充说明：K 的取值直接决定了网络的容量。K 太小，中心覆盖不住数据分布，欠拟合；K 太大，每个高斯函数只管极小的区域，网络退化为查表，过拟合且计算量上升。由于 K 均值的结果依赖初始中心，常用做法是多次随机初始化取最优，或用 k-means++ 按距离概率选初始中心。另外注意：带宽公式对 K 是敏感的，K 翻倍时带宽减半，每个基函数的响应范围也跟着缩小一半，所以调整 K 时不能把带宽当作独立参数看待。

6.2 递归最小二乘拟合输出层

隐藏层的训练完成后，就可以开始输出层的训练了。输出层的输入信号是每个隐藏神经元输出信号的线性组合，因而递归最小二乘法是训练权重向量的合适选择。

权重向量和隐藏神经元输出之间的关系可以表示为

$$R(n)\,\hat{w}(n) = r(n)$$

式中的 R 表示 K 个隐藏神经元输出之间的相关矩阵，ŵ 表示待训练的未知权重向量，r 表示期望响应和隐藏单元输出之间的 K×1 维互相关向量，自变量 n 则代表了训练的轮次。

递归最小二乘法的作用在于简化逆矩阵 $R^{-1}(n)$ 的求解：它不直接求逆，而是用矩阵求逆引理把上一步的逆矩阵递推更新，每来一个新样本只做一次低秩修正。这让它的计算量随样本逐个到来而线性累积，适合在线学习。

6.3 反向传播微调

在训练完成后还可以添加额外的一个步骤，利用反向传播算法对径向基网络的所有参数进行一次微调，以达到更好的训练效果。

这是由于无论是 K 均值聚类还是递归最小二乘法，都是针对特定层次的优化，反向传播优化的对象则是作为整体的径向基网络，它可以在统计意义上保证整个系统的最优性。

补充说明：两阶段训练的价值在于解耦。若一上来就用反向传播端到端训练，中心向量、带宽、输出权重全都要靠梯度下降找，非凸性带来的局部极小会让结果对初始化非常敏感。先用无监督的 K 均值把中心放到数据密集的地方，等于给了一个有物理意义的初值，再让梯度去微调，收敛就稳得多。这与今天深度网络"预训练 + 微调"的做法在思路上是同源的。

七、局部逼近与全局逼近的对比

与感知器类型的神经网络相比，径向基网络代表的则是局部逼近的工作方式：神经元的输入离径向基函数中心越近，神经元的激活程度就越高。但两者都能够实现**通用逼近**，也就是对任意非线性函数的逼近。

对比项	多层感知器	径向基网络
逼近方式	全局逼近	局部逼近
隐藏层激活	Sigmoid 等单调函数	高斯等径向基函数
输入到隐藏层	可训练权重	权重固定为 1
隐藏层参数	权重与偏置	中心向量与带宽
训练方法	反向传播端到端	K 均值 + 最小二乘，可选微调
收敛速度	较慢	较快
可解释性	较弱	中心即原型，较直观

局部逼近的优势是收敛快、样本改动影响局部；代价是维度高时需要的中心数目增长很快——输入维度为 d 时，覆盖整个空间所需的局部单元数随 d 指数增长。这就是所谓的**维度灾难**，也是径向基网络在大规模高维任务上不如深度网络的原因。

四个常见误区

- **“RBF 网络就是用了高斯核的 SVM”**——两者都用到核函数，但 RBF 网络是“基函数展开 + 线性输出层”的两阶段模型，SVM 是最大间隔分类器，训练目标完全不同。
- **“中心越多拟合越好”**——中心过多会跟着噪声走，而且每个中心都要算一次距离，计算量随中心数线性增长。
- **“RBF 只能做回归”**——输出层换成 Sigmoid 或 Softmax，它就是分类器；结构本身对任务类型没有限制。
- **“两阶段训练一定比端到端差”**——数据少、需要快速建立基线时，两阶段训练反而更稳；端到端需要更多数据才能把中心也学好。

八、要点回顾

1. 多层感知器是全局逼近，每个权重影响整个输入空间；径向基网络是局部逼近，每个神经元只对特定区域响应。
2. 局部作用有生理学依据，对应神经科学中的感受野概念。
3. 径向基网络采用三层结构，输入层到隐藏层的权重固定为 1，隐藏神经元以径向基函数为传递函数。
4. 常用径向基函数是高斯函数，形状由中心向量 w_i 与带宽 σ 共同决定。
5. 隐藏层完成从输入空间到高维特征空间的非线性变换，作用是让线性不可分的数据变得可分，与支持向量机的核技巧同源。
6. 异或问题可以用两个高斯函数映射到二维特征平面后，由一条直线分开，且整个过程不增加维数。
7. 从插值角度看，径向基网络是用一组以样本为中心的高斯曲面叠加拟合出目标超曲面，新样本的预测主要由邻近样本决定。
8. 训练分两阶段：先用 K 均值确定中心与带宽，再用递归最小二乘拟合输出权重，最后可用反向传播整体微调。
9. 径向基网络与多层感知器都能通用逼近任意非线性函数，前者胜在收敛快、可解释，后者胜在高维下参数效率更高。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
全局逼近	Global Approximation	—	每个权重都影响整个输入空间输出的逼近方式
局部逼近	Local Approximation	—	每个神经元只对输入空间中特定区域响应的逼近方式
感受野	Receptive Field	—	能引起某感觉神经元反应的刺激区域
径向基函数网络	Radial Basis Function Network	RBFN	以径向基函数为隐藏层传递函数的三层前馈网络
径向基函数	Radial Basis Function	RBF	只取决于与中心点距离、呈圆周对称的函数
中心向量	Center Vector	—	径向基函数的中心位置，在 RBF 网络中作为隐藏层权重

名称	英文全称	英文缩写	简短介绍
带宽	Bandwidth	σ	控制径向基函数宽窄、即局部响应范围的参数
高斯函数	Gaussian Function	—	形如 $\exp(-\|x-w\|^2/2\sigma^2)$ 的钟形径向基函数
高斯核	Gaussian Kernel	RBF Kernel	支持向量机中形式与高斯函数相同的核函数
核技巧	Kernel Trick	—	用核函数隐式完成高维映射、避免显式计算的方法
Cover 定理	Cover's Theorem	—	非线性映射到高维后线性可分概率显著提高的结论
多变量插值	Multivariate Interpolation	—	用已知离散点构造通过它们的连续曲面的方法
超曲面	Hypersurface	—	高维空间中比所处空间低一维的曲面
正则化径向基网络	Regularized RBF Network	—	允许曲面不严格经过样本点、加平滑惩罚的 RBF 网络
K 均值聚类	K-Means Clustering	—	用 K 个中心迭代划分样本的无监督聚类算法
递归最小二乘	Recursive Least Squares	RLS	逐个样本递推更新最小二乘解的在线算法
相关矩阵	Correlation Matrix	—	隐藏神经元输出之间的二阶统计量矩阵
互相关向量	Cross-correlation Vector	—	期望响应与隐藏单元输出之间的相关向量
维度灾难	Curse of Dimensionality	—	维数升高时覆盖空间所需样本或单元数指数增长的现象
通用逼近	Universal Approximation	—	网络能以任意精度逼近任意连续函数的能力