自组织特征映射：竞争学习、侧向抑制与拓扑排序

读前须知

- **前置**：欧氏距离与聚类的基本思路。
- **这一篇的位置**：无监督神经网络代表。它不用标签，却能把高维数据按“相似性”铺到一张二维网格上。
- **读完能做什么**：解释竞争学习与侧向抑制的作用；说清“拓扑保持”意味着什么；自己安排一次从粗到细的学习率衰减。

一、从监督到无监督

1.1 两种逼近方式的共同前提

无论是全局逼近的多层感知器，还是局部逼近的径向基网络，在训练中用到的都是**监督学习**的方法：每个训练样本都必须带一个标签，网络靠输出与标签的差来调整权重。

这条前提看起来天经地义，实则是很强的一个约束。现实中的数据绝大多数没有标签，给数据打标签的成本往往比训练模型本身更高。如果把无监督学习引入神经网络中，对应的结构就是**自组织特征映射**（Self-Organizing Map），这是芬兰赫尔辛基大学的泰乌沃·柯霍宁于 1981 年提出的一类神经网络。

1.2 自组织映射的两个不同

相比于前面介绍的神经网络，自组织映射有两个明显的不同。

第一，它能够将高维的输入数据映射到低维空间之上（通常是二维空间），因而起到**降维**的作用。在降维的同时，自组织映射还能维持数据在高维空间上的原始拓扑，将高维空间中相似的样本点映射到网络输出层的邻近神经元上，从而保留输入数据的结构化特征。

第二，自组织映射采用的是**竞争性学习**而非传统的纠错学习。在竞争性学习中，对输入样本产生响应的权利并不取决于预设的权重系数，而是由各个神经元相互竞争得到的。不断竞争的过程就是网络中不同神经元的作用不断专门化的过程。

> **新手提示：拓扑保持是什么意思**
>
> 降维方法很多，但大多只关心“距离别差太远”，不保证邻接关系。拓扑保持是更强的要求：在高维空间里相邻的两个样本，映射到低维后必须落在相邻的位置；反之，低维上相邻的两个位置，也应当对应高维中相似的样本。这相当于要求映射在局部是一一对应且连续的。一张世界地图要能当地图用，靠的正是这个性质，而不仅仅是把球面压平。

二、竞争学习与侧向抑制

2.1 胜者通吃

竞争性学习的理念来自于神经科学的研究。在生物的神经系统中存在着一种名叫**侧向抑制**的效应，它描述的是兴奋的神经元会降低相邻神经元活性的现象。

侧向抑制能够阻止从侧向刺激兴奋神经元到邻近神经元的动作电位的传播。当某个神经元受到刺激而产生兴奋时，再刺激相近的神经元，则后者的兴奋对前者就会产生抑制作用。这种抑制作用会使神经元之间出现竞争，在竞争中胜出的神经元就可以“胜者通吃”，将竞争失败的神经元全部抑制掉。

自组织映射中的竞争性学习模拟的就是上述的侧向抑制机制。对每个输入，只有一个（或极少数）神经元被选为优胜者，其余神经元的响应被压制。

2.2 侧向抑制的意义

如果所有神经元都对同一个输入产生同样强度的响应，输出就没有任何信息量。侧向抑制的作用是制造**稀疏性**：让响应集中到少数神经元上，从而使不同的输入激活不同的神经元，形成分工。

这与多层感知器中靠随机初始化打破对称性的思路不同。多层感知器是被动地避免对称，自组织映射是主动地制造差异：每次竞争都在强化胜者对特定输入的专属权。

补充说明：纯胜者通吃有一个隐患：有些神经元可能从始至终都没赢过，权重原地不动，成为“死单元”。输入样本少、初始化又不好时，这种情况很常见。常见的补救办法有三种：一是给每个神经元记一个“获胜次数”，次数越多则下次获胜的难度越大；二是在竞争中给距离较大的神经元一点补偿；三是每隔一段时间把死单元的权重重置到某个样本上。这些做法与 K 均值里处理空簇的思路是一致的。

三、网格拓扑：位置即含义

3.1 一维或二维网格

自组织映射的拓扑结构并非如多层感知器般的层次结构，而是一张一维或者二维的网格，网格中的每个节点都代表一个神经元，神经元的权重系数则是和输入数据的维度相同的向量。

输入层与输出层之间没有隐藏层，连接方式则是全连接——每个输入分量都连到每个输出神经元。所谓“网络”，在这里指的是一张平面上的节点阵列。

3.2 距离即相似

在拓扑结构中，每个神经元的位置都不是随意选取的，而是和功能有着直接的关系。距离较近的神经元能够处理模式相似的数据，距离较远的神经元处理对象的差异也会很大。

由于神经元在网格中的位置至关重要，因而训练过程就是在空间上对神经元进行有序排列的过程。自组织映射为神经元建立起一个坐标系，由于每个网格神经元对应一类特定的输入模式，输入模式的内在统计特征就是通过神经元的坐标来表示的。

换句话说，自组织映射的输出不是一个分类标签，而是一个**位置**。这个位置本身就是对输入特征的编码。

因此，自组织映射的主要任务就是将任意维度的输入模式转换为一维或二维的离散映射，并以拓扑有序的方式自适应地实现这个映射。

四、训练的四个过程

4.1 竞争：找最佳匹配

在训练过程中，自组织映射中每个神经元的权重系数首先要初始化，初始化的方式通常是将其赋值为较小的随机数，这可以保证不引入无关的先验信息。当初始化完成后，网络的训练就包括以下三个主要过程，加上后续的排序收敛，可以概括为四个环节。

竞争过程：对每个输入模式，网络中的神经元都计算其判别函数的取值，判别函数值最大的神经元成为竞争过程的优胜者。

竞争过程的实质是找到输入模式和神经元之间的最佳匹配。由于输入模式 x 和权重系数 w 是具有相同维度的向量，因而可以计算两者的内积作为判别函数：

$$j^* = \arg\max_j \ w_j^\top x$$

在线性代数中，内积表示的是向量之间的关系，两个归一化向量的相关度越高，其内积也就越大。因而通过选择具有最大内积的神经元，就可以决定兴奋神经元拓扑邻域的中心位置。

两个向量的内积越大，它们之间的欧氏距离就越小，因而内积最大化的匹配准则等效于欧氏距离最小化。这层等价关系可以从距离平方的展开式直接看出：

$$\|x - w_j\|^2 = \|x\|^2 + \|w_j\|^2 - 2w_j^\top x$$

当输入与权重都被归一化为单位长度时，前两项都是常数，最小化距离就等价于最大化内积。从这个角度看，获胜神经元就是对输入模式的最佳匹配。

> **新手提示：权重归一化为什么重要**
>
> 若权重向量长度不受约束，内积最大的神经元未必是最相似的——长度大的向量天然占优，即使方向对不上。两种解决办法：训练前把输入和权重都归一化，或干脆直接用欧氏距离作判别。柯霍宁最初的算法采用前者，后来的实现多用后者，两者在归一化条件下是等价的。

4.2 合作：界定拓扑邻域

竞争过程确定了合作神经元的拓扑邻域的中心，合作过程就要界定中心之外的拓扑邻域。

借鉴侧向抑制效应，自组织映射中的拓扑邻域被定义成以最佳匹配神经元和兴奋神经元之间的侧向距离为自变量的**单峰函数**。由于神经元在传导时倾向于激活距离较近的神经元，因而拓扑邻域的幅度在距离为 0 的中心点取到最大值，并随着侧向距离的增加而单调衰减。

同时，拓扑邻域还应该满足**平移不变性**，也就是邻域幅度不依赖于中心点的位置。除了单峰值和平移不变性之外，自组织映射中的拓扑邻域还有另一个特点，就是其大小会随着时间的推移而收缩，也就是幅度值随着时间的增加而下降。这个时变性质的意义在于逐渐减少需要更新的神经元的数量。

一种常用的邻域函数是高斯型：

$$h_{j,i}(n) = \exp\left(-\frac{d_{j,i}^2}{2\sigma^2(n)}\right)$$

式中 d_{j,i} 是神经元 j 与获胜神经元 i 在网格上的距离，σ(n) 是随训练轮次递减的邻域半径。

4.3 自适应：调整权重

网络的自组织特性要求神经元的权重系数具备自动调节的功能。权重系数的整体变化趋势是向数据靠拢，因而其分布也将趋于输入模式的分布。权重系数的更新方程为

$$w_j(n+1) = w_j(n) + \eta(n)\, h_{j,i(x)}(n)\,[x(n) - w_j(n)]$$

式中的 η(n) 是随时间增加而下降的学习率参数，h_{j,i(x)}(n) 则是拓扑邻域函数。

这个式子的结构很值得注意：更新量正比于“输入与当前权重的差”，也就是把权重向量朝输入的方向拉一把；拉动的幅度由学习率与邻域函数共同决定。获胜神经元的邻域函数值为 1，拉得最狠；邻域外的神经元函数值接近 0，几乎不动。所有被拉动的神经元都朝同一个输入靠拢，这正是“邻近的神经元学会相似的模式”这一现象的来源。

4.4 排序阶段与收敛阶段

因而，自适应过程可以分为两个阶段。第一阶段是**排序阶段**，权重系数的拓扑排序在这个阶段形成；第二阶段是**收敛阶段**，通过微调特征映射实现对输入模式的精确描述。

只要算法的参数没有问题，自组织映射就能将完全无序的初始状态按照输入模式以有组织的方式重构，这也是“自组织”的含义。

补充说明：自组织映射与时下常用的 t-SNE、UMAP 目标相似，都是把高维数据压到二维并尽量保留邻接关系，但实现路径完全不同。自组织映射靠一批原型向量与竞争学习，映射关系是显式的——每个样本落在哪个网格点上可以直接查出来，新样本也能直接映射。t-SNE 与 UMAP 则是在优化一个全局目标函数，没有“原型”的概念，映射结果依赖本次优化的具体样本集，新样本要重新嵌入。前者适合在线使用与增量更新，后者在可视化效果上通常更紧凑。

> **新手提示：为什么学习率和邻域都要随时间衰减**
>
> 训练初期需要大范围调整，让网格上相距较远的神经元也能被同一个输入拉动，从而形成大尺度的有序排列；若此时邻域很小，各神经元只在局部调整，全局秩序永远建立不起来。训练后期则相反，需要小步微调，避免已经形成的秩序被打乱。学习率的衰减同理：早期大步快跑，后期小步收敛。这两个参数一起构成了一条“先粗后细”的退火策略。

五、权重更新与初始化

5.1 训练步骤汇总

由于自组织映射采用的是迭代的训练方法，初始值的好坏便至关重要。综合起来，自组织映射的训练算法可以归纳为以下几个步骤：

1. 使用主成分法或随机法初始化神经元的权重系数；
2. 选取训练集中的样本用于激活整个网络；
3. 根据最小距离准则寻找最佳匹配神经元；
4. 通过更新方程调整所有神经元的权重系数；
5. 重复以上步骤直到在从输入模式到神经元的映射关系中观察不到明显变化。

补充说明：逐个样本更新的做法有两个不便：结果依赖样本到达的顺序，而且训练后期学习率很小时收敛很慢。为此有一个批量版本，通常称为 **Batch SOM**：每一轮先固定权重，把所有样本分配到最近的神经元，然后按邻域权重对所有样本的贡献取平均，一次性更新全部原型。这样就去掉了顺序依赖，也让训练可以并行。代价是每一轮都要遍历全量数据，且邻域与学习率仍要按轮次退火。

5.2 随机初始化与主成分初始化

传统算法采用的是随机方式的初始化，后来又提出了基于主成分的初始化方法。

事实上，初始化方法的性能取决于输入数据集的几何形状。如果数据集在主成分上的投影是线性的，就应该选择主成分初始化；可对于非线性数据集而言，随机初始化反而是最优选择。

这个结论初看有些反直觉：主成分初始化明明用了更多数据信息，为什么反而不如随机？原因在于主成分只捕捉了数据的线性结构，若数据本身沿一条弯曲的低维流形分布，主成分方向会给出一个错误的大尺度布局，而自组织映射一旦在大尺度上排错，后续的局部调整很难扭转过来。随机初始化的“无知”反而避免了这种误导。

补充说明：自组织映射与 K 均值有很深的渊源。把邻域函数换成“只在获胜神经元处取 1、其余为 0”，更新方程就退化成在线版本的 K 均值：每个输入只更新最近的那个中心。所以自组织映射可以看作**带拓扑约束的 K 均值**——它不仅要求每个输入找到最近的中心，还要求相邻的中心在网格上也是相邻的。这一条额外约束，正是它能保持拓扑、而 K 均值不能的原因。

六、特征映射的性质

6.1 数据压缩与向量量化

从输入模式到神经元的映射关系被称为**特征映射**，它具有很多良好的性质。

由于权重系数的维度会远远小于输入数据的可能数目，因而特征映射可以对输入空间提供一个良好的近似，起到数据压缩的作用。

从信息论的角度看，这件事的实质是**向量量化**：用有限个码字（权重向量）去近似一个连续的输入分布，每个码字代表一个区域。K 个神经元就是 K 个码字，训练过程就是在寻找一组最能代表数据分布的码字。

6.2 编码器—解码器视角

从这个角度理解，自组织映射可以看成是一个编码器—解码器模型：寻找最佳匹配神经元就是对输入模式进行编码，确定权重系数则是对编码结果进行解码，邻域函数则可以表示对编解码过程造成干扰的噪声的概率密度。

自组织映射的这个性质与信息论中用于数据压缩的向量量化方法不谋而合。

6.3 概率分布的定性表示

当算法收敛后，特征映射就能够表示出输入模式的统计特性。如果输入空间上的某些数据出现的概率较高，它们就会被映射到输出空间中更大的区域上，也就会涵盖更多的神经元。

但这个趋势只有定性的意义，自组织映射不能给出输入数据固有概率分布的精确表示，因而不具备定量描述的能力。虽然不能定量描述固有分布，但自组织映射依然能够选择出一组最优的特征，使这组特征在逼近固有分布时具有最佳的效果。

补充说明：判断一个自组织映射训练得好不好，通常看两个指标。**量化误差**衡量每个样本到其获胜神经元的平均距离，反映码字对数据的拟合精度；**拓扑误差**衡量每个样本的最近邻样本在网格上是否也相邻，反映拓扑保持的程度。两个指标往往互相牵制：把邻域调小能降低量化误差，但拓扑误差可能上升。实际调参就是在这两者之间找平衡。另一个常用的可视化手段是 **U 矩阵**：把每个神经元与其网格邻居的权重距离画成灰度图，距离大的地方形成“山脊”，正好对应不同簇之间的分界。

七、典型应用

自组织映射通过以无监督方式训练大量数据实现特征映射，以实现不同类型数据的区分。其简便易行的特性和强大的可视化能力使它在不少需要大规模数据训练的应用中得到使用。

自组织映射一个典型的应用是在图像处理中检测和描述语义目标和目标类之间的存在关系，以及自然语言中单词的语义规则。

在自然语言处理中，把词向量送入二维自组织映射，语义相近的词会聚集在网格上相邻的位置，形成一张“语义地图”；在工业监测中，把设备的多维运行参数送入映射，正常工况会占据网格上稳定的区域，一旦运行点漂移到边缘区域就提示异常；在客户分析中，高维的用户行为特征被压缩到二维平面，簇的分布可以直接用肉眼观察。

补充说明：自组织映射在今天不再是主流的表示学习方法，但它留下的两个思想仍有影响。其一是**竞争与专门化**：让不同的单元负责不同的输入区域，而不是所有单元平均响应，这一原则在稀疏编码与混合专家模型里都能看到。其二是**拓扑保持的可视化**：把高维数据压到二维平面并保持邻接关系，至今仍是数据探索阶段最实用的手段之一，t-SNE 与 UMAP 在目标上与自组织映射一致，只是优化方式不同。

四个常见误区

- **“SOM 就是聚类算法”**——它给的是拓扑映射，不是硬划分。一个节点可以代表多个样本，也没有明确的簇边界。
- **“网格越大越精细越好”**——网格过大时很多节点得不到充分训练，拓扑反而混乱；网格应随数据量与内在维度选择。
- **“拓扑保持是严格成立的”**——它只在训练充分且数据流形与网格维度匹配时近似成立，数据折叠或维度不匹配时会被扭曲。
- **“学习率固定即可”**——必须从大到小衰减，否则后期权重持续抖动、无法收敛到稳定映射。

八、要点回顾

1. 自组织映射是一类无监督学习的神经网络，模拟了生物神经系统的竞争性学习机制。
2. 它有两个特点：把高维输入映射到一维或二维并保持拓扑结构；用竞争学习替代纠错学习。
3. 竞争学习的生理学依据是侧向抑制，胜者通吃，使不同神经元逐渐专门化。
4. 输出层是一维或二维网格，神经元之间的距离对应输入模式的相似程度，位置本身就是编码。
5. 竞争过程用内积或欧氏距离找最佳匹配神经元，两者在归一化条件下等价。
6. 合作过程用单峰、平移不变、随时间收缩的邻域函数，界定哪些神经元参与更新。
7. 自适应过程按更新方程把权重朝输入方向拉动，训练分排序与收敛两个阶段。
8. 初始化可选随机或主成分法：数据线性时主成分更好，非线性时随机反而更优。
9. 特征映射具有数据压缩与向量量化的性质，能定性反映输入分布但不能定量描述。
10. 自组织映射可视作带拓扑约束的 K 均值，量化误差与拓扑误差是评价它的两个基本指标。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
自组织特征映射	Self-Organizing Map	SOM	用竞争学习把高维数据映射到低维网格并保持拓扑的网络
无监督学习	Unsupervised Learning	—	不使用标签、只从数据本身结构学习的范式
竞争学习	Competitive Learning	—	神经元相互竞争、只有胜者被更新的学习方式
侧向抑制	Lateral Inhibition	—	兴奋神经元压制相邻神经元活性的生理效应
胜者通吃	Winner-Takes-All	WTA	只有响应最强的神经元被激活或更新的机制
拓扑结构	Topology	—	神经元在网格中的邻接与距离关系
拓扑保持	Topology Preservation	—	高维相邻样本映射到低维后仍然相邻的性质
判别函数	Discriminant Function	—	用于比较各神经元响应强度、选出优胜者的函数

名称	英文全称	英文缩写	简短介绍
最佳匹配神经元	Best Matching Unit	BMU	对当前输入响应最强的神经元，即竞争胜者
拓扑邻域	Topological Neighborhood	—	以获胜神经元为中心、按距离衰减的参与更新区域
邻域函数	Neighborhood Function	—	描述邻域内各神经元更新权重随距离衰减的函数
学习率	Learning Rate	η	控制权重朝输入方向拉动幅度的参数
排序阶段	Ordering Phase	—	训练前期形成权重全局拓扑排列的阶段
收敛阶段	Convergence Phase	—	训练后期微调权重以精确描述输入模式的阶段
主成分初始化	PCA Initialization	—	用主成分方向设定神经元初始权重的初始化方法
特征映射	Feature Map	—	从输入模式到输出神经元的映射关系
向量量化	Vector Quantization	VQ	用有限个码字近似连续输入分布的压缩方法
码字	Codeword	—	向量量化中代表一个区域的代表向量
量化误差	Quantization Error	—	样本到其获胜神经元权重的平均距离
拓扑误差	Topological Error	—	最近邻样本在网格上不相邻的样本所占比例
U 矩阵	Unified Distance Matrix	U-Matrix	以邻居权重距离着色、用于可视化簇边界的矩阵
维度灾难	Curse of Dimensionality	—	维数升高时所需样本或单元数指数增长的现象