深度学习概述：深蓝与 AlphaGo、层级抽象与工程条件

读前须知

- **前置**：机器学习的基本概念（007 篇）与多层感知器（018 篇）。
- **这一篇的位置**：从“浅层模型”转向“深层网络”的转折点，也是理解后面五篇（前馈、正则、优化、自编码、强化学习）的框架。
- **读完能做什么**：说清“深”到底带来了什么；解释为什么深度学习要等到 2012 年之后才真正可用；区分工程突破与理论突破。

一、两种棋类智能的对比

1.1 深蓝：以算取胜

1997 年，IBM 的深蓝在国际象棋棋盘上战胜了当时的人类世界冠军加里·卡斯帕罗夫。十余年后，2016 年，DeepMind 的 AlphaGo 在围棋棋盘上战胜了李世石。两场胜利相隔近二十年，背后却是两条完全不同的技术路线。

棋类游戏的核心在于根据棋局判断下一手的最优下法，深蓝通过穷举的方法在国际象棋的棋局中解决了这个问题。在 64 格的国际象棋棋盘上，深蓝的运算能力决定了它能算出 12 手棋之后的局面下的最优解，而身为人类棋手执牛耳者的卡斯帕罗夫最多只能算出 10 手棋，多出来的两手棋就会成为左右战局的关键因素。

深蓝的核心在于“算”：利用强大的计算资源来优化目标函数。深蓝本身就是一套专用于国际象棋的硬件，大部分逻辑规则是以特定的象棋芯片电路实现，辅以较少量负责调度与实现高阶功能的软件代码。其算法的核心是暴力穷举：生成所有可能的下法，然后执行尽可能深的搜索，并不断对局面进行评估，尝试找出最佳的一手。

1.2 AlphaGo：以想取胜

可在围棋棋盘上，可以落子的点数达到了 361 个。别说 12 手棋，就是 6 手棋的运算量都已经接近于天文数字。

这个数字可以用博弈树的规模来估。若每步平均有 b 种选择、向前搜索 d 手，需要考察的叶节点数约为：

$$N \approx b^d$$

这个量随深度指数增长。国际象棋的 b 约为 35，围棋的 b 约为 250。同样搜 6 手，国际象棋约 1.8×10^9 个节点，围棋则达到 2.4×10^{14} 个，相差五个数量级。这就是为什么“多算两手”在国际象棋里是优势，在围棋里却成了一场灾难。

这使得计算机相对于人脑的运算优势变得微不足道，走出优于人类棋手的妙手的概率也微乎其微，这也是计算机在围棋领域被看衰的原因。

围棋的棋盘状态远比国际象棋复杂，以穷举法进行最优落子策略的推演无异于痴人说梦。事实上，顶级的围棋棋手更多地依赖模糊的直觉来评判特定的棋盘状态的好坏。但理性推演与感性判断之间似乎存在着不可逾越的巨大鸿沟，尤其是对于计算机程序而言，依赖直觉是不可能的事情。因此并没有显而易见的方式来将国际象棋领域的成功复制到围棋上，直到 AlphaGo 的横空出世。

与深蓝相比，AlphaGo 的核心则在于“想”。与专用硬件深蓝不同，AlphaGo 是一套能够运行在通用硬件之上的纯软件程序。它汲取了人类棋手海量的棋谱数据，并依赖人工神经网络和深度学习技术从这些数据中学会了预测人类棋手在任意的棋盘状态下走子的概率，模拟了以人类棋手的思维方式对棋局进行思考的过程。

补充说明：AlphaGo 并不只是“把棋谱喂给神经网络”这么简单。它由三个部件协同工作：**策略网络**负责给出候选落子，把搜索范围从 361 个点压缩到少数几个；**价值网络**评估某个局面的胜率，替代了深蓝那种靠手工编写的局面评估函数；**蒙特卡洛树搜索**则把两者组织起来，向前推演若干步并回溯更新各节点的得分。策略网络解决“往哪看”，价值网络解决“看不看得清”，树搜索解决“怎么算”。三者缺一不可——单靠策略网络下棋的水平远不及人类职业棋手。

1.3 从 AlphaGo 到 AlphaZero

与深蓝的区别正是 AlphaGo 的突破之处。早期的计算机就已经被用来搜索优化已有函数的方式，深蓝的特点仅仅在于搜索的目标是优化尽管复杂但形式大多数由已有的国际象棋知识表达的函数，其思想与人工智能早期的多数程序并无二致。而在整个算法中，除了“获胜”这个概念，AlphaGo 对于围棋规则一无所知，更遑论定式等围棋的高级专门概念了。这也是 AlphaGo 和深蓝的本质区别。

同是战胜了棋类世界冠军，深蓝仍然是专注于国际象棋的、以暴力穷举为基础的专用人工智能；AlphaGo 是几乎没有特定领域知识的、基于机器学习的、更加通用的人工智能。

但 AlphaGo 的故事还远没有结束。2017 年 10 月，其升级版 AlphaGo Zero 诞生。AlphaGo Zero 完全抛弃了来自棋谱数据的人类经验，而是通过左右互搏迅速提升棋力，在 AlphaGo 的基础上青出于蓝。放在人类世界里，这就如一个从没上过学的学霸靠自己刷题复习，刷了一个月就拿到高考状元般不可思议。可仅仅一个月后，DeepMind 又推出了 AlphaGo Zero 的升级版 AlphaZero。AlphaZero 一不需要人工特征，二不需要棋谱知识，三不需要特定优化，可就是这个“三无”算法实现了对围棋、国际象棋和日本将棋的通吃，以摧枯拉朽之势横扫这些棋类游戏的顶级算法。

这条演进线索值得留意：深蓝依靠人编写的评估函数，AlphaGo 依靠人提供的棋谱，AlphaGo Zero 连棋谱也不要了，只剩下规则和奖励。每往前一步，人的先验知识就少一分，而系统的通用性就多一分。

二、什么是深度学习

2.1 定义：多个隐藏层

AlphaGo 的胜利也是深度学习的胜利。

深度学习是利用包含多个隐藏层的人工神经网络实现的学习。在介绍多层感知器时提到过，在原理上，两个隐藏层足以解决任何类型的非线性分类问题，因而浅层神经网络最多只会包含两个隐藏层。相比于浅层神经网络，正是这“多个”隐藏层给深度学习带来了无与伦比的优势。

写成通式，一个 L 层的前馈网络是若干次“仿射变换 + 非线性变换”的复合：

$$h^{(l)} = f\left(W^{(l)}h^{(l-1)} + b^{(l)}\right), \qquad l = 1, 2, \cdots, L$$

每一层的输出 $h^{(l)}$ 都是对上一层表示的一次重新编码，最终的输出层再做一次任务相关的变换。

2.2 深度带来的优势

在深度学习中，每个层可以对数据进行不同水平的抽象，层间的交互能够使较高层在较低层得到的特征基础上实现更加复杂的特征提取。不同层上特征的组合既能解决更加复杂的非线性问题，也能识别更加复杂的非线性模式。

这句话的要点在于“不同水平”四个字。浅层网络的所有隐藏层都在同一个抽象层次上工作，区别只在于参数取值；深度网络的各层处在不同的抽象层次上，后面层看到的是前面层加工过的表示，而不是原始输入。

> **新手提示：深度学习不等于“层数越多越好”**
>
> 深度学习的“深度”指隐藏层的数目，而不是网络的参数量或训练时长。一个宽度很大但只有一两个隐藏层的网络，参数量可能超过一个二十层的小网络，但它不属于深度学习。反过来，层数也不是越多越好：层数增加会带来梯度消失、训练不稳定、退化等问题，需要残差连接、归一化等配套技术才能训练起来。深度是一种结构选择，不是简单的堆叠。

补充说明：深度带来的是表达效率，不只是表达力。万能逼近定理保证了单隐藏层网络也能逼近任意连续函数，但它不保证所需的神经元数目是可行的——对某些函数，单层网络需要的宽度随输入维度指数增长，而深层网络只需多项式级的参数。直观地说，深度允许“复用”：低层的简单函数被高层的多个函数共享，不必为每种组合单独准备一套参数。这也是为什么同样参数量下，深网络通常比宽网络表现更好。

三、来自视觉系统的启发

3.1 胡贝尔与魏泽尔的实验

与人工神经网络一样，深度学习的思想同样来源于生理学上的研究进展。

1981 年，两位神经生物学家大卫·胡贝尔和托尔斯滕·魏泽尔连同另一位科学家分享了诺贝尔医学奖，他们二位的主要贡献在于“发现了视觉系统的信息处理方式，即可视皮层是分级的”。

1958 年，胡贝尔和魏泽尔在美国的约翰霍普金斯大学开展关于瞳孔区域与大脑皮层神经元对应关系的研究。他们给小猫展现形状和亮度各不相同的物体，并改变每个物体放置的位置与角度。在这一过程中，小猫的瞳孔感受不同类型和不同强度的刺激，小猫大脑的枕叶上则被植入电极，用来测量神经元的活跃程度。

这一实验的目的是验证一个假设：位于枕叶皮层的不同视觉神经元与瞳孔感受到的刺激信号之间，存在某种相关性。一旦瞳孔受到某种特定的刺激，枕叶皮层的某些特定神经元就会活跃。

3.2 方向选择性细胞

经过长期的实验，胡贝尔和魏泽尔发现了**方向选择性细胞**：当瞳孔发现了眼前物体的边缘，而且这个边缘指向某个方向时，这种神经元细胞就会活跃。

这一发现不仅在生理学上具有里程碑式的意义，更是无心插柳地促成了人工智能在四十年后的突破性发展。方向选择性细胞的发现表明，神经—中枢—大脑的工作过程，或许正是一个不断迭代、不断抽象的过程。人眼处理来自外界的视觉信息时，首先提取出目标物的边缘特性，再从边缘特性中提取出目标物的特征，最后将不同特征组合成相应的整体，进而准确地区分不同的物体。

在这个过程中，高层特征是低层特征的组合，从低层到高层，特征变得越来越抽象，语义的表现就越来越清晰，对目标物的识别也就越来越精确。

> **新手提示：为什么“边缘”是视觉的第一站**
>
> 从信息的角度看，一张图像中绝大部分像素值与邻居高度相关，直接表示整幅图是极其浪费的。真正携带信息的，是像素值发生突变的地方——也就是边缘。边缘把图像切成若干区域，区域内部的颜色与纹理近似均匀，区域之间才有语义上的差别。先在边缘上做文章，等于先把“信息量最大的部分”抽出来，后面的加工就不必面对全部像素。这与压缩编码里先做边缘检测是同一个道理。

补充说明：卷积网络几乎是把这一发现直接写成了架构。卷积核在局部窗口上滑动，每个核学习一种特定方向的边缘或纹理，这与方向选择性细胞只对特定朝向的刺激响应高度一致；多个卷积核并行，相当于一层里有多种方向选择性的细胞；堆叠多层则实现了从边缘到形状再到物体的逐级抽象。1980 年福岛邦彦提出的神经认知机已经包含了这一思想，而 1998 年 LeCun 的 LeNet 用反向传播把它训练了出来。所以卷积网络不是从数学里推导出来的，而是从视觉皮层里"抄"出来的。

四、逐层抽象：深度网络的表示方式

4.1 从边缘到目标

深度学习正是受启于视觉系统的感受方式。在深度学习中，这个过程可以利用多个隐藏层进行模拟：第一个隐藏层学习到"边缘"的特征，第二个隐藏层学习到的是由"边缘"组成的"形状"的特征，第三个隐藏层学习到的是由"形状"组成的"图案"的特征，最后的隐藏层学习到的是由"图案"组成的"目标"的特征。

这条链条的每一环都有一个共同点：它只依赖上一环的输出，不需要回到原始输入。这就是"层次化表示"的含义，也是深度学习区别于"把原始特征一次性喂给分类器"的关键。

4.2 跨模态的通用性

当然，这样的识别思想不只适用于视觉信息的处理，对其他类型的信息同样适用。

语音信号可以被切成帧，帧组成音素，音素组成词，词组成句子；文本可以被切成字，字组成词，词组成短语，短语组成句子。两者的抽象链条与视觉的"边缘—形状—图案—目标"在结构上完全一致，只是每一层的物理含义不同。这也解释了为什么同一套网络结构稍作调整就能同时用于图像、语音和文本。

补充说明：层级抽象并非卷积网络的专利。循环网络沿时间轴展开，把"前一时刻的隐藏状态"当作一层表示传给下一时刻，实现的是时间维度上的层次化；Transformer 用多头注意力在每一层重新组合所有位置的表示，抽象的方向由数据决定而非由邻接关系预先规定。三者形式不同，但共同点都是"用多级表示逐步提高语义层次"。换句话说，深度学习的核心不是某一种层，而是"分层表示"这一组织原则。

五、两大工程条件

5.1 数据井喷

虽然关于认知的理论早已成熟，但真正推动深度学习走到聚光灯下的还是工程上的两大进步，也就是数据的井喷和计算力的飙升。

在目前的算法水平上，要提取出复杂的深层特征，必须要以大量训练样本为基础。简单的数据集只会让深度学习"消化不良"，因而大数据和深度学习的搭配称得上天作之合。

这个判断有具体的数量依据。以 ImageNet 为例，它的训练集包含百万量级的标注图像，分属一千个类别。若参数规模在千万量级，样本数与参数量的比例才勉强够用；而在深度学习兴起之前，公开数据集的规模通常只有几万张，这个比例远远不够，模型只能退回到人工设计特征加浅层分类器的组合。

5.2 算力飙升

另一方面，多个隐藏层的使用引入了大量隐藏神经元，这使得深度神经网络的参数规模随层数线性增长，总量迅速膨胀，给网络的训练带来沉重的计算负荷。而基于向量和矩阵计算的图形处理单元（graphical processing unit，GPU）完美解决了这一问题，其庞大的处理吞吐量能够使深度神经网络的训练显著提速，因而也成了深度学习的标配硬件。

如果说深度学习是一台探矿机，大数据就是那座有待挖掘的金矿，计算能力的进展则为这台探矿机提供了源源不断的动力。

> **新手提示：GPU 为什么比 CPU 快**

> CPU 只有几十个核心，但每个核心都能做复杂的逻辑判断与分支预测，适合串行的、逻辑复杂的任务。GPU 有数千个简单的计算核心，单个核心很笨，只会做乘加，但成千上万个一起干活时，吞吐量远超 CPU。神经网络的绝大部分计算是矩阵乘法，每个输出元素的计算彼此独立，正好适合这种“简单但极多”的并行模式。这不是 GPU 为深度学习专门设计的结果，而是深度学习的计算形态恰好撞上了 GPU 的强项。

补充说明：算力的增长不只看峰值浮点性能，还要看软件栈。NVIDIA 在 2007 年推出 CUDA，让研究者可以用类 C 的语言直接写 GPU 程序，不必再把算法映射成图形渲染的纹理操作。此后 cuDNN 把卷积、池化、归一化等常用算子做了高度优化，PyTorch 与 TensorFlow 又把算子调度与自动求导封装起来。一个研究者写下一行矩阵乘法，背后可能是几千个线程的调度与分块。深度学习的工程门槛正是在这一层层封装中被降下来的。

六、理论基础的争议

6.1 炼金术之争

尽管取得了很多成果，但关于深度学习技术的争论正显出愈演愈烈的趋势，“深度学习是炼金术”的争议更是让不少大咖针锋相对。

研究者批判深度学习的一个焦点在于其缺乏坚实的理论基础。在机器学习和浅层神经网络中，绝大部分最优解的最优性都是可以证明的。但在深度学习中，很多结果都是经验性而非理论性的，隐隐透出一丝看天吃饭的无力感。

这种批评有其道理：为什么某种初始化更好、为什么某个深度最优、为什么批归一化有效，很多问题的答案至今仍是“实验上如此”。超参数的选择大量依赖经验与试错，调参过程确实带着几分炼金术的气味。

6.2 信息瓶颈

抛开互怼的言论不论，深度学习在理论上依然有诸多要解决的问题，这也催生了“信息瓶颈”等新理论与新方法。

信息瓶颈的思路是把网络的一层看作一个信息通道：它要尽可能保留输入中与输出相关的信息，同时尽可能丢弃与输出无关的信息。形式化之后，可以用互信息写出一个权衡目标，理论上可以推出表示应当具有的性质。这类工作试图给“什么样的表示是好的”提供一个可计算的标准，而不只是靠下游任务的准确率来间接评判。

补充说明：近几年理论上最有影响的两个结果，恰好都指向“经典理论可能问错了问题”。其一是**神经正切核**：它证明在无限宽、初始化尺度特定的极限下，梯度下降训练的网络等价于一个核方法，此时训练动力学完全可分析——但这个极限下的网络几乎学不到特征，与真正有用的深度学习相去甚远。其二是**双下降现象**：经典理论认为模型复杂度超过插值阈值后泛化必然变差，而实际观察到的是测试误差先升后降，第二次下降发生在参数远多于样本的过参数化区间。这两个结果都说明，深度学习的理论不能简单照搬浅层学习的框架。

七、深度学习改变了什么

7.1 端到端学习

深度学习带来的最直接变化是**端到端**：输入原始数据，输出最终结果，中间的所有变换都由网络自己学。

传统流程是“人工特征 + 分类器”：先由领域专家设计边缘、纹理、MFCC 之类的特征，再把特征送进 SVM 或随机森林。特征设计的好坏决定了性能上限，分类器只是在这个上限内做优化。端到端把特征设计这一环也纳入了学习，人只需要定义网络结构与损失函数。

这种转变的代价是可解释性下降，收益是性能上限被大幅抬高——因为人工特征无论如何精巧，都受限于设计者对数据的先验理解，而网络可以从数据中发现人没想到的模式。

7.2 特征工程的退场

在图像领域，这个变化最为彻底。SIFT、HOG 这些曾经的标准特征，在 2012 年之后的图像分类竞赛中迅速被卷积网络取代。在语音领域，MFCC 逐渐让位给直接在频谱上做卷积。在自然语言领域，词袋与 TF-IDF 让位给词向量与预训练模型。

但“退场”不等于“无用”。人工特征在样本极少、算力受限、需要强可解释性的场景中依然有效；而且在很多任务里，把领域知识编码成网络结构（比如卷积的平移不变性、循环网络的时间顺序）比编码成特征更有效。特征工程没有消失，它换了个位置，从数据预处理搬到了架构设计里。

补充说明：端到端并不意味着人完全退出。网络结构、损失函数、数据增强、优化器、正则化强度，每一项都是人做的选择，而这些选择对最终性能的影响往往不亚于数据本身。所谓“端到端”，准确的说法是“把特征设计自动化”，而不是“把设计自动化”。一个反面的例子是：如果损失函数没有正确表达任务目标，网络会非常忠实地优化一个错误的目标，而且因为它容量大，错得比浅层模型更彻底。

四个常见误区

- **“深度学习就是把多层感知器堆起来”**——真正带来突破的是结构先验：卷积的平移不变性、循环网络的时间共享、注意力机制的内容寻址。同样是十层，全连接与卷积在图像上的效果差得很远。
- **“参数越多越容易过拟合”**——过参数化区间存在双下降现象，测试误差会二次下降。能不能别住靠的是正则化、数据量与优化过程，而不是简单的参数计数。
- **“2012 年是一夜突破”**——反向传播在 1986 年已被普及，逐层预训练在 2006 年证明了深层可训，2012 年只是 GPU 与 ImageNet 同时就位的引爆点。
- **“深度的收益来自更多的参数”**——深度真正买来的是表达效率：同一个函数，深层结构需要的参数可以远少于单层宽网络。

八、要点回顾

1. 深蓝以暴力穷举与专用硬件取胜，AlphaGo 以神经网络从棋谱中学习走子概率取胜，两者代表专用与通用的分野。
2. AlphaGo 由策略网络、价值网络与蒙特卡洛树搜索协同工作，三者分别解决搜索范围、局面评估与推演回溯。
3. 深度学习是利用包含多个隐藏层的人工神经网络实现的学习，深度指隐藏层数目而非参数量。
4. 深度带来的主要是表达效率：同样的函数，深层结构所需的参数可能远少于单隐藏层结构。
5. 深度学习的思想来源之一是视觉系统：胡贝尔与魏泽尔发现可视皮层分级处理，存在只对特定朝向边缘响应的方向选择性细胞。
6. 深度网络按“边缘—形状—图案—目标”的顺序逐层抽象，每一层只依赖上一层输出。
7. 层级抽象不限于视觉，语音与文本的抽象链条结构相同，这也是同一套结构能跨模态复用的原因。
8. 数据井喷与 GPU 算力是深度学习落地的两大工程条件，前者提供样本，后者提供吞吐。
9. 深度学习的理论基础仍不完整，信息瓶颈、神经正切核与双下降等现象说明经典理论框架不足以解释它。
10. 端到端学习把特征设计纳入模型，代价是可解释性下降，收益是性能上限提高。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
深度学习	Deep Learning	DL	利用多个隐藏层神经网络从数据中分层学习表示的方法
深蓝	Deep Blue	—	IBM 专用于国际象棋的计算机，以暴力穷举战胜人类冠军
AlphaGo	AlphaGo	—	结合策略网络、价值网络与树搜索的围棋程序
AlphaGo Zero	AlphaGo Zero	—	抛弃人类棋谱、纯靠自我对弈训练的版本
AlphaZero	AlphaZero	—	不依赖领域知识、可通吃多种棋类的通用版本
策略网络	Policy Network	—	输出各候选动作概率的神经网络
价值网络	Value Network	—	评估局面或状态长期回报的神经网络
蒙特卡洛树搜索	Monte Carlo Tree Search	MCTS	通过随机模拟与回溯统计选择动作的搜索算法
自我对弈	Self-play	—	智能体与自己博弈生成训练数据的训练方式
隐藏层	Hidden Layer	—	输入层与输出层之间执行变换的层
层级抽象	Hierarchical Abstraction	—	逐层把低层特征组合为更高层语义表示的机制
方向选择性细胞	Orientation-selective Cell	—	只对特定朝向边缘响应的视觉皮层神经元
感受野	Receptive Field	—	能引起某神经元响应的输入区域
神经认知机	Neocognitron	—	福岛邦彦提出的早期层级视觉网络，卷积网络前身
卷积网络	Convolutional Neural Network	CNN	用局部卷积核提取平移不变特征的深度网络
图形处理单元	Graphics Processing Unit	GPU	拥有大量简单核心、擅长大规模矩阵运算的处理器
CUDA	Compute Unified Device Architecture	CUDA	NVIDIA 提供的通用 GPU 计算编程接口
信息瓶颈	Information Bottleneck	IB	用互信息权衡表示压缩与任务相关信息保留的理论

名称	英文全称	英文缩写	简短介绍
神经正切核	Neural Tangent Kernel	NTK	无限宽网络在特定极限下等价于核方法的理论工具
双下降	Double Descent	—	测试误差随模型复杂度先升后降的现象
端到端学习	End-to-end Learning	—	从原始输入直接学习到最终输出、中间环节不手工设计
特征工程	Feature Engineering	—	人工设计并提取输入特征的过程
参数规模	Parameter Count	—	网络中可训练权重的总数，衡量模型容量