自编码器：欠完备编码、栈式预训练与变分生成

读前须知

- **前置**：多层感知器、反向传播，以及重构误差这类损失函数。
- **这一篇的位置**：无监督表示学习的主线。它用“压缩再还原”这个任务，逼网络自己找出数据的有效编码。
- **读完能做什么**：解释欠完备编码为什么能学到结构；说清去噪自编码器与稀疏自编码器的区别；理解变分自编码器里的重参数化技巧。

一、自编码器是什么

1.1 结构与用途

自编码器（auto-encoder）是一类执行无监督学习任务的神经网络结构，它的目的是学习一组数据的重新表达，也就是编码。

在结构上，自编码器是包含若干隐藏层的深度前馈神经网络，其独特之处是输入层和输出层的单元数目相等；在功能上，自编码器的目的不是根据输入来预测输出，而是重建网络的输入，正是这样的功能将自编码器和其他神经网络区分开来。由于自编码器的图形表示像极了杂技中使用的道具空竹，因而也得了个“空竹网络”的雅号。

“输出等于输入”这个设定初看没有意义——如果目标就是复制一份输入，那模型直接输出输入不就完了？关键在于中间的隐藏层通常比输入窄，网络被迫在这个窄通道里保留最重要的信息，于是隐藏层的激活值就成了输入的一种压缩表示。自编码器的价值不在输出端，而在中间那个被逼出来的表示。

1.2 编码与解码

自编码器结构由编码映射和解码映射两部分组成。如果将编码映射记作 φ，解码映射记作 ψ，自编码器的作用就是将输入 X 改写为 (ψ∘φ)(X)：

$$z = \phi(X), \qquad \hat{X} = \psi(z) = (\psi \circ \phi)(X)$$

这相当于将输入从一个表象下转换到另一个表象下来表示，就像量子力学中粒子不同表象之间的变化一样。

补充说明：自编码器与降维、特征提取是同一件事的三个视角。从几何看，编码把数据点从原始空间投影到低维流形；从统计看，它寻找数据的主变化方向；从表示学习看，它把原始像素、词袋这类“表层的、冗余的”表示换成“紧凑的、去相关的”表示。后者正是实际价值所在：把自编码器的编码层输出接到分类器上，往往比直接用原始输入效果更好，尤其是在标注样本很少时——因为编码是在无标注数据上学的，没有浪费未标注样本。

> **新手提示：自编码器不需要标签**
>
> 自编码器的训练目标是重建输入，而输入本身就是标签，所以它属于无监督学习。这个特点让它的适用范围很广：图像、语音、文本、传感器读数，只要有数据就能训练，不必等人标注。代价是它学到的是“如何压缩这些数据”，而不是“如何区分这些类别”。所以自编码器通常不直接用于分类，而是作为预训练、特征提取或异常检测的前置步骤。判断一个样本是否为异常，只需看它的重建误差——正常样本能被很好地重建，异常样本不能。

二、损失函数与欠完备编码

2.1 均方误差与最大似然

如果以均方误差作为网络训练中的损失函数，自编码器的目的就是找到使均方误差最小的编解码映射的组合：

$$\phi, \psi = \arg\min_{\phi,\psi} \|X - (\psi \circ \phi)(X)\|^2$$

在最简单的情形，也就是只有一个隐藏层的情形下，自编码器隐藏层的输出就是编码映射。在自编码器的另一端，输出层将隐藏层的输出转换为自编码器的整体输出，从而实现了解码映射的功能。

如果隐藏神经元的传递函数是非线性的，编码映射就能够捕捉到输入分布中更加复杂的特征，均方误差准则也可以写成对数似然函数 −ln p(X | φ(X)) 的形式。当误差 p(X | φ(X)) 满足高斯分布时，均方误差和最大似然是等价的。

2.2 欠完备与主成分分析

当隐藏层的维度小于输入数据的维度时，这就是个**欠完备**（undercomplete）的自编码器。欠完备自编码器的作用相当于对输入信号做了主成分分析：隐藏层的 k 个线性神经元在均方误差准则下保留贡献最大的 k 个主成分，原始信号就被投影到由这 k 个主成分所展成的新空间上。

补充说明：线性自编码器与 PCA 的关系比“相当于”更强，在特定条件下是严格等价的。若编码与解码都是线性变换、损失为均方误差、且编码器的权重矩阵满足正交约束，则训练得到的编码子空间就是 PCA 的前 k 个主成分张成的子空间。证明思路是把重建误差展开，写成关于数据协方差矩阵的二次型，最优解由协方差矩阵的前 k 个特征向量给出。若去掉正交约束，学到的子空间仍然相同，只是基向量可能被任意线性组合，不再是正交的。这也提示了一件事：非线性自编码器的价值恰恰在于超出 PCA 的能力——它能捕捉数据流形上的弯曲结构，而 PCA 只能找到线性子空间。

2.3 非线性编码

从信息论的角度看，编码映射可以看成是对输入信源 X 的有损压缩。有损压缩的特点决定了它不可能对所有输入都具有较小的信息量损失，因而学习的作用就是习得在训练数据集上更加精确的映射，并希望这样的映射在测试数据上同样表现良好，也就是使自编码器具有较好的泛化性能。

三、过度完备的悖论

3.1 恒等映射的风险

当自编码器的隐藏单元数目大于输入信号的维度，也就是编码映射的分量数目大于输入信号的分量数目时，这就是个**过度完备**（overcomplete）的自编码器。

过度完备的自编码器面临的一个严重问题是：如果没有额外约束的话，那么它可能只能够习得识别功能，得到的编码映射和解码映射都是恒等映射，这显然是白费功夫。

这个道理不难想：隐藏层比输入层宽时，网络完全可以把输入原样“复制”到隐藏层，再原样“粘贴”到输出层，损失为零，却什么都没学到。容量过剩加上没有约束，最优解就是恒等映射。

3.2 为什么仍能学到有用表示

可出人意料的是，自编码器的这个缺点恰恰能被过度完备性克服。实际结果表明，当使用随机梯度下降训练时，过度完备的非线性自编码器能够生成有用的表示。这个结论是由将自编码器的输出作为其他分类算法的输入，并统计分类错误得到的。

对这种现象的解释是：当结合早停使用时，随机梯度下降的效果类似于对参数的 L2 正则化。为了实现连续输入的完美重构，具有非线性隐藏单元的单隐藏层自编码器需要在隐藏层中使用较小的权重，而在输出层使用较大的权重。尤其是在处理二进制输入时，大的权重系数还有利于最小化重构误差。但由于种种隐式或显式正则化规则的限制，大权重系数是难以实现的，因而自编码器只能对数据进行重新的编码。

这意味着在新的表象下，数据的表示利用的是训练集中存在的统计规律，而不是使用恒等映射简单地复制粘贴。

补充说明：这里的关键词是"隐式正则化"。梯度下降从随机初始点出发，沿着损失曲面缓慢下降，在到达恒等映射这种"精确解"之前会先经过一批损失接近零但结构不同的解。早停在这些解附近就结束了训练，相当于只保留了"容易学到的"那部分结构——通常是数据中方差大的方向。这就是为什么过完备网络也能学到东西：不是容量不够，而是优化过程本身充当了约束。同样的道理也解释了为什么随机初始化的小尺度、特定的优化器（如带动量的 SGD）会影响最终表示的质量，哪怕它们理论上都能到达同一个最优解。

> **新手提示：瓶颈不是必须的**
>
> 大学教科书常把自编码器画成"宽—窄—宽"的沙漏形状，容易让人以为必须有瓶颈层才能学到表示。实际上瓶颈只是最容易实现的约束方式。没有瓶颈时，靠稀疏约束、噪声注入、收缩惩罚、早停，同样能逼出有意义的表示。判断自编码器是否学到了东西，看的不是结构，而是编码在 downstream 任务上有没有用、重建误差是否明显低于平凡基线。结构只是手段。

四、栈式自编码器

4.1 深度结构的好处

虽然自编码器通常只包含单个隐藏层，但这并不是强制的选择。和其他前馈网络一样，自编码器也会受益于深度结构。

通用近似定理保证了具有单隐藏层的自编码器能够以任意精度逼近任意的连续函数，但难以对这样的自编码器任意添加额外的约束条件。相比之下，深度自编码器既能降低某些函数的计算成本，也能降低训练数据的数量要求，还能得到更高的压缩效率。

4.2 逐层无监督预训练

在实际中，训练深度自编码器的普遍策略是先训练一些浅层自编码器，再利用这些浅层自编码器贪心地预训练深度结构，因而浅层自编码器可以看作深度自编码器的中间件。换句话说，当需要使用 3 个隐藏层的深度自编码器时，我们的做法是将 3 个单隐藏层的自编码器逐层堆叠，而不会去直接训练一个 5 层的深度架构。用浅层自编码器搭建成的深度自编码器被称为**栈式自编码器**（stacked autoencoder）。

栈式自编码器的训练策略可以归结为两个步骤：**无监督预训练 + 有监督微调。**

无监督预训练就是每个浅层自编码器的工作方式。原始数据输入 X 被用于训练网络的第一层，得到参数后，网络第一层就可以将原始输入转化成为由隐藏单元激活值组成的向量 X_1；接下来把 X_1 作为第二层的输入，继续训练得到第二层的参数后又可以计算出第二层的输出 X_2。对后面的各层也采取同样的策略，即将前层的输出作为后层输入的方式依次训练。在以上的训练方式中，训练每一层的参数时都会保持其他各层的参数固定不变。

补充说明：这套"逐层预训练"的做法在 2006 年前后是训练深层网络的主要手段。当时 ReLU、批归一化和残差连接都还没有普及，直接用反向传播训练五六层以上的网络几乎必然失败——梯度在传回底层时已经衰减到零。Hinton 与 Bengio 等人的工作表明，先用无监督方式把每一层训练成一个能重建输入的自编码器，再整体微调，深层网络就能训起来了。这件事在当时被视为深度学习的转折点。有意思的是，几年后 ReLU 与更好的初始化普及，逐层预训练变得不再必要，但在标注数据极少的场景下，它依然是有效的策略，并且直接启发了今天"预训练 + 微调"的范式。

4.3 有监督微调

如果要得到全局意义上更优的结果，需要在上述预训练过程完成之后，利用反向传播算法同时调整所有层的参数以改善全局性能，这个过程就是**微调**。在参数训练到接近收敛时，使用微调会得到良好的效果。

如果设计的深度自编码器只是用于分类的话，惯用的做法是丢掉栈式自编码器的解码映射，直接把最后一个隐藏层的输出送入 softmax 分类器进行分类。如此一来，softmax 分类错误的梯度值就可以直接反向传播给编码映射了。

同其他深度结构一样，逐层训练给栈式自编码器带来的是强大的表达能力，这体现在它通常能够获取到输入的从部分到整体的层次化结构。如果栈式自编码器的输入是几何形状，那么它的第一层就会学习如何识别边缘，第二层会在第一层学到的边缘概念的基础上，学习如何通过边缘的组合得到轮廓，更高层还会学到如何通过轮廓的组合得到不同的形状这类更高阶的特征。

五、稀疏自编码器

5.1 稀疏性参数

自编码器面对的一个问题是，对输入信号什么样的表达才能称为好的表达呢？同深度学习领域中的大多数问题一样，这个问题也不存在标准答案。从不同的角度回答它，得到的就是对原始自编码器的不同改进。

一种回答是：好的表示应当是**稀疏**的。在隐藏层中，大部分神经元被抑制，只有少数能够输出特征表达，这样的结构被称为**稀疏自编码器**（sparse autoencoder）。

稀疏自编码器以**稀疏性参数**表示神经元的平均活跃程度，稀疏性参数为 0.01 意味着每次映射中只有 1% 的神经元被激活，但每次被激活的不会总是相同的 1%。这个“不会总是相同”很关键：如果每次都是同一批神经元活跃，那和降维没有区别；正因为激活的集合随样本变化，才能用少数几个单元的不同组合去表示大量不同的输入。

5.2 KL 散度正则项

稀疏自编码器在损失函数中引入 KL 散度作为正则化项，来控制激活神经元的数目，进而控制特征表达的有效性。

设第 j 个隐藏单元在训练集上的平均激活值为 $\hat{\rho}_j$，期望的稀疏水平为 ρ，则惩罚项为：

$$\mathrm{KL}(\rho \,\|\, \hat{\rho}_j) = \rho \ln \frac{\rho}{\hat{\rho}_j} + (1-\rho) \ln \frac{1-\rho}{1-\hat{\rho}_j}$$

这个量在 $\hat{\rho}_j$ 等于 ρ 时取最小值零，偏离越远惩罚越大。把它对所有隐藏单元求和，就构成了稀疏正则项。

补充说明：需要澄清原文一处容易混淆的表述：**过度完备与稀疏是两条正交的改进方向**，不是同一个东西的两种叫法。过度完备指隐藏层比输入宽，稀疏指激活值大部分为零。两者可以组合——一个隐藏层很宽但每次只有 1% 神经元活跃的自编码器，既过完备又稀疏，这是实践中很常见的配置，因为宽层给了组合自由度，稀疏约束防止了恒等映射。稀疏的实现方式除了 KL 散度，也常用 L1 惩罚（直接对激活值取绝对值之和），后者实现更简单，但 KL 形式对“平均激活率”的控制更精确。

六、去噪自编码器

6.1 损坏与重建

如果一个自编码器要从噪声中恢复出信号，对被干扰的非理想数据 $\tilde{X}$ 进行编解码，就不能对输入仅仅施加恒等复制，而是要移除噪声的影响，这样的自编码器就是**去噪自编码器**（denoising autoencoder）。

相比于原始的自编码器，去噪自编码器要求对非理想数据的处理结果尽可能逼近原始数据，最小均方误差的形式也变为：

$$\left\| X - (\psi \circ \phi)(\tilde{X}) \right\|^2$$

注意损失里比较的两端：输入是损坏样本 $\tilde{X}$，目标却是原始样本 X。这个不对称是去噪自编码器的全部要害——网络必须学会"猜出被破坏的部分"，而不能照抄输入。

在去噪自编码器的训练中，需要引入条件分布 $p(\tilde{X} \mid X)$，这个分布表示了从数据样本 X 产生损坏样本 $\tilde{X}$ 的概率。自编码器则将 $(X, \tilde{X})$ 作为训练样本来学习重构分布 $p(X \mid \tilde{X})$，也就是在从损坏样本到原始数据样本的逆概率问题。在引入编码映射和解码映射之后，待学习的重构分布就变成了 $p(X \mid (\psi \circ \varphi)(\tilde{X}))$。

6.2 得分匹配

上面的逆概率最大化问题可以转化为负对数似然的最小化，并利用基于梯度的方法求解。另一种训练方法是**得分匹配**，它让模型在每个样本点上获得与数据分布相同的得分，因而可以得到概率分布的一致估计，得分的形式则是一个特定的梯度场。

补充说明：得分匹配之所以重要，是因为它绕开了对归一化常数的依赖。概率密度 $p(x)$ 通常带有一个难以计算的配分函数 Z，但它的对数梯度 $\nabla_x \ln p(x)$ 与 Z 无关，因为 Z 是常数，求梯度后消失。得分匹配的目标就是让模型的对数梯度去逼近数据分布的对数梯度，从而不必显式计算 $p(x)$。去噪自编码器与得分匹配之间存在深刻联系：在噪声很小的高斯损坏下，去噪自编码器学到的重建方向正比于数据分布的得分。这一联系后来成为扩散模型的理论基础之一——扩散模型的训练目标本质上就是得分匹配。

七、收缩与变分自编码器

7.1 收缩自编码器

去噪自编码器的作用是对抗信号中的噪声，**收缩自编码器**（contractive autoencoder）的作用则是对抗信号中的微小扰动，这可以通过在损失函数中添加显式的正则化项来实现。

正则化项首先要计算隐藏层输出值关于输入 x 的雅可比矩阵（Jacobian matrix），再来计算得到的雅可比矩阵的 Frobenius 范数，也就是矩阵所有元素平方和的平方根：

$$\Omega(h) = \left\| \frac{\partial h}{\partial x} \right\|_F^2$$

通过雅各比矩阵和 F 范数的计算，收缩自编码器就能抑制训练样本在低维度流形曲面上的扰动。

这个惩罚的含义是：输入发生微小变化时，编码输出应当尽量不变。因此编码对训练数据所在流形的切向方向不敏感，只对离开流形的方向敏感——这正是"收缩"一词的来源。

7.2 变分自编码器

如果要使用自编码器来建立生成模型，用到的就是**变分自编码器**（variational autoencoder）。

变分自编码器的主要特点是在编码映射中添加了额外的限制，使隐藏层的参数大致遵循正态分布。这样一来，自编码器的所有参数都被转换为随机变量，计算随机变量分布参数的过程就是"推理"的过程。引入变分逼近法可以将推理问题转化为优化问题，并使用随机梯度下降法解决。

由于均方误差只适用于描述不同数值之间的差异，而不能描述不同概率分布的区别，因而变分自编码器同样使用 KL 散度作为误差度量。在有限的训练数据集上，变分自编码器能够学习到样本的概率分布，并利用这个概率分布进一步生成新的样本，因而可以作为生成模型使用。

补充说明：变分自编码器的训练目标可以写成：

$$-\mathrm{KL}\left(q(z \mid x) \,\|\, p(z)\right) + \mathbb{E}_{q(z|x)}\left[\ln p(x \mid z)\right]$$

第一项把编码分布拉向标准正态先验，第二项要求解码能重建输入。两项合起来是证据下界（ELBO），最大化它等价于在近似推断的同时最大化数据似然。实现上有一个关键技巧叫**重参数化**：直接从 $N(\mu, \sigma^2)$ 采样会阻断梯度，改为先采 $\varepsilon \sim N(0,1)$，再令 $z = \mu + \sigma \odot \varepsilon$，采样就变成了对 μ、σ 的确定性变换，梯度可以正常传回编码器。没有这一步，变分自编码器根本训不起来。

> **新手提示：重建得好不等于生成得好**
>
> 评估生成模型时，最容易犯的错是只看重建误差。一个记忆型的自编码器可以把训练样本重建得分毫不差，但它采样的新样本完全不可用——因为它把每个样本都存成了一块独立的编码，潜在空间里有大片未定义的空白区域。变分自编码器之所以在目标里加 KL 项，正是要把编码分布向先验拉，使潜在空间连成一片，随机采样从哪里取都能解码出合理结果。所以看生成质量要看采样结果，不看重建误差；两者存在权衡：重建太准，潜在空间就可能不够规整；KL 太强，重建就会模糊。

四个常见误区

- **“自编码器是一种降维算法”**——它确实能压缩，但编码器可以是高度非线性的，得到的表示也不保证各维正交或按方差排序，与 PCA 的性质不同。
- **“重构误差小就说明表示好”**——模型可能只是学会了恒等映射。必须靠瓶颈、噪声、稀疏约束等手段限制它，表示才有意义。
- **“变分自编码器在最大化似然”**——它优化的是对数似然的下界（证据下界），两者之间存在差距，这也是生成结果偏模糊的原因之一。
- **“去噪自编码器在恢复原图”**——它的目标是学到对噪声鲁棒的表示，输出不必逐像素还原，细节损失是可以接受的。

八、要点回顾

1. 自编码器是无监督网络，输入与输出单元数相等，目标是重建输入而非预测标签。
2. 编码映射把输入压到隐藏表示，解码映射从表示重建输入，价值在于中间的表示。
3. 以均方误差为损失时，训练目标是最小化重建误差；高斯假设下它与最大似然等价。
4. 欠完备自编码器在隐藏层维度低于输入时，线性情形下与主成分分析等价。
5. 过度完备自编码器若无约束会退化为恒等映射，但隐式正则化（如早停）仍能使其学到有用表示。
6. 栈式自编码器由多个浅层自编码器逐层堆叠，采用无监督预训练加有监督微调的训练策略。
7. 逐层预训练在 ReLU 与批归一化普及前是训练深层网络的关键手段，也是“预训练 + 微调”范式的先声。
8. 稀疏自编码器用 KL 散度或 L1 惩罚约束平均激活率，使表示只由少数单元的组合构成。
9. 去噪自编码器从损坏样本重建原始样本，迫使网络学习数据的结构而非复制输入。
10. 得分匹配通过比较对数梯度训练模型，绕开配分函数，是扩散模型的理论基础之一。
11. 收缩自编码器惩罚编码对输入的雅可比范数，使表示对沿数据流形的扰动不敏感。
12. 变分自编码器把编码输出参数化为分布，用 ELBO 训练，可作生成模型，实现依赖重参数化技巧。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
自编码器	Auto-encoder	AE	以重建输入为目标的对称式无监督神经网络
编码映射	Encoder	—	把输入变换为隐藏表示的映射
解码映射	Decoder	—	把隐藏表示还原为输入的映射
隐藏表示	Latent Representation	—	网络中间层对输入压缩后的编码向量
欠完备自编码器	Undercomplete Auto-encoder	—	隐藏层维度小于输入维度的自编码器
过度完备自编码器	Overcomplete Auto-encoder	—	隐藏层维度大于输入维度的自编码器
主成分分析	Principal Component Analysis	PCA	用正交变换提取数据主要变化方向的降维方法
栈式自编码器	Stacked Auto-encoder	SAE	由多个浅层自编码器逐层堆叠而成的深度结构
无监督预训练	Unsupervised Pre-training	—	用无标签数据逐层训练网络初始参数的过程
有监督微调	Supervised Fine-tuning	—	在预训练后用带标签数据联合调整全部参数
稀疏自编码器	Sparse Auto-encoder	—	加稀疏约束、使隐藏层少数单元活跃的自编码器
稀疏性参数	Sparsity Parameter	—	期望的隐藏单元平均激活比例
KL 散度	Kullback-Leibler Divergence	KL	衡量两个概率分布差异的非对称指标
去噪自编码器	Denoising Auto-encoder	DAE	从随机损坏的输入重建原始样本的自编码器
得分匹配	Score Matching	—	通过匹配对数概率梯度来训练模型的方法
得分函数	Score Function	—	对数概率密度关于输入的梯度场
收缩自编码器	Contractive Auto-encoder	CAE	惩罚编码雅可比范数、使表示抗扰动的自编码器
雅可比矩阵	Jacobian Matrix	—	输出对各输入分量一阶偏导构成的矩阵

名称	英文全称	英文缩写	简短介绍
Frobenius 范数	Frobenius Norm	—	矩阵所有元素平方和的平方根
变分自编码器	Variational Auto-encoder	VAE	用变分推断训练、可生成新样本的自编码器
证据下界	Evidence Lower Bound	ELBO	变分推断中可优化的对数似然下界
重参数化技巧	Reparameterization Trick	—	把随机采样写成确定性变换以保持梯度可传
生成模型	Generative Model	—	学习数据分布并能采样新样本的模型
扩散模型	Diffusion Model	—	通过逐步去噪学习数据分布的生成模型