深度强化学习：马尔可夫决策、深度 Q 网络与策略梯度

读前须知

- **前置**：概率论中的期望、梯度下降，以及“函数逼近”的想法。
- **这一篇的位置**：从“预测与分类”转向“序贯决策”。这里的反馈不是标签，而是延迟到达的奖励。
- **读完能做什么**：写出马尔可夫决策的五元组与贝尔曼方程；解释 DQN 的两个稳定化手段（经验回放、目标网络）；说清策略梯度与值函数方法各自的优缺点。

一、从奖励中学习

1.1 强化学习与监督学习的差别

强化学习（reinforcement learning）实质上是智能系统从环境到行为的学习过程，智能体通过与环境的互动来改善自身的行为，改善准则是使某个累积奖励函数最大化。

具体来说，强化学习是基于环境反馈实现决策制定的通用框架，根据不断试错得到来自环境的奖励或者惩罚，从而实现对趋利决策信念的不断增强。它强调在与环境的交互过程中实现学习，产生能获得最大利益的习惯性行为。

与监督学习相比，差别在两处。第一，监督学习每一步都有明确标签，告诉你“这个输入对应的正确输出是什么”；强化学习只有奖励信号，它评价的是动作的好坏，却不告诉你正确的动作是什么。第二，监督学习的样本是独立同分布的，而强化学习中当前动作会改变后续状态分布——你做了什么，决定了你接下来会看到什么。

相比于纯人造的监督学习和无监督学习，强化学习的思想根源来自于认知科学。20 世纪初，美国心理学家爱德华·桑代克在对教育过程的研究中提出了强化学习的原始理论，而作为人工智能方法的强化学习则力图使计算机在没有明确指导的情况下实现自主学习，完成从数据到决策的转变。

1.2 探索与利用

强化学习的特点在于由环境提供的强化信号只是对智能体所产生动作的好坏作一种评价，和监督学习中清晰明确的判定结果相比，环境的反馈只能提供很少的信息。所以强化学习需要在探索未知领域和遵从已有经验之间找到平衡。

一方面，智能体要在陌生的环境中不断摸着石头过河，来探索新行为带来的奖励；另一方面，智能体也要避免在探索中玩儿脱，不能放弃根据已有经验来踏踏实实地获得最大收益的策略。

这个矛盾称为**探索与利用的困境**，是强化学习区别于其他学习范式的核心难题。只探索不利用，学不到能赚钱的策略；只利用不探索，可能永远不知道还有更好的选择。

> **新手提示：奖励稀疏是最常见的失败原因**
>
> 很多任务的自然奖励极其稀疏——下棋只在终局给出胜负，机器人抓取只在成功时给 1。在这种设定下，智能体随机探索几乎不可能碰到第一次奖励，学习根本启动不了。解决办法有两个方向：一是设计**中间奖励**，比如按距离目标的远近给连续的小奖励（这叫奖励塑造，但要小心设计不当会引导出奇怪的行为）；二是用**示范数据**或课程学习，先让智能体在简单版本的任务里学会基本动作，再逐步加难。遇到“训练很久完全没有进步”，第一件事应当检查奖励是否稀疏，而不是怀疑算法。

二、马尔可夫决策过程

2.1 状态、动作、转移与奖励

描述强化学习最常用的模式是**马尔可夫决策过程**（Markov decision process）。马尔可夫决策过程是由离散时间随机控制的过程，可以用以下的四元组来定义：

1. **S**：由智能体和环境所处的所有可能状态构成的有限集合；
2. **A**：由智能体的所有可能动作构成的有限集合；
3. **P_a(s, s') = Pr(s_{t+1} = s' | s_t = s, a_t = a)**：智能体在 t 时刻做出的动作 a 使马尔可夫过程的状态从 t 时刻的 s 转移为 t+1 时刻的 s' 的概率；
4. **R_a(s, s')**：智能体通过动作 a 使状态从 s 转移到 s' 得到的实时奖励。

“马尔可夫”三个字是一个假设：下一状态只依赖当前状态与当前动作，与更早的历史无关。这个假设把无限长的历史压缩成一个状态，使问题变得可计算。实际任务中若状态设计得不好（比如只给了一帧图像），就会破坏这个假设，导致智能体“看不懂”运动方向——这也是为什么 Atari 上的深度强化学习要把连续四帧堆叠起来作为状态。

2.2 交互循环与回报

除了这个四元组之外，强化学习还包括一个要素，就是描述主体如何获取奖励的规则。强化学习主体和环境之间的交互是以离散时间步的方式实现的。在某个时间点上，智能体对环境进行观察，得到这一时刻的奖励，接下来它就会在动作集中选择一个动作发送给环境。来自智能体的动作既能改变环境的状态，也会改变来自环境的奖励。而在智能体与环境不断互动的过程中，它的终极目标就是让自己得到的奖励最大化。

“让奖励最大化”需要精确化：不是每一步奖励之和，而是带折扣的累积回报：

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

其中 γ ∈ [0,1) 是折扣因子。

补充说明：折扣因子 γ 有两个作用，一个是数学上的，一个是语义上的。数学上，当 γ < 1 且奖励有界时，无穷级数收敛，回报是有限值，避免了“无限时间累积无穷大”的麻烦。语义上，γ 表示对未来的重视程度：γ 接近 0 时智能体只顾眼前，γ 接近 1 时愿意为长远收益牺牲当下。它直接影响学到的策略性格——在稀疏奖励任务中 γ 太小，智能体会看不到“现在吃苦、很久以后才有回报”的路径，从而学不会。引入折扣回报后，最优价值函数满足**贝尔曼最优方程**：

$$Q^*(s,a) = \mathbb{E}\left[R(s,a) + \gamma \max_{a'} Q^*(s',a')\right]$$

这个方程是几乎所有价值型强化学习算法的出发点：它把一个全局的最优化问题拆成了“当前奖励 + 下一状态的最优价值”这样的递归形式。

三、深度强化学习的三条路线

3.1 感知与决策的结合

深度强化学习（deep reinforcement learning）是深度学习和强化学习的结合，它将深度学习的感知能力和强化学习的决策能力熔于一炉，用深度学习的运行机制达到强化学习的优化目标，从而向通用人工智能迈进。

这个结合解决的是一个具体的瓶颈：传统强化学习要求状态是可枚举的离散表格，而真实任务的状态是图像、语音这样的高维连续信号。用神经网络把高维状态映射为价值或策略，等于给强化学习装上了一双能看懂原始输入的眼睛。

2017 年，《麻省理工科技评论》的十大突破性技术中"强化学习"榜上有名。如果把时钟调回到一年多之前的围棋人机大战，彼时的深度强化学习在 AlphaGo 对李世乭的横扫中就已经初露峥嵘。而在进化版 AlphaGo Zero 中，深度强化学习更是大放异彩——AlphaGo Zero 之所以能够摆脱对人类棋谱的依赖，其原因就在于使用纯粹的深度强化学习进行端到端的自我对弈，从而超越了人类的围棋水平。

3.2 三种范式

根据实施方式的不同，深度强化学习方法可以分成三类，分别是基于价值、基于策略和基于模型的深度强化学习。

- **基于价值**：学一个函数，评估在状态 s 下做动作 a 有多好，再据此选动作；
- **基于策略**：直接学一个从状态到动作的映射，跳过价值评估；
- **基于模型**：先学环境的动力学（做了动作之后世界会怎么变），再用这个模型做规划。

三者的关系并非互斥，现代算法常常混用，比如行动者—评论家就同时维护策略网络与价值网络。

四、基于价值：深度 Q 网络

4.1 Q 学习

基于价值（value-based）的深度强化学习的基本思路是建立一个价值函数的表示。价值函数（value function）通常被称为 Q 函数，以状态空间 S 和动作空间 A 为自变量。但对价值函数的最优化可以说是醉翁之意不在酒，其真正目的是确定智能体的行动策略。

策略是从状态空间到动作空间的映射，表示的是智能体在状态 s_t 下选择动作 a，执行这一动作并以概率 P_a(s_t, s*{t+1}) 转移到下一状态 s*{t+1}，同时接受来自环境的奖赏 R_a(s_t, s_{t+1})。价值函数和策略的关系在于它可以表示智能体一直执行某个固定策略所能获得的累积回报。如果某个策略在所有状态—动作组合上的期望回报优于所有其他策略，这就是个最优策略。

基于价值的深度强化学习就是要通过价值函数来找到最优策略，最优策略的数目可能不止一个，但总能找到其中之一。在没有"深度"的强化学习中，使用价值函数的算法叫做 **Q 学习算法**（Q-learning）。Q 算法其实非常简单，就是在每个状态下执行不同的动作，来观察得到的奖励，并迭代执行这个操作：

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[r + \gamma \max_{a'} Q(s',a') - Q(s,a) \right]$$

括号里的项称为**时序差分误差**：它衡量"实际得到的奖励加上下一状态的最好估计"与"当前估计"之间的差距，学习就是不断缩小这个差距。

本质上说，Q 学习算法是有限集上的搜索方法，如果出现一个不在原始集合中的新状态，Q 算法就无能为力了，所以这是一种不具备泛化能力的算法，也就不能对未知的情况做出预测。用神经网络替代这张表，泛化能力就来了——相近的状态会得到相近的价值估计。

补充说明：Q 学习是**离策略**的：它更新用的是 max 操作下的最优动作，而这个动作未必是当前行为策略真正执行的动作。好处是行为策略可以随便探索（比如 ε-贪心），学习目标依然是最优策略；坏处是 max 会带来**最大化偏差**——噪声估计中的最大值会被系统性地高估，因为"碰巧估高的那个"更容易被 max 选中。解决方法是 Double Q 学习：用一套网络选动作、另一套网络评估这个动作，把选择与评估解耦，偏差显著降低。这个思想后来被直接搬到了深度 Q 网络中。

4.2 经验回放

为了实现具有预测功能的 Q 算法，深度强化学习采用的方式是将 Q 算法的参数也作为未知的变量，用神经网络来训练 Q 算法的参数，这样做得到的就是**深度 Q 网络**。

深度 Q 网络中有两种值得一提的机制，分别是经验回放和目标 Q 网络。

经验回放的作用就是避免“熊瞎子掰苞米，掰新的扔旧的”这种窘境。通过将以往的状态转移数据存储下来并作为训练数据使用，经验回放能够克服数据之间的相关性，避免网络收敛到局部极小值。

这一点很关键：智能体连续采集的样本高度相关（相邻帧几乎一样），直接拿来做随机梯度下降会严重违反独立同分布假设，网络会在最近的经验上反复过拟合。把转移数据存进缓冲区再随机抽样，等于人为打散了相关性。

> **新手提示：回放缓冲区不是越大越好**
>
> 缓冲区太小，样本多样性不够，旧经验很快被覆盖，网络容易在最近的策略上过拟合；缓冲区太大，里面大量样本来自早已过时的旧策略，用它们训练会拖慢甚至误导学习。常见做法是取几十万到上百万条转移作为缓冲，并在训练初期先用少量样本把网络稳定下来再放大缓冲区。另一个细节是：采样时必须保证每条样本被抽到的概率均等，否则会让价值估计偏向出现频率高的状态。

4.3 目标网络

目标 Q 网络则对当前 Q 值和目标 Q 值做了区分，单独使用一个新网络来产生目标 Q 值。这相当于对当前 Q 值和目标 Q 值进行去相关，从而克服了非平稳目标函数的影响，避免算法得到震荡的结果。

如果不加区分，更新公式里的目标和预测用的是同一个网络：每更新一次参数，目标也跟着动，相当于在追一个自己也在跑的目标。目标网络每隔若干步才从当前网络同步一次参数，在这期间目标保持不动，训练就变成了一个稳定的回归问题。

补充说明：深度 Q 网络之后出现了不少针对性改进。**Double DQN** 用当前网络选动作、用目标网络评估，缓解最大化偏差；**Dueling DQN** 把 Q 值分解为“状态价值”与“动作优势”两部分再相加，使网络在不需要区分动作好坏的状态下也能高效学习状态价值；**优先经验回放**按时序差分误差的大小给样本加权采样，让“学得不好的”样本被更频繁地复习；**Rainbow** 则把上述若干改进合并，在 Atari 基准上取得了明显提升。这些改进指向同一个方向：Q 学习的瓶颈不在网络容量，而在目标估计的稳定性与样本的利用效率。

五、基于策略：策略梯度

5.1 参数化策略

既然对价值函数的学习也是以最优策略为终极目标，那为什么不绕开价值函数，直接来学习策略呢？基于策略（strategy-based）的深度强化学习的基本思路就是直接搜索能够使未来奖励最大化的最优策略。

具体的做法是利用深度神经网络对策略进行参数化的表示，再利用策略梯度方法进行优化，通过不断计算总奖励的期望关于策略参数的梯度来更新策略参数，最终收敛到最优策略上。

这个路线有一个天然优势：它可以输出随机的策略。在石头剪刀布这类博弈中，确定性的最优策略不存在（对手一旦知道你的规律就能克制你），只有在动作上保持一定随机性才是最优。价值型方法通过 ε-贪心间接引入随机，而策略型方法可以直接学出概率分布。

5.2 策略梯度与行动者—评论家

策略梯度方法的思想是直接使用逼近函数来近似表示和优化策略，通过增加总奖励较高情况的出现概率来逼近最优策略：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta}\left[\nabla_\theta \ln \pi_\theta(a \mid s)\, G_t\right]$$

其运算方式与深度学习中的梯度下降类似，只是更新方向相反：它沿梯度的正方向做梯度上升，以最大化目标函数。

这个公式的直观含义是：如果某个动作带来的回报高，就提高它的对数概率；回报低就降低。整条轨迹的回报作为权重，把"好"与"坏"的信号分配给沿途的每个动作。

补充说明：策略梯度的弱点在于方差。同一条策略跑两次，轨迹可能差别很大，回报 G_t 的波动直接传到梯度上，导致估计噪声极重。标准解法是减去一个**基线**：把 G_t 换成 G_t − b(s)，其中 b(s) 只依赖状态、与动作无关。数学上可以证明减去基线不改变梯度的期望，但方差会显著减小。最常用的基线就是状态价值函数 V(s)，此时"回报减基线"变成了**优势函数** A(s,a) = Q(s,a) − V(s)，含义从"这个动作带来多少绝对回报"变成了"这个动作比平均水平好多少"。用另一个网络来估计 V(s) 或 Q(s,a)，就得到了**行动者—评论家**结构：行动者（策略网络）负责做决策，评论家（价值网络）负责打分。

5.3 UNREAL 与异步训练

这种方法的问题是在每一轮的策略梯度更新中都需要大量智能体与环境的互动轨迹作为训练数据，但在强化学习中，大量的在线训练数据是难以获取的，这无疑给策略梯度方法带来了很大的限制。

一种实用的策略梯度方法是无监督强化辅助学习（UNsupervised REinforcement and Auxiliary Learning），简称 UNREAL 算法。UNREAL 算法的核心是**行动者—评论家**（actor-critic）机制，两者分别代表两个不同的网络。行动者是策略网络，用于对策略进行更新；评论家则是价值函数网络，通过逼近状态—动作对的价值函数来判定哪些是有价值的策略。这种机制就和人类的行为方式非常接近了，也就是用价值观来指导行为，而行为经验又会对价值观产生反作用。

在行动者—评论家机制的基础上，UNREAL 做出了一些改进。首先是采用**异步训练**的思想，即让多个训练环境同时采集数据并执行训练，这不仅提升了数据的采样速度，也提升了算法的训练速度。在不同训练环境采集样本还能避免样本之间的强相关性，有利于神经网络的性能提升。UNREAL 的另一个改进是引入了多重的**辅助任务**。多个辅助任务同时训练单个网络既能加快学习速度，又能进一步提升性能，代价则是计算量的增加。常用的辅助任务包括控制任务和回馈预测任务。需要注意的是，虽然并行执行的任务种类不同，但它们使用的都是同样的训练数据，因而可以看成是对已有数据价值更加充分的挖掘与利用。

补充说明：异步训练的思路被 A3C 系统化之后，成为了深度强化学习工程实践的标配。但异步更新带来的梯度陈旧问题也随即暴露：各线程用自己的参数算梯度、往共享参数上写，先算出的梯度可能已经过期。后来 **PPO** 用另一种方式解决稳定性——它不并行多个环境，而是限制每次策略更新的幅度，把新旧策略的概率比裁剪到 [1−ε, 1+ε] 区间内，超出就不给梯度。这个改动实现简单、调参不敏感，使 PPO 成为目前应用最广的通用强化学习算法，从机器人控制到大模型对齐都在用。可以说，策略梯度的实用化路径是"降低方差 → 限制更新幅度"，而不是把梯度算得更准。

六、基于模型

6.1 转移模型

无论是基于价值还是基于策略的深度强化学习方法，都没有对环境模型做出任何先验假设。基于模型（model-based）的深度强化学习的基本思路是构造关于环境的模型，再用这个模型来指导决策。

关于环境的模型可以使用转移概率 p(r, s' | s, a) 来表示，它描述了从当前的状态和动作到下一步的状态和奖励的可能性。将转移概率在状态空间和动作空间上遍历，就可以得到完整的转移概率张量。不同的转移概率可以通过深度网络训练得到。

6.2 误差累积与优势

和前两种方法相比，基于模型的方法存在很多问题，相关的研究和应用也比较少。在转移概率的估计中，每个概率值上都会存在误差，而这些误差在较长的状态转移序列上累积起来，可能会达到相当惊人的水平。这将导致计算出的奖励值和真实奖励值之间的南辕北辙。

可即便如此，基于模型的方法仍有较强的现实意义。它能减少与真实环境进行互动的次数，而这种互动在实践中往往是受限的。此外，如果能学到一个足够准确的环境模型，对智能体的控制难度也会大大降低。

补充说明：模型误差的累积有两个表现。一是**分布偏移**：模型只在真实数据覆盖的区域准确，一旦策略为了追求高回报跑到没见过的状态，模型的预测就失去依据，而错误的预测又会让策略跑得更远。二是**复合误差**：单步预测误差为 ε，规划 H 步之后的误差上界大约是 ε 的 H 倍量级。应对方法包括：用模型集成的方差来估计不确定性，在不确定的地方回退到真实环境；缩短规划步数，用模型做短程想象再由真实交互校正；或者干脆把模型当作辅助损失（如 Dyna 架构），主要学习仍靠真实数据。这些方法在机器人控制与自动驾驶中尤为重要，因为真实交互的代价太高，“仿真里练、现实中用”几乎必须依赖模型的准确性。

七、三种范式的对比

7.1 数据效率与稳定性

三条路线的性格差别，可以按数据效率与稳定性两个维度看。

基于价值的方法样本效率较高，因为每一步的经验都能立刻用于更新 Q 值，而且不需要完整的轨迹。但它的动作空间必须离散（要枚举每个动作取 max），连续控制要做离散化，维度一高就爆炸。稳定性方面，它受目标估计偏差影响较大，需要目标网络、Double 之类的技巧来稳住。

基于策略的方法天然支持连续动作与随机策略，梯度估计是无偏的，但方差大、样本效率低，常常需要与环境交互上百万步。稳定性靠限制更新幅度来保证。

基于模型的方法样本效率最高，因为它可以从少量真实交互中学到一个模型，然后在模型里反复练习。代价是对模型精度的依赖极强，模型一旦有偏差，规划出来的策略可能完全不可用。

7.2 适用场景

按这个画像，选择就不难了：动作离散且交互便宜（游戏、推荐），优先考虑价值型；动作连续且需要平滑控制（机器人、自动驾驶），优先考虑策略型；真实交互代价极高、有可信仿真器（工业控制、芯片设计），优先考虑基于模型的方法。

现代实践更多是混合的：AlphaGo 的树搜索属于基于模型的规划，策略网络与价值网络则分别承担基于策略与基于价值的角色；MuZero 更进一步，连环境模型都从数据里学出来，再用学到的模型做搜索。三条路线的边界正在变得模糊，这本身也说明强化学习还远未定型。

> **新手提示：强化学习的复现比监督学习难得多**
>
> 同一个算法、同一份代码，换一个随机种子跑两次，结果可能差一倍。原因在于强化学习的训练过程本身就是数据采集过程：初始策略略有不同，采集到的数据就不同，学到的策略随之不同，误差在循环中被放大。所以见到“某算法在某任务上达到某某分数”时，要关注它跑了多少个种子、报告的是均值还是最大值。自己实验时至少跑 3 到 5 个种子，用均值加减标准差报告结果，否则很容易把随机波动当成改进。

四个常见误区

- **“奖励函数就是目标”**——智能体会精确优化你写下的奖励，而不是你心里想的那个目标。奖励设计稍有偏差，就会出现钻空子的行为。
- **“DQN 输出的 Q 值就是真实价值”**——它是用自举方式拟合出来的估计，存在系统性高估，Double DQN 正是为此提出的修正。
- **“策略梯度一定比值函数方法好”**——策略梯度直接优化目标、适合连续动作，但方差大、样本效率低；值函数方法样本效率高，却不擅长连续控制。
- **“强化学习什么都能学”**——它依赖大量交互样本与可靠的奖励信号，在仿真成本高、奖励稀疏的真实场景中往往难以直接应用。

八、要点回顾

1. 强化学习通过与环境交互、最大化累积奖励来学习决策，反馈只有奖励好坏而没有正确动作。
2. 核心矛盾是探索与利用的平衡，只探索学不到策略，只利用找不到更优解。
3. 马尔可夫决策过程用状态、动作、转移概率、奖励四元组描述问题，并假设下一状态只依赖当前状态与动作。
4. 目标是最大化折扣累积回报，折扣因子 γ 兼顾数学收敛与对未来收益的重视程度。
5. 最优价值函数满足贝尔曼最优方程，把全局优化拆成递归形式。
6. 深度强化学习用神经网络把高维状态映射为价值或策略，解决状态空间不可枚举的问题。
7. 三类范式分别为基于价值、基于策略、基于模型，边界并不互斥。
8. Q 学习通过时序差分误差迭代更新 Q 值，是把全局最优拆成局部更新的经典做法。
9. 深度 Q 网络用经验回放打散样本相关性、用目标网络稳定回归目标，是深度强化学习的里程碑。
10. 策略梯度直接优化参数化策略，按回报调高好动作的概率，减去基线可显著降方差。
11. 行动者—评论家让策略网络负责决策、价值网络负责打分，是两者的结合形式。
12. 基于模型的方法学习环境动力学，样本效率最高，但受模型误差累积与分布偏移限制。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
强化学习	Reinforcement Learning	RL	通过与环境交互最大化累积奖励来学习决策的方法
智能体	Agent	—	在环境中观察、决策并获取奖励的学习主体
探索与利用困境	Exploration-Exploitation Dilemma	—	在尝试新动作与沿用已知好动作之间的权衡
马尔可夫决策过程	Markov Decision Process	MDP	用状态、动作、转移概率与奖励描述序贯决策的框架
马尔可夫性	Markov Property	—	下一状态只依赖当前状态与动作的假设

名称	英文全称	英文缩写	简短介绍
策略	Policy	π	从状态到动作（或动作分布）的映射
状态价值函数	State Value Function	V(s)	从状态 s 出发按某策略行动的期望回报
动作价值函数	Action Value Function	Q(s,a)	在状态 s 执行动作 a 后按某策略行动的期望回报
回报	Return	G_t	从时刻 t 起的折扣奖励总和
折扣因子	Discount Factor	γ	控制未来奖励相对当前权重的系数
贝尔曼方程	Bellman Equation	—	把价值函数写成当前奖励与后继价值递归关系的等式
时序差分误差	Temporal Difference Error	TD Error	实际奖励加后继估计与当前估计之差
Q 学习	Q-learning	—	基于时序差分误差迭代更新动作价值表的离策略算法
深度 Q 网络	Deep Q-Network	DQN	用神经网络表示 Q 函数并配合经验回放与目标网络的算法
经验回放	Experience Replay	—	存储历史转移并随机抽样以打散样本相关性的机制
目标网络	Target Network	—	参数延迟同步、用于生成稳定回归目标的副本网络
最大化偏差	Maximization Bias	—	取最大值操作导致价值被系统性高估的现象
双深度 Q 网络	Double DQN	DDQN	分离动作选择与价值评估以缓解最大化偏差的变体
竞争网络结构	Dueling Network	—	把 Q 值分解为状态价值与动作优势之和的网络结构
优先经验回放	Prioritized Experience Replay	PER	按时序差分误差大小加权采样的回放策略
策略梯度	Policy Gradient	PG	直接对参数化策略求梯度以最大化期望回报的方法
基线	Baseline	b(s)	从回报中减去、不改变梯度期望但降低方差的函数
优势函数	Advantage Function	A(s,a)	动作价值与状态价值之差，表示动作相对平均的好坏

名称	英文全称	英文缩写	简短介绍
行动者—评论家	Actor-Critic	AC	策略网络负责决策、价值网络负责评估的混合结构
异步优势行动者评论家	Asynchronous Advantage Actor-Critic	A3C	多环境并行异步更新共享参数的强化学习算法
近端策略优化	Proximal Policy Optimization	PPO	通过裁剪概率比限制更新幅度的稳定策略梯度算法
信任域策略优化	Trust Region Policy Optimization	TRPO	用 KL 约束限制策略更新幅度的算法
无监督强化辅助学习	UNsupervised REinforcement and Auxiliary Learning	UNREAL	引入辅助任务与异步训练加速学习的框架
基于模型的强化学习	Model-based Reinforcement Learning	MBRL	先学环境动力学模型再据此规划决策的方法
分布偏移	Distribution Shift	—	策略进入训练数据未覆盖区域导致模型预测失效的现象
自我对弈	Self-play	—	智能体与自身对局生成训练数据的训练方式