# 深度信念网络：受限玻尔兹曼机、对比散度与逐层预训练

**读前须知**

- **前置**：概率论中的联合分布与条件分布；能量模型的思想。
- **这一篇的位置**：深度学习复兴的起点。它第一次证明“深层网络可以逐层训练”，把“深”从理论口号变成了可运行的工程。
- **读完能做什么**：写出 RBM 的能量函数与条件概率；说清对比散度近似了什么；解释逐层预训练为什么能缓解深层网络的训练困难。

## 一、深度信念网络的提出

### 1.1 一次转折

2006 年，乔弗里·辛顿提出了**深度信念网络**（deep belief network）。在此之前，多层神经网络已经在理论上被证明具有强大的表达能力，却在实际训练中屡屡失败——层数一多，反向传播传到低层的梯度就接近于零，网络的前几层几乎学不到东西。深度信念网络的意义不在于模型本身有多复杂，而在于它带来了一套可行的训练流程，让“深”重新变得可训练。

也正因如此，它常被视为连接主义学派复兴的起点。

### 1.2 生成模型的定位

深度信念网络是一种**概率生成模型**：它不直接给出“输入属于哪一类”的判别边界，而是建立输入数据与类别之间的联合概率分布 $p(x, y)$，再由此推导后验概率完成分类。

这与 002 板块中讨论过的生成式与判别式方法对应得上：判别模型直接建模 $p(y \mid x)$，生成模型先建模 $p(x, y)$ 或 $p(x)$，再通过贝叶斯公式得到判别结果。生成模型通常需要更强的假设、更多的计算，但也能完成判别模型做不到的事——采样出新的数据。

### 1.3 网络结构概览

深度信念网络由多个隐藏层堆叠而成，隐藏变量通常是二值的，用来对输入信号做逐层的特征提取。输入从最底层进入，自下而上地传递。

结构上有一处特别之处：最上面的两层之间没有方向，连接是对称的，这两层共同构成一个**联想记忆**（associative memory）。下面的各层则是有向的。正是这种“底层有向、顶层无向”的混合结构，决定了它特殊的训练方式。

从功能上看，每个隐藏层都对应输入数据的一种中间表示，层内的每个神经元对应某一层次上的特征，层间的连接则刻画这些特征之间的关系。所有特征连同它们之间的关系，合起来构成对输入数据的抽象描述。

## 二、受限玻尔兹曼机

### 2.1 两层结构与“受限”

深度信念网络的基本构件是**受限玻尔兹曼机**（restricted Boltzmann machine）。它早在 1986 年就已提出，却沉寂了近二十年，直到辛顿用它堆出深度结构才重新受到重视。

受限玻尔兹曼机就是一个两层的网络：一层**可见层**（visible layer）负责接收数据，一层**隐藏层**（hidden layer）负责处理数据。两层之间全连接，也就是任意一个可见单元与任意一个隐藏单元之间都有边。

关键在于同层之内没有连接：可见层内部不连，隐藏层内部也不连，因此同一层内不存在信息流动。这正是名称中"受限"二字的来源——它把一般玻尔兹曼机中杂乱无章的层内连接砍掉了，换来的是计算上的极大便利。

## 2.2 能量函数与联合分布

受限玻尔兹曼机借用统计物理的语言，用一个**能量函数**描述每个状态的好坏：

$$E(\mathbf{v}, \mathbf{h}) = -\mathbf{a}^\top \mathbf{v} - \mathbf{b}^\top \mathbf{h} - \mathbf{v}^\top \mathbf{W} \mathbf{h}$$

其中 v 是可见层的状态向量，h 是隐藏层的状态向量，W 是两层之间的权重矩阵，a、b 分别是可见层与隐藏层的偏置。能量越低，这个状态越"稳定"，出现的概率越大。

状态 (v, h) 的联合概率由玻尔兹曼分布给出：

$$p(\mathbf{v}, \mathbf{h}) = \frac{1}{Z} \exp\left(-E(\mathbf{v}, \mathbf{h})\right), \qquad Z = \sum_{\mathbf{v}, \mathbf{h}} \exp\left(-E(\mathbf{v}, \mathbf{h})\right)$$

Z 是配分函数，要把所有可能的状态求和才能算出来。对一张小图像而言，可见单元可能有几百个，状态总数就是 2 的几百次方，直接计算完全不可行。这个难以处理的 Z，是后面所有近似方法的根源。

## 2.3 条件独立与激活概率

层内无连接这个限制，在这里发挥了作用：给定可见层的状态，各个隐藏单元之间彼此独立，于是联合条件概率可以拆成连乘：

$$p(\mathbf{h} \mid \mathbf{v}) = \prod_j p(h_j \mid \mathbf{v})$$

单个隐藏单元被激活的概率因此有简洁的闭式解：

$$p(h_j = 1 \mid \mathbf{v}) = \sigma\left(b_j + \sum_i W_{ij} v_i\right)$$

同理，给定隐藏层时，可见单元也彼此独立：

$$p(v_i = 1 \mid \mathbf{h}) = \sigma\left(a_i + \sum_j W_{ij} h_j\right)$$

其中 σ 是对数几率函数。这两个式子说明：**整个网络可以逐单元地采样，不需要一次性枚举所有状态。**这正是"受限"换来的最大好处，也是对比散度能够工作的前提。

> **新手提示：为什么用 S 型函数**
>
> 当可见层与隐藏层都使用 S 型传递函数时，神经元的输出可以解释为单个节点的激活概率，取值落在 0 到 1 之间。这时候"前向传播"就不再是确定性的数值计算，而是一次伯努利采样：以算出的概率为参数，掷一次硬币决定该单元取 1 还是 0。理解这一点，才能理解受限玻尔兹曼机为什么是"随机"网络，而不是普通的前馈网络。

# 三、对比散度

## 3.1 重构：从隐藏层回到可见层

受限玻尔兹曼机训练的目标，是让模型分布尽量贴近训练数据的分布。如果只用前向传播得到一个输出，那和普通神经网络没有区别；它真正要做的是**重构**——用隐藏层的激活反推回可见层，看看能否还原出原始输入。

具体做法是保持所有权重不变、只把方向反转：每个隐藏单元的输出按照同一组系数反馈给可见层，可见层的每个单元收到的是各隐藏单元输出的线性组合，再加上一组新的偏置，就得到了对原始输入的估计。估计值与原始输入之间的差异，就是**重构误差**。

## 3.2 对数似然的梯度

从最大似然的角度看，训练的目标是最大化训练数据出现的概率，其梯度有一个非常整齐的形式：

$$\frac{\partial \ln p(\mathbf{v})}{\partial W_{ij}} = \mathbb{E}_{\text{data}}\left[v_i h_j\right] - \mathbb{E}_{\text{model}}\left[v_i h_j\right]$$

第一项是数据分布下的期望，容易估计——把训练样本喂进去，算一次激活概率即可，称为**正梯度**（positive phase）。第二项是模型分布下的期望，需要对模型自己生成的样本求平均，称为**负梯度**（negative phase）。麻烦就出在第二项：它要求从模型分布中采样，而这又回到那个算不出来的配分函数。

## 3.3 用少量吉布斯步近似

辛顿提出的**对比散度**（contrastive divergence）做了一个大胆的近似：不从模型分布慢慢采样到平衡，而是**从训练样本出发，只跑很少几步吉布斯采样**就停下来，用这几步得到的样本来估计模型期望。

一步对比散度的流程如下：

1. 取一个训练样本作为可见层的初始状态 $v^{(0)}$；
2. 由 $p(h \mid v^{(0)})$ 采样出隐藏层的状态 $h^{(0)}$；
3. 由 $p(v \mid h^{(0)})$ 采样出重构的可见层 $v^{(1)}$；
4. 再由 $p(h \mid v^{(1)})$ 采样出新的隐藏层 $h^{(1)}$；
5. 用两组状态的外积之差更新权重。

$$\mathbf{W} \leftarrow \mathbf{W} + \epsilon\left(\mathbf{v}^{(0)}\mathbf{h}^{(0)\top} - \mathbf{v}^{(1)}\mathbf{h}^{(1)\top}\right)$$

$$\mathbf{a} \leftarrow \mathbf{a} + \epsilon\left(\mathbf{v}^{(0)} - \mathbf{v}^{(1)}\right), \qquad \mathbf{b} \leftarrow \mathbf{b} + \epsilon\left(\mathbf{h}^{(0)} - \mathbf{h}^{(1)}\right)$$

其中 ε 是学习率。这个更新式的含义很直观：正梯度那一项把权重往“更能解释真实数据”的方向推，负梯度那一项把权重往“不再解释模型自己编造的数据”的方向拉，两者相减，就是一次带方向的修正。

**补充说明**：对比散度并不是在对数似然上做真正的梯度上升，它优化的是另一个量。严格地说，它最小化的是“从数据分布出发跑 k 步吉布斯链后的分布”与模型分布之间的 KL 散度。这带来两个后果：一是 k 取得越小，偏差越大，但因为起点已经是数据分布，偏差在实践中往往可以接受；二是更新方向不保证是任何目标函数的梯度，所以训练曲线可能出现震荡。后来的持续对比散度（persistent CD）通过保留一条跨批次延续的吉布斯链来减小偏差，是常见的改进。另外要说明的是，对比散度并不保证收敛到最大似然解，但在特征提取任务上，它学到的表示已经足够好用了。

## 3.4 训练在做什么

把上面的过程连起来看，对比散度的训练本质上是在寻找一组参数，使模型分布最符合训练数据集的统计特性——也就是让训练数据出现的概率最大。

前向传输时，网络在给定权重 W 的条件下用输入 x 预测隐藏状态 a，即求 p(a | x; W)；反向重构时，目标变成求 p(x | a; W)。两个条件概率结合，就得到输入与输出的联合分布 p(x, a)。重构误差在两层之间来回传播，权重随之不断修正，直到隐藏层能准确提取可见层的特征、又能根据这些特征较好地还原可见层。

# 四、堆叠成深度信念网络

## 4.1 隐藏层的双重角色

把若干个受限玻尔兹曼机首尾相接，就得到了深度信念网络。除了最顶层和最底层，中间的每个隐藏层都扮演双重角色：对下面那个玻尔兹曼机来说它是隐藏层，对上面那个来说它又是可见层。

这种“一层两用”的结构，使得逐层训练成为可能——每一层都只需要和相邻的一层打交道，不必一次性面对整个深度网络。

## 4.2 逐层无监督预训练

深度信念网络采用的训练策略是**无监督预训练 + 有监督微调**，这一点与 026 中讲过的栈式自编码器完全一致，区别只在于基本单元不同：那边是自编码器，这边是受限玻尔兹曼机。

预训练逐层进行。对第一个受限玻尔兹曼机，它的可见层就是深度网络的输入层。用输入样本 $x = h^{(0)}$ 训练它，得到的是条件概率 $p(h^{(1)} \mid h^{(0)})$，其中 $h^{(1)}$ 是第一个隐藏层的输出。第一个玻尔兹曼机的隐藏层又是第二个玻尔兹曼机的可见层，于是 $h^{(1)}$ 可以作为输入继续训练，得到 $h^{(2)}$。如此重复，就完成了所有隐藏层的预训练。

注意每一步都只训练当前这一层的参数，其余各层保持冻结。这使得每一层的训练都是一个浅层问题，避开了深层网络难以优化的困境。

## 4.3 有监督微调

预训练结束后，网络已经有了一个不错的初始点，但各层是分别优化的，整体上未必协调。这时需要在最顶层再加一个**反向传播层**，以受限玻尔兹曼机的输出作为它的输入，执行有监督训练，再把误差自顶向下地传回每一个受限玻尔兹曼机，完成对整个网络的微调。

这正是深度信念网络要在最上面两层使用无方向连接的原因：顶层作为联想记忆，既能为预训练提供无监督信号，又能承接微调阶段自上而下的误差。实际使用中，负责微调的未必是反向传播，大多数用于分类的判别模型都可以胜任。

**补充说明**：预训练与微调的分工可以这样理解：预训练负责“把表示学好”，微调负责“把任务做好”。前者只用无标签数据，学到的是数据本身的统计结构；后者用标签，把这种结构对齐到具体的分类目标。两者结合的效果，在标注数据稀缺时尤其明显——预训练阶段没有浪费任何无标注样本。

# 五、梯度弥散与预训练的意义

## 5.1 梯度为什么会消失

传统的反向传播用于深度结构，在原则上是可行的，实际中却过不了**梯度弥散**（gradient vanishing）这一关。

所谓梯度弥散，是指误差反向传播时，传播的距离越远，梯度值就衰减得越小，参数更新得也越慢。后果是：靠近输出层的隐藏层已经收敛，靠近输入层的隐藏层却几乎没有变化，还停留在随机初始值上。整个网络实际上只有上面几层在工作，深度带来的表达能力并没有兑现。

从链式法则看，这个现象几乎是必然的：每穿过一层，梯度就要乘上一个雅可比矩阵，层数一多，连乘的结果要么趋近于零，要么爆炸。而当时的传递函数普遍使用 S 型函数，其导数最大只有 0.25，几层相乘就所剩无几。

## 5.2 预训练为何能缓解

基于预训练的方法不受这个困扰。在梯度下降之前先做无监督预训练，相当于给每一层都找到了一个合理的初始位置：隐藏层的参数不再是随机噪声，而是已经能提取数据特征的变换。

这样一来，即使反向传播的梯度在低层衰减得厉害，低层也已经处在一个不错的解附近，不需要靠梯度从零开始摸索。逐层预训练因此在所有隐藏层上一视同仁地实现了较好的优化效果，并给深度结构带来了强大的表达能力。

这套思路一度被视为训练深度结构的不二法门。

## 5.3 后来的反思

随着研究深入，人们发现无监督预训练并没有想象中那么神奇。

一方面，良好的初始化策略完全可以比逐层预训练更高效——合理缩放初始权重、使用批归一化，都能让深层网络直接训练起来。另一方面，梯度弥散的根源并不是反向传播算法本身有问题，而在于非线性传递函数的性质：S 型函数在两端饱和、导数极小，连乘自然衰减。换成整流线性单元，正区间的导数恒为 1，梯度就能顺畅地传回低层。

于是，2012 年前后，逐层预训练逐渐退场，被 ReLU、更好的初始化和更大的数据量取代。但它留下的遗产并未消失：**“先用无监督方式学好表示，再针对任务微调”**这一范式，正是今天预训练语言模型的思想源头。

> **新手提示：梯度弥散不等于梯度爆炸**
>
> 两者都源于连乘，方向相反。梯度弥散是连乘结果趋近于零，低层学不动；梯度爆炸是连乘结果迅速增大，参数一步跳到很远的地方，损失变成 NaN。前者常见于深层 S 型网络，后者常见于循环网络沿时间展开。应对手段也不同：弥散靠换激活函数、加残差连接、做归一化；爆炸靠梯度裁剪。判断属于哪一种，看训练日志里损失和梯度的量级即可。

# 六、历史地位

深度信念网络今天的使用远不如卷积神经网络广泛，但它是一次“吃螃蟹”的成功尝试。

它的价值有两层。第一层是模型层面：它示范了如何用无监督的、基于能量的构件搭出深层结构，为后来的生成模型提供了思路。第二层是方法论层面：辛顿真正的贡献与其说是这个模型，不如说是对深度模型训练方法的改进——逐层预训练让“深”重新变得可行，直接推动了此后十年深度学习的复兴。

这种复兴不仅体现在训练效率的提升上，更体现在研究者开始认真追问训练机制本身：梯度去哪了、初始化为什么重要、表示究竟学到了什么。这些问题意识，比任何一个具体模型都更持久。

**四个常见误区**

- **“逐层预训练是训练深度网络的唯一办法”**——它解决的是当年没有 ReLU、批归一化与残差连接时的训练困难。这些技术成熟后，端到端训练成为主流。
- **“对比散度等价于最大似然”**——它只是最大似然梯度的一种近似，步数越少偏差越大。步数趋于无穷时才接近真实梯度。
- **“RBM 可以算出精确概率”**——配分函数要对所有隐层状态求和，规模是指数级的，只能近似估计。
- **“DBN 是判别模型”**——它的主体是生成式的，判别能力要靠额外加一层有监督输出并微调。

# 七、要点回顾

1. 深度信念网络是概率生成模型，建立输入与类别的联合概率分布，由多个隐藏层堆叠而成。
2. 最上面两层无方向、连接对称，构成联想记忆；下面各层有向。
3. 受限玻尔兹曼机是两层结构，可见层与隐藏层全连接，同层内不连接，“受限”即指此。
4. 它的联合分布由能量函数经玻尔兹曼分布给出，配分函数难以计算，是训练困难的根源。
5. 层内无连接使条件概率可分解，隐藏单元与可见单元都能逐单元采样。
6. 对数似然梯度等于数据期望减模型期望，前者易算，后者需要采样。
7. 对比散度从训练样本出发只跑少量吉布斯步，用重构样本来近似模型期望。
8. 权重更新为学习率乘以正负两组外积之差，偏置更新为两组状态之差。
9. 多个受限玻尔兹曼机堆叠成深度信念网络，中间隐藏层兼具隐藏层与可见层双重角色。
10. 训练采用无监督逐层预训练加有监督微调，微调靠顶层的反向传播完成。
11. 梯度弥散源于连乘与饱和激活函数，预训练通过给出良好初始点来缓解。
12. 无监督预训练后来被更好的初始化与 ReLU 取代，但“预训练 + 微调”的范式延续至今。

# 八、名词汇总

| 名称 | 英文全称 | 英文缩写 | 简短介绍 |
| --- | --- | --- | --- |
| 深度信念网络 | Deep Belief Network | DBN | 由多个受限玻尔兹曼机堆叠而成的概率生成模型 |
| 受限玻尔兹曼机 | Restricted Boltzmann Machine | RBM | 层内无连接的两层随机神经网络 |
| 可见层 | Visible Layer | — | 接收数据的底层单元集合 |
| 隐藏层 | Hidden Layer | — | 对可见层做特征提取的单元集合 |
| 能量函数 | Energy Function | — | 描述网络状态“好坏”的标量函数 |
| 配分函数 | Partition Function | — | 玻尔兹曼分布中对全部状态求和的归一化常数 |
| 玻尔兹曼分布 | Boltzmann Distribution | — | 概率随能量指数衰减的分布形式 |
| 吉布斯采样 | Gibbs Sampling | — | 逐变量条件采样、逐步逼近联合分布的采样方法 |

| 名称 | 英文全称 | 英文缩写 | 简短介绍 |
| --- | --- | --- | --- |
| 对比散度 | Contrastive Divergence | CD | 从数据出发跑少量吉布斯步来近似似然梯度的方法 |
| 正梯度 | Positive Phase | — | 数据分布下可见与隐藏单元外积的期望 |
| 负梯度 | Negative Phase | — | 模型分布下可见与隐藏单元外积的期望 |
| 重构误差 | Reconstruction Error | — | 由隐藏层反推的可见层与原始输入的差异 |
| 逐层预训练 | Layer-wise Pre-training | — | 逐层用无监督方式初始化深层网络参数的方法 |
| 有监督微调 | Supervised Fine-tuning | — | 用带标签数据自顶向下联合调整全部参数 |
| 联想记忆 | Associative Memory | — | 由对称连接构成、可按内容检索模式的记忆结构 |
| 梯度弥散 | Gradient Vanishing | — | 反向传播中梯度随层数增加而衰减至近零的现象 |
| 生成模型 | Generative Model | — | 学习数据联合分布并能采样新样本的模型 |
| 判别模型 | Discriminative Model | — | 直接学习条件概率或决策边界的模型 |