卷积神经网络：卷积运算、稀疏感知与特征映射

读前须知

- **前置**：矩阵乘法、前馈网络；知道“参数”是什么。
- **这一篇的位置**：图像领域的第一次真正突破。卷积与权值共享这两个设计，至今仍是视觉模型的默认起点。
- **读完能做什么**：手算一次二维卷积；解释稀疏连接与权值共享省下了多少参数；说清感受野、步长、填充与池化各自控制什么。

一、从人脸识别说起

1.1 一个日常应用

2017 年 9 月，苹果推出 iPhone X，“刷脸解锁”成了它最引人注目的卖点。无论当时的识别精度是否配得上宣传，人脸识别乃至更广义的图像识别，都已经从实验室走进了日常生活。

支撑这类应用的关键技术之一，就是**卷积神经网络**（convolutional neural network）。它诞生于 1989 年，却直到九年后才迎来首秀：1998 年，燕乐存提出了第一个卷积神经网络模型 LeNet-5，用来识别手写数字。这个模型在当时并不受欢迎——它消耗的计算资源太多，训练一次要花上数天。

真正的转机出现在 2006 年。逐层初始化训练方法的提出，让沉寂多年的卷积神经网络重新焕发生机，此后它逐渐成长为深度学习队伍中的中坚力量。

1.2 为什么是“卷积”

顾名思义，卷积神经网络指的是至少在某一层中用**卷积运算**（convolution）代替矩阵乘法的神经网络。

这一替换之所以有效，是因为卷积运算的特性天然适配一类特定的数据结构——具有网格状结构的数据。最典型的网格型数据就是数字图像：无论是灰度图还是彩色图，都是定义在二维像素网格上的一组标量或向量。也正因如此，卷积神经网络自诞生起便广泛应用于图像与文本识别，后来又扩展到语音处理等领域。

二、卷积运算

2.1 数学定义

卷积是对两个函数进行的一种数学运算，在不同学科中有不同的解释方式。在卷积网络中，参与运算的两个函数分别叫做**输入**和**核函数**（kernel function）。本质上讲，卷积就是以核函数作为权重系数，对输入进行加权求和。

为了突出这个本质，卷积神经网络中针对二维函数的卷积运算在原始数学定义上做了一些调整——省去了翻转，只保留滑动加权求和，写成：

$$Y(i,j) = (X * H)(i,j) = \sum_{m}\sum_{n} X(i+m,\, j+n)\, H(m,n)$$

其中 X 是输入矩阵，H 是核函数，Y 是输出。核函数在输入上逐行逐列滑动，每到一个位置就与覆盖住的局部区域做加权求和，把所有结果排成矩阵，就得到输出。

2.2 卷积就是内积

这个式子虽然写成了二维形式，但如果把被覆盖的局部区域和核函数各自拉成一维向量，卷积计算的实际上就是两者的**内积**。

内积的作用是描述两个向量的关系：方向越一致，内积越大；彼此正交，内积为零。因此卷积的结果反映的正是输入局部与核函数之间的相似程度——输出越大，说明这块局部越像核函数所描述的模式。

这一点是理解卷积网络的关键：**核函数不是抽象的参数，而是一个可学习的模式模板**。

2.3 一个做菜的类比

用生活中的例子类比，卷积可以看成是做菜：输入函数是原料，核函数是菜谱。

同一条鲤鱼，如果菜谱里酱油的权重较大，做出来的是红烧鱼；如果糖和醋的权重较大，做出来的是西湖醋鱼；如果辣椒的权重较大，做出来的就是辣鱼。不同的菜谱对应不同的口味，不同的核函数也对应不同的输出。训练的过程，就是根据"这道菜好不好吃"反过来调整菜谱里各味调料的配比。

> **新手提示：卷积与互相关**
>
> 严格按数学定义，卷积要先翻转核函数再滑动。深度学习框架里实现的其实是**互相关**（cross-correlation），省掉了翻转这一步。因为核函数本身是学出来的，翻不翻转只相当于把学到的核转个方向，对表达能力没有任何影响，所以工程上统一叫卷积。阅读框架文档时看到 conv2d，心里要清楚它算的是互相关。

三、三项关键性质

卷积之所以适合图像，是因为它同时具备三项性质。这三项性质不是附加的技巧，而是卷积结构自带的结果，它们共同解释了为什么卷积网络的参数这么少、又这么好训。

3.1 稀疏感知

稀疏感知（sparse interaction）指的是卷积层核函数的尺寸通常远小于图像尺寸。

输入图像在两个维度上可能各有几千个像素，而核函数最大也不过几十个像素。选择小核函数的好处有两层：一方面有助于发现图像中细微的局部特征，另一方面显著提升了存储效率与运行效率。

更深一层的道理在于：对图像的全局感知可以通过综合多个局部感知得到。这与人的认知方式一致——我们看一张脸，先看到的是眼睛、鼻子、嘴巴这些局部，再把它们组合成整体，而不是一次性把握全部像素。

3.2 参数共享

参数共享（parameter sharing）指的是在模型的不同位置使用同一组参数。

具体到卷积网络，就是在每一轮训练中用同一个核函数去和图像的所有分块做卷积。这能大幅降低参数量。以一个具体例子对比：若输入是 1000×1000 的图像，直接接到 1000 个神经元的全连接层，权重需要 10^9 个；而改用 64 个 3×3 的卷积核，参数量只有 3×3×64 = 576 个，并且与输入尺寸无关。

参数共享之所以成立，基础在于图像特征的提取与位置无关：如果在图像的一个区域上，某些像素的组合构成一条直线，那么在图像的其他区域，具有相同灰度关系的像素组合仍然是直线，而不会变成圆。图像的统计特性并不取决于空间位置，因此同一套特征提取规则可以在整幅图上通用。

3.3 平移等变

平移等变（translational equivalence）指的是：当输入发生平移时，输出等于原来的输出做出相同数量的平移。也就是说，平移操作与卷积运算可以交换次序。

从卷积的线性性质出发，这个结论很容易推导：输入整体右移一格，卷积结果也整体右移一格，形状不变。

它的意义在于，当任务只关心某个特征是否出现、而不关心出现在哪里时，平移等变性质尤为有用。检测图像里有没有眼角，不需要为图像的每个位置单独训练一套参数。

补充说明：这里需要区分两个容易混淆的概念。**平移等变**说的是“输入平移，输出跟着平移”；**平移不变**说的是“输入平移，输出不变”。卷积本身是等变的，不变性要靠池化或全局池化来获得。另外，卷积对平移的容忍是有限的：一旦位移超过感受野能覆盖的范围，或者遇到旋转、缩放，卷积并不能自动应对，这也是数据增强存在的理由。教材里常把后者笼统称为“平移不变性”，严格说来并不准确。

四、卷积层

4.1 核函数与特征映射

卷积层是卷积神经网络的核心，其参数是一个或多个随机初始化的核函数。

核函数像探照灯一样逐行逐列扫描输入图像，对像素矩阵从左到右、从上到下地滑动覆盖。每一个被覆盖的区域都是与核函数维度相同的像素组合，作为输入与核函数做卷积。扫描完毕后，所有卷积结果排成一个新矩阵，这个矩阵就是**特征映射**（feature map）。

若输入尺寸为 W×W、核函数尺寸为 F×F、步长为 S、边缘填充为 P，则输出的边长为：

$$\left\lfloor \frac{W - F + 2P}{S} \right\rfloor + 1$$

这个式子在实际设计网络时经常用到：想保持尺寸不变，就让填充量取 (F−1)/2；想降采样，就把步长调大。

4.2 为什么能提取特征

回到 2.2 的结论：卷积的结果度量的是局部与核函数的相似程度。

如果选取的核函数表示一个直角，那么原始图像中凡是出现直角的地方，特征映射上就会出现一个较大的数值；数值所在的坐标，正好指示了这个直角在输入图像中的位置。同理，表示边缘的核函数会在边缘处响应最强，表示某种纹理的核函数会在该纹理处响应最强。

因此在实践中，卷积层通常会同时训练多个不同的核函数，以提取不同类型、不同方向的特征。一个卷积层输出几十甚至几百个通道，每个通道对应一种模式。

4.3 激活层

卷积层得到的特征映射一般会送到**激活层**处理，给系统添加非线性元素。

激活层最常用的传递函数是**整流线性单元**（rectified linear unit），它的做法是把负值置零、正值原样保留。这里的顺序要理清：卷积的输出可以为负，表示“这块局部与模板方向相反”；ReLU 把负响应压成零，只让正的匹配信号通过。

这一步不可省略。如果整个网络只有卷积和全连接，无论堆多少层，整体仍然是一个线性变换，表达能力与单层网络没有本质区别。非线性正是深度能够逐层抽象的前提，这一点在 023 中已经详细讨论过。

五、池化层

5.1 下采样

卷积层之间通常周期性地插入**池化层**（pooling layer）。它更恰当的名字是**下采样层**（downsampling layer），作用是对特征映射矩阵进行筛选和压缩。

卷积层给出了核函数与图像每个局部的相似程度，但真正对分析有帮助的，往往只是那些取值较大、也就是相似程度较高的部分。

5.2 最大池化

最常见的做法是**最大池化**（max pooling）：把特征映射划分为若干个互不重叠的矩形区域，取每个区域中的最大值作为输出。

这样做的直接效果是数据量成倍下降——一个 2×2 的最大池化能把特征映射的边长减半、元素数降到四分之一。同时，由于输出的只是区域内的极值，那些微小的扰动被自动忽略，过拟合的风险也随之降低。

5.3 池化到底带来了什么

直观来看，池化之所以有效，是因为特征在图像中的绝对位置，远不如它与其他特征的相对位置重要。

例如判断一张图像中是否包含人脸，我们需要找到左右对应的一双眼睛，但不必知道这两只眼睛的精确坐标。池化把"精确坐标"这个信息丢弃，保留了"这一带有没有眼睛"这个更关键的信息。

池化也可以看成参数共享的另一种体现：在一个图像区域有用的特征，极有可能在另一个区域同样适用，因而对不同位置的特征做聚合统计，就是提取主要特征的有效方法。

补充说明：常见说法称池化带来了旋转不变性，理由是"图像怎么旋转，区域内的最大值都不会变"。这个说法并不成立——旋转会改变像素落入哪个池化窗口，区域内的最大值完全可能变化。池化真正提供的是对**小幅平移**的鲁棒性：只要特征还在同一个窗口内移动，输出就不变。至于旋转不变性，需要靠旋转数据增强、可变形卷积或专门的等变网络结构来获得。把这一点分清，才不会在设计网络时对池化寄予过高的期望。

> **新手提示：池化层没有参数**
>
> 池化只做取最大值或取平均，不涉及任何权重，因此不参与梯度更新。反向传播时，最大池化只把梯度回传给当初取到最大值的那一个位置，其余位置梯度为零；平均池化则把梯度均分给窗口内的所有位置。这也是为什么池化层计算便宜、又不容易过拟合——它没有可学的参数。近年不少网络用步长大于 1 的卷积代替池化，目的就是让降采样过程本身也能被学习。

六、全连接层与整体流程

6.1 全连接层

卷积层与池化层循环使用，实现的是对图像特征的逐层提取；根据这些特征得出分类结果，则要交给**全连接层**完成。

全连接层的神经元与前一层的所有激活单元相连，其激活与否可以通过矩阵乘法计算，与常规神经网络别无二致。它通常接在最后一层池化之后，把二维的特征映射拉平成一维向量，再经由 softmax 分类器输出各个类别的概率。

对应的损失函数通常取交叉熵，这一点与 023 中讨论的分类网络一致。

6.2 工作流程

把上述结构串起来，卷积神经网络的工作流程是：

1. 输入层把待处理的图像转化为一个或多个像素矩阵；
2. 卷积层利用一个或多个卷积核从像素矩阵中提取特征；
3. 特征映射经过非线性激活函数处理；
4. 池化层对激活结果执行降维；
5. 卷积与池化交替若干次，逐层提取从边缘到部件、再到整体的特征；
6. 最后的特征送入全连接层，由分类器输出结果。

6.3 训练

卷积神经网络中待训练的参数是卷积核，也就是卷积层中的权重系数矩阵，外加各层的偏置。

训练同样采用反向传播：误差从输出层传回，梯度经由池化层、激活层，最终作用到每个卷积核上。参数的不断更新提升了特征提取的精度——网络会自己发现该用什么样的模板去扫描图像，而不需要人来设计边缘检测算子。

补充说明：卷积的反向传播有一个漂亮的对称性：对输入的梯度，等于把核函数翻转后与上游梯度做卷积；对核函数的梯度，等于把输入与上游梯度做卷积。也就是说，前向是卷积，反向还是卷积，只是参与运算的对象换了一下。这也是卷积网络在 GPU 上高效的原因之一——整个前向与反向过程都可以归约为同一类高度优化的矩阵运算。

七、残差网络

近年来卷积神经网络的一项重要进展是**残差网络**（residual network）的提出。

把深度结构用于卷积网络可以增强表达能力，在图像分类、目标检测等任务上表现优异。但实验发现，当层数超过某个阈值后，训练误差反而会随层数增加而上升——这不是过拟合，因为训练集上的表现也变差了。这种现象被称为网络退化。

残差网络通过**残差结构单元**解决了这个问题。其做法是在层间加一条恒等捷径，让这一层的输出变成：

$$\mathbf{y} = F(\mathbf{x}) + \mathbf{x}$$

网络不再需要直接学习目标映射，只需学习“相对于恒等映射的修正量” F(x)。当某一层其实没什么可学的时候，把 F(x) 压到零即可，最差也能保持恒等变换，不会让性能倒退。

这条捷径同时也为梯度提供了一条直通通道，缓解了深层网络的梯度弥散。凭借这一结构，网络层数得以做到千层以上，成为此后绝大多数视觉骨干网络的基础。

四个常见误区

- **“卷积就是图像滤波”**——传统滤波的核由人设计，网络里的核是学出来的；而且是多通道同时卷积再求和，不是单通道上的固定算子。
- **“池化越多越好”**——池化确实降低了计算量并带来一定平移不变性，但也丢掉了位置信息。现代网络常用步长卷积代替池化，就是为了保留更多空间细节。
- **“CNN 只能做图像”**——一维卷积用于语音与文本，图卷积用于社交网络与分子结构。卷积的本质是“局部连接 + 权值共享”，与数据是不是网格无关。
- **“感受野越大越好”**——感受野可以通过堆叠小卷积核获得，而且大卷积核的参数代价高。三层 3×3 卷积的感受野等于一层 7×7，参数却只有后者的一半左右。

八、要点回顾

1. 卷积神经网络是至少在一层中用卷积运算代替矩阵乘法的神经网络，适用于网格状结构的数据。
2. 卷积以核函数为权重对输入做加权求和，把局部区域与核函数拉直后，计算的就是两者的内积。
3. 内积度量相似度，因此卷积输出的大小反映局部与模板的匹配程度。
4. 稀疏感知指核函数远小于输入，靠综合局部感知来获得全局信息。
5. 参数共享指同一核函数在整幅图上复用，使参数量与图像尺寸无关。
6. 平移等变指输入平移时输出同步平移；平移不变性要靠池化获得，两者不是一回事。
7. 卷积层的输出是特征映射，多个核函数对应多个通道，各自捕捉一类模式。
8. 激活层引入非线性，常用 ReLU 把负响应置零、保留正响应。
9. 池化层做下采样，最大池化取窗口极值，降低数据量并提升对小位移的鲁棒性。
10. 全连接层把特征映射拉平后接 softmax，完成分类输出。
11. 卷积反向传播对输入和核函数的梯度都可以写成卷积形式，便于 GPU 加速。
12. 残差网络用恒等捷径学习残差，解决了深层网络的退化问题。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
卷积神经网络	Convolutional Neural Network	CNN	用卷积运算提取网格数据局部特征的网络
卷积	Convolution	—	以核函数为权重对输入做滑动加权求和
核函数	Kernel Function	—	卷积中参与运算的模板，即待学习的权重
卷积核	Convolutional Kernel	—	卷积层中一个通道对应的权重矩阵
特征映射	Feature Map	—	一个核函数扫描整幅图后得到的响应矩阵
步长	Stride	—	核函数每次滑动的像素距离
填充	Padding	—	在输入边缘补零以控制输出尺寸的操作
感受野	Receptive Field	—	输出中一个单元所对应的输入区域大小
稀疏感知	Sparse Interaction	—	核函数尺寸远小于输入，只做局部连接
参数共享	Parameter Sharing	—	同一组权重在输入的不同位置重复使用
平移等变	Translational Equivalence	—	输入平移时输出做相同平移的性质
激活层	Activation Layer	—	对卷积输出施加非线性变换的层

名称	英文全称	英文缩写	简短介绍
整流线性单元	Rectified Linear Unit	ReLU	把负值置零、正值保留的激活函数
池化层	Pooling Layer	—	对特征映射分区域聚合以降低分辨率
最大池化	Max Pooling	—	取窗口内最大值作为输出的池化方式
平均池化	Average Pooling	—	取窗口内平均值作为输出的池化方式
下采样	Downsampling	—	降低特征映射空间分辨率的过程
全连接层	Fully Connected Layer	FC	每个单元与上一层全部单元相连的层
softmax 分类器	Softmax Classifier	—	把输出归一化为各类别概率的分类层
交叉熵	Cross Entropy	—	衡量预测分布与真实分布差异的损失函数
残差网络	Residual Network	ResNet	用恒等捷径学习残差、可训练极深层的网络
残差结构单元	Residual Block	—	含恒等捷径的基本构件，输出为 F(x)+x
网络退化	Degradation	—	层数增加反而使训练误差上升的现象
互相关	Cross-correlation	—	不翻转核函数的卷积实现，框架中通称卷积