生成式对抗网络：零和博弈、极小极大与训练难题

读前须知

- **前置**：概率分布、KL 散度与交叉熵；反向传播。
- **这一篇的位置**：生成模型的一条激进路线——不显式写出概率密度，而是让两个网络互相对抗。
- **读完能做什么**：写出 GAN 的极小极大目标；解释最优判别器下生成器在优化什么散度；说清模式崩塌与训练不稳定的成因。

一、一场保密通信实验

1.1 实验设置

2016 年 10 月，谷歌大脑的研究者做了一个耐人寻味的实验：用三个并不复杂的神经网络执行保密通信。

其中两个是合法的通信方，共享的只有一把密钥，**没有**事先商定的加解密算法；第三个网络扮演窃听者，全程监听信道。

这个配置颠覆了密码学的常识。无论公钥体制还是私钥体制，加解密算法都是公开的，安全性建立在密钥之上。如果通信双方连算法都无法统一，保密通信根本无从谈起。

1.2 实验说明了什么

实验的结果同样出人意料：经过反复试错与调整，接收方能够精确恢复发送方的明文，而窃听者的错误率稳定在 50% 左右——正好等于随机猜测。

也就是说，两个网络在没有任何先验规则的情况下，自己协商出了一套第三方无法破译的编码方式。

这个实验的意义超出了密码学。它展示了神经网络的一种潜能：不仅能从大量数据中无监督地学到规律，还能在学习过程中根据对手的反应动态调整策略。

实验所处的框架，正是 2014 年由伊安·古德菲洛提出的**生成式对抗网络**（generative adversarial network）。

二、零和博弈中的两个玩家

2.1 生成器与判别器

生成式对抗网络是一类在无监督学习中使用的人工智能算法，由两个在零和游戏框架下相互竞争的神经网络构成。

两个玩家各有分工：

生成器（generator）的任务是从随机噪声中模拟真实数据的潜在分布，生成以假乱真的样本。它像一个仿造者，手里没有任何真品，只能凭反馈不断调整工艺。

判别器（discriminator）的任务是判断输入样本到底来自真实数据，还是出自生成器之手。它像一位鉴定师，见过的真品越多，眼力越准。

两者都可以用深度神经网络实现。对抗就是训练的主旋律：仿造者越做越像，鉴定师越看越精，双方在竞争中共同进化，直到真假难辨为止。

2.2 零和博弈

“零和游戏”（zero-sum game）这个术语来自博弈论，指博弈双方的利益之和为零。

一方所得必为另一方所失，因此双方不可能合作，属于典型的非合作博弈。生成器希望判别器犯错，判别器希望自己不出错，两者的目标恰好相反——这正是对抗训练的动力来源。

补充说明：并非所有博弈都是零和的。合作博弈中双方可以共赢，非零和博弈中也可能出现双输。生成式对抗网络之所以选择零和框架，是因为它把“判断真假”简化成了一个二分类问题：判别器的准确率每提高一分，生成器的“被骗率”就下降一分，两者严格互补。这种设计的好处是目标清晰，坏处是训练容易失衡——一方过强，另一方的梯度就会消失。

三、目标函数

3.1 极小极大形式

两个玩家对抗的目的，是建立数据的生成模型，使生成器尽可能精确地估计出数据样本的分布。

从学习方式看，对抗性学习属于无监督学习；但对抗的引入使生成器能够利用来自判别器的反馈，因而又带上了某些监督学习的影子。

把这场博弈写成数学形式，就是一个**极小极大**问题：

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}\left[\ln D(x)\right] + \mathbb{E}_{z\sim p_z}\left[\ln\left(1 - D(G(z))\right)\right]$$

其中 G 是生成器，D 是判别器，p_data 是真实数据分布，p_z 是噪声分布。

逐项拆开看：第一项要求判别器给真实样本打高分，第二项要求它给生成样本打低分。max 表示判别器要最大化这两项之和，也就是把真假分得越开越好；min 表示生成器要最小化它，也就是让判别器分不开。

3.2 判别器的最优解

训练通常交替进行，先从判别器开始：固定生成器，求解最优的判别器。

由于判别器是一个基于对数几率函数的二分类器，使用交叉熵作为损失是自然的选择。对来自真实分布的真样本标注为 1，对来自生成器的假样本标注为 0，训练目标就是让这两类样本的输出尽量分别靠近 1 和 0。

在这个设定下，可以逐点地对目标函数求极值。对任意样本 x，令 y = D(x)，则被积的部分是：

$$p_{\text{data}}(x)\ln y + p_g(x)\ln(1-y)$$

对 y 求导并令其为零，得到：

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$$

这个结果很有信息量：最优判别器的输出，恰好是“这个样本来自真实数据的概率”。当 p_g 与 p_data 完全相同时，D*(x) 处处等于 0.5——判别器只能瞎猜。

3.3 全局最优

把最优判别器代回目标函数，可以得到生成器真正面对的优化目标：

$$V(G) = -\ln 4 + 2\cdot \text{JSD}\left(p_{\text{data}} \,\|\, p_g\right)$$

其中 JSD 是 JS 散度，衡量两个分布的差异，取值非负，且仅当两分布相同时为零。

于是结论一目了然：**当且仅当 p_g = p_data 时，目标函数取得全局最优。**此时生成器学到的分布与真实分布完全一致，判别器对每个样本的输出都是 0.5，再也分不出真假。

这也说明，生成式对抗网络本质上是在最小化真实分布与生成分布之间的 JS 散度——只是这个散度不是直接算出来的，而是通过判别器"隐式"估计的。

> **新手提示：为什么用 JS 散度而不是 KL 散度**
>
> KL 散度不对称，且当两个分布的支撑集不重叠时会发散到无穷。训练初期，生成器造出的样本与真实数据往往几乎不重合，此时 KL 散度没有意义，梯度也无从谈起。JS 散度做了对称化，并且有界（最大为 ln 2），在支撑集不重叠时仍然给出一个有限的数值。这个设计让训练在初期不至于立刻失效。代价是当两分布完全分离时，JS 散度会饱和成一个常数，梯度仍然趋于零——这后来成为 Wasserstein 距离被引入的动机。

四、训练流程

4.1 交替迭代

对整体极小极大问题，实践中通过**交替迭代**求解。

每一轮通常先更新若干次判别器的参数，再对生成器的参数执行一次更新。顺序不能随意颠倒：判别器必须先具备一定的鉴别能力，它给生成器的梯度才有方向；判别器太弱，生成器就学不到东西。

判别器更新时，生成器固定，梯度只回传到判别器；生成器更新时，判别器固定，但误差要穿过判别器传回生成器——这一步要求判别器本身是可微的，这也是为什么判别器通常用神经网络而不是别的分类器。

4.2 一个实践细节

更新生成器时，目标函数里的第二项在训练初期会饱和：生成器造的样本太假，判别器一眼看穿，D(G(z)) 接近 0，ln(1−D(G(z))) 的梯度几乎为零。

工程上的常见做法是把生成器的目标从"最小化 ln(1−D(G(z)))"改成"最大化 ln D(G(z))"。两者在理论上最优解相同，但后者在训练初期梯度更大，收敛更快。这种改写在文献中被称为**非饱和博弈**（non-saturating game）。

补充说明：交替训练并不能保证收敛到纳什均衡。理论上，只有当双方都采用最优策略、且任何一方单方面改变策略都不会获益时，才处于纳什均衡。实际训练中，判别器和生成器轮流优化，更像是在一个非凸的高维曲面上相互追逐，可能出现震荡、循环甚至发散。后来的改进大多围绕这一点：WGAN 用 Earth Mover 距离替换 JS 散度，谱归一化约束判别器的 Lipschitz 常数，都是为了让这场追逐变得平滑一些。

五、与传统生成模型的区别

5.1 摆脱对分布假设的依赖

既然都是学习数据分布，生成式对抗网络与其他生成模型有什么不同？

传统生成模型通常先**定义**一个分布族，再去求解参数。比如假定数据服从正态分布，就用最大似然估计从样本中算出均值和方差。

这个套路在人脸这类复杂数据上就行不通了：没有人知道人脸服从什么先验分布，硬套一个分布族，模型再准也画不出真实的人脸。

生成式对抗网络的好处在于摆脱了对模型分布的依赖，也不限制生成的维度。它不假设数据服从某种解析形式，而是让生成器直接把噪声映射成样本，由判别器来评判像不像。这大大拓宽了可生成数据的范围。

5.2 判别器就是损失函数

生成式对抗网络还有一个特别之处：它没有**显式**的损失函数。

之所以这么说，是因为训练的目标是生成器，判别器只是训练过程中的副产品。对生成器而言，判别器被用来度量生成分布与真实分布之间的偏差——所以判别器本身就是它的损失函数。

而作为损失函数的判别器，又会随着真实分布的变化而变化。从这个角度看，生成式对抗网络可以**自动学习损失函数**，这是传统生成模型做不到的。

这一点常被概括为“用网络学网络”。传统方法的损失是人为指定的（均方误差、交叉熵），而这里的损失是另一个网络现场学出来的，因而更贴合数据的实际结构。

六、局限

6.1 理论基础的缺失

最主要的问题是缺乏理论支撑。

回到开头的保密通信实验：我们只知道通信双方达成了关于算法的共识，但这个共识是如何达成的，仍然是个黑箱。生成器为什么能从随机样本出发学到真实的数据分布，同样缺乏清晰的理论解释。

没有坚实的理论，对算法的推广自然存在困难。在图像生成等少数领域表现突出，在大多数任务上仍乏善可陈。

6.2 训练的不稳定

另一个主要问题是训练难度。

对抗网络的训练目标，是在连续分布的高维参数下达到纳什均衡，也就是让双方的损失同时取到最小。但待优化的问题往往是非凸的，直接追求纳什均衡可能让算法难以收敛，从而引发欠拟合，导致表示能力不足。

古德菲洛本人针对训练难的问题提出过一系列改进措施，并应用在半监督学习上取得了不错的效果，但这些措施大多是经验性的。

6.3 模式崩溃

训练不稳定的一个典型表现是**模式崩溃**（mode collapse）：生成器发现某几个样本特别容易骗过判别器，于是反复只生成这几类，放弃了对整个分布的覆盖。

从目标函数看，这并不奇怪：只要判别器分不出真假，生成器就“完成任务”了，它没有义务覆盖所有模式。判别器如果对某些区域过于宽松，生成器就会挤向那里。

应对手段包括小批量判别、加入多样性正则项、使用多个生成器，以及在损失中显式引入覆盖度的度量。

6.4 变体的泛滥

自 2014 年诞生以来，各种各样的对抗网络变体层出不穷，有名有姓的超过两百种，给它们命名几乎让拉丁字母都不够用。

可这些改进究竟有多少效果？谷歌的一项研究表明：没有证据表明哪种变体带来了实质性的改进。

问题仍然出在理论基础上。没有理论就没有明确的改进方向，只能从应用问题出发盲目摸索优化技巧。运气好的话，通过调整架构或损失函数能在特定任务上获得提升，但提升的适用范围往往很窄，换个场合就不好用了。

这其实不只是生成式对抗网络的问题，而是整个深度学习"炼金术"处境的缩影。

> **新手提示：判别器不是越强越好**
>
> 直觉上会觉得判别器越准越好，实际恰恰相反。若判别器过强，真假样本被完全分开，生成器的梯度就会饱和到零，训练随即停滞。所以实践中常要控制判别器的能力：减少它的更新次数、加噪声、做标签平滑（把真样本的标签从 1 改成 0.9），都是有意削弱它的手段。这与监督学习里"模型越强越好"的直觉相反，根源在于这里是博弈而非单方优化。

七、一次突破

虽然优缺点都很明显，生成式对抗网络的提出依然可以看作深度学习的一次突破。

给定一张猫的图片，过往的神经网络只能判断它是不是猫，还不一定判得准；生成式网络却能模仿现有图片，自己画出另一只类似的猫。不管这是简单的数据拟合，还是更高级的特征重组，它都是机器自己完成的再创作，这种行为方式无疑更接近人类。

它同时也打开了一条新路：不再由人设计损失函数，而是让模型自己去构造评判标准。今天在图像生成、风格迁移、数据增强、超分辨率等方向上，对抗训练已经成为常用工具，其思想还在扩散到其他领域。

四个常见误区

- **"生成器真的在最小化 JS 散度"**——这一结论只在判别器达到最优时成立。实际训练中判别器远未最优，生成器优化的目标一直在漂移。
- **"判别器越强越好"**——判别器过强时，生成器的梯度会趋近于零，学习停滞；两者需要保持在势均力敌的状态。
- **"训练不稳定是代码写错了"**——这是极小极大的博弈结构决定的，与实现无关。WGAN、谱归一化等手段都是在改造这个结构。
- **"GAN 只能生成图片"**——文本、语音、音乐、分子结构、表格数据都能生成，只要能把生成结果交给判别器打分。

八、要点回顾

1. 生成式对抗网络由生成器和判别器两个网络构成，在零和博弈框架下相互对抗。
2. 生成器把随机噪声映射为样本，判别器判断样本来自真实数据还是生成器。
3. 零和博弈指双方利益之和为零，一方所得即另一方所失。
4. 目标函数是极小极大形式：判别器最大化真假区分度，生成器最小化它。
5. 固定生成器时，最优判别器等于样本来自真实数据的后验概率。
6. 把最优判别器代回，生成器的目标等价于最小化两分布之间的 JS 散度。
7. 全局最优在 p_g = p_data 时取得，此时判别器对任何样本都输出 0.5。

8. 训练采用交替迭代，先多次更新判别器，再更新一次生成器。
9. 生成器常用非饱和目标“最大化 ln D(G(z))”，以避开训练初期的梯度饱和。
10. 相比传统生成模型，它不预设分布族，并且用判别器充当可学习的损失函数。
11. 主要问题是理论缺失、训练不稳定与模式崩溃，多数变体缺乏实质改进。
12. 它的意义在于让机器自己构造评判标准，并从判别走向生成。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
生成式对抗网络	Generative Adversarial Network	GAN	由生成器与判别器对抗训练而成的生成模型
生成器	Generator	G	把随机噪声映射为伪造样本的网络
判别器	Discriminator	D	区分真实样本与生成样本的网络
零和博弈	Zero-sum Game	—	双方收益之和恒为零的非合作博弈
极小极大问题	Minimax Problem	—	一方求最大、另一方求最小的对抗优化形式
纳什均衡	Nash Equilibrium	—	任何一方单方面改变策略都不获益的状态
真实数据分布	Data Distribution	p_data	训练样本所服从的未知概率分布
生成分布	Generated Distribution	p_g	生成器所产生样本的概率分布
噪声分布	Noise Distribution	p_z	生成器输入端随机变量的分布
最优判别器	Optimal Discriminator	D*	固定生成器时使目标最大的判别器
JS 散度	Jensen-Shannon Divergence	JSD	对称化且有界的分布差异度量
KL 散度	Kullback-Leibler Divergence	KL	衡量两个分布差异的非对称指标
交替迭代	Alternating Optimization	—	轮流固定一方、优化另一方的训练方式
非饱和博弈	Non-saturating Game	—	用最大化 ln D(G(z)) 代替最小化 ln(1−D) 的改写
模式崩溃	Mode Collapse	—	生成器只覆盖少数模式、输出缺乏多样性的现象
纳什均衡收敛	Nash Convergence	—	双方策略同时达到最优的收敛状态

名称	英文全称	英文缩写	简短介绍
Wasserstein 距离	Wasserstein Distance	—	衡量分布差异的最优传输代价，WGAN 的基础
标签平滑	Label Smoothing	—	把硬标签改为接近值以削弱判别器的手段
半监督学习	Semi-supervised Learning	—	同时利用少量标注与大量未标注数据的学习方式
数据增强	Data Augmentation	—	通过变换扩充训练样本、提升泛化的手段