长短期记忆网络：门控机制、记忆单元与梯度弥散

读前须知

- **前置**：循环神经网络与 BPTT；知道梯度消失是怎么回事。
- **这一篇的位置**：RNN 的“工程修复版”。它用门控把“记住多久”变成一个可学习的决策。
- **读完能做什么**：写出遗忘门、输入门、输出门的计算式；解释细胞状态为什么被称为“传送带”；说清 LSTM 缓解梯度消失的机制与它的剩余局限。

一、名字与由来

1.1 断句

长短期记忆网络（long short-term memory）是一类特殊的循环神经网络。

这个词的断句方式是“长—短期记忆网络”，表达的含义是：一类可以把短期记忆持续很长时间的模型。它不是“长期记忆”与“短期记忆”的并列，而是“长—短期”，重点在“长”字上。

这种模型的一大优势是对时隙长度不敏感——两个相关信息之间隔了多久，并不需要事先知道，因而它适用于序列中信息时滞不确定的场合。

1.2 记忆的深度问题

循环神经网络通过在时间上共享参数引入了记忆，从而能把先前的信息用到当前任务上。可这种记忆通常只有有限的深度。

有过追剧经历的人都有体会：国外电视剧每周更新一集，即使隔了一周，也能把上一集的内容和新一集无缝接上。循环网络的记忆却没有这么强的延续性——别说一周的断片，插播一段五分钟的广告，就足以让它记忆脱节，造成理解上的混乱。

真实世界的信息不是静止的，而是不断流转与跃变。如果网络保存不住长期记忆，处理信息的能力就会大打折扣。长短期记忆网络要解决的正是这个问题：实现任意长度的记忆，并且让“记住长期信息”成为默认行为，而不是需要付出很大代价才能获得的能力。

补充说明：这里的“记忆”要区别于硬盘上的存储。循环网络的记忆体现在隐藏状态这个向量里，它没有明确的读写地址，而是随输入连续变化。所谓“记住”，指的是某个时刻的信息在若干步之后仍然对隐藏状态有可测量的影响；所谓“忘记”，指的是这种影响衰减到噪声水平。理解了这一点，才能理解为什么“控制信息的保留与丢弃”会成为网络设计的核心。

二、记忆与遗忘

2.1 存储要精打细算

要实现长期记忆，网络既要学会记忆，也要学会遗忘。

长期记忆的基础是足够的存储，但宝贵的存储不能被滥用。它不是收集桶，不能有用的没用的都一股脑儿往里扔。长期记忆要求模型具备对信息价值的判断能力：结合自身的状态确定哪些信息应当保留，哪些应当舍弃。

比如电视剧里的一段支线情节结束了，模型就应当重置相关的信息，只保留对应的结果；否则陈旧的细节会不断累积，挤占真正重要的内容。

2.2 遗忘是一种能力

同理，收到新的输入时，模型也要判断这些信息是否有用、是否需要保存。

遗忘不是缺陷，而是能力。一个只能记住、不能忘记的系统，很快就会被无关信息填满，对新输入失去响应。这一点在 030 讨论循环网络的梯度问题时已经埋下伏笔——那里是“记不住”，这里是“不会忘”，两者是同一个问题的两面。

2.3 从长期记忆到工作记忆

除了添加遗忘机制，长短期记忆单元还要能把长期记忆聚焦成**工作记忆**——也就是哪一部分记忆此刻需要立刻使用。

有用的信息不会每时每刻都有用。记忆单元并不总是调用全部长期记忆，而是根据当前的相关性做出取舍，这类似于人类注意力的运作方式。

遗忘与选择，使长短期记忆网络能对记忆做更细粒度的处理。它不同于循环网络一视同仁的方式，因而可以对信息进行长期而精确的跟踪。

> **新手提示：门不是开关**
>
> 初学时常把“门”想象成电路里的通断开关。实际上三个门输出的都是 0 到 1 之间的连续值，相当于一个可微的旋钮，而不是二值的闸刀。之所以必须连续，是因为训练要靠梯度：如果门只有开与关两种状态，梯度处处为零，参数就没法更新了。正是这种“软”门控，让长短期记忆网络可以端到端地训练。

三、单元结构

3.1 四个部件

长短期记忆网络由相应的基本单元构成。一个基本单元通常包含四个功能不同的部分：

- **记忆模块**（memory cell）：存储数值或状态，存储时限既可以是长期也可以是短期；
- **输入门**（input gate）：决定哪些新信息被写入记忆模块；
- **遗忘门**（forget gate）：决定哪些信息被从记忆模块中丢弃；
- **输出门**（output gate）：决定记忆模块中的哪些信息被用于计算整个单元的输出。

相比只有一个激活函数的一般循环神经元，这套结构要复杂得多。

值得一提的是，长短期记忆网络的最初版本只有输入门和输出门，遗忘门是后来作为一项改进添加的——而恰恰是这个后加的部件，成了它能够保存长期信息的关键。

3.2 三个门的作用

三个门都使用对数几率函数作为传递函数，因此输出落在 (0, 1) 区间，正好可以解释为“放行比例”。

它们的职责可以概括为一句话：**遗忘门管弃旧，输入门管图新，输出门管取用。**

这里的“门”作用在记忆模块的状态上，而不是作用在输入本身。这是它与普通循环神经元最本质的区别：普通神经元每一步都把旧状态整体替换掉，而长短期记忆单元只是在旧状态上做增删。

四、工作流程

下面的推导中，x_t 表示时刻 t 的输入，h*{t−1} 表示上一时刻的输出*，*C*{t−1} 表示上一时刻的记忆状态，⊙ 表示逐元素相乘。

4.1 遗忘门

记忆模块要根据时刻 t 的输入来更新现有的记忆，这个过程首先由遗忘门完成。

如果网络处理的是这样一句话："李雷 XXX，韩梅梅 XXX"，那么当"韩梅梅"出现时，遗忘门就能察觉到主语的变化，从而降低"李雷"在记忆单元中的权重。

当然，记忆的更新不一定意味着完全替换——把新输入的部分信息与原有存储的部分信息加以整合，也是可以的。这正是门控值为中间值时的含义。

遗忘门的输入包括上一时刻的输出 h_{t−1} 和当前时刻的输入 x_t，两者的加权组合送入对数几率函数：

$$\mathbf{f}_t = \sigma\left(\mathbf{W}_f \mathbf{x}_t + \mathbf{U}_f \mathbf{h}_{t-1} + \mathbf{b}_f\right)$$

若遗忘门的输出为 0，意味着记忆单元的当前存储被全部舍弃；输出为 1 则意味着全部保留。

4.2 输入门

决定哪些来自输入的信息进入记忆模块，由输入门负责。

输入门的工作机制与遗忘门类似，但多了一层：它先用对数几率函数对当前输入与上一时刻输出的组合做过滤，确定哪些信息被保留、以何种比例被添加；同时还要用一个双曲正切函数生成候选记忆，也就是"准备写入的内容"。

$$\mathbf{i}_t = \sigma\left(\mathbf{W}_i \mathbf{x}_t + \mathbf{U}_i \mathbf{h}_{t-1} + \mathbf{b}_i\right)$$

$$\tilde{\mathbf{C}}_t = \tanh\left(\mathbf{W}_c \mathbf{x}_t + \mathbf{U}_c \mathbf{h}_{t-1} + \mathbf{b}_c\right)$$

这里用 tanh 而不是 sigmoid，是因为候选记忆需要能取负值——它表示的是一个增量，可正可负；而门控值只表示比例，必须落在 0 到 1 之间。

4.3 状态更新

遗忘门和输入门的工作完成后，记忆模块的状态就是"万事俱备，只欠更新"。

更新操作是舍弃旧信息与添加新信息的组合：

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t$$

这个式子是整个长短期记忆网络的心脏，值得逐项拆解：f_t ⊙ C*{t−1} 是"按遗忘门的比例保留旧记忆"，i_t ⊙ C̃*t 是"按输入门的比例写入新记忆"，两者相加得到新的记忆状态。

补充说明：符号 ⊙ 表示**逐元素相乘**（Hadamard 积），不是外积。这一点常被写错。逐元素相乘要求两个向量维度相同，结果是同维向量；外积则会把两个向量变成矩阵，维度对不上，式子根本无法成立。区分方法很简单：看等号两边的形状——C_t 与 C_{t−1} 同为记忆向量，运算必然是逐元素的。

4.4 输出门

记忆状态更新之后，就要从中选择有用的信息输出，这部分工作由输出门完成。

由于主语已经从"李雷"变成了"韩梅梅"，那么谓语出现"化妆"的可能性就远大于出现"打球"的可能性。输出门同样用对数几率函数对当前输入与上一时刻输出的组合做过滤，生成一组权重：

$$\mathbf{o}_t = \sigma\left(\mathbf{W}_o \mathbf{x}_t + \mathbf{U}_o \mathbf{h}_{t-1} + \mathbf{b}_o\right)$$

需要注意的是加权对象：不是记忆状态本身，而是记忆状态的**双曲正切值**。因此单元在时刻 t 的输出为：

$$\mathbf{h}_t = \tanh\left(\mathbf{C}_t\right) \odot \mathbf{o}_t$$

先用 tanh 把记忆状态压到 (−1, 1)，再按输出门的比例取用，可以防止记忆值无限增长。这个输出又会作为下一时刻的输入之一出现，循环由此继续。

五、门镜连接

基本结构之外，一种常见的改进是加入**门镜连接**（peephole connection）。

设计的出发点是：语义信息的载体不仅包括具体的文字，也包括文字之间的时序。即使在通信高度发达的今天，某些民族依然保留着用有节奏的鼓声传递消息的传统——事件之间的时间差，也就是通常所说的"节奏"，本身就可以作为一种模式被识别。

门镜连接的作用，是让三个门都能直接接收来自记忆模块的输入。也就是说，每个门都能观察到模块当前的状态，并把状态信息纳入自己的判断：

$$\mathbf{f}_t = \sigma\left(\mathbf{W}_f \mathbf{x}_t + \mathbf{U}_f \mathbf{h}_{t-1} + \mathbf{v}_f \odot \mathbf{C}_{t-1} + \mathbf{b}_f\right)$$

其余两个门同理，各自多出一个与记忆状态逐元素相乘的参数向量。

这一改进的作用是提升网络对时间的识别精度——门不再只根据输入和上一时刻的输出来决策，还能看到"记忆里现在装着什么"。

> **新手提示：门镜连接是可选项**
>
> 门镜连接并非长短期记忆网络的必需部件。多数框架的默认实现并不包含它，需要时得手动开启或自行实现。它的收益依赖任务：在需要精确计时的任务（如动作分割、节拍识别）上提升明显，在一般文本任务上差别不大。看到论文里说"带 peephole 的 LSTM"时，指的就是这一变体，不必把它当作标准配置。

六、为什么能解决梯度弥散

6.1 连乘之害

先回到 030 留下的问题：循环网络的梯度为什么要沿时间连乘，又为什么会衰减。

根据链式法则，循环网络的层次和时间之间是通过连续的乘法关联起来的。用复利来类比：一个赌徒每轮只损失 1% 的赌本，看起来不多，可几十轮下来，一座金山也会输个精光。梯度也是如此——每经过一个时间步就乘上一个小于 1 的因子，几百步之后，数值小到无法用于网络学习。

这就是**梯度弥散**（gradient vanishing）。它导致网络只能记住最近若干步的信息，长距离依赖学不到。

6.2 加法通道

长短期记忆网络的应对方式，是在记忆状态的更新路径上把乘法换成加法。

观察状态更新式 C_t = f_t ⊙ C*{t−1}* + *i_t* ⊙ C̃t：从 C_{t−1} 到 C_t 的梯度，主路径上只需要乘上遗忘门 f_t 这一个因子：

$$\frac{\partial \mathbf{C}_t}{\partial \mathbf{C}_{t-1}} = \operatorname{diag}\left(\mathbf{f}_t\right)$$

如果遗忘门长期取接近 1 的值，这个因子就接近 1，梯度可以沿时间轴一路传回去而不衰减。也就是说，网络学会了一件很聪明的事：**当它判断某条信息重要时，就把遗忘门开到底，让这条通路变成一条几乎无阻的加法直道。**

这一结构后来被称为**常量误差传送带**（constant error carousel）。它并不是说梯度永远不会消失，而是说梯度不再被强制按指数衰减——是否保留、保留多久，交由网络自己学。

6.3 代价

门控并非没有代价。

参数量增加了约四倍：普通循环神经元只有一套输入权重和一套状态权重，而长短期记忆单元有四个门，各自需要一套。计算量随之上升，训练也更慢。

此外，门控机制缓解了梯度弥散，却没有根治梯度爆炸。沿加法通道回传的梯度若在某些路径上被反复放大，仍可能溢出，实践中仍需梯度裁剪兜底。

补充说明：后来出现的门控循环单元（gated recurrent unit）把输入门与遗忘门合并成一个更新门，并合并了记忆状态与隐藏状态，参数量比长短期记忆网络少约四分之一，在多数任务上表现相当。二者的取舍很像工程中的常见权衡：结构更简单，训练更快，但可解释性和精细控制稍弱。选型时不必迷信某一种，先看数据规模和任务对长依赖的敏感程度。

七、应用

目前长短期记忆网络最著名的应用，大概要数机器翻译。

2016 年谷歌发表的论文中提到，其神经机器翻译系统由带 8 个编码器和 8 个解码器的深度长短期记忆网络组成，还额外使用了注意力机制和残差连接。相比此前基于短语的统计翻译系统，新系统的翻译误差平均降低了 60%，提升相当明显。

除此之外，语音识别、文本生成、手写识别、时序预测等任务中，长短期记忆网络都曾是主力结构。它的价值不仅在于做阅读理解这类具体任务，更在于让机器理解事物之间的**长序联系**——一段话的主语可能出现在开头，而结论在结尾，中间的推理链条要靠记忆串起来。

四个常见误区

- **“门控就是一个记忆开关”**——三个门都由当前输入与上一时刻隐状态共同决定，是连续取值的软门，而不是非开即关的硬开关。
- **“LSTM 彻底解决了梯度消失”**——细胞状态的加性更新缓解了连乘衰减，但门本身仍含 Sigmoid，序列极长时梯度依旧会衰减。
- **“LSTM 参数量与普通 RNN 差不多”**——每个门都有独立权重，参数量约为普通 RNN 的四倍，训练与推理成本也相应上升。
- **“所有序列任务都该用 LSTM”**——在长序列与大规模数据上，基于注意力的结构并行性更好、长程依赖建模更强，已成为多数场景的首选。

八、要点回顾

1. 长短期记忆网络是一类特殊的循环神经网络，断句为“长—短期记忆”，指短期记忆可延续很久。
2. 它对时隙长度不敏感，适用于相关信息之间时滞不确定的序列。
3. 循环网络的记忆深度有限，容易被中断，长短期记忆网络要实现任意长度的记忆。
4. 长期记忆既要求会记，也要求会忘，存储必须按信息价值分配。
5. 工作记忆指从长期记忆中聚焦出当前需要用到的部分，类似注意力机制。
6. 基本单元由记忆模块、输入门、遗忘门、输出门四部分组成，三个门均用对数几率函数。
7. 遗忘门决定旧记忆保留多少，输入门决定新信息写入多少，输出门决定对外输出多少。
8. 状态更新为 C_t = f_t ⊙ *C{t−1}* + *i_t* ⊙ C̃t，其中 ⊙ 是逐元素相乘。
9. 输出为 h_t = tanh(C_t) ⊙ o_t，先用 tanh 压缩再按门控比例取用。
10. 门镜连接让三个门直接观察记忆状态，可提升对时序节奏的识别精度。

11. 梯度弥散源于沿时间连乘，长短期记忆网络用加法通道把连乘因子化为遗忘门一项。
12. 门控的代价是参数量与计算量增加，且梯度爆炸仍需梯度裁剪处理。

九、名词汇总

名称	英文全称	英文缩写	简短介绍
长短期记忆网络	Long Short-term Memory	LSTM	用门控控制记忆读写、可捕捉长依赖的循环网络
记忆模块	Memory Cell	—	存储并传递状态向量的核心部件
输入门	Input Gate	—	控制新信息写入记忆模块的比例
遗忘门	Forget Gate	—	控制旧记忆被保留或丢弃的比例
输出门	Output Gate	—	控制记忆状态对外输出的比例
候选记忆	Candidate Memory	—	由当前输入与上一输出生成、等待写入的内容
门控	Gating	—	用 0 到 1 的连续系数调节信息通过比例
对数几率函数	Logistic Function	—	把实数压到 (0,1) 的 S 型函数，常用作门控
双曲正切	Hyperbolic Tangent	tanh	把实数压到 (−1,1) 的激活函数
逐元素相乘	Hadamard Product	⊙	两个同维向量对应位置相乘的运算
门镜连接	Peephole Connection	—	让门直接接收记忆状态输入的改进结构
常量误差传送带	Constant Error Carousel	CEC	记忆状态上的加法通路，使梯度不按指数衰减
梯度弥散	Gradient Vanishing	—	反向传播中梯度沿时间连乘衰减至近零的现象
梯度爆炸	Gradient Explosion	—	梯度沿时间连乘后急速增大导致训练发散
梯度裁剪	Gradient Clipping	—	梯度范数超阈值时按比例缩小以防爆炸
门控循环单元	Gated Recurrent Unit	GRU	合并门控、参数更少的循环网络变体
神经机器翻译	Neural Machine Translation	NMT	用端到端神经网络完成翻译的任务范式
编码器	Encoder	—	把源序列压缩为表示向量的网络部分

名称	英文全称	英文缩写	简短介绍
解码器	Decoder	—	从表示向量逐步生成目标序列的网络部分
注意力机制	Attention Mechanism	—	按相关性动态加权聚合信息的方法
残差连接	Residual Connection	—	把输入直接加到输出上以畅通梯度的结构