概率图模型：贝叶斯网络、马尔可夫随机场与条件独立性

读前须知

- **前置**：条件概率、链式法则与贝叶斯公式；能看懂简单的有向图。
- **这一篇的位置**：深度学习之外的另一条概率建模路线。它不把一切塞进黑箱，而是把变量之间的关系画出来。
- **读完能做什么**：把一个联合分布按图结构分解成多个小因子；用顺连、分连、汇连三种结构判断条件独立；解释马尔可夫随机场的势函数与配分函数各自管什么。

一、从逻辑学到概率论

1.1 理想世界与现实世界

早年间的人工智能以逻辑学为地基。谓词逻辑、产生式系统、归结推理，构成了符号主义的整套工具箱。

逻辑学适用的，是一个理想化的世界：命题非真即假，规则不含例外，推理链条上不出现任何不确定性。可真实世界并不是这样运作的——它由随机性与误差主宰。传感器有噪声，观测有遗漏，规则有反例。

在这光怪陆离的环境中，纯粹的数理逻辑就像一个古板的老夫子，与周遭格格不入。

1.2 一个没有唯一解的问题

即使抛开噪声与干扰不论，很多问题本身就没有固定的解。

医学上有一个典型例子：子女的基因一半来自母亲、一半来自父亲，如果子女与母亲的基因型已经确定，父亲的基因仍有多种可能的组合。信息不足，答案就不唯一。

这类问题无法用“真”或“假”来回答，只能用“哪种可能性的概率更大”来刻画。要处理这种不确定性推理，就必须借助概率论。

1.3 图论的加入

单靠概率论还不够。一个真实问题往往涉及几十上百个随机变量，把它们的联合分布完整写出来，参数数量会随变量数指数增长，既存不下也算不动。

于是研究者引入图论：用图的顶点表示随机变量，用边表示变量之间的依赖关系。**概率论负责刻画不确定性，图论负责刻画结构**，两者结合，得到的就是**概率图模型**（probabilistic graphical model）。

它还有一个名字，叫**结构化概率模型**（structured probabilistic model）——强调的正是“用结构来压缩概率分布”这一层含义。

按边的性质，概率图模型分为两大类：边有方向的叫**贝叶斯网络**（Bayesian network），边无方向的叫**马尔可夫随机场**（Markov random field）。

二、贝叶斯网络

2.1 有向无环图

贝叶斯网络的拓扑结构是一张**有向无环图**（directed acyclic graph，DAG）。

“有向”指连接不同顶点的边带方向，起点和终点不能调换；“无环”指从任意顶点出发，沿箭头走若干步都无法回到出发点，图中找不到任何环路。

这两条约束合起来，保证了图上的变量可以排出一个拓扑序：所有边都从序靠前的顶点指向序靠后的顶点。

2.2 顶点与边的含义

网络中的每个顶点表示一个随机变量。这个变量既可以是可观测的显式变量，比如“是否下雨”，也可以是未知的参数或隐变量，比如“患者的真实病因”。

若两个变量之间存在因果关系，对应的顶点就用带箭头的边连接，箭头由表示原因的变量指向表示结果的变量。边的“权重”不是数值，而是一张**条件概率表**（conditional probability table，CPT），记录父节点取各种组合时子节点取各值的概率。

2.3 联合分布的分解

贝叶斯网络最核心的作用，是把多个随机变量的联合概率分布分解成若干条件概率因子的乘积。

按条件概率的链式法则，五个随机变量的联合概率可以无条件地写成：

$$p(a,b,c,d,e) = p(a)\,p(b \mid a)\,p(c \mid a,b)\,p(d \mid a,b,c)\,p(e \mid a,b,c,d)$$

这个式子是恒成立的，但没有任何实用价值——最后一项要求知道四个变量的全部组合。

如果这五个变量之间存在 A→B、A→C、B→C、B→D、C→E 这样的依赖结构，那么每个变量只需要以它的父节点为条件：

$$p(a,b,c,d,e) = p(a)\,p(b \mid a)\,p(c \mid a,b)\,p(d \mid b)\,p(e \mid c)$$

对比两式可以看出变化：p(d | a,b,c) 化简成了 p(d | b)，p(e | a,b,c,d) 化简成了 p(e | c)。依据就是图上的结构——D 只从 B 接收箭头，所以在给定 B 之后，A 和 C 的信息对 D 不再有额外影响。

2.4 与朴素贝叶斯的关系

这个分解式让人想起朴素贝叶斯分类。

朴素贝叶斯的基础假设是：在类别给定的条件下，各属性之间相互独立。用图来表示，就是类别节点指向所有属性节点，属性节点之间一条边也没有。此时后验概率正比于先验与各条件概率的乘积：

$$p(c \mid x_1,\ldots,x_n) \propto p(c)\prod_{i=1}^{n} p(x_i \mid c)$$

但在绝大多数真实任务中，这个假设并不成立——文档里的两个词往往同时出现，图片里的两个像素彼此相关。把这些依赖关系纳入图中，得到的就是通用的贝叶斯网络。从这个角度看，**朴素贝叶斯只是贝叶斯网络的一个极端特例**：结构固定，参数最少，代价是假设过强。

三、条件独立性

3.1 定义

贝叶斯网络引出的一个重要概念是**条件独立性**（conditional independence）。

如果事件 a 和 b 在事件 c 发生时条件独立，就意味着在 c 发生的条件下，a 发生与否与 b 发生与否互不相关，两者的联合条件概率等于各自条件概率的乘积：

$$p(a, b \mid c) = p(a \mid c)\, p(b \mid c)$$

一个直观的例子：天降大雪，一对夫妻各自从单位回家，两人到家的时间都会因为下雪而推迟，但各自耽搁多久在“下雪”这个条件下是独立的。可如果丈夫要去接妻子一起回家，这条路径就把两人的时间耦合起来了，条件独立性随之失效。

3.2 三种连接结构

条件独立性是概率论视角下的概念。从图论的角度看，变量之间的依赖与独立，对应着顶点之间的连通与分隔。

直观地说，两个直接相连的变量一定不独立；两个不直接相连的变量之间，信息必须经过其他顶点中转，只要所有中转通道都被堵死，两者就条件独立。

假设两个变量 X 和 Y 通过第三个变量 Z 相连，连接方式只有三种，箭头方向决定了条件独立成立与否：

- **顺连**：X → Z → Y。Z 已知时 X 与 Y 条件独立。
- **分连**：X ← Z → Y。Z 已知时 X 与 Y 条件独立。
- **汇连**：X → Z ← Y。Z 未知时 X 与 Y 条件独立；Z 已知时反而不独立。

顺连的直觉是：Z 是一个确定的中间量，它被固定之后就不再随 X 变化，X 的变化自然无法通过它传到 Y。Z 就像一扇关死的水闸，隔断了上下游。

分连代表一因多果。原因一旦确定，各个结果之间就没有相互影响，因此 Z 已知时 X 与 Y 独立。

汇连要多绕一个弯，代表多因一果。Z 未知时，X 与 Y 各自独立地产生结果，彼此没有约束；可一旦观察到 Z，两者就被联系起来了——如果 Z 已经发生，而 X 没有贡献，那么 Y 就必须贡献得更多。这种“此消彼长”的效应叫**解释消除**（explaining away），它让原本独立的两个原因在结果已知时变得相关。

> **新手提示：汇连为什么反着来**
>
> 顺连和分连是“已知就阻断”，汇连是“已知反而连通”，这一点最容易记反。可以这样想：顺连和分连里的 Z 是通道上的闸门，关掉闸门水就断流；汇连里的 Z 是两条河流汇合处的观测站，不观测时两条河各自流淌互不相干，一旦在观测站测到水量，就能反推两条河各自的贡献，它们的信息就此纠缠在一起。注意，观测 Z 的**后代节点**同样会连通 X 与 Y。

3.3 局部马尔可夫性

条件独立性可以进一步提炼成贝叶斯网络的一个良好性质，通常称为**局部马尔可夫性**（local Markov property）：给定某个顶点的父节点之后，这个顶点与它的所有非后代节点条件独立。

这里有一个常见的表述错误需要澄清：不能简单说成“顶点只取决于有箭头指向它的顶点，而与其余顶点条件独立”。原因有两点。其一，兄弟节点共享父节点，彼此之间往往并不独立；其二，后代节点显然依赖祖先。准确的表述必须带上“给定父节点”和“非后代”这两个限定。

把父节点、子节点、以及子节点的父节点合在一起，得到一个顶点的**马尔可夫毯**（Markov blanket）。在贝叶斯网络中，给定马尔可夫毯，该顶点与图中其余所有顶点条件独立。这个结论在特征选择和变量消元中很有用：要做局部推断，只需要看这一圈邻居。

补充说明：结构带来的直接收益是参数量的压缩。假设模型含 8 个二值随机变量，完整联合分布需要 2^8 − 1 = 255 个自由参数。若每个变量最多只有两个父节点，则每个节点只需 2^2 = 4 个自由参数（条件概率表的 2^3 = 8 个表项按行归一化后只剩 4 个），8 个节点合计 32 个。变量数上千时，这个差距会拉开若干个数量级——这正是概率图模型在工程上可用的原因。

四、推断与构造

4.1 由果溯因与由因得果

贝叶斯网络是基于不确定性的因果推断模型，它的用武之地在于：信息不完备时，根据已观察的随机变量推断未观察的随机变量。

给定变量之间的层次关系，推断有两个方向。

自底向上是由果溯因的**诊断**：医生看到发热、咳嗽、白细胞升高，反推最可能的病因。这条路径与贝叶斯公式的方向一致，也是贝叶斯网络在专家系统时代最经典的应用。

自顶向下是由因得果的**推理**：已知病因和患者的个体情况，预测症状出现的概率。由于它给出的是结果的分布，贝叶斯网络因此也可以当作**生成模型**使用——从先验出发采样祖先节点，再按条件概率逐层采样后代。

4.2 构造的两个步骤

建立一个贝叶斯网络需要两步。

第一步是确定拓扑结构，也就是哪些变量之间有边、方向朝哪。这一步通常依赖领域知识，纯靠数据学习在计算上非常昂贵。

第二步是确定每条边上的条件概率，也就是训练。网络规模较小时可以直接统计频次并做平滑；规模较大、存在隐变量时，则要用期望最大化等方法迭代求解。

补充说明：结构学习之所以困难，一在于搜索空间随节点数超指数增长，二在于可辨识性——不同的图可能编码完全相同的条件独立关系，这类图称为**马尔可夫等价类**（Markov equivalence class）。仅凭观测数据，无法区分等价类内部的成员；要确定箭头方向，往往需要干预实验或额外的时序信息。

五、马尔可夫随机场

5.1 从有向到无向

把贝叶斯网络的有向边全部替换为无向边，得到的就是马尔可夫随机场。

无向边不能表示推理方向，因此马尔可夫随机场失去了因果解释能力；但换来的好处是解除了无环限制，可以表示**循环依赖**——图像中相邻像素彼此影响、社交网络中用户相互影响，这类关系天然是双向的，用有向图很难表达而不引入虚假的方向。

与贝叶斯网络侧重于“依赖的传递方向”不同，马尔可夫随机场侧重于表示随机变量之间的**相互作用**。

5.2 势函数与配分函数

贝叶斯网络中每个节点对应一个先验或条件分布，联合分布可以直接写成这些分布的乘积。马尔可夫随机场没有这样的便利，因为变量之间没有明确的父子关系，无法逐点归一化。

它的联合分布通常写成一组**势函数**（potential function）的乘积：

$$p(\mathbf{x}) = \frac{1}{Z} \prod_{k} f_k(\mathbf{x}_k), \qquad Z = \sum_{\mathbf{x}} \prod_{k} f_k(\mathbf{x}_k)$$

式中的 x_k 是一个**团**（clique），也就是顶点集合中任意两点都相连的一个子集；f_k 是该团上的势函数，只要求取非负值，不要求归一化；Z 是归一化常数，称为**配分函数**（partition function）。

之所以必须归一化，是因为势函数的乘积本身不对应概率——它可能处处大于 1，求和也不等于 1。除以 Z 之后才成为合法的概率分布。

势函数常取指数形式 f_k(x_k) = exp(−E_k(x_k))，此时联合分布形如 exp(−E(x)) / Z。这里的 E 称为**能量函数**（energy function），这一形式直接借自统计物理：低能量状态概率高，高能量状态概率低。玻尔兹曼机就是这一思路的典型代表。

5.3 无向图上的独立性

马尔可夫随机场中，变量独立性与顶点连通性的对应关系比贝叶斯网络更简单。

要判断两个变量是否条件独立，只需看对应的顶点之间是否存在一条避开观察集的信息通路。若把所有已观察的顶点从图中删去后，X 与 Y 不再连通，则它们在给定观察集的条件下独立。这个判据称为**分离**（separation）。

用马尔可夫毯来描述会更简洁：在无向图中，一个顶点的马尔可夫毯就是与它直接相邻的所有顶点。给定这些邻居，该顶点与图中其余部分条件独立。

补充说明：配分函数 Z 需要对所有变量组合求和，变量数一多就无法精确计算。这构成了概率图模型在工程上的核心瓶颈——所有近似推断算法，包括变分推断、马尔可夫链蒙特卡洛、信念传播，本质上都在绕开 Z 的计算。需要强调的是，很多任务（如求最大后验状态）只需要比较不同状态的概率比值，此时 Z 会被约掉，反而不必计算。

六、表示、推断、学习

6.1 三步框架

无论是贝叶斯网络还是马尔可夫随机场，都属于结构化的概率模型。它们把概率模型的结构可视化，而对图形的观察能加深对模型性质的认识，其中最主要的性质就是变量之间的条件独立性。

除此之外，概率图模型还隐式地承载了图形背后的数学表达，可以用统一的三步框架来描述：

- **表示**：如何对不确定性和随机变量之间的关系建模；
- **推断**：如何从建立的模型中推演出待求解的概率；
- **学习**：对于给定的数据，如何确定模型的参数与结构。

这个框架的价值在于分层：同一个表示可以配不同的推断算法，同一种推断算法也可以服务于不同的表示。工程实践中遇到问题时，先判断瓶颈落在哪一层，往往比直接换模型更有效。

6.2 两种模型的取舍

贝叶斯网络和马尔可夫随机场各有长短。

前者能表达因果方向，参数含义清晰，适合由领域知识搭建的诊断与生成任务；后者不受无环约束，适合表达对称的相互作用的场景，比如图像分割、立体视觉、社交网络中的同质性。

两者并非水火不容。把有向边与无向边混合在同一个图中，得到的是**链图**（chain graph）；而在判别式建模的语境下，条件随机场就是一个典型的无向图模型——它不建模输入的分布，只建模标签序列在给定输入时的条件分布，因而避开了对输入的强假设。

四个常见误区

- **"贝叶斯网络的箭头就是因果关系"**——箭头主要编码条件独立结构。同一组独立关系可以用不同的图方向表达，因果只是其中一种解释。
- **"条件独立等于独立"**——给定 z 之后 x 与 y 无关，不代表不看 z 时两者也无关。事实上，汇连结构里恰恰相反：不看 z 时独立，看了 z 反而相关。
- **"势函数就是概率"**——势函数只要非负即可，不必归一。真正的概率要除以配分函数 Z，而 Z 往往算不出来，这也是推断困难的根源。
- **"图模型已经被深度学习淘汰"**——它仍广泛用于需要结构先验与可解释推断的场景，如医疗诊断、故障定位。变分自编码器里的隐变量结构，本质上也是一个有向图模型。

七、要点回顾

1. 纯逻辑学只适用于无不确定性的理想世界，真实问题需要概率论处理不确定性。
2. 概率图模型是把概率论与图论结合的建模方法，也称结构化概率模型。
3. 贝叶斯网络的拓扑是有向无环图，顶点表示随机变量，箭头由原因指向结果。
4. 贝叶斯网络把联合分布分解为各节点以父节点为条件的概率乘积，从而大幅压缩参数量。
5. 朴素贝叶斯是贝叶斯网络的特例：类别节点指向全部属性节点，属性之间无边。
6. 条件独立性写作 p(a,b | c) = p(a | c)p(b | c)，对应图上通道被阻断。
7. 顺连与分连在中间节点已知时独立，汇连在中间节点未知时独立，已知反而相关。
8. 局部马尔可夫性：给定父节点，顶点与所有非后代条件独立；马尔可夫毯给出更强的判据。
9. 贝叶斯网络的推断分为由果溯因的诊断与由因得果的推理，后者可作生成模型。
10. 构造分两步：先建拓扑结构，再求条件概率；结构学习受马尔可夫等价类限制。
11. 马尔可夫随机场把有向边换成无向边，能表示循环依赖，侧重刻画相互作用。
12. 其联合分布为团上势函数的乘积再除以配分函数 Z，Z 的不可计算性是推断的核心瓶颈。

八、名词汇总

名称	英文全称	英文缩写	简短介绍
概率图模型	Probabilistic Graphical Model	PGM	用图表现随机变量条件依赖关系的建模方法
结构化概率模型	Structured Probabilistic Model	—	概率图模型的另一名称，强调结构对分布的压缩

名称	英文全称	英文缩写	简短介绍
贝叶斯网络	Bayesian Network	BN	以有向无环图表示因果依赖的概率模型
马尔可夫随机场	Markov Random Field	MRF	以无向图表示变量相互作用的概率模型
有向无环图	Directed Acyclic Graph	DAG	边有方向且不存在环路的图结构
条件概率表	Conditional Probability Table	CPT	记录父节点各组合下子节点取值的概率
联合概率分布	Joint Probability Distribution	—	所有随机变量同时取某组值的概率
条件独立性	Conditional Independence	CI	给定第三方变量后两变量互不影响的性质
顺连	Causal Chain	—	X→Z→Y 结构，Z 已知时 X 与 Y 独立
分连	Common Cause	—	X←Z→Y 结构，Z 已知时 X 与 Y 独立
汇连	Common Effect	—	X→Z←Y 结构，Z 未知时 X 与 Y 独立
解释消除	Explaining Away	—	汇连中观测到结果后两个原因变得相关的现象
局部马尔可夫性	Local Markov Property	—	给定父节点，顶点与所有非后代条件独立
马尔可夫毯	Markov Blanket	—	父节点、子节点与子节点父节点构成的邻域
马尔可夫等价类	Markov Equivalence Class	—	编码相同条件独立关系的所有图的集合
团	Clique	—	任意两顶点都相连的顶点子集
势函数	Potential Function	—	定义在团上、非负但不必归一化的函数
配分函数	Partition Function	Z	对势函数乘积求和得到的归一化常数
能量函数	Energy Function	—	势函数的指数形式中定义状态“代价”的函数
分离	Separation	—	删除观察集后两顶点不连通即条件独立

名称	英文全称	英文缩写	简短介绍
链图	Chain Graph	—	同时含有向边与无向边的混合图模型
条件随机场	Conditional Random Field	CRF	对标签序列建模的判别式无向图模型
变分推断	Variational Inference	VI	用可解分布近似后验的推断方法
马尔可夫链蒙特卡洛	Markov Chain Monte Carlo	MCMC	通过采样近似目标分布的推断方法