迁移学习：源域目标域、四类迁移方法与元学习

读前须知

- **前置**：机器学习中的域、任务与泛化误差；知道预训练与微调是什么。
- **这一篇的位置**：数据稀缺时的主流解法。它把“从头训练”换成“先学通用知识，再迁移到具体任务”。
- **读完能做什么**：用符号写出源域与目标域的形式化定义；区分基于样本、模型、特征、关系的四类方法；判断一次迁移什么情况下会出现负迁移。

一、举一反三

1.1 教学里最常强调的那件事

无论是小学还是大学，教学中反复强调的一件事就是举一反三：把学到的规律灵活地运用到相似的场景中去。

人做这件事几乎不费力。学会了骑自行车，再去骑摩托车并不需要从头学起；学会了弹钢琴，学电子琴只是熟悉键位的问题。可机器做不到这一点——在训练集上无往不胜的模型，换一批数据就可能彻底失效。

要让机器学会举一反三，用到的就是**迁移学习**（transfer learning）：运用已学习的知识来求解不同但相关领域的问题，目的是让机器“学会学习”。

1.2 两个默认假设

许多机器学习和数据挖掘算法，都建立在两个默认假设之上：

- 训练样本与测试数据处于相同的特征空间，并具有相同的分布；
- 有足够的高质量训练样本作为学习资源。

遗憾的是，这两个假设在大多数实际应用中难以成立。

一方面，训练数据与测试数据在时间上的差异会导致分布漂移。用去年的用户行为训练出的推荐模型，今年的效果往往明显下滑。

另一方面，对大量数据做标注不仅费时费力，还容易受知识产权问题的制约。医疗影像、金融交易、工业质检，这些领域的数据既贵又敏感。

一旦没有数据，再好的深度学习方法都是无源之水、无本之木，难以发挥作用。

1.3 迁移学习解决什么

迁移学习正是为这个局面准备的框架：当训练数据与测试数据来自不同的特征空间，或遵循不同的概率分布时，如果能把从训练数据上习得的知识迁移到测试数据上，就可以回避掉大量数据标注工作，同时提升学习性能。

它能够对仅有少量、甚至完全没有标签的样本进行学习，从而解决目标问题。

说到底，迁移学习可以看作提升泛化性能的一条思路。现实世界不是标准化、结构化的数据集，而是杂乱无章的万花筒，包含大量从未在训练集中出现过的全新场景。迁移学习帮助算法处理这些新场景，用一般化的规律去应对富于变化的环境。

二、域与任务

2.1 源域与目标域

在迁移学习中，已有的知识——包括样本数据集及其分布——称为**源域**（source domain），要学习的新知识称为**目标域**（target domain）。

同样，待解决的任务也分成**源任务**（source task）与**目标任务**（target task）。

2.2 形式化描述

一个域由特征空间和边缘分布两部分组成，一个任务由标签空间和条件分布两部分组成：

$$\mathcal{D} = \{\mathcal{X}, P(X)\}, \qquad \mathcal{T} = \{\mathcal{Y}, P(Y \mid X)\}$$

迁移学习要做的，是在给定源域 D_s、源任务 T_s、目标域 D_t、目标任务 T_t 的情况下，借助 D_s 与 T_s 中的知识，改进目标域上预测函数 f_t 的学习：

$$\min_{f_t} \mathbb{E}_{(x,y)\sim P_t}\left[\ell\left(f_t(x), y\right)\right], \qquad \mathcal{D}_s \neq \mathcal{D}_t \text{ or } \mathcal{T}_s \neq \mathcal{T}_t$$

这个式子点出了迁移学习的边界条件：只有源与目标在域或任务上**存在差异**时，才谈得上迁移。差异太小时问题是普通的同分布学习，差异太大时则根本迁不过去。

2.3 三类迁移学习

根据源域与目标域、源任务与目标任务的组合关系，迁移学习可以划分为三类。

- **归纳迁移学习**（inductive transfer learning）：目标任务与源任务不同，源域与目标域可能相同也可能不同。目标域可能有少量标签，也可能完全没有，后者常被称为自学习迁移。
- **直推式迁移学习**（transductive transfer learning）：目标任务与源任务相同，但源域与目标域不同。目标域没有标签，模型在训练阶段就能看到目标域的样本。
- **无监督迁移学习**（unsupervised transfer learning）：目标任务与源任务不同，且源域与目标域的数据都没有标签。

三类的区别可以用一句话概括：**任务换了没有、域换了没有、标签有没有。**

> **新手提示：直推式和半监督容易混**
>
> 直推式迁移学习与半监督学习形式上很像，都是"有标签数据加无标签数据"，区别在于无标签数据来自哪里。半监督学习的无标签样本与有标签样本同属一个域，只是缺标签；直推式迁移学习的无标签样本来自另一个域。这个区别决定了方法不同：前者靠数据的内在结构做正则，后者必须显式处理两个域之间的分布差异。

三、三个前置问题

3.1 迁移什么

迁移什么明确的是迁移的作用对象。

显然，迁移的应该是普适性的知识，而不是特定领域的知识。背古诗词的技巧不一定适用于背化学方程式，这时需要迁移的是整体意义上的记忆方法，而不是某一首诗的内容。

在深度网络中，这个问题的答案相对具体：浅层学到的边缘、纹理、色彩统计往往是通用的，深层的语义特征则与任务强绑定。所以迁移通常只搬浅层，深层重新训练。

3.2 能不能迁移

确定了迁移什么，接下来要回答能不能迁移。

只有当源域与目标域具有较高相关性时，迁移才会有助于学习。如果不加分辨地把知识生搬硬套到风马牛不相及的问题上，反而会起负作用，这种现象称为**负迁移**（negative transfer）。

骑车技巧可以用在骑摩托车上，因为两者都是两轮、都靠平衡；可如果用骑自行车的方法骑三轮车，只怕是要翻车。

负迁移在工程上并不罕见：源域数据量远大于目标域时，模型会强烈偏向源域，目标域上的表现甚至不如从头训练。遇到这种情况，往往需要降低源域样本的权重，或者干脆放弃迁移。

3.3 如何迁移

解决了前两个问题，剩下的就是迁移学习最核心的一问：如何迁移。

主流方法可以归为四类——基于样本、基于特征、基于模型、基于关系。下面依次展开。

四、四类迁移方法

4.1 基于样本的迁移

基于样本的迁移（instance transfer）是对已有样本的重用过程：通过调整源域中原始样本的权重系数，使源域的分布向目标域靠拢，进而把调整后的样本用于目标域的训练。

基本做法是度量源域样本与目标域样本的相似度，据此重新分配采样权重：与目标域越相似的源域样本，对目标任务的训练越有利，权重被强化；相似度低的样本，权重被削弱。

在归纳迁移学习中，TrAdaBoost 是典型的基于样本的方法。它假定两个域的数据具有不同分布，但使用完全相同的特征与标签。由于分布差异，不同的源域数据对目标任务既可能有用也可能有害，TrAdaBoost 通过多轮迭代调整源域样本的权重，鼓励“好”数据、抑制“坏”数据。

基于样本的方法也可以用于直推式迁移学习。此时学习的出发点是经验风险最小化，常用工具是**重要性采样**（importance sampling）。核心是给每个源域样本乘上一个密度比：

$$w(x) = \frac{P_t(x)}{P_s(x)}$$

这个比值把关于目标域的期望转化为关于源域的加权期望，从而可以直接用源域样本估计目标域上的风险。密度比本身可以用核均值匹配、最小化 KL 散度等方法估计。

4.2 基于特征的迁移

基于特征的迁移（feature representation transfer）是特征表示的重建过程：通过特征变换，把源域数据与目标域数据映射到同一个特征空间，再在这个公共空间上学习。

这类方法适用于所有迁移学习任务，也是深度迁移学习中最常用的一类。

其基本思想是学习一组在相关任务间共享的低维特征表示。具体有两条路径。

基于特征选择的做法，是识别出源域与目标域共有的特征表示，再基于这些共有特征实现迁移。由于与类别高度相关的特征应当在模型中占更高权重，在找出共同特征之后，还需从目标域数据中挑选其特有特征，对共同特征训练出的通用分类器做精化，得到适合目标域的最终分类器。

基于特征映射的做法，是把每个领域的数据从原始高维空间映射到新的低维空间，使两个域的数据在新空间中具有相同分布。这样就能用低维空间中带标签的源域数据，来训练目标域上的分类器。

两者的区别在于：特征选择得到的特征仍是原始特征的子集，而特征映射得到的是全新的特征，不再对应任何单个原始维度。

4.3 基于模型的迁移

基于模型的迁移（parameter transfer）是已有模型的转移过程。它假设源任务与目标任务共享某些参数或先验分布，把在源域上训练好的成熟模型直接应用到目标域。

应用于归纳迁移学习的大多数模型方法，都源自**多任务学习**（multi-task learning）。两者的差别在于目标：多任务学习试图同时提升源任务与目标任务的效果，迁移学习只关心目标域的性能。

因此实践中会给目标域的损失分配更大权重，确保优化方向偏向目标任务——必要时甚至可以冻结大部分共享参数，只微调最后一层。

4.4 基于关系的迁移

基于关系的迁移（relational knowledge transfer）是问题结构的复制过程。如果源域与目标域共享某种相似的关系结构，就可以把源域上的逻辑关系网络搬到目标域上使用。

与前三种方法不同，关系方法处理的是关系域中的迁移问题：其中的数据在概率上不需要满足独立同分布，但必须能用相似的关系来表示。最典型的实例是物理网络数据与社交网络数据——两者的实体完全不同，但“中心节点影响力大”这类结构规律可以共享。

这类方法常用的工具是数理逻辑与图模型。

五、深度网络中的迁移

5.1 预训练与微调

在深度学习实践中，基于模型的迁移被具体化为**预训练加微调**（pre-training and fine-tuning）的范式。

先在超大规模数据上训练一个通用模型，再把它的参数作为初始值搬到目标任务上，用少量目标域数据继续训练。如果目标数据极少，可以只放开最后几层；如果数据稍多，可以放开更多层，甚至全部参数。

这一范式之所以成立，前提是 4.2 节提到的假设：浅层特征具有通用性。卷积网络的前几层学到的是边缘与色块，这些特征在识别猫、识别汽车、识别病灶时都适用。

5.2 为什么冻结层数是个超参数

到底冻结多少层，没有普适答案。

目标域与源域越接近，可以冻结的层越多，训练越省；两者差距越大，需要解冻的层越多。此外还有学习率的问题：微调时通常要用比预训练小得多的学习率，否则一次大步更新就会把预训练学到的通用特征冲垮。

> **新手提示：微调不是免费的**
>
> 微调看起来只是“接着训练”，实际有几个坑。其一，若目标数据分布与预训练数据差别很大，冻结浅层反而会拖累效果；其二，批归一化的统计量在小批量上估计不准，需谨慎处理；其三，预训练模型可能带有源数据中的偏见，微调并不能自动消除它。真正省事的做法不是照搬默认配置，而是先用小规模实验确认冻结策略。

六、元学习

6.1 归纳偏差

每个特定的学习算法，都建立在一系列关于数据的假设之上，这组假设称为**归纳偏差**（inductive bias）。

只有当归纳偏差与学习问题相匹配时，算法才能取得良好效果。卷积网络的平移等变假设适合图像，循环网络的时间共享假设适合序列；把两者互换，性能立刻下降。

这给机器学习算法加上了应用的约束，也限制了它们的通用性：没有一个算法能在所有问题上都最好，这就是所谓的“没有免费午餐”。

6.2 学习如何学习

正因如此，学习的灵活性对通用人工智能至关重要。

元学习（meta-learning）的目标，是通过对元数据的自动化学习来提升学习算法的灵活性——通俗地说，是对学习方法的学习。

利用学习问题的属性、算法属性、派生模式等不同类型的元数据，元学习可以对不同的学习算法进行学习、选择、修改或组合，从而有效地解决给定的学习问题。

一个常见的实现思路是：不再学一个从输入到输出的映射，而是学一个“好的初始参数”或“好的更新规则”，使得面对新任务时只需少量样本和几步梯度就能适应。

6.3 与迁移学习的关系

迁移学习与元学习关系密切，但不相等。

迁移学习关心的是“把已有知识用到新问题上”，一次迁移对应一个目标域；元学习关心的是“获得快速适应的能力”，训练阶段就模拟大量不同的任务，学会的是适应过程本身。

补充说明：从遗传进化的角度看，基因编码的演化本身就是一个学习过程，而且这个过程在大脑中执行——每个人其实都是元学习的践行者。但元学习能否大规模推广到机器学习中，仍受制于任务分布的构造：元学习要求训练时的任务分布与测试时的任务分布一致，而真实场景中这一点往往无法保证。

四个常见误区

- **“用了预训练模型就一定更好”**——源域与目标域差异过大时会发生负迁移，效果可能还不如从零训练。迁移前先看两边的数据分布有多接近。
- **“微调就是改最后一层”**——数据量与算力决定了解冻多少层。数据少时只训分类头，数据充足时可以全量微调，中间还有逐层解冻的折中方案。
- **“迁移学习等于多任务学习”**——前者是“先在一个任务上学，再迁到另一个”，顺序进行；后者是“多个任务同时训练、共享表示”。
- **“元学习就是更快的迁移学习”**——元学习学的是“如何学习”这件事本身，目标是让模型面对新任务时只需极少样本就能适应。

七、要点回顾

1. 迁移学习是运用已学知识求解不同但相关领域问题的方法，目的是让机器学会学习。
2. 传统机器学习依赖两个假设：同分布、有充足标注数据，二者在现实中常不成立。
3. 域由特征空间与边缘分布构成，任务由标签空间与条件分布构成。
4. 迁移学习成立的边界是源与目标在域或任务上存在差异，差异过大则无法迁移。

5. 三类任务：归纳迁移、直推式迁移、无监督迁移，区别在任务是否更换、域是否更换、有无标签。
6. 三个前置问题：迁移什么、能不能迁移、如何迁移；迁移的对象应是普适知识。
7. 源域与目标域相关性不足会导致负迁移，效果可能不如从头训练。
8. 基于样本的方法通过重加权复用源域样本，TrAdaBoost 与重要性采样是典型代表。
9. 基于特征的方法把两个域映射到公共空间，分特征选择与特征映射两条路径。
10. 基于模型的方法迁移参数或先验，深度学习中体现为预训练加微调。
11. 基于关系的方法迁移逻辑结构，适用于不满足独立同分布的关系型数据。
12. 元学习是对学习方法的学习，目的是获得快速适应新任务的能力，与迁移学习互为补充。

八、名词汇总

名称	英文全称	英文缩写	简短介绍
迁移学习	Transfer Learning	TL	用已学知识求解不同但相关领域问题的方法
源域	Source Domain	—	提供已有知识与标注数据的领域
目标域	Target Domain	—	需要学习、通常缺少标注的新领域
源任务	Source Task	—	已有知识所对应的原任务
目标任务	Target Task	—	待解决的新任务
域	Domain	—	由特征空间与边缘分布构成的集合
任务	Task	—	由标签空间与条件分布构成的集合
归纳迁移学习	Inductive Transfer Learning	—	目标任务与源任务不同的一类迁移
直推式迁移学习	Transductive Transfer Learning	—	任务相同而域不同、目标域无标签的一类迁移
无监督迁移学习	Unsupervised Transfer Learning	—	任务不同且两个域都没有标签的一类迁移
负迁移	Negative Transfer	—	迁移反而损害目标域性能的现象
基于样本的迁移	Instance Transfer	—	通过调整源域样本权重复用数据的方法
基于特征的迁移	Feature Representation Transfer	—	把两个域映射到公共特征空间的方法
基于模型的迁移	Parameter Transfer	—	迁移模型参数或先验分布的方法
基于关系的迁移	Relational Knowledge Transfer	—	迁移实体间逻辑结构的方法

名称	英文全称	英文缩写	简短介绍
多任务学习	Multi-task Learning	MTL	同时优化多个相关任务的联合学习范式
重要性采样	Importance Sampling	IS	用密度比加权把源域期望转为目标域期望
密度比	Density Ratio	—	目标域与源域边缘分布之比，即重加权系数
核均值匹配	Kernel Mean Matching	KMM	通过匹配核均值估计密度比的方法
预训练	Pre-training	—	在大规模数据上先训练通用模型的过程
微调	Fine-tuning	—	用目标域数据继续训练预训练模型的过程
元学习	Meta-learning	—	对学习方法本身进行学习的一类方法
归纳偏差	Inductive Bias	—	学习算法对数据所做的先验假设
没有免费午餐	No Free Lunch	NFL	不存在对所有问题都最优的算法的结论