知识图谱：知识推理、软性逻辑与分布式表示

读前须知

- **前置**：谓词逻辑与三元组的基本概念（006 篇）；向量表示的想法（001 篇）。
- **这一篇的位置**：把人类知识写成机器可计算的形式，再在上面做推理。它是搜索引擎、问答系统与推荐系统的共同底座。
- **读完能做什么**：把一个事实写成头实体—关系—尾实体三元组；说清 PRA、马尔可夫逻辑网与概率软逻辑各自的思路；用 TransE 解释"向量加减为何能表示关系"。

一、黑箱与可解释性

1.1 炼金术之争

关于深度学习是不是"炼金术"的争议，这些年愈演愈烈。

争议的根源在于黑箱特性：深度学习算法能把图片里的猫认出来，却说不清为什么这么判断，也无法保证这套判定方法具备普适性。换个角度、换批数据、甚至只加一点噪声，结论就可能翻转。

工程上，这是一个可靠性问题；科学上，这是一个认识论问题。一个不能解释自己判断依据的系统，很难在医疗、司法、金融这类需要问责的场合被接受。

1.2 可解释人工智能

因此，人工智能的一个重要研究方向，是开发具有更好可解释性、更容易被人理解的模型。

理想的模型不只是辨认出图片里有只猫，还能指出判断依据是猫特有的眼睛、耳朵和胡须。这样的系统能够同时克服概念认知与语言认知上的障碍——它既知道"这是什么"，也能说清"凭什么这么认为"。

要构造可解释的人工智能，靠大数据训练更复杂的模型显然不是办法：模型越大，黑箱越深。可行的方向是回归逻辑推演，把知识显式地组织起来。而**知识图谱**（knowledge graph）很可能成为可解释人工智能的一项关键技术。

1.3 符号主义的遗产

人类的智能源于对知识内部表示的推理过程，这也是早期人工智能研究者热衷符号主义的原因。

人类的认知过程，正是不断用概念、属性和关系去理解世界、解释世界的过程；这些理解共同构成了人脑中高度组织化、结构化的知识网络。知识图谱要做的事，本质上就是把这张网络外化到机器里。

二、什么是知识图谱

2.1 定义

知识图谱是由大量概念实体以及它们之间的关系共同构成的语义网络。

它采集星罗棋布的碎片化信息和数据，按标准化的方式加以整理，再把各个看似不相关、背后却有共同联系的信息关联起来，从中挖掘规律。

某种程度上，它类似于今天广受推崇的思维导图，但具有更规范的层次结构和更强大的知识表示能力——思维导图的连线没有语义，知识图谱的每条边都标明了关系的类型。

2.2 四个要素

为了构造知识的基本框架，知识图谱除了包含实体之外，一般还包括概念、属性、关系等信息。

- **实体**（entity）：现实世界中可辨识的具体对象，如“莱昂内尔·梅西”；
- **概念**（concept）：实体所属的类别，如“足球运动员”；
- **属性**（attribute）：实体的特征或取值，如“国籍是阿根廷”“效力于巴塞罗那”；
- **关系**（relation）：实体与实体之间的联系，如“内马尔是梅西的前队友”“C 罗是梅西的主要竞争对手”。

用梅西这个例子可以一次看清四者：即使不熟悉足球的人也知道他是足球运动员，这是概念；常看球的人知道他的国籍与俱乐部，这是属性；更狂热的球迷知道他与内马尔、C 罗的纠葛，这是关系。

2.3 三元组

知识图谱的基本存储单位是**三元组**（triple），形如（头实体，关系，尾实体），例如（梅西，效力于，巴塞罗那）。

属性可以视为关系的一种特例：把属性值也当作实体，属性名当作关系，三元组格式就能统一。正是这种统一的表示，让知识图谱既便于存储，也便于计算。

三、知识推理：归纳

3.1 从特殊到一般

知识图谱不只是一个存储结构，它还能用于推理。而推理最广泛的应用是**知识库问答**：理解自然语言中的问题，从知识库中寻找答案。

但正所谓“生也有涯，知也无涯”，即使最庞大的百科全书也不可能把所有知识尽收囊中。这时就需要推理出场：根据已有实体的概念、属性和关系，为新概念自动生成属性；或明确新实体之间的关系。

具体说来，推理分为归纳与演绎两类，分别对应“从特殊到一般”和“从一般到特殊”两个方向。

归纳（induction）指从某类事物的大量实例出发，推出关于这类事物的一般性结论。认识的朋友里小张很聪明、老李很聪明、大刘也很聪明，于是有理由相信程序员大多聪明——这就是归纳。

归纳能从旧知识中获取新知识，是知识的增殖过程。

3.2 路径排序算法

在归纳推理中，软性推理的一个典型应用是**路径排序算法**（path ranking algorithm，PRA）。

知识图谱中的实体由二元关系相连，因此现实世界的规则在图上就体现为不同实体之间的关系路径。比如“出生在 A 城市的人通常效力于 A 城市的球队”，对应的是“出生地”与“效力球队”两条边构成的一条路径。

路径排序算法以实体之间的路径为依据，在不完全的知识库中学习目标关系的分类器：

$$\text{score}(h,t) = \sum_{\pi \in \Pi} \theta_\pi \, x_\pi(h,t)$$

式中 Π 是路径集合，x*π(h,t) 表示是否存在从 h 到 t 的路径 π，或这条路径的到达概率；θ*π 是学习到的路径权重，可以理解为该路径作为规则的置信度。

θ_π 越大，说明这条路径越能支持目标关系；权重为负的路径则构成反例规则。把分类器应用到整个图谱上，就能自动挖掘并筛出可靠的规则。

3.3 三个步骤

路径排序算法的实现包括三步。

特征抽取：生成路径特征的集合，并做筛选。图谱中路径数量随长度指数增长，全用既不可行也没必要，通常只保留出现频次足够高的短路径。

特征计算：对每个训练样本计算其对应的特征取值，也就是每条路径的命中情况。

分类器训练：以特征取值为输入、以目标关系是否成立为标签，训练一个分类器。训练完成后，对图中任意实体对都能给出关系成立的可能性。

四、知识推理：演绎

4.1 从一般到特殊

把归纳的方向调转，就是**演绎**（deduction）：从一般性的前提出发，推导出个别结论或具体陈述。

既然已经归纳出“程序员大多聪明”，那么遇到陌生的程序员小赵时，即使对他一无所知，也能推出“小赵很可能聪明”这个符合一般性原则的具体陈述。

如果对形式逻辑还有印象，不难发现经典的三段论就是一类演绎推理：大前提、小前提、结论。

演绎推理可以解决复杂问题，但它只是把已有事实揭示出来，并不产生新知识。前提已经蕴含了结论，演绎的价值在于把隐含的知识显式化。

4.2 硬性规则与软性规则

数理逻辑实现的推建立在一个硬性约束之上：命题非真即假，推理只能是非黑即白的。

小品里有句包袱：“一加一在什么情况下等于三？在算错的情况下等于三。”这是典型的以对错来区分的硬性规则——一加一等于三，要么真要么假。

可现实中的知识很少这么干净。规则总有例外，证据常常不全，结论往往只是“更可能”。知识图谱要处理这种知识，就必须把硬性约束软化为可加权的形式。

4.3 马尔可夫逻辑网

把无向概率图模型与一阶谓词逻辑结合起来，得到的就是**马尔可夫逻辑网**（Markov logic network，MLN）。

它是一个一阶逻辑公式的集合，其中每条逻辑规则都被分配一个实数作为权重系数，以此实现规则的软化：

$$P(\mathbf{X}=\mathbf{x}) = \frac{1}{Z}\exp\left(\sum_i w_i\, n_i(\mathbf{x})\right)$$

式中 n_i(x) 是第 i 条规则在世界 x 中成立的次数，w_i 是该规则的权重，Z 是配分函数。

权重的作用是调节规则的“硬度”：权重越大，违反该规则的世界概率越低，约束力越强；当权重趋于正无穷时，软性规则退化为硬性规则，违反它的世界概率为零。

在马尔可夫逻辑网中，一加一等于三也是“合法”的，只是这个合法世界与真实世界差别极大，因而其成立的可能性极小、概率极低。规则并没有被禁止，只是被赋予了极低的概率。

建立模型之后，就可以利用已有的规则与权重推断未知事实成立的概率。如果规则与权重部分未知或全部未知，则可以自动学习它们，这相当于马尔可夫随机场的结构学习。

4.4 概率软逻辑

在马尔可夫逻辑网的基础上，若给每个原子事实赋予一个连续分布的真值，得到的就是**概率软逻辑**（probabilistic soft logic，PSL）。

真值从 {0, 1} 扩展到 [0, 1] 之后，逻辑运算也随之软化：合取取最小值，析取取最大值，否定用 1 减去真值。这样一来，部分成立的事实也能参与推理，不必强行二值化。

概率软逻辑能对不确定的事实与不确定的规则同时建模，因而具有更强的不确定性处理能力；连续真值的引入还让优化问题变得可微，推理效率大幅提升。

五、数值推理

5.1 符号推理的局限

归纳也好，演绎也罢，实现的都是**符号推理**：直接在知识图谱的实体与关系符号上做运算。

符号推理的优点是结论可解释——每一步都能追溯到一条规则。缺点是脆弱：知识库稍有缺失，长链条推理就会中断；图谱规模一大，规则匹配的组合爆炸也难以承受。

与符号推理对应的是**数值推理**：用数值计算模拟推理过程。其典型方案是基于分布式表示的推理。

5.2 分布式知识表示

分布式知识表示（knowledge graph embedding）是把包含实体与关系的知识图谱组件嵌入到连续向量空间中，在保持图谱内在结构的同时简化操作。

做法分三步：先定义实体与关系在向量空间中的表示形式；再定义打分函数，衡量每个三元组成立的可能性；最后构造优化问题，学习实体与关系的低维向量表示。

最简洁的模型是 TransE，它把关系看作头实体到尾实体的平移：

$$f_r(h,t) = -\left\|\mathbf{h}+\mathbf{r}-\mathbf{t}\right\|$$

理想情况下 h + r ≈ t，此时打分最高。训练时让正样本的分数尽量高、负样本（随机替换头或尾得到的伪三元组）的分数尽量低。

这个假设简单却有效。它的局限也明显：一个实体在不同关系下应当有不同的表示，而 TransE 只给每个实体一个向量，处理一对多、多对一、对称关系时会力不从心。后续的 TransH、TransR、RotatE 等模型，都是围绕这一点改进的。

5.3 三类下游任务

在分布式表示的基础上，数值推理可以完成多类任务。

链接预测（link prediction）：用打分函数计算所有候选答案的得分，为缺失的三元组补全最可能的答案。这是知识图谱补全的核心任务。

三元组分类：判断某个三元组的得分是否超过预设阈值，从而判定它是真事实还是噪声。

实体解析（entity resolution）：计算不同实体表示向量之间的相似度，把指向同一现实对象的不同表述归并起来。

> **新手提示：补全不等于查漏**
>
> 链接预测给出的答案往往是“统计上最可能”，而不是“逻辑上必然”。模型补出的三元组需要人工或规则二次校验，直接写回知识库是危险的——错误会沿着推理链条扩散，而且越补越难追溯。工程上的常规做法是只把高置信度的结果入库，其余作为候选交由人工确认。

六、常识问题

6.1 常识为什么难

在讨论形式逻辑时提过一个关键问题：人工智能的一大短板是常识的缺失。

常识的特点是数量庞大、边界模糊、几乎不成文。人知道“杯子掉地上会碎”“下雨要打伞”“鸟一般会飞但企鹅不会”，这些知识从未被系统整理过，却支撑着日常判断。

知识图谱的出现，是否能为计算机注入常识？

部分可以。把常识写成三元组确实能补上一块，大规模常识库的建设也已经持续多年。但难点在于覆盖度与维护成本：常识的长尾极长，靠人工录入永远补不完；靠自动抽取，又会引入大量错误与歧义。

6.2 知识图谱与语言模型的分工

补充说明：知识图谱与大规模语言模型并不是替代关系，而是各有所长。语言模型擅长处理模糊、开放的语言理解，但知识存在幻觉，且难以追溯来源；知识图谱擅长精确的事实查询与多跳推理，结论可溯源，但覆盖面有限、构建成本高。当前的常见做法是把两者结合——用图谱约束生成的事实性，用语言模型补足图谱的语言接口。这也是可解释人工智能一条现实可行的路径。

四个常见误区

- **“知识图谱就是一张大数据库表”**——它多了模式约束与推理能力：从已有三元组能推出未显式存储的事实，这是普通表做不到的。
- **“三元组能表达一切知识”**——n 元关系、时序、否定与模态都需要扩展。常见做法是引入事件节点、时间戳或超边。
- **“TransE 适用于所有关系”**——它假设关系是平移向量，在一对多、多对一、多对多关系上会失效，这也是 TransH、RotatE 等模型出现的原因。
- **“图谱规模越大越好”**——噪声与冲突会随规模增长，而推理对错误极其敏感。维护一套一致性与溯源机制，比盲目扩充更重要。

七、要点回顾

1. 深度学习的黑箱特性引发可解释性危机，回归逻辑推演是一条可行路径。
2. 知识图谱是由大量概念实体及其关系构成的语义网络，可视为带语义的思维导图。
3. 四个要素：实体、概念、属性、关系；基本存储单位是三元组。
4. 属性可以看作关系的特例，统一表示便于存储与计算。
5. 归纳是从特殊到一般，能产生新知识；演绎是从一般到特殊，只把已有事实显式化。
6. 路径排序算法用关系路径作为特征，为每个目标关系训练分类器。
7. 实现分三步：特征抽取、特征计算、分类器训练。
8. 数理逻辑只能做非黑即白的硬性推理，知识图谱需要软性推理。
9. 马尔可夫逻辑网给每条一阶规则赋权，权重趋于无穷时退化为硬规则。
10. 概率软逻辑把真值扩展到 0 到 1 的连续区间，可同时对不确定事实与规则建模。
11. 分布式知识表示把实体与关系嵌入向量空间，用打分函数衡量三元组的可信度。
12. 数值推理可完成链接预测、三元组分类与实体解析等任务。

八、名词汇总

名称	英文全称	英文缩写	简短介绍
知识图谱	Knowledge Graph	KG	由概念实体及其关系构成的语义网络
可解释人工智能	Explainable Artificial Intelligence	XAI	能说明判断依据的人工智能系统
符号主义	Symbolism	—	用符号与逻辑规则表示知识的研究路线
实体	Entity	—	现实世界中可辨识的具体对象
概念	Concept	—	实体所属的类别
属性	Attribute	—	实体自身的特征或取值
关系	Relation	—	实体与实体之间带语义的联系
三元组	Triple	—	形如（头实体，关系，尾实体）的知识单元
知识库问答	Knowledge Base Question Answering	KBQA	理解自然语言问题并从知识库取答案
归纳	Induction	—	从大量实例推出一般性结论的推理
演绎	Deduction	—	从一般前提推出具体结论的推理
三段论	Syllogism	—	由大前提、小前提推出结论的演绎形式
路径排序算法	Path Ranking Algorithm	PRA	以关系路径为特征学习规则置信度的归纳方法
硬性规则	Hard Rule	—	非真即假、不可违反的逻辑规则
软性规则	Soft Rule	—	带权重、允许违反但降低概率的规则
马尔可夫逻辑网	Markov Logic Network	MLN	一阶逻辑加权的无向概率图模型
概率软逻辑	Probabilistic Soft Logic	PSL	真值连续化的软逻辑推理框架
符号推理	Symbolic Reasoning	—	直接在实体与关系符号上做的推理
数值推理	Numeric Reasoning	—	用数值计算模拟推理过程的方法
分布式知识表示	Knowledge Graph Embedding	KGE	把实体与关系嵌入连续向量空间的方法

名称	英文全称	英文缩写	简短介绍
打分函数	Scoring Function	—	衡量三元组成立可能性的函数
TransE	Translating Embeddings	TransE	把关系视为向量平移的嵌入模型
链接预测	Link Prediction	—	为图谱中缺失的三元组补全答案的任务
实体解析	Entity Resolution	—	判定不同表述是否指向同一现实对象
常识	Commonsense Knowledge	—	人类普遍具备但极少成文的日常知识